

真实执行流程 / 生物量研究 / 自定报告结构

同一输入的两次重复；编号节点为实际工具尝试，F 为真实最终答复；保留失败和修订

实验：research-report-agent-v31-20261010 题目：v3_eval_auto

蓝 L：工具命令来自 LLM 绿 M：工具命令来自 Motif 橙：失败；橙底线：失败后的同工具重试 粗边框：三个模型语义决定

重复 1 | 普通 DSH

LLM 请求 16 工具尝试 15 成功 14 跳过 LLM 0 失败 1 50.7s 估费 ¥0.03500 / 峰值 ¥0.07001

v31_eval_auto_r1_baseline 执行顺序 1 已交付 / 3 页



图型：累积分布、分布与均值、效应区间 数值表：estimate,ci_low,ci_high,p_value,n,excluded_rows

大纲：研究背景与问题 → 数据与统计方法 → 结果 → 假设检查与不确定性 → 结论、限制与后续建议

实际失败：#6 选择图文方案：大纲重复使用科学角色

重复 1 | DSH + Motif

LLM 请求 5 工具尝试 14 成功 14 跳过 LLM 10 失败 0 35.5s 估费 ¥0.02535 / 峰值 ¥0.05071

v31_eval_auto_r1_execute 执行顺序 2 已交付 / 2 页



图型：分布与均值、效应区间、累积分布 数值表：estimate,ci_low,ci_high,p_value,n

大纲：方法 → 结果 → 诊断与稳健性 → 局限与解释

节点按真实调用顺序排列；F 为已匹配原始响应的最终答复，不计入工具尝试。完整参数、结果与答复见 flow-evidence.json。

重复 2 | 普通 DSH

LLM 请求 18 工具尝试 17 成功 14 跳过 LLM 0 失败 3 61.8s 估费 ¥0.04797 / 峰值 ¥0.09594

v31_eval_auto_r2_baseline 执行顺序 10 已交付 / 2 页



图型：累积分布、效应区间、分布与均值 数值表：estimate,ci_low,ci_high,p_value,n

大纲：研究方法与统计分析 → 结果 → 诊断与不确定性 → 结论与后续工作建议

实际失败：#6 选择图文方案：续接权限字段缺失或不是布尔值；#10 LLM 写正文：未绑定数字 token；#11 LLM 写正文：正文 schema 拒绝额外字段

重复 2 | DSH + Motif

LLM 请求 7 工具尝试 16 成功 14 跳过 LLM 10 失败 2 46.1s 估费 ¥0.03739 / 峰值 ¥0.07477

v31_eval_auto_r2_execute 执行顺序 9 已交付 / 3 页



图型：累积分布、分布与均值、效应区间 数值表：estimate,ci_low,ci_high,p_value,n

大纲：研究背景与统计方法 → 分析结果 → 假设检查与诊断 → 不确定性、限制与后续工作

实际失败：#9 LLM 写正文：未绑定数字 token；#10 LLM 写正文：正文 schema 拒绝额外字段

真实执行流程 / 学习者成绩 / 指定大纲

同一输入的两次重复；编号节点为实际工具尝试，F 为真实最终答复；保留失败和修订

实验: research-report-agent-v31-20261010 题目: v3_eval_outline

■ 蓝 L: 工具命令来自 LLM

- 绿 M: 工具命令来自 Motif

■ 橙：失败；橙底线：失败后的同工具重试

粗边框：三个模型语义决定

重复 1 | 普通 DSH

LLM 请求 17 工具尝试 16 成功 14 跳过 LLM 0 失败 2 58.8s 估费 ¥0.04706 / 峰值 ¥0.09413

v31_eval_outline_r1_baseline 执行顺序 4 已交付 / 3 页



图型：配对变化图、变化值分布、效应区间 数值表：estimate,ci_low,ci_high,p_value,n,excluded_rows

大纲：研究问题 → 数据与方法 → 主要结果及图表 → 局限与下一步

实际失败: #9 LLM 写正文: 未绑定数字 token; #10 LLM 写正文: 未绑定数字 token

重复 1 | DSH + Motif

LLM 请求 8 工具尝试 17 成功 14 跳过 LLM 10 失败 3 48.6s 估费 ¥0.04043 / 峰值 ¥0.08087

v31_eval_outline_r1_execute 执行顺序 3 已交付 / 3 页



图型：配对变化图、效应区间、变化值分布 数值表：estimate,ci_low,ci_high,p_value,n


大纲：研究问题 → 数据与方法 → 主要结果及图表 → 局限与下一步

实际失败: #6 选择图文方案: 大纲重复使用科学角色; #7 选择图文方案: 续接权限字段缺失或不是布尔值; #11 LLM 写正文: 未绑定数字 token、缺少因果边界声明

重复 2 | 普通 DSH

LLM 请求 20 工具尝试 19 成功 14 跳过 LLM 0 失败 5 63.3s 估费 ¥0.04739 / 峰值 ¥0.09479

v31_eval_outline_r2_baseline 执行顺序 11 已交付 / 3 页



图型：配对变化图、变化值分布、效应区间 数值表：estimate,ci_low,ci_high,p_value,n,effect_size,excluded_rows


大纲：研究问题 → 数据与方法 → 主要结果及图表 → 局限与下一步

实际失败: #2 批准统计: 分组列名不在 CSV 中; #7 选择图文方案: 所选图型数量或兼容性不符合要求; #8 选择图文方案: 所选图型数量或兼容性不符合要求; #9 选择图文方案: 大纲重复使用科学角色; #13 LLM 写正文: 未绑定数字 token、未知数字占位符

重复 2 | DSH + Motif

LLM 请求 10 工具尝试 19 成功 14 跳过 LLM 10 失败 5 55.5s 估费 ¥0.04083 / 峰值 ¥0.08167

v31_eval_outline_r2_execute 执行顺序 12 已交付 / 3 页



图型：配对变化图、效应区间、变化值分布 数值表：estimate,ci_low,ci_high,p_value,n,excluded_rows

大纲：研究问题 → 数据与方法 → 主要结果及图表 → 局限与下一步

实际失败: #2 批准统计: 续权限字段缺失或不是布尔值; #3 批准统计: 分组列名不在 CSV 中; #4 批准统计: 组别名称与数据中的实际条件不一致; #9 选择图文方案: 大纲重复使用科学角色; #13 LLM 写正文: 缺少因果边界声明

真实执行流程 / 设备能耗 / 单页摘要

同一输入的两次重复；编号节点为实际工具尝试，F 为真实最终答复；保留失败和修订

实验：research-report-agent-v31-20261010 题目：v3_eval_brief

蓝 L：工具命令来自 LLM 绿 M：工具命令来自 Motif 橙：失败；橙底线：失败后的同工具重试 粗边框：三个模型语义决定

重复 1 | 普通 DSH

LLM 请求 21 工具尝试 20 成功 14 跳过 LLM 0 失败 6 53.0s 估费 ¥0.05121 / 峰值 ¥0.10242

v31_eval_brief_r1_baseline 执行顺序 5 已交付 / 1 页




图型：散点与回归 数值表：estimate,ci_low,ci_high,p_value,n
大纲：方法与数据 → 主要结果 → 诊断与主要限制 → 结论与后续工作
实际失败：#6 选择图文方案：单页限制：最多一图、四个标题；#7 选择图文方案：续接权限字段缺失或不是布尔值；#8 选择图文方案：续接权限字段缺失或不是布尔值；#12 LLM 写正文：正文及图件超出实测单页容量；#13 LLM 写正文：正文及图件超出实测单页容量；#14 LLM 写正文：正文及图件超出实测单页容量

重复 1 | DSH + Motif

LLM 请求 8 工具尝试 17 成功 14 跳过 LLM 10 失败 3 35.9s 估费 ¥0.03247 / 峰值 ¥0.06495

v31_eval_brief_r1_execute 执行顺序 6 已交付 / 1 页



图型：散点与回归 数值表：estimate,ci_low,ci_high,p_value,n
大纲：方法与数据 → 核心结果 → 诊断、限制与结论
实际失败：#6 选择图文方案：单页限制：最多一图、四个标题；#10 LLM 写正文：正文及图件超出实测单页容量；#11 LLM 写正文：正文 schema 拒绝额外字段

重复 2 | 普通 DSH

LLM 请求 17 工具尝试 16 成功 14 跳过 LLM 0 失败 2 42.4s 估费 ¥0.03268 / 峰值 ¥0.06537

v31_eval_brief_r2_baseline 执行顺序 14 已交付 / 1 页



图型：散点与回归 数值表：estimate,ci_low,ci_high,p_value,n
大纲：方法与分析范围 → 核心结果 → 模型诊断 → 主要限制与结论
实际失败：#6 选择图文方案：单页限制：最多一图、四个标题；#7 选择图文方案：续接权限字段缺失或不是布尔值

重复 2 | DSH + Motif

LLM 请求 8 工具尝试 17 成功 14 跳过 LLM 10 失败 3 36.0s 估费 ¥0.03229 / 峰值 ¥0.06458

v31_eval_brief_r2_execute 执行顺序 13 已交付 / 1 页



图型：散点与回归 数值表：estimate,ci_low,ci_high,p_value,n
大纲：方法与数据 → 核心结果 → 诊断与限制 → 结论与后续
实际失败：#6 选择图文方案：单页限制：最多一图、四个标题；#7 选择图文方案：续接权限字段缺失或不是布尔值；#11 LLM 写正文：正文及图件超出实测单页容量

真实执行流程 / 水质研究 / 技术讨论

同一输入的两次重复；编号节点为实际工具尝试，F 为真实最终答复；保留失败和修订

实验：research-report-agent-v31-20261010 题目：v3_eval_technical

蓝 L：工具命令来自 LLM 绿 M：工具命令来自 Motif 橙：失败；橙底线：失败后的同工具重试 粗边框：三个模型语义决定

重复 1 | 普通 DSH

LLM 请求 17 工具尝试 16 成功 14 跳过 LLM 0 失败 2 69.3s 估费 ¥0.05502 / 峰值 ¥0.11003

v31_eval_technical_r1_baseline 执行顺序 8 已交付 / 3 页



图型：散点与回归、残差图、效应区间 数值表：estimate,ci_low,ci_high,p_value,n
大纲：方法与数据 → 结果：效应方向与不确定性 → 残差诊断 → 对下一轮采样设计的含义与待验证假说 → 局限性
实际失败：#9 LLM 写正文：正文 schema 缺少必填字段；#10 LLM 写正文：未绑定数字 token

重复 1 | DSH + Motif

LLM 请求 8 工具尝试 17 成功 14 跳过 LLM 10 失败 3 57.1s 估费 ¥0.04681 / 峰值 ¥0.09361

v31_eval_technical_r1_execute 执行顺序 7 已交付 / 3 页



图型：散点与回归、残差图、效应区间 数值表：estimate,ci_low,ci_high,p_value,n
大纲：方法与数据 → 结果与不确定性 → 残差与模型假设诊断 → 对下一轮采样设计的启示 → 结论与局限
实际失败：#6 选择图文方案：大纲重复使用科学角色；#7 选择图文方案：续接权限字段缺失或不是布尔值；#11 LLM 写正文：未绑定数字 token

重复 2 | 普通 DSH

LLM 请求 17 工具尝试 16 成功 14 跳过 LLM 0 失败 2 62.7s 估费 ¥0.04374 / 峰值 ¥0.08748

v31_eval_technical_r2_baseline 执行顺序 15 已交付 / 4 页



图型：散点与回归、残差图、效应区间 数值表：estimate,ci_low,ci_high,p_value,n
大纲：分析背景与数据范围 → 结果：效应方向、幅度与不确定性 → 残差与模型假设诊断 → 对下一轮水质采样设计的含义与后续研究选择比较 → 局限性与待验证假说 → 小结
实际失败：#6 选择图文方案：续接权限字段缺失或不是布尔值；#7 选择图文方案：大纲重复使用科学角色

重复 2 | DSH + Motif

LLM 请求 8 工具尝试 17 成功 14 跳过 LLM 10 失败 3 63.3s 估费 ¥0.05051 / 峰值 ¥0.10102

v31_eval_technical_r2_execute 执行顺序 16 已交付 / 4 页



图型：散点与回归、残差图、效应区间 数值表：estimate,ci_low,ci_high,p_value,n,excluded_rows
大纲：分析对象与方法 → 温度与溶解氧的线性关系结果 → 模型假设与残差诊断 → 对下一轮水质采样设计的含义 → 结论与证据边界
实际失败：#2 批准统计：统计设计依据未引用已提供的原文；#10 LLM 写正文：正文 schema 拒绝额外字段；#11 LLM 写正文：未绑定数字 token