

保留模型写作的 科研报告 Agent

统计后选图表与完整正文交给 LLM；确定的执行步骤交给 Motif。

综合实验报告 · v3.1 · 2026-10-10 · Linux / DeepSeek Flash / 真实 DSH 与 MCP

本实验回答：如果不把科研讨论压缩成固定模板，而让模型根据真实统计结果选择图表、撰写报告，Motif 还能否在相同质量要求下减少费用？实验数据是脚本生成的合成数据；模型请求、统计运算、绘图和 PDF 输出均真实执行。

正式评测，共 16 次运行	普通 DSH	DSH + Motif
合格报告 / 计划运行	7/8	6/8
实际 LLM 请求	143	62
DSH 工具调用尝试	135	134
成功执行的 MCP 工具	112	112
API 峰值保守估费（元）	0.720166	0.612174
API 非峰估费（元）	0.360083	0.306087

本轮执行阶段 API 估费降低 15.00%，LLM 请求减少 56.64%。两项均包含全部失败与重提。

科学审阅普通组 7/8、Motif 组 6/8。全部执行费用除以合格稿数分别为 0.10288080 和 0.10202900 元/份，仅低 0.83%；不能把执行费用变化理解为等质量成果成本显著改善。

经验收集与独立确认（3次普通DSH运行）另需 0.234533 元。首八次 Motif 执行加经验收集与确认共 0.846707 元，高于普通组 0.720166 元。按本轮均费差，约 18 次同类任务执行抵消经验收集与确认费用，含不合格稿，不代表 18 份合格成果。

普通组与 Motif 组使用同一份输入、同一模型、同一套工具和质量标准。两组都自由生成分析方案、图表选择与正文，因此文本和篇幅可能不同；这是同任务交付比较，不是相同正文的纯调度消融。

“普通 DSH”指真实 DSH 原有执行循环接入本实验同一套 MCP 工具、关闭 Motif 的对照组；不代表未配置任何工具的默认安装。两组的模型重试、压缩和上下文裁剪设置相同。

阅读顺序：数据与任务 → LLM/Motif 分工 → 模体来源 → 费用与调用 → 质量评审 → 实际科研报告 → 复现与边界。

1 / 数据集与真实任务

四个留出任务覆盖三种统计设计与四种报告要求。每个任务在两组中各运行两次，第二次翻转组间先后顺序；重复运行用于观察模型波动，不当作新的独立研究。

任务及数据类型	分析问题	报告要求
生物量：两组独立培养样本	营养处理组与对照组的均值差、区间及数据分布	无指定大纲，模型组织内容和页数
学习者：同一人训练前后	按实验单元配对，估计平均变化及个体差异	保留用户四节大纲，最多三页
设备能耗：连续变量关联	负载与能耗的一元线性回归、误差与限制	恰好一页，至少一张图
水质：连续变量关联	温度与溶解氧的关系、残差诊断及后续采样选择	技术讨论，比较至少两种后续方案

经验收集、独立确认与评测分开

经验收集使用材料强度和算法准确率两个普通DSH任务，再由另一份水质数据作独立确认。这3次运行的API费用用于准备轨迹（原代码称训练/认证），没有训练或微调DeepSeek权重。准备运行和四个留出任务具有不同随机种子与CSV字节；评测轨迹不进入本轮模体库。

本轮种子偏移为 2000000。03-05 优化针对已批准统计步骤的续接授权与学习覆盖，既有 v3 工具、schema 和统计算法保持不变。两组共同题面明确用户允许该续接，但模型仍需显式提交 true/false；false 会保留，不能为凑覆盖手工补边。

旧 v3 仅作历史参考：本轮数据种子和两组共同措辞同时变化，不能把前后实验当作只改变三个调度步骤的受控消融。

数据标识	输入行数	实验设计说明
v3_eval_auto	56	两组独立实验单元，每个样本只测量一次；组间方差未知，不假设相等。
v3_eval_outline	64	同一实验单元在两个条件下重复测量，必须按 subject 对齐，不能当作独立样本。
v3_eval_brief	52	独立的连续型解释变量与响应变量观测；拟合带截距的一元线性关系，不能推断因果。
v3_eval_technical	52	独立的连续型解释变量与响应变量观测；拟合带截距的一元线性关系，不能推断因果。

真实与合成的边界

合成的是观测数据和题目情境；并未连接真实实验仪器或外部科研数据库。真实的是 CSV 文件、MCP 通信、统计计算、图件、LLM API 响应以及最终 PDF。数值真值仅用于独立评审，模型不能读取 oracle。

2 / 让模型在结果出现之后做决定

模型先判断研究设计，再读取已验证统计结果选择图型、表格指标和报告结构；实际图件通过检查后，模型提交各章节完整正文。程序只展开有来源的数值占位符、放置图表和执行排版。选图是从工具提供的有限图型中选择，不代表模型检查过图片像素或证明了图型最优。



这里的“正文由 LLM 写”有逐段证据：提交工具的原始实参、段落中的数值绑定、展开后的报告内容，以及最终 PDF 来源链都保留。组装工具不补写标准讨论段落。

模体如何形成



人工先设计工具、参数和授权边界；离线编译器从正常轨迹学习实际出现的返回字段传递关系。当前实现不声称能从任意科研任务自主发现完整 workflow。

3 / 与普通 DSH 的流程对比

LLM / Motif 是命令发起者，不是执行统计的工具。两组都经真实 DSH 派发同名 MCP 工具；区别只是部分确定命令是否还需要请求模型生成。

谁发起命令，与谁实际执行，是两件事
两组工具名与实现相同；DSH 派发，MCP 服务执行计算、绘图和排版。

步骤 / 用途	普通 DSH	DSH + Motif
01 读取任务与数据	LLM 发起 → DSH → MCP 执行 工具: inspect_study	LLM 发起 → DSH → MCP 执行 工具: inspect_study
02 模型提交统计方案	LLM 发起 → DSH → MCP 执行 工具: approve_analysis	LLM 发起 → DSH → MCP 执行 工具: approve_analysis
03 执行已批准的统计	LLM 发起 → DSH → MCP 执行 工具: run_analysis	Motif 发起 → DSH → MCP 执行 工具: run_analysis
04 独立复算统计结果	LLM 发起 → DSH → MCP 执行 工具: verify_analysis	Motif 发起 → DSH → MCP 执行 工具: verify_analysis
05 整理可引用证据	LLM 发起 → DSH → MCP 执行 工具: build_evidence	Motif 发起 → DSH → MCP 执行 工具: build_evidence
06 模型选图表与结构	LLM 发起 → DSH → MCP 执行 工具: approve_presentation	LLM 发起 → DSH → MCP 执行 工具: approve_presentation
07 实际绘制图件	LLM 发起 → DSH → MCP 执行 工具: render_figures	Motif 发起 → DSH → MCP 执行 工具: render_figures
08 检查图件与来源	LLM 发起 → DSH → MCP 执行 工具: verify_figures	Motif 发起 → DSH → MCP 执行 工具: verify_figures
09 模型提交完整正文	LLM 发起 → DSH → MCP 执行 工具: submit_report_text	LLM 发起 → DSH → MCP 执行 工具: submit_report_text
10 组装已提交的内容	LLM 发起 → DSH → MCP 执行 工具: compose_report	Motif 发起 → DSH → MCP 执行 工具: compose_report
11 生成 PDF 排版	LLM 发起 → DSH → MCP 执行 工具: layout_report	Motif 发起 → DSH → MCP 执行 工具: layout_report
12 核验版面与页数	LLM 发起 → DSH → MCP 执行 工具: audit_layout	Motif 发起 → DSH → MCP 执行 工具: audit_layout
13 核验成品完整性	LLM 发起 → DSH → MCP 执行 工具: verify_report	Motif 发起 → DSH → MCP 执行 工具: verify_report
14 返回交付文件	LLM 发起 → DSH → MCP 执行 工具: deliver_report	Motif 发起 → DSH → MCP 执行 工具: deliver_report
15 最后回复用户	LLM 生成用户可见回复 无工具调用；不是 MCP 步骤	LLM 生成用户可见回复 无工具调用；不是 MCP 步骤

本次 library 记录 10 条已学衔接；绿色标可由 Motif 发起的工具命令。
图示条件：当前授权、来源与守卫均有效。失败、撤销或证据变化时回到 LLM；实际次数另行审计。

完整工具名前缀统一为 mcp_research_report_。图读取实际 library：10 条已学衔接，其中03–05统计段 3/3。具体运行能否自动接管，还取决于当次授权、来源和执行守卫。

3.1 / 03-05 到底计算什么，怎样续接

第二步仍由 LLM 根据研究说明选择设计、变量、缺失处理和置信水平；批准后的计划编号 `plan_id` 指向真实持久化记录。03-05 只执行确定计算与证据整理，第六步必须再让 LLM 看本次结果选图表。第04步是复算和一致性检查，不替代研究设计或模型假设判断。Shapiro等诊断会进入证据；第06步的LLM仍需解读，遇到异常或未知分析需求时重新决策，不能机械沿用原方案。

真实工具接口	参数 → 返回字段	确定工作及本库状态
03 / <code>run_analysis(plan_id)</code>	<code>plan_id</code> → <code>analysis_id</code>	按已批准方案读取 CSV，清洗完整观测，计算效应、CI、p 和诊断。本库已学；守卫有效才由 Motif 发起
04 / <code>verify_analysis(analysis_id)</code>	<code>analysis_id</code> → <code>verified_id</code>	独立重读 CSV，用另一路公式复算，并校验数据版本与结果误差。本库已学；守卫有效才由 Motif 发起
05 / <code>build_evidence(verified_id)</code>	<code>verified_id</code> → <code>evidence_id</code>	汇集已核验数值、单位与限制，列出可选图型；到此停止自动续接。本库已学；守卫有效才由 Motif 发起

参数就是工具需要的输入；返回字段就是工具结果中一个有名称的值。例如 `run_analysis` 接收 `plan_id`，完成后返回 `analysis_id`。插件核验当前返回记录，再把同一个编号填入 `verify_analysis(analysis_id)`，不让模型重新抄写一次。

方案与场景	真实计算接口	主要输出
<code>independent_groups</code> / 独立两组	<code>scipy.stats.ttest_ind(b, a, equal_var=False)</code> ; Welch 自由度与 t 分位数区间	比较组减参考组的均值差、按已批准置信水平的 CI、双侧 p; Hedges g
<code>paired</code> / 同一实验单元前后	按 subject 配对; <code>scipy.stats.ttest_rel(b, a)</code> ; 差值的 t 区间	完整配对的平均变化、CI、p; Cohen dz
<code>regression</code> / 一元关联	<code>statsmodels.api.OLS(y, add_constant(x)).fit()</code>	含截距斜率、CI、p、R ² 、残差标准差；不作因果证明

共同核验：pandas/NumPy 负责输入整理，Shapiro-Wilk 只作残差诊断；独立复算走 csv + Python statistics + 显式公式，t 分布函数和诊断仍依赖 SciPy，不能称完全独立的软件实现或独立科学证明。工具通过只证明约定数值核对成功，不证明独立性、正态性或科学论断。

代码入口：benchmarks/research_report_agent_v3/workflow_tools.py 的 `run_analysis`、`verify_analysis`、`build_evidence`；实际数值例程复用 `research_report_agent_v1/data_tools.py`，附加核验复用 v2。没有为本轮替换算法或删除掉03-05。

实际证据：8次Motif评测中，03-05共记录 24 次已验证的模型请求旁路；两组各成功执行 112 个MCP工具。优化的是中间命令生成，没有省掉统计计算和复核。

3.2 / 绘图、组装和交付也是真实工具

LLM 或 Motif 决定下一条工具命令由谁发起；DSH 仍经 MCP 调用同一个 Python 工具。两组不会因为换了发起者，就省略绘图、排版或核验。

步骤 / 实际工具	真实实现与产物	检查边界
07 / render_figures	调用 v2._draw_figure；Matplotlib + NumPy 绘制实际数据，保存高分辨率 PNG 和矢量 SVG/PDF。	按第06步选择的图型绘制；不调用模型生成绘图代码。
08 / verify_figures	Pillow 读取像素尺寸和非空性；Python 检查文件 SHA、SVG 路径及图中绑定的分析指标。	文件和数值来源检查，不能判断选图理由或正文图号一定正确。
10 / compose_report	Python 读取已提交的 LLM 章节，绑定真实数值，按批准位置放入图和指标表。	不补写研究讨论，不修改模型原意；正文来源仍可追溯。
11 / layout_report	ReportLab 流式排版；最多四个字号/间距/图高候选；同稿同版本复用已校验结果。	不删字、不加填充；页数不满足时明确失败。
12 / audit_layout	PyMuPDF 重新打开真实 PDF，检查正文、图、页数、边界与 SHA；保留轻微格式警告。	不会把统计或科研文字的语义正确性当成已验证。
13 / verify_report	重复文件/布局核验，比较组装正文与已提交 LLM 正文，保存来源链。	输出明确科学推理尚未认证（scientific_prose_verified 为 false）。
14 / deliver_report	再次验证，返回真实 PDF 路径、页数、SHA 和警告，持久化交付记录。	最终第15步才由 LLM 写聊天答复；该答复不是 PDF 正文。


源码位置：v3/workflow_tools.py 对外提供上述 MCP 工具；绘图复用 v2/workflow_tools.py 的 _draw_figure，文件检查复用 v1/report_ops.py；PDF 引擎在 v2/document_engine.py。这里的 v1/v2/v3 均指 benchmarks/research_report_agent_v* 目录。

用户先前看到的两页只是旧综合报告截取的预览；本版固定展示四个任务各自第一次 Motif 运行的原件全部页面，不按结果优劣挑选，并另建全部16份原始成品的导航。

4 / 费用比较：保留写作后是否仍有收益

柱高为同题两次运行的平均费用，圆点是每次真实结果，细线是两次的范围而非置信区间。全部费用由实际命中输入、未命中输入和输出 token 重算。


费用范围：被测 Agent 的 DeepSeek API 请求；服务器计算、开发时间和本次外部独立 AI 审阅未计价，因此不是整套服务的总拥有成本。



每题平均，峰值估值/元	普通 DSH	Motif	节省
生物量 / 自动组织	0.082973	0.062740	+24.4%
学习者成绩 / 指定大纲	0.094458	0.081266	+14.0%
设备能耗 / 一页简报	0.083895	0.064765	+22.8%
水质 / 技术讨论	0.098757	0.097317	+1.5%

供应商缓存会改变费用：省去的调度请求可能原本就有高缓存命中率；自由写作的输出长度也会变化。因此，请求减少比例不等于省钱比例。

4.1 / 费用来自哪里，是否仍在反复修正



真实 HTTP 请求类别	普通 DSH	Motif
分析、选图和正文的语义提交	55 次 / 0.479183 元	54 次 / 0.509256 元
执行步骤的工具指令	80 次 / 0.178966 元	0 次 / 0.000000 元
模型未请求工具的回复	8 次 / 0.062016 元	8 次 / 0.102918 元


工具拒绝 / 失败发生在哪一步	普通 DSH	Motif
approve_analysis	1	4
approve_presentation	12	8
submit_report_text	10	10

排版实际情况：16 次 layout_report，0 次排版工具失败；同稿重复排版 0 次，新增草稿 0 份。工具内部总共尝试 64 个版面候选；另有 5 次正文容量预检拒绝。

本轮 LLM 请求总差额 81 次，日志核验的 Motif 绕过 80 次；两者差额 1 次还受失败重提等实际路径影响。两组自由生成方案和正文，不能把全部费用差都归因于调度优化。

“失败”包括参数不合规范、遗漏已要求内容或数字没有绑定来源后的重新提交。只有 layout_report / audit_layout / verify_report 的拒绝才属于后续排版或成品环节问题；应与前面的模型语义修正区分。

5 / 调用次数与全部运行记录



任务	组	重复	LLM	工具尝试	失败	页	审阅	估费/元
生物量	普通	1	16	15	1	3	未过	0.07001
生物量	Motif	1	5	14	0	2	通过	0.05071
学习者成绩	Motif	1	8	17	3	3	通过	0.08087
学习者成绩	普通	1	17	16	2	3	通过	0.09413
设备能耗	普通	1	21	20	6	1	通过	0.10242
设备能耗	Motif	1	8	17	3	1	通过	0.06495
水质	Motif	1	8	17	3	3	未过	0.09361
水质	普通	1	17	16	2	3	通过	0.11003
生物量	Motif	2	7	16	2	3	通过	0.07477
生物量	普通	2	18	17	3	2	通过	0.09594
学习者成绩	普通	2	20	19	5	3	通过	0.09479
学习者成绩	Motif	2	10	19	5	3	通过	0.08167
设备能耗	Motif	2	8	17	3	1	通过	0.06458
设备能耗	普通	2	17	16	2	1	通过	0.06537
水质	普通	2	17	16	2	4	通过	0.08748
水质	Motif	2	8	17	3	4	未过	0.10102

工具尝试包含参数验证失败和业务规则拒绝，不能全部称为成功 MCP 执行。普通组成功 112 次，Motif 组成功 112 次；合计 45 次失败均保留在费用里。各类失败原始原因见审计记录。

每一行都保留在总费用分母中。工具拒绝后的模型重新提交、最终回复、统计后解释和正文写作均计入；Motif 自己生成的工具指令不会被误算成真实 LLM 请求。

6 / 报告质量与评审边界

先看能否合格交付，再解释费用。独立审查分为数值/来源核验、科研文字阅读和实际页面检查；程序“返回成功”不足以说明科学解释正确。

共同检查	本轮核验范围
数值与实验设计	从 CSV 独立复算样本数、效应、区间和检验，核对配对/独立关系、缺失处理与单位。
结果后选图表	核对实际模型请求已包含本次证据；检查所选图型、理由和真实图件是否相容。
正文来源与科学性	逐段绑定真实 LLM 提交内容；检查效应方向、区间含义、因果限制、诊断与后续选择。
版面和交付	核对 PDF 页数、图文完整性、无物理裁切或严重重叠；保留实际失败和修正。

独立审查后的合格交付	普通 DSH	Motif
生物量 / 自动组织	1/2	2/2
学习者成绩 / 指定大纲	2/2	2/2
设备能耗 / 一页简报	2/2	2/2
水质 / 技术讨论	2/2	0/2

普通 DSH：全部评测费用 / 合格报告数 = 0.102881 元/份（峰值估费）。

Motif：全部评测费用 / 合格报告数 = 0.102029 元/份（峰值估费）。

两组通过的任务构成不同：本轮技术讨论普通组2/2、Motif组0/2。因此每份合格稿均费的约0.83%差别只作描述，不能证明等质省费，也不能证明科学写作质量提升。

未通过科学审阅的具体问题

生物量 / 自动组织 / 普通 DSH / 重复 1：没有定义实际重要性阈值或功效目标，就将当前可检出效应与实意义效应排序；正确的CI和非显著声明不支持该排序。

水质 / 技术讨论 / Motif / 重复 1：斜率置信区间单位mg/L/deg C与残差SD单位mg/L不能直接比较；未选温差换算，也无目标精度/样本量分析，就断言样本量非瓶颈并支撑研究优先级。

水质 / 技术讨论 / Motif / 重复 2：本次没有定义科学收益、目标精度或决策损失，不能仅凭当前CI和p断言精度再提升科学价值有限。此句明确声称直接支持，不能用后段一般待验声明当作撤回。

“通过”允许不改变主要科学含义的轻微问题。逐份记录仍保留单位表达、部分图文措辞、条件性建议及末页留白等改进项；原始科学报告未作后期润色。

科研文字和页面由独立 AI 阅读与程序检查共同审阅，不是外部专家盲评。该审阅是实验评估，不在被测 Agent 执行循环内，其成本未计入 DeepSeek 费用；专业修改和维护成本也未测量。详细逐份问题随报告包提供。

另一个交付界面问题：2次最终聊天答复残留未展开的数值占位符（见独立 answer.md），其中生物量 / Motif / 第一次的 {{confidence_pct}}% 未展开。PDF正文无该残留；这项minor单独记录，不混入PDF科学质量分母。

示例规则：固定四个任务各自第一次Motif运行，完整展示共 9 页，包含未通过审阅的原稿。另附导航收录全部16次原件，包括技术报告第二次运行的两份完整四页PDF；这里没有用旧版页数替代新原件。

研究简报

营养处理对培养样本生物量的影响

数据分析结果与研究讨论

方法

研究问题：营养处理是否改变培养样本的生物量。研究说明声明为「两组独立实验单元，每个样本只测量一次；组间方差未知，不假设相等」，因此采用独立两组设计，以 value (Biomass, 单位 g) 为主要结局，group 为分组变量，对照为 control (参考组)，处理为 treatment (比较组)。

结果

营养处理是否改变培养样本的生物量？实验比较了 control 组 (n = 27) 与 treatment 组 (n = 27)，两组样本量相等。对照组生物量均值为 8.2518 g (SD = 1.6487 g)，处理组为 8.6937 g (SD = 1.4628 g)。点估计显示处理组平均生物量略高，但两组的个体观测范围大幅重叠，目视难以判别组间差异；下一步以正式假设检验与区间估计为准。

按 treatment 减 control 的方向，处理效应估计为 0.44194 g (标准误 0.42417 g，自由度 51.273)，95% 置信区间为 -0.40951 至 1.2934 g；原假设为效应等于 0 g。该区间包含 0，说明仅凭本数据无法排除「营养处理不改变生物量」这一可能。

采用双侧 Welch t 检验进行两组比较，检验统计量 $t = 1.0419$ ， $p = 0.30235$ 。在双侧检验阈值 $\alpha = 0.05$ 下， $p \geq \alpha$ ，差异未达统计显著；效应量估计为 0.27946 (标准化指标)，属于小到中等量级，点估计的方向偏正但不确定性很大。统计推断的处理单位是完整观测 (每个独立培养样本一条记录)。为便于直接比较，下表汇总了效应、区间、p 值与分析样本量，图 2 以区间形式展示了同一效应及其不确定性。

统计量	计算结果	统计量	计算结果
效应估计	0.44194	CI 下界	-0.40951
CI 上界	1.2934	双侧 p	0.30235
有效样本	54		




图 1 | 每个点是一条有效观测；菱形为组均值，误差线为各组均值的双侧 95% t 置信区间。组间差异的推断以本报告统计表中的均值差及其置信区间为准。

7 / 生物量 / 自动组织 · 完整原件

固定展示 Motif 第一次运行 · 原件第 2 / 2 页 · 通过本轮独立审阅 (minor 问题仍保留)




图 2 | 圆点和区间直接取自统计分析记录；虚线表示零效应。区间表达估计不确定性，不代表个体观测的范围。

诊断与稳健性

分布假设方面，对重建残差做 Shapiro-Wilk 检验得 $W = 0.98747$, $p = 0.84204$ ；注意这是残差正态性的检验结果，与原假设效应的 $p = 0.30235$ 是两个不同的量，且不构成正态性成立的证明。两组标准差为 1.6487 与 1.4628 g，未显示极端离散差异；由于研究说明不假设方差相等，比较采用不要求等方差的 Welch 形式，其自由度 51.273 小于简单合并方差情形，给出的区间偏保守。

缺失值方面，原始数据共 56 行，其中 2 行因主要结局缺失被排除，最终 54 行进入完整案例 (complete-case) 分析。缺失机制未在数据说明中给出，因此无法排除缺失与分组或测量值相关的可能；若缺失非随机，效应估计与区间可能产生偏倚，本报告不作零填充或插补。诊断仅为对当前数据的描述性核查，不能证明模型假设成立。




图 3 | 经验累积分布直接由排序后的有效观测计算，不依赖直方图分箱；组间曲线差异展示整体分布而不只比较均值。

局限与解释

本数据为合成数据：研究范围说明明确全部观测值由独立随机种子生成，仅用于软件实验，不能作为真实学科证据。因此上述数值只能用于演示分析流程与不确定性表达，不应外推为任何真实营养处理的生物学结论，也不涉及具体培养体系或实验条件的推外。此外，本研究无随机化与处理分配信息，即使结果显著也不能建立因果关系；当前结果未达显著，更不能用于宣称处理无效或有效。

置信区间刻画的是所估计参数（处理组与对照组均值差）的不确定性，不是单个样本观测值的取值范围，也不等于预测区间；区间的一端为正、另一端为负，说明当前样本量下该效应方向尚未被数据确定。 p 值只反映在原假设下观察到当前或更极端数据的相容程度，未达显著不等于证明无差异，也可能是抽样波动或样本量不足所致。

基于以上结果，后续研究可考虑（1）扩大且预先说明样本量与研究设计，以提高对较小效应的检出能力；（2）在数据收集阶段记录并报告缺失原因与机制，以便评估完整案例分析的潜在偏倚，或采用合适的敏感性分析；（3）若需探讨剂量-反应关系，可考虑在具备真实实验数据时引入剂量（%）作为解释变量并使用回归设计，但需明确该设计本次并未执行，其可行性以真实实验条件为前提。以上均为基于当前证据的条件性建议，实施前需权衡成本、独立性与覆盖范围。

来源与工具记录：c375eb0f5185；完整哈希见交付旁证。

全部页面均展示，无后期润色。可放大阅读或打开同目录 complete_report_examples.pdf（原页矢量合订版，带书签）与 report_examples.html。

同一学习者训练前后测验成绩的配对分析

数据分析结果与研究讨论

研究问题

本研究关注同一批学习者在训练前后的测验成绩是否存在系统性变化。数据集以 `subject` 为配对实验单元，在两个条件（`condition` 为 before 与 after）下重复测量同一连续型主要结局（`value`，单位 points），因此分析单位是完整配对而非独立个体。

研究问题是：在同一学习者内部，训练后成绩减训练前成绩的平均变化是否偏离零？报告同时给出该参数估计的不确定性区间、个体层面变化的分布形态，以及缺失记录对结果的可能影响。本报告使用数据集中声明的合成数据，结论仅用于方法演示，不构成对真实教学干预有效性的证据。本分析描述该数据集内部的配对差异，不建立任何因果关系。

数据与方法

原始数据共 64 行，每行是一次 subject 与 condition 组合的观测，`value` 存在少量缺失，`subject` 与 `condition` 无缺失。由于同一学习者在两个条件下重复测量，分析前必须按 `subject` 对齐两次观测，绝不可把行数当作独立样本数；这一配对结构是本研究选择配对而非独立组方法的核心依据。

缺失处理采用完整配对策略（complete-case）：任何在一个条件下缺失 `value` 的 subject，其整个配对均被排除，最终保留 60 行、共 30 个完整配对，删除 4 行（即相应数量的不完整配对）。缺失机制未知，未做插补、未做零填充，因此所有结果都是在完整配对子集上的条件结论。

统计方法为双侧配对 t 检验，对比方向为 after 减 before，检验其均值是否偏离零效应（0），采用双侧检验与 95% 置信区间；区间基于 t 分布并以配对为单位计算标准误 0.83274，自由度 29。同时报告以配对标准差标准化的效应量 1.1524，以及在重构残差上计算的 Shapiro-Wilk 正态性检查（ $W = 0.97682$ ， $p = 0.73625$ ）；需注意该 p 值不是效应检验的 p 值，也不能证明假设成立。

统计量	计算结果
效应估计	5.2564
CI 下界	3.5533
CI 上界	6.9596
双侧 p	6.7889e-07
有效样本	30

主要结果及图表

在 30 个完整配对中，before 条件均值为 66.542 points（标准差 12.291，30 个观测），after 条件均值为 71.799 points（标准差 12.518，30 个观测）。个体内平均变化（after 减 before）为 5.2564 points，即训练后成绩平均高约 5.2564 分。图形展示三方面信息：图 1 为每位学习者训练前后的配对连线，用于直接查看个体变化方向与异质性；图 2 为平均变化及其 95% 置信区间；图 3 为个体差值的分布。

估计的不确定性由置信区间表达：95% 置信区间为 [3.5533, 6.9596] points，该区间不包含零效应（0），检验统计量 $t = 6.3122$ ，双侧 $p = 6.7889e-07$ 。按 0.05 的显著性水平，可以拒绝平均变化为零的原假设。同时，

7 / 学习者成绩 / 指定大纲 · 完整原件

固定展示 Motif 第一次运行 · 原件第 2 / 3 页 · 通过本轮独立审阅 (minor 问题仍保留)

标准差量级的个体差异 (约 12.291 与 12.518 分) 与平均变化 (5.2564 分) 处于不同尺度, 说明个体内部变化的均值虽稳定偏离零, 但个体之间的反应幅度并不一致, 这一点可从图 1 与图 3 的离散形态直接读出。

残差正态性检查结果 ($W = 0.97682$, $p = 0.73625$) 未显示明显违背正态假设的迹象, 因此配对 t 检验的区间与 p 值在正态性方面没有可见的异常信号; 但该检查既不能验证全部模型假设, 也无法证明数据生成过程。此外, 置信区间刻画的是平均变化这一参数的估计不确定性, 不是个体观测或个体预测的取值范围。




图 1 | 同一条线连接同一个体的两次观测; 仅纳入完整配对。连线展示个体变化及异质性, 不把配对数据当作独立样本。




图 2 | 圆点和区间直接取自统计分析记录; 虚线表示零效应。区间表达估计不确定性, 不代表个体观测的范围。

全部页面均展示, 无后期润色。可放大阅读或打开同目录 [complete_report_examples.pdf](#) (原页矢量合订版, 带书签) 与 [report_examples.html](#)。

7 / 学习者成绩 / 指定大纲 · 完整原件

固定展示 Motif 第一次运行 · 原件第 3 / 3 页 · 通过本轮独立审阅 (minor 问题仍保留)




图 3 | 先按个体匹配, 再计算比较条件减去参照条件的差值; 直方图展示变化分布, 虚线为零变化, 实线为平均变化。分箱采用 Freedman-Diaconis 规则。

局限与下一步

首先, 数据来源为合成数据 (由随机种子生成), 仅用于软件与方法演示, 不能作为真实学科证据; 本分析只描述该数据集内部的配对差异, 不建立训练导致成绩提高的因果结论, 也不涉及任何实际教学效果的推断。其次, 观察到的显著差异不等于实践重要性, 效应量 1.1524 及其区间应结合具体测评的分数量表来解读, 而当前数据未提供量表等距性等信息。

第三, 缺失处理的影响需明确保留: 缺失机制未知 (可能随机也可能与成绩相关), 采用完整配对删除后删除了 4 行, 即相应数量的完整配对, 保留 30 个配对。若被删除的学习者系统性不同于保留者, 平均变化估计 5.2564 及其区间 [3.5533, 6.9596] 可能存在方向或幅度上的偏差, 而当前数据无法检验这一选择偏差。所有结论仅适用于完整配对子集, 且样本规模有限, 区间宽度也反映了这一点。

第四, 本报告仅使用一种对比 (after 减 before) 与一种缺失策略, 未做敏感性分析, 也未检查顺序效应、练习效应或测量误差结构。若需推进, 可先对缺失机制做敏感性分析 (例如在不同极端假设下重新估计平均变化), 并在获得真实数据后重复同一配对流程; 这些后续方案属于有待检验的条件性设想, 其收益取决于数据可获得性与配对结构的完整性, 成本与假设限制需在实施前评估。

本报告的全部数字均来自同一条经独立复核的分析记录 (样本单位: 完整配对), 图表与关键指标表由该记录直接生成, 未做人工改写或事后填补。

来源与工具记录: 94a17c08e3b2; 完整哈希见交付旁证。

全部页面均展示, 无后期润色。可放大阅读或打开同目录 complete_report_examples.pdf (原页矢量合订版, 带书签) 与 report_examples.html。

7 / 设备能耗 / 一页简报 · 完整原件

固定展示 Motif 第一次运行 · 原件第 1 / 1 页 · 通过本轮独立审阅 (minor 问题仍保留)

研究简报

设备负载与能耗关系：一页摘要

数据分析结果与研究讨论

方法与数据

数据为设备负载 (%) 与能耗 (kWh) 的成对观测, 共 52 行。采用带截距的一元 OLS 回归, 估计负载每增加1%的解释变量每原始单位的拟合斜率。

响应变量存在少量缺失, 按完整观测策略隐去 2 行, 最终分析样本为 50 个完整观测。缺失机制未知, 未作任何填补。推断单位为单个观测, 取双侧检验, 置信水平 95%。数据由独立随机种子生成, 仅用于软件实验, 不构成真实学科证据。

核心结果

负载效应 (斜率) 为 0.82671 kWh/%, 95% 置信区间 0.78657 至 0.86685 kWh/%, 标准误 0.019964, 统计量 41.411 (自由度 48), 双侧 0 假设下 p 值为 3.2026e-39。区间整体位于零之上, 表明在本数据负载范围内存在正向线性关系。判定系数为 0.97277, 残差标准差 3.5909 kWh, 截距 17.301 kWh。图 1 为原始观测与拟合直线。

统计量	计算结果	统计量	计算结果
效应估计	0.82671	CI 下界	0.78657
CI 上界	0.86685	双侧 p	3.2026e-39
有效样本	50		




图 1 | 点为原始有效观测, 线为单变量最小二乘拟合, 阴影为均值的双侧 95% 置信带; 该带不是预测区间。相关关系本身不证明因果关系。

诊断、限制与结论

残差近似对称, Shapiro-Wilk 检验 W 为 0.9841、p 为 0.73227, 未发现拒绝正态性的证据, 散布无显著结构; 但该检验不能证明假设成立。

主要限制: (1) 区间只描述被估参数, 不是新观测的预测区间; (2) 观测数据拟合不能推断因果; (3) 显著性不等于工程实用价值, 斜率与残差标准差量纲不同, 比较前需指定有意义的负载差值; (4) 删除 2 行可能引入偏差; (5) 数据为合成数据, 不得作为真实设备证据。

结论: 在本合成样本负载范围内, 能耗随负载近似线性上升, 斜率约 0.82671 kWh/%。后续可检验不同负载区间的模型形式、缺失机制影响与更广采样条件, 均属待验证的条件性假设。

来源与工具记录: 72f33b0b9287; 完整哈希见交付旁证。

合成数据 / Synthetic data

1

全部页面均展示, 无后期润色。可放大阅读或打开同目录 complete_report_examples.pdf (原页矢量合订版, 带书签) 与 report_examples.html。

RESEARCH ANALYSIS / 技术报告

温度与溶解氧关系的技术讨论

数据分析结果与研究讨论

方法与数据

本报告的数据集为系统生成的合成水质数据（study 声明 synthetic），包含 52 行原始观测与 sample_id、Temperature（°C）、Dissolved oxygen（mg/L）三列，其中响应变量存在缺失。按照预先批准的分析方案，采用带截距的一元最小二乘回归刻画温度与溶解氧之间的线性关系，缺失值处理策略为完整案例删除：删除 2 行后共 50 个完整观测进入分析，样本单元为单个完整观测。响应变量为溶解氧，解释变量为温度，效应定义为温度每上升 1 deg C 时溶解氧的拟合变化量，单位 mg/L/deg C；检验为双侧、显著性水平 0.05，置信水平 95%，检验自由度为 48。

本分析的核心估计与结论边界：置信区间仅描述拟合参数自身的不确定性，不构成对个体观测或预测范围的描述；所用模型为单项 OLS，未调整任何协变量，也未使用随机效应或时间结构，因此分辨率仅限本数据集内的线性关联方向与量级。

结果与不确定性

在 50 个完整观测上，温度与溶解氧呈显著负向线性关联：拟合斜率为 -0.16976 mg/L/deg C（标准误 0.013992，t = -12.132，df = 48，双侧 p = 3.1339e-16），95% 置信区间为 [-0.19789, -0.14162]，该区间不含零效应值 0，且整体位于零的负侧。截距为 11.679 mg/L。模型的决定系数为 0.75409，即在本次数据中温度线性项可解释溶解氧变异的约四分之三；残差标准差为 0.63481 mg/L，其量纲与斜率不同，不能直接当作单点预测误差使用。

从效应方向与量级看，估计值指向“温度升高伴随溶解氧下降”，且 95% 置信区间上下限均为负，说明在该线性模型下方向是稳定的；但 p 值极小主要反映估计精度与样本量，并不自动等同于实际重要性——是否重要需比较区间宽度与具体管理关注的水温差异后再判断。

图1以原始散点叠加拟合均值线与均值置信带呈现上述关系；图3以点与区间形式呈现斜率估计及其不确定性，便于直接读取效应量级与区间边界。

统计量	计算结果
效应估计	-0.16976
CI 下界	-0.19789
CI 上界	-0.14162
双侧 p	3.1339e-16
有效样本	50




图 1 | 点为原始有效观测，线为单变量最小二乘拟合，阴影为均值的双侧 95% 置信带；该带不是预测区间。相关关系本身不证明因果关系。

7 / 水质 / 技术讨论 · 完整原件

固定展示 Motif 第一次运行 · 原件第 2 / 3 页 · 未通过本轮科学/视觉门槛，保留原稿




图 3 | 圆点和区间直接取自统计分析记录；虚线表示零效应。区间表达估计不确定性，不代表个体观测的范围。

残差与模型假设诊断

残差诊断基于实际观测值减拟合值重建。Shapiro-Wilk 检验在重建残差上得 $W = 0.96318$, $p = 0.1208$, 以 0.05 为阈值时未拒绝正态性；需强调这只是“不足以证明偏离”，并非证明残差严格正态，也绝不能把该 p 值与效应的 p 值 $3.1339e-16$ 混用。残差标准差为 0.63481 mg/L，可作为同方差性判断的相对基准。

图2给出残差与拟合值（或解释变量）的对应关系，用于检查系统弯曲、漏斗形散布与极端点。若图中出现明显弯曲，说明一元线性形式可能不足，应考虑多项式、分段或对温度作变换；若散布随拟合值增大而扩张，则标准误与区间可能被低估。当前并未完成诸如自相关或异方差检验的更细诊断，故这些判断在多大程度上适用于真实数据仍需独立阅读与进一步核查。

此外，删除的 2 行缺失机制未知（非随机缺失与随机缺失都会导致不同后果），完整案例分析在样本单元上保持独立观测假设，但无法排除删除带来的选择偏差；本次也未评估温度测量误差，这可能使斜率估计产生衰减偏倚。




图 2 | 残差由实际观测值减去拟合值计算。系统弯曲、漏斗形散布或极端点提示模型假设可能不适合；此图不自动证明假设成立。

对下一轮采样设计的启示

首先明确：以下建议均为依赖本次结果、待验证的条件性假设，而不是已被数据证实的因果结论。本次分析是观察性设计，不能推断因果关系；斜率与残差标准差量纲不同，比较两者前必须先指定有意义的水温差异（例如若干 °C 的跨度对应多少个 mg/L 的拟合变化）。

第一，精度分配。本次 95% 置信区间在残差标准差 0.63481 mg/L 量级下已较窄，说明在当前温度覆盖范围内样本量对斜率精度并非瓶颈；因此与其无差别增加重复次数，不如在保持总观测数可控的前提下扩大温度梯度覆盖，以直接压缩标准误 0.013992，同时把新数据放在本次尚未覆盖的温度区，用于真正检验线性假设。

第二，缺失与质量。删除的 2 行在当前 52 行中比例虽小，但因缺失机制未知，下一轮应统一并记录采样、保存与检测流程，按同一规程补报缺失，并预先声明缺失处理策略，以降低选择偏差对斜率的影响。

第三，分层与独立性。若下一轮改为多水体、多深度或多季节采样，观测不再相互独立，需改用分层或混合效应模型，并预先设定分层变量，否则会低估不确定性；同时应在每个站点内保留足够温度跨度，否则逐站点斜率将不可估计。

第四，协变量与因果边界。要判断温度“效应”是否被其他共变因素（盐度、深度、光照、采样时刻或季节）混淆，必须同步测量这些协变量；即便测量完整，观察性数据也仅支持条件性关联陈述与因果假设的检验设计，不构成因果证明。

合成数据 / Synthetic data

2

全部页面均展示，无后期润色。可放大阅读或打开同目录 complete_report_examples.pdf（原页矢量合订版，带书签）与 report_examples.html。

7 / 水质 / 技术讨论 · 完整原件

固定展示 Motif 第一次运行 · 原件第 3 / 3 页 · 未通过本轮科学/视觉门槛，保留原稿

关于后续研究选择，请见本节末尾的比较摘要。

方案一：扩大温度跨度与温度梯度设计的单因子重复采样（不同温度下重复、平衡布点）：本次斜率约为 $-0.16976 \text{ mg/L/deg C}$ ，95% 置信区间为 $[-0.19789, -0.14162]$ ，区间本身较窄但仍有压缩空间；区间宽度主要由斜率标准误 0.013992 与残差标准差 0.63481 mg/L 共同决定，而解释变量范围越大，斜率标准误越小，这是可以由设计直接影响的量。因此在更宽的温度区间内按近似平衡的温度梯度重复布点，是压缩参数不确定性、并在更宽预测区间内检验线性假设的最近一步。取舍与限制：成本相对最低、可复用现有分析流程，但代价是：其一，观测范围扩展到本次数据未覆盖的温度区后，“直线在整段区间成立”本身就是待验证假设，过度外推可能引入系统偏差；其二，只要缺失机制仍未知，扩大范围并不能修复完整案例删除（本次删除了 2 行）带来的潜在偏差；其三，同一水体不同温度下的重复测量可能共享时间与空间结构，独立观测假定将受到威胁。

方案二：多水体/多深度/多季节的分层与纵向采样，并同步记录协变量：本次 50 个完整观测只覆盖单一采样来源， 0.75409 的拟合优度虽高，但残差标准差 0.63481 mg/L 与斜率量纲不同，无法换算成个体预测精度，也无法说明关系是否在其他水体、深度或季节保持一致。分层采样可检验“斜率是否在层间改变”，并借助协变量（盐度、浊度、营养盐、光照与采样时刻）把当前单变量模型扩展为多变量模型，从而判断负向关联中有多少可由共变因素解释。取舍与限制：生态效度与外推范围更强，但设计、船时、实验室与数据管理成本显著更高；样本单元不再相互独立，必须改用分层/混合效应模型，自由度与解释复杂度上升；单站点内的温度跨度可能小于本次，逐站点斜率估计未必更精确；引入的协变量若测量有误差或彼此高度共线，还可能削弱而不是加强因果解释力。

两项选择共享同一目标：把“温度—溶解氧”关系从本次的散点相关推进为可支撑采样与运行判断的证据，但取舍方向不同。扩大温度范围是在当前单因子框架内直接压缩斜率不确定性，改动最小、成本可控，却会加剧对线性假设与外推的依赖，并且只要缺失机制未明，它无法消除删除偏差；多站点分层采样则通过引入站点、深度、时间、盐度等分层因子来提高生态效度与结论外推范围，但设计、船时与实验室成本更高，样本单元不再相互独立，必须改用分层或混合效应模型，且它在每个站点内的温度跨度可能比本次更小，从而使单个斜率的估计精度未必高于方案一。因此，若目标是快速检验本次负向斜率是否稳健并以最小代价降低参数不确定性，优先考虑方案一；若目标是为水质管理提供跨环境条件的证据并识别斜率在何处改变，应选择方案二，并预先明确分层变量与模型结构。两者的共同前提是先在统一的采样与分析规程下补报缺失，再以观察性设计能支持的因果弱形式（如因果图约束下的倾向评分或工具变量）讨论因果方向——这些推断目前均未被本次分析检验。

结论与局限

在本次合成数据的完整观测（ $n = 50$ ）中，温度与溶解氧呈稳健的负向线性关联：斜率 $-0.16976 \text{ mg/L/deg C}$ ，95% 置信区间 $[-0.19789, -0.14162]$ ，双侧 $p = 3.1339\text{e-}16$ ，决定系数 0.75409 ；重建残差的 Shapiro-Wilk 检验（ $W = 0.96318$ ， $p = 0.1208$ ）未显示明显偏离正态，但并未完成异方差与自相关的系统诊断。

主要局限包括：本数据为合成数据，仅供软件实验，不能作为真实学科证据；分析为单变量 OLS 且为观察性设计，不能推断因果；完整案例分析删除了 2 行且缺失机制未知，可能引入偏差；置信区间仅关于拟合参数，不是预测区间；此外未评估测量误差与独立观测假定的可靠性。因此所有关于采样设计的结论都应视为待验证假设，需要在真实数据与非合成设计中重新检验。

来源与工具记录：93c676369298；完整哈希见交付旁证。

全部页面均展示，无后期润色。可放大阅读或打开同目录 complete_report_examples.pdf（原页矢量合订版，带书签）与 report_examples.html。

8 / 学习成本、复现与适用范围

两次经验收集与一次独立确认（3次普通DSH运行）合计峰值估费 0.234533 元。这笔开销不藏入免费准备阶段；正式部署时可按后续报告份数摊销。

把这笔准备费也计入本轮，Motif总费除以 6 份合格稿为 0.14111791 元/份，高于普通组的 0.10288080 元/份。回本次数只按每次任务尝试的费用差估算，不是同等科学合格产出的回本证明。

后续任务执行次数 N	经验准备摊销 / 次	Motif 执行均费 + 摊销
8	0.029317	0.105838
100	0.002345	0.078867
1000	0.000235	0.076756

按当前四题的平均执行费用差估算，约需 18 次同类任务执行抵消一次经验收集/独立确认费用。均费包含不合格稿，不等于交付相同数量的合格成果；这是假定任务分布和费用差保持不变的情景估算，未计入开发、维护和专家修改成本。

本轮审计列入的开发运行峰值估费为 0.000000 元，失败与重提均保留；旧 v3 及更早实验仍计入全局总账。新统计覆盖实验采用种子偏移 2000000，与旧 v3 不是相同数据消融。开发API费、经验准备费与主实验分列。

本轮开发、经验收集/确认和评测共 255 次真实请求，峰值估费 1.566873 元。连同先前实验，累计 1419 次请求、峰值估费 7.420987 元（非峰 3.710494 元），仍在授权的 100 元以内。

复现入口与材料

实际运行环境：Linux / Python 3.12.15 / Node v22.23.3 / DSH 0.1.5-rc.3。真实 stdio MCP 工具契约共 14 项；测试结果以本轮冻结环境和测试证据为准。

执行工具沿用 benchmarks/research_report_agent_v3；本轮准备和统计覆盖诊断位于 benchmarks/research_report_agent_v31。两组通过同一 runner.py 调用现有 DSH SDK 与真实 MCP；预算代理沿用共用账本。prepare_experiment.py / generate_cases.py 准备新数据，普通DSH经验轨迹由 compile_motifs.py 编译，run_matrix.py 执行显式矩阵。具体命令与实际文件名以随包 README 为准。

适用范围

当前覆盖独立两组、配对比较和一元回归，图型来自有限真实绘图工具，报告结构映射到明确的章节角色。相同工具体系以外的科研设计、任意图形、任意格式或任意 Harness 仍需适配。两个重复不足以推断所有任务的平均效果或统计显著性。

价格及证据

DeepSeek 官方中文价格页于 2026-10-10 核对：Flash 峰值每百万 token 的命中输入、未命中输入、输出分别为 0.04、2、8 元，非峰减半。本轮运行在周六，非峰估费更接近对应时段；峰值用于保守预算。两者都不是提供商逐笔账单。

https://api-docs.deepseek.com/zh-cn/quick_start/pricing/?helper=penn

审计源 SHA256: c9e8a68c05c3744f340a62758e7caad5154b36cdc8a5c228f00e01b0d7d0023f

费用、正文、图件与每次调用的可追溯记录保存在同一实验目录；旧版实验保持原样。