

同一学习者训练前后测验成绩的配对分析

数据分析结果与研究讨论

研究问题

本次分析关注一个明确的问题：同一批学习者在同一实验单元内接受训练前后两个条件下的重复测验，其测验成绩是否发生系统变化？由于两种条件来自同一实验单元而非不同人群，研究单位是学习者个体，比较的对象是同一位学习者在两个条件下的成绩高低，而不是两组互不相干的人。

问题包含两层要求。第一层是给出效应大小的点估计与不确定性区间，说明平均变化的方向与幅度，并明确区间的精度有多高。第二层是呈现每一位学习者各自的变化，避免仅用组均值掩盖个体之间的差异；同时需要交代样本中缺失记录的处理方式以及缺失对结论可能造成的影响。

数据与方法

数据来自本研究项目的 data.csv，共 64 行原始记录，字段为 subject（配对实验单元）、condition（before 与 after 两种条件）和 value（连续型测验成绩，单位为 points）。由于同一 subject 出现两次，行数并不等于学习者人数，任何把行当作独立观测的做法都会错误地夸大样本量并低估标准误。

依据研究说明中“同一实验单元在两个条件下重复测量，必须按 subject 对齐，不能当作独立样本”的界定，统计方案批准为配对设计：先在 subject 层面把 before 与 after 配对，形成个体内差值，再对差值做双侧配对 t 检验（双侧配对 t 检验），对比方向定义为 after 减 before，检验的零假设值为 0。显著性水平为 0.05，置信水平 95%，因此结果中的区间是 95% 置信区间。

缺失处理采用完整配对策略（complete-case）：只要某位学习者在任一条件下缺测，整对即被删除，不做零填充，也不做插补。原始 64 行中保留 60 行、删除 4 行，最终得到 30 对完整配对作为全部分析的样本单位（样本单位：完整配对），参照条件与比较条件各 30 与 30 个完整观测。

模型假设检查方面，配对 t 检验主要依赖差值近似正态。对按个体重构的差值做 Shapiro-Wilk 检验，得到 $W = 0.97682$ 、 $p = 0.73625$ ；该 p 值仅用于描述差值分布与正态分布的相容程度，不能证明假设成立，也不能替代对个体变化形态的直接查看。因此后文同时给出个体层面的图形，以便读者自行判断均值与区间是否足以概括这批数据。

统计量	计算结果
效应估计	5.2564
CI 下界	3.5533
CI 上界	6.9596
双侧 p	6.7889e-07
有效样本	30
排除行	4

主要结果及图表

主要结果显示训练后的成绩高于训练前。以 after 减 before 为对比方向，平均变化为 5.2564 points，标准误 0.83274，检验统计量 $t(29) = 6.3122$ ，双侧 $p = 6.7889e-07$ 。该 p 值远小于既定的 0.05 阈值，说明在差值均值为 0 的零假设下，观察到如此规模的样本平均变化并不常见。

与点估计配套的 95% 置信区间为 [3.5533, 6.9596] points，区间完全位于零的同一侧，其下限 3.5533 仍大于 0。需要强调该区间的含义：它刻画的是被估计参数（总体平均变化）的不确定性，而不是个体观测值的取值范围；个

体的成绩变化可以远超或低于该区间。标准化效应量为 1.1524，可用来说明变化幅度相对于个体间差异的规模。两个条件的描述统计为：before 均值 66.542 (SD 12.291) ， after 均值 71.799 (SD 12.518) 。

图 1 按 subject 连接每位学习者的两次观测，直接回应“展示每个人的变化”这一要求；图中可见多数连线方向向上，但并非全部如此，个体变化存在明显异质性，仅看均值会掩盖这一事实。图 2 以圆点和区间呈现效应估计与不确定性，虚线为零效应参照，区间不跨越该参照线。图 3 展示个体内差值的分布，虚线标记零变化，实线标记平均变化，其分箱按 Freedman-Diaconis 规则确定；差值的中心位于零的右侧，同时分布中仍可见位于零左侧的个体。




图 1 | 同一条线连接同一个体的两次观测；仅纳入完整配对。连线展示个体变化及异质性，不把配对数据当作独立样本。





图 2 | 圆点和区间直接取自统计分析记录；虚线表示零效应。区间表达估计不确定性，不代表个体观测的范围。

Distribution of within-subject changes



Synthetic benchmark data | fixed input snapshot

图 3 | 先按个体匹配，再计算比较条件减去参照条件的差值；直方图展示变化分布，虚线为零变化，实线为平均变化。分箱采用 Freedman-Diaconis 规则。

局限与下一步

首要局限来自数据本身：本数据集标记为合成数据（synthetic），全部观测值由独立随机种子生成，仅用于软件实验，不能作为真实学科或教学效果证据。因此上述数字应被读作流程演算的结果，而不是关于任何真实训练方案效果的结论。

第二个局限是缺失。缺失处理是完整配对删除，机制未知：如果缺测与成绩水平或训练反应相关（例如表现较差者更易漏测），剩余的 30 对完整配对就不能代表全部学习者，删除的 4 行记录可能引入偏差，且删除整对会同时损失该个体两个条件的信息。由于原始记录未提供缺失原因字段，此处无法判断缺失属于完全随机、随机还是非随机，也无法对偏差方向做出可靠估计，只能如实报告删除量并保留该不确定性。

第三个局限是推断边界。本设计只比较同一批学习者在两个条件下测得的两组成绩，未包含随机化、对照条件或时间记录，因此本分析不能建立因果关系：p 值与置信区间都不构成训练导致成绩提高的因果证据，本次分析不宣称任何因果效应。同时，统计显著也不等同于实际教学意义上的重要性，估计值是否“足够有用”需要结合测验的量纲与教育决策场景单独判断。Shapiro-Wilk 结果同样只能说明差值分布与正态分布的相容程度，不能证明假设成立或说明样本量充足性。

第四，缺失情况目前只能以删除量概括，未能刻画缺失的个体特征与分布。若后续仍使用本流程，可考虑在数据采集端完整记录每个 subject 的两个条件并提供缺失原因，以便在完整配对之外补充敏感性分析（例如对缺失个体的极端假设对比）；此类扩展属于条件性的研究设计建议，需要重新评估其成本、独立性与覆盖范围，不能由当前结果直接支持。

综上，在 30 对完整配对的范围内，本分析给出的平均变化为 5.2564 points，95% 置信区间 [3.5533, 6.9596]， $p = 6.7889e-07$ ；解释应以合成数据与删除 4 行记录这两项限制为前提。

来源与工具记录：c1adef3ec73a；完整哈希见交付旁证。