

同一数据划分下两种算法准确率的配对比较

数据分析结果与研究讨论

研究背景与目的

在机器学习实验中，评价两种算法优劣的常规做法是在同一份数据划分上分别训练与评估，再比较两者的准确率。由于两次评估共享相同的训练集、验证集与测试集，同一次划分内部的随机性与数据难度会同时作用于两种算法，两次测量因此并不相互独立。本报告的研究对象正是这类同划分、同实验单元的重复测量，目的是估计两种算法准确率之差的大小及其不确定性，而不是把全部观测当作互不相干的样本。

为回应这一问题，本报告采用配对设计：以 after 减 before 作为被估计的对照量，检验其是否偏离零效应（即 0），并给出 95% 置信区间。我们同时报告完整配对的实际样本量与被排除的观测数量，以便读者判断估计精度与缺失处理带来的潜在偏差。需要预先说明，本项分析的推断对象是该参数本身，而非单个观测或未来预测的取值范围。

数据与方法

数据来自随本任务提供的训练划分记录，共 64 行观测，包含实验单元标识 subject、条件标识 condition（取值为 before 与 after）以及连续型结局 value（准确率，单位为 fraction）。同一 subject 在两个条件下各出现一次，构成一组配对。全部观测值由独立随机种子生成，仅在软件实验意义上使用；本报告不将其视为关于真实算法性能的学科证据。

分析方案在读取真实数据前即已确定。由于描述明确指出同一实验单元在两个条件下重复测量、必须按 subject 对齐而不能当作独立样本，我们选择配对设计，并以 双侧配对 t 检验 计算估计与检验统计量；由于数据存在少量缺失值，缺失处理策略选定为完整配对分析，样本单位因此是 完整配对，而不是行数。原始 64 行中有 4 行被排除，不完整的配对整组删除，即缺失排除以配对为单位发生，而非逐列零填充或插补。

对完整配对，我们按 subject 逐对匹配后计算差值，检验统计量的自由度为 29。除效应检验外，我们还对重建残差进行了 Shapiro-Wilk 正态性检查（ $W = 0.92473$ ， $p = 0.035634$ ），该 p 值仅用于描述性诊断，与效应检验的 p 值含义不同，不能互相替代。所有区间均采用双侧 95% 置信水平。

统计量	计算结果
效应估计	0.019867
CI 下界	0.014085
CI 上界	0.025649
双侧 p	9.9581e-08
有效样本	30
排除行	4

结果

完整配对共有 30 对。before 条件下准确率均值为 0.79122（标准差 0.038045，样本量 30）；after 条件下均值为 0.81109（标准差 0.040389，样本量 30）。按 after 减 before 定义的准确率变化点估计为 0.019867（fraction），标准误为 0.0028271，对应 95% 置信区间为 0.014085 至 0.025649。区间的整体位于零效应之上，未跨越 0。

配对 t 检验结果为 $t(29) = 7.0271$ ，双侧 $p = 9.9581e-08$ 。作为效应尺度的补充参考，标准化配对效应量约为 1.283。图 1 以连线方式展示每对观测在两个条件间的移动，图 2 展示配对差值的分布并以虚线标出零变化、实线标出平均变化。两图显示改善方向在多数实验单元上一致，差值分布整体偏向正值，这与区间下限高于 0 的结果相符。

图 3 呈现点估计与不确定性区间。需要强调，区间刻画的是被估参数的不确定性，并不代表个体观测或预测值的取值范围； $p = 9.9581e-08$ 说明在本模型与缺失处理假设下该差异不易由抽样波动解释。本分析不建立因果关系，因此不能据此断定两种算法之间的差异是由某一算法本身引起的。同时，统计显著也不能仅凭 p 值推断差异在实践中具有重要价值。




图 1 | 同一条线连接同一个体的两次观测；仅纳入完整配对。连线展示个体变化及异质性，不把配对数据当作独立样本。




图 2 | 先按个体匹配，再计算比较条件减去参照条件的差值；直方图展示变化分布，虚线为零变化，实线为平均变化。分箱采用 Freedman-Diaconis 规则。

Effect estimate and uncertainty




图 3 | 圆点和区间直接取自统计分析记录；虚线表示零效应。区间表达估计不确定性，不代表个体观测的范围。

局限性与推广条件

本分析有若干项须明确披露的限制。首先，数据为合成数据，由独立随机种子生成，仅用于验证统计流程，不能作为关于任何真实算法优劣的学科结论。其次，缺失机制未知：4 行被排除，虽然按配对整组删除避免了错配，但若缺失与准确率水平相关，完整配对样本可能对目标总体产生选择偏差，而当前数据无法检验这一点。再次，正态性诊断给出 Shapiro-Wilk $p = 0.035634$ ，提示残差正态假设存在可察觉的偏离；配对 t 检验对轻度偏离通常较为稳健，但这仍属未经当前数据充分验证的假设。

关于推广到其他数据集，必须保持谨慎。本估计只描述了当前这一份划分上两种算法的准确率之差，其数值依赖该划分的样本规模、类别分布、数据难度与噪声结构。把结论推广到新的数据集、新的划分比例、新的随机种子，或者改换评价指标，均属未经检验的假设，而不是由现有证据支持的结论。区间宽度也仅反映该参数在当前样本量下的精度，不能据此推断改变样本量或更换设计所带来的收益。

因此，本次结论的合理表述是：在合成数据的当前训练划分上，配对分析给出了一个方向为正、区间不含零的准确率变化估计（0.019867，95% 置信区间 0.014085 至 0.025649）。这一结果描述的是观测到的差异，不构成因果关系。后续工作应作为条件性方案开展：在真实且独立的数据集上重复同划分配对评估，报告缺失机制与缺失比例；在多份划分或多随机种子上重复配对设计以考察效应在不同划分间的变异；并预先设定实际意义阈值，以判断观察到的差异是否达到实践上有用的幅度。

来源与工具记录：4280d5176e31；完整哈希见交付旁证。