保留模型理解的 科研 PPT Agent

综合实验报告 · 同伴结构版 · 2026-10-10 · Linux / DeepSeek Flash / 真实 DSH 与 MCP

论文理解、选材与叙事交给模型；可验证的来源读取衔接交给 Motif。

本实验回答：接收真实 PDF / PPTX，交付可编辑科研幻灯片时，能否减少模型调用与 token？公开论文、DeepSeek 请求、MCP 工具、PPTX、LibreOffice 预览均实际执行。题面由本项目自定义，尚未经历课题组真实使用者的前瞻验收。

第二轮 / 5 题 × 3 组	普通 DSH	组合脚本	DSH + Motif
会话完成并程序交付	4/5	5/5	5/5
真实 LLM 请求	104	90	71
全部 token	4,073,257	2,777,868	1,947,029
API 代理估费 / USD	0.181262	0.151764	0.109505
verified 模型请求旁路	0	0	5

第二轮全部任务：Motif 相对普通 DSH 请求减少 31.73%，全部 token 减少 52.20%，代理估费减少 39.59%。

上述包含 E2 普通组 40 步失败、无确认成品，不能解释为同质量节省。只比较双方均有成品的 E1 / E3 / E4 / E5：请求少 17.19%，token 少 25.56%，估费低 9.75%，记录运行耗时反而增加 3.49%。E1 / E3 / E5 仍需要内容修订。

最强局部证据是 E4：两组文档内容和 6 页渲染图完全一致，请求 8 → 7；它只支持这个简单改版任务的局部调度节省。每个 Motif 运行只有 1 次 verified 旁路，全部请求差额不能归因于这个旁路。

RSI 真实提出并测试了 6 个准入候选，最终回到原基准规则；未观察到新规则或优化收益。学习、认证、RSI、失败与两轮对照累计 592 次上游请求，代理估费 $0.983503248。账单、人工盲评和修订成本尚未知。

阅读顺序：数据与任务 → 结果后决策 → 三组工具流程 → 费用 → 完整运行 → 质量 → 全页原稿 → 学习与复现。

1 / 数据集与真实任务

五题是自定义 PPT 任务；不是仓库 18 项合成科研决定中的五题。

任务与来源	交付要求	关键质量条件
E1 / Transformer、BERT、LoRA	15 页中文组会 / generate / lab	各自问题、方法、实验、局限；不能跨实验条件排名成本。
E2 / ResNet、DDPM	8 页方法比较 / generate / academic	区分分类与生成目的；解释实验条件，避免不同指标硬比较。
E3 / LoRA	6 页短讲 / generate / academic	低秩机制、真实实验、限制和来源；覆盖不能因短篇幅缺失。
E4 / 冻结旧 6 页 PPTX	6 页保留内容 / restyle / academic	文字、notes、页数与对象保留；原稿本身已为 academic 纯文字。
E5 / 旧稿 + BERT	10 页更新 / generate / lab	保留旧稿相关内容、增加新证据并标出来源；避免拼接式因果与成本比较。

经验收集、独立认证与评测分开

训练轨迹来自 SimCLR、ViT 两个真实普通 DSH 任务，另用 CLIP 作独立留出认证；这三次运行不进入五题评测。所谓训练是从工具轨迹编译 Motif，没有训练或微调 DeepSeek 权重。任务独立性标签由 Agent 声明，尚待人工核验。

评测来源包含五篇公开论文和一份冻结旧 PPT。LoRA 在 E1/E3 重复，BERT 在 E1/E5 重复，旧 PPT 在 E4/E5 重复；不能当作五个完全独立来源集合。论文先在本机下载，再传到服务器；每次来源和任务快照保留 SHA256。

两轮配置的边界

R1 与 R2 都执行五题三组，共 30 个对照运行。R2 使用修复后的图片/组合处理与更高运行上限，不是仅改变 Motif 开关的同条件重复；统计按 cohort 分开。每轮每组每题仅运行一次，不能据此推断平均效应或显著性。

真实的是论文文件、工具通信、API 响应与实际幻灯片；自定义的是任务题面和旧稿使用场景。未连接真实会议投影或多人协作审阅流程，当前属于真实 API 工程实验。

2 / 让模型在结果出现之后做决定

当前“结果”首先指工具真实返回值；不能把已规划路线冒称结果后的科学判断。

模型先按任务选择允许的来源。pin_source 真正解析文件并返回 source_id 后，认证 Motif 才能绑定 read_source 的参数；读取结果回到模型，模型据此理解论文、选择内容、生成逐页计划。图件候选和验证错误出现后，仍由模型决定选图、补读或改计划。



Motif 如何形成

人工先定义 MCP 工具、schema、权限和参数边界；离线编译器从 SimCLR / ViT 正常轨迹识别真实 source_id 传递关系，在 CLIP 轨迹独立认证后冻结 library。新任务用本次返回值执行同名真实工具，旧结果和频率不能替代新证据。

已认证图只有 pin_source → read_source。生成、渲染、验收都是现有代码工具；论文理解、选材、叙事和科学判断仍属于模型。当前没有模型生成新工具，也没有从轨迹学出新的 code node。

3 / 与普通 DSH 的流程对比

三组经真实 DSH / MCP 调用工具；变化在命令发起方式与是否用普通组合入口。

步骤 / 工具	普通 DSH	组合脚本	DSH + Motif
选择与固定 / pin_source	LLM 发起	LLM 发起	LLM 发起
来源读取 / read_source	LLM 抄 source_id 并发起	LLM 发起	认证 Motif 绑定结果并发起
补读 / read_page；选图 / extract_figure	LLM 决策并发起	LLM 决策并发起	LLM 决策并发起
叙事与逐页内容 / JSON 计划	LLM 编写	LLM 编写	LLM 编写
生成或改版 / render_deck；restyle_deck	LLM 分步发起	LLM 调 build_delivery，代码内部执行	LLM 分步发起
核验 / inspect_deck；validate_deck	LLM 分步发起	组合代码内部核验	LLM 分步发起
交付 / deliver_deck	LLM 发起，MCP 重核	组合代码内部交付	LLM 发起，MCP 重核
错误反馈与最后回复	LLM 恢复、答复	LLM 恢复、答复	LLM 恢复、答复

绿色行是当前 library 唯一可能接管的衔接。Motif 不会省掉 read_source 工具执行；它省掉一次让模型抄写句柄并发起读取的整次请求。生成/检查/交付长链未获得此类认证。

graph、code、LLM 的具体位置

类型	当前实际实现
graph / 学得结构	两个可执行工具节点 + source_id 参数流 + schema / 版本 / 权限守卫。
code / 确定实现	文本规范化、按页读取、图件定位、PptxGenJS 排版、notes、LibreOffice / PDF / PNG 验证与 SHA；组合入口把固定生成验收工作封装。
LLM / 语义缺口	选择资料和补读、内容覆盖、研究关系、实验条件、图表解释、逐页文字及错误后的修正。

共享工具 schema 及顺序保持一致，所有组关闭思考和入口压缩。工具全部开放且遵循执行提示，模型实际选择及失败重提仍可能不同；这是同任务交付比较，不是固定相同全文的纯调度消融。

3.1 / 认证边与 RSI：实际接管到哪

认证结构与模型提出的准入规则分别记账；两者不能混称自我优化收益。

证据项	当前状态
唯一认证边	mcp__ppt__pin_source.source_id → mcp__ppt__read_source.source_id
来源与留出	SimCLR / ViT 两条训练；CLIP 留出。code_nodes = []。
真实执行顺序	收到本次 pin 结果 → 绑定 read 参数 → 检查 schema / 来源版本 / 权限 → 跳过一整次请求 → 实际读工具 → 复核结果。
旁路计数	R1 5 次，R2 5 次，每个 Motif run 1 次；合计 10 次。
失败恢复	来源变化、无效 manifest、schema 漂移或权限/写 barrier 不允许旁路；重新交回模型。

真实 RSI 提案、测试、反馈与准入

DeepSeek 被要求提出受限 guard 程序，服务端按固定协议检查并执行反例测试；失败结果交回模型，合格候选才启用。该入口支持真实反馈闭环，但不是任意代码生成，也不能绕过外层权限边界。

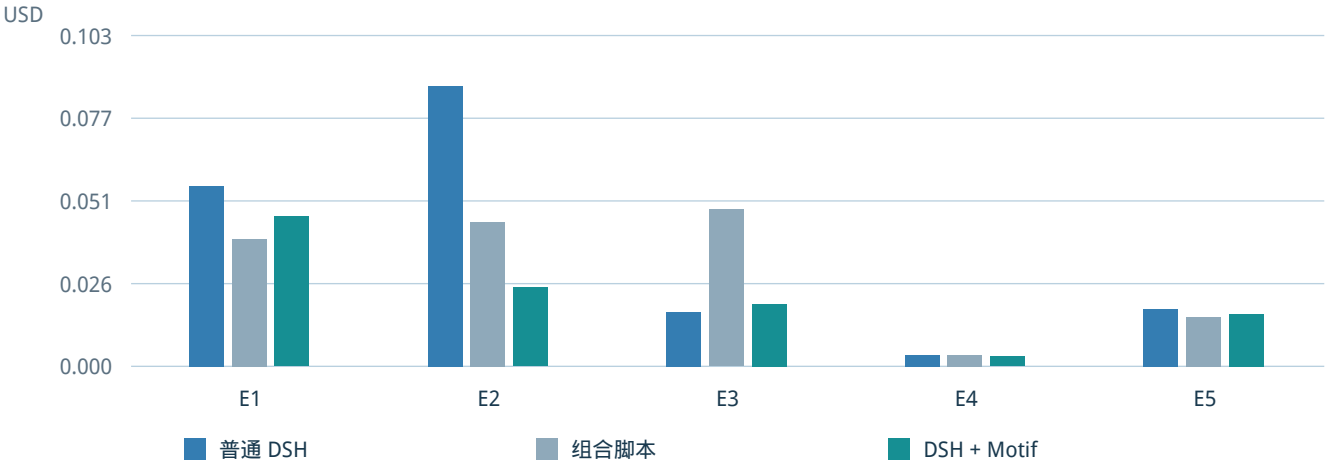
候选	实际结果
1、2、4、5	不符合固定 schema，被拒绝。
3	min_text_chars=200 / max_pages=100；short_pdf 反例应准入却被拒，未启用。
6	formats=[pdf,pptx]，min_text_chars=1，max_pages=200；通过 7 项检查，但与原基准一致。

RSI 共 7 次真实上游请求、20,680 token、代理估费 $0.003636780；未观察到新规则或优化收益。模型提案和测试反馈确实发生，最终没有形成更优准入机制。

历史要求最多 3 次当时只有提示，实际 6 次偏离保留。之后补上服务端每任务持久化 3 次硬限制，schema 失败也计数、重启不重置；此补丁不追改历史结果。

4 / 费用比较：保留理解后是否有收益

第二轮每题一次真实运行；没有重复点或置信区间。柱高包含该运行的失败与重提。



任务	普通 DSH / USD	组合 / USD	Motif / USD	Motif 费用变化
E1	0.056057	0.039521	0.046462	+17.1% 降低
E2	0.087001	0.044733	0.024436	+71.9% 降低
E3	0.016784	0.048721	0.019260	-14.8% 降低
E4	0.003547	0.003575	0.003081	+13.1% 降低
E5	0.017873	0.015215	0.016267	+9.0% 降低

E2 普通组耗尽 40 步，没有确认 PPT；其失败费用必须保留，但与 Motif 的成品不能组成同质量配对。E3 是反例：请求 16 → 19、token 349,214 → 456,027，估费也增加约 14.75%。

模型仍自由编写内容、选图和修正计划，输出长度及失败路径不同。R2 普通 / Motif 请求差 33 次，但只有 5 次经审计 verified 旁路；不能把其余 28 次或全部费用差归因于学得结构。

费用范围为被测 Agent 的 DeepSeek API 代理估费；服务器、开发维护、Codex 辅助审查与人工修订尚未计价，不是完整服务总成本。

4.1 / token、缓存与成品配对

token 减少与费用减少是两个指标；缓存命中输入也计算 token，但价格较低。

第二轮	未命中输入	命中输入	输出	全部 token	估费 / USD
普通 DSH	163,566	3,818,624	91,067	4,073,257	0.181262
组合脚本	150,308	2,551,424	76,136	2,777,868	0.151764
DSH + Motif	137,905	1,761,152	47,972	1,947,029	0.109505

全部 token = 未命中输入 + 缓存命中输入 + 输出。运行时固定费用表：DeepSeek Flash 每百万 token 未命中输入 $0.30、命中输入 $0.006、输出 $1.20。按实际 usage 结算代理预留；这些是仓库价格配置和代理估费，未核对供应商逐笔实付账单。

仅双方均有成品的四题

E1 / E3 / E4 / E5	普通 DSH	Motif	变化
真实请求	64	53	+17.19% 降低
全部 token	1,930,326	1,436,864	+25.56% 降低
估费 / USD	0.094261	0.085069	+9.75% 降低
运行记录耗时 / 秒	239.534	247.887	-3.49% 降低

有成品不等于合格：E1 / E3 / E5 仍被辅助审查判为需要修订，四题未证明质量等价。耗时含被记录的单次运行阶段，未计两次运行间隔、资料准备、学习与人工验收；不能宣称普遍加速。

E4：相同结果下的局部节省

两组 PPTX 解压后 40 个非目录条目的内容全部相同，6 页 slide / notes XML 相同，6 页真实渲染 PNG SHA 全部相同。PPTX 容器时间戳不同，整体二进制 SHA 不同；PDF 整体也不同，未将其贸然解释为仅元数据变化。

请求 8 → 7（少 12.5%）、token 39,758 → 35,891（少 9.73%）、估费 $0.003546972 → $0.003080904（低 13.14%）。输入已为 academic 纯文字，无图片/表/图；证据只支持此单题，仍需直接代码 0 模型对照。

4.2 / 历史轮与全部已记录开销

两轮不合并为同条件效果；全成本清单保留失败、学习和辅助交付。

第一轮	请求	全部 token	估费 / USD	完整程序交付	verified
普通 DSH	89	2,768,158	0.132809	5/5	0
组合脚本	97	3,401,530	0.175874	3/5	0
DSH + Motif	65	1,975,644	0.123842	4/5	5

R1 Motif 比普通请求少 26.97%、token 少 28.63%，估费仅低 6.75%，完整交付 4/5 对 5/5。组合组请求、token 和估费均增加。部分组合运行已有确认 PPT，但会话未完成；不把成品存在记为完整运行成功。

592 次上游请求来自哪些阶段

阶段	记录数	真实请求	估费 / USD	口径
训练轨迹收集	2	20	0.021521	不进入对照
独立认证	1	20	0.024800	不进入对照
开发试跑 / 失败	3	29	0.058490	不进入对照
RSI 提案	1	7	0.003637	不进入对照
两轮对照	30	516	0.875056	对照
辅助修订	1	0	0.000000	工具辅助；成本未全计
最终辅助风格交付	2	0	0.000000	工具辅助；成本未全计
总计	40	592	0.983503248	非实付账单

辅助修订和最终两套 15 页风格稿新增 DeepSeek 请求为 0，但有人/Codex参与；不称零总成本，不改变原运行的质量结论。学习与认证花费 $0.046320936；开发三条失败/诊断共 29 请求、$0.058489680，均已保留。

本表是当前 40 条记录的总账范围，不能代替项目所有历史账单。实际账单、人工修订分钟、外部审查、开发与维护耗时未知，因此当前无法计算合格成果的完整均费。

5 / 调用次数与全部运行记录 · R2

按实际运行顺序列出全部 15 条；失败与有成品但会话未结束均保留。

任务 / 组	请求	全部 token	估费 / USD	状态 / 成品	辅助审查	run ID 前 8 位
E4 / 组合	8	42,829	0.003575	完成 / 有	未见重大问题	b000eaa6
E4 / Motif	7	35,891	0.003081	完成 / 有	未见重大问题	f4da4e96
E4 / 普通	8	39,758	0.003547	完成 / 有	未见重大问题	12a3c1a5
E3 / 组合	31	1,045,059	0.048721	完成 / 有	需要修订	9b38b7e1
E3 / Motif	19	456,027	0.019260	完成 / 有	需要修订	f6b52bcf
E3 / 普通	16	349,214	0.016784	完成 / 有	需要修订	9688e193
E5 / 组合	10	171,108	0.015215	完成 / 有	需要修订	5a65bfb3
E5 / Motif	11	225,149	0.016267	完成 / 有	需要修订	62c046b0
E5 / 普通	13	272,496	0.017873	完成 / 有	需要修订	284d9caa
E1 / 组合	18	698,618	0.039521	完成 / 有	需要修订	c62786d3
E1 / Motif	16	719,797	0.046462	完成 / 有	需要修订	de52e46d
E1 / 普通	27	1,268,858	0.056057	完成 / 有	需要修订	bef76b66
E2 / 组合	23	820,254	0.044733	完成 / 有	未见重大问题	d35ae942
E2 / Motif	18	510,165	0.024436	完成 / 有	需要修订	eba9b7fc
E2 / 普通	40	2,142,931	0.087001	未完成 / 无	无确认成品	c754d1ff

“完成”只指会话完成并程序确认交付。“未见重大问题”是 AI 辅助审查结论，仍有人工盲评缺口；不写成专家质量认证。完整 run ID、命中/未命中/输出、耗时和失败标记见随包 all-40-running-records.csv / .json。

E2 普通组累计 40 请求、2,142,931 token、$0.087001080；没有确认成品，是本轮主要失败。Motif 每条运行 1 次 verified。工具实际尝试与成功次数没有在此表按统一口径另行聚合，不用模型步数或旁路数替代工具次数。

5 / 调用次数与全部运行记录 · R1

按实际运行顺序列出全部 15 条；失败与有成品但会话未结束均保留。

任务 / 组	请求	全部 token	估费 / USD	状态 / 成品	辅助审查	run ID 前 8 位
E4 / 组合	7	36,516	0.003571	完成 / 有	未见重大问题	a1ca6e4a
E4 / Motif	7	35,592	0.003267	完成 / 有	未见重大问题	a2083a1a
E4 / 普通	8	39,122	0.003423	完成 / 有	未见重大问题	19af4985
E3 / 组合	12	237,582	0.018798	完成 / 有	需要修订	e0383815
E3 / Motif	15	418,957	0.023408	完成 / 有	需要修订	35bbbf06
E3 / 普通	24	761,511	0.028549	完成 / 有	需要修订	d9a21fbf
E5 / 组合	24	671,810	0.039874	完成 / 有	需要修订	57a1425c
E5 / Motif	14	296,506	0.019135	完成 / 有	需要修订	f627bba7
E5 / 普通	20	463,010	0.028839	完成 / 有	需要修订	6f811205
E1 / 组合	22	1,013,713	0.061606	未完成 / 有	需要修订	38d03655
E1 / Motif	18	950,650	0.061985	未完成 / 无	无确认成品	9567705d
E1 / 普通	25	1,244,280	0.057437	完成 / 有	需要修订	2609c1e5
E2 / 组合	32	1,441,909	0.052026	未完成 / 有	未见重大问题	fc3c958e
E2 / Motif	11	273,939	0.016047	完成 / 有	需要修订	8f5fe3de
E2 / 普通	12	260,235	0.014561	完成 / 有	需要修订	11e33667

“完成”只指会话完成并程序确认交付。“未见重大问题”是 AI 辅助审查结论，仍有人工盲评缺口；不写成专家质量认证。完整 run ID、命中/未命中/输出、耗时和失败标记见随包 all-40-running-records.csv / .json。

R1 的本地 HTTP429 表象与账本均为上游 200 的记录相容；间接证据支持本地预算代理拒绝（likely_local_budget_gate），不称 DeepSeek 上游限流。第二轮上限提高是配置变化，不删除首轮失败。

5.1 / 非评测记录与追溯链

全部 40 条包括 30 条对照和以下 10 条其他记录；不是 40 个独立任务。

记录 / 阶段	请求	全部 token	估费 / USD	状态 / 边界
训练 SimCLR	10	135,770	0.009908	done
训练 ViT	10	132,097	0.011613	done
独立认证 CLIP	20	636,040	0.024800	done
development-missing-api-environment	0	0	0.000000	未完成 / 失败
development-demo-invalid-plan	12	375,401	0.024683	done
development-demo-rate-limit	17	637,674	0.033807	未完成 / 失败
真实 RSI 准入提案	7	20,680	0.003637	done
assistant-aided-demo-revision	0	0	0.000000	工具辅助交付
final-assisted-revision-02-academic	0	0	0.000000	工具辅助交付
final-assisted-revision-02-lab	0	0	0.000000	工具辅助交付

逐次请求、工具与成果如何定位

运行账本逐请求保留 request_id、模型、HTTP状态、provider usage、估费、时间和预留；Harness 事件保留模型输入输出及工具实参/返回。任务 job、来源 SHA、工具顺序、有效配置、library / guard digest、确认交付 PPTX / PDF / PNG SHA 形成追溯链。原始资料和日志留在受保护 .local/ 与 test-logs/，不提交到 Git。

随报告提供的是派生运行表与逐页拼图索引，不包含密钥、论文原件或原始会话。30 条对照的失败和费用在统计中保留；辅助修订不进入三组收益分母。两条最终辅助记录原摘要未写 total_tokens，本表仅由明确的 0 个组件推导 0，未修改原摘要。

报告输入摘要字节 SHA256：
eb8f0cb833cddee9c2d48cfac0eb3dd8032d1bd77e72f5f3466ea8c8deee44ac

E4 输出等价审查 SHA256：
52cc75c703737fcd0bc6a1cacd0e847c45da245fa6370dc660a02488eb9c6436

6 / 报告质量与评审边界

先判断任务交付是否可用，再解释调用和费用；程序成功不证明科学结论或视觉效果。

共同门槛	当前核验范围与缺口
文件与可编辑性	实际 PPTX 包、页数、原生文本/表格/图表；论文原图仍是图片。
来源与数值	notes / 页码 / SHA 追溯，辅助逐页对照论文数值和实验设置；页码存在不保证引用正确。
内容与科研判断	检查问题、方法、实验、局限、跨论文比较和条件；未做外部专家盲评。
视觉与展示	LibreOffice 真正渲染 PDF / PNG 并逐页辅助目检；现场投影、用户审美和修改时间未知。

第二轮 / 原稿	普通 DSH	组合脚本	Motif
E1	需要修订	需要修订	需要修订
E2	无确认成品	未见重大问题	需要修订
E3	需要修订	需要修订	需要修订
E4	未见重大问题	未见重大问题	未见重大问题
E5	需要修订	需要修订	需要修订

R1：14 份确认成品共 120 页；R2：14 份确认成品共 127 页。每轮都是 10 个需修订、4 个未观察到重大问题、1 个无成品运行。AI 辅助审查与程序检查共同完成，不能当作独立人工盲评或据此计算合格成果均费。

保留的内容与视觉负面证据

E1 有跨论文成本排序、LoRA 局限覆盖与 BERT 指标条件/页码问题；E3 有方法局限缺失；E5 有来源定位和更新叙事问题。R1 曾出现黑图片、近空页和条件遗漏，修复后另记 R2，不回写旧结果。逐项 findings 仍在冻结审查记录。

当前视觉是基础样式。harness-anything 主要参考 JSON/预设/验收思路；PptxGenJS 实际用于渲染，pptx-automizer 未集成，未完整吸收成熟设计 Skill。本报告排版精细化不代表原实验 PPT 已达到精美度要求。

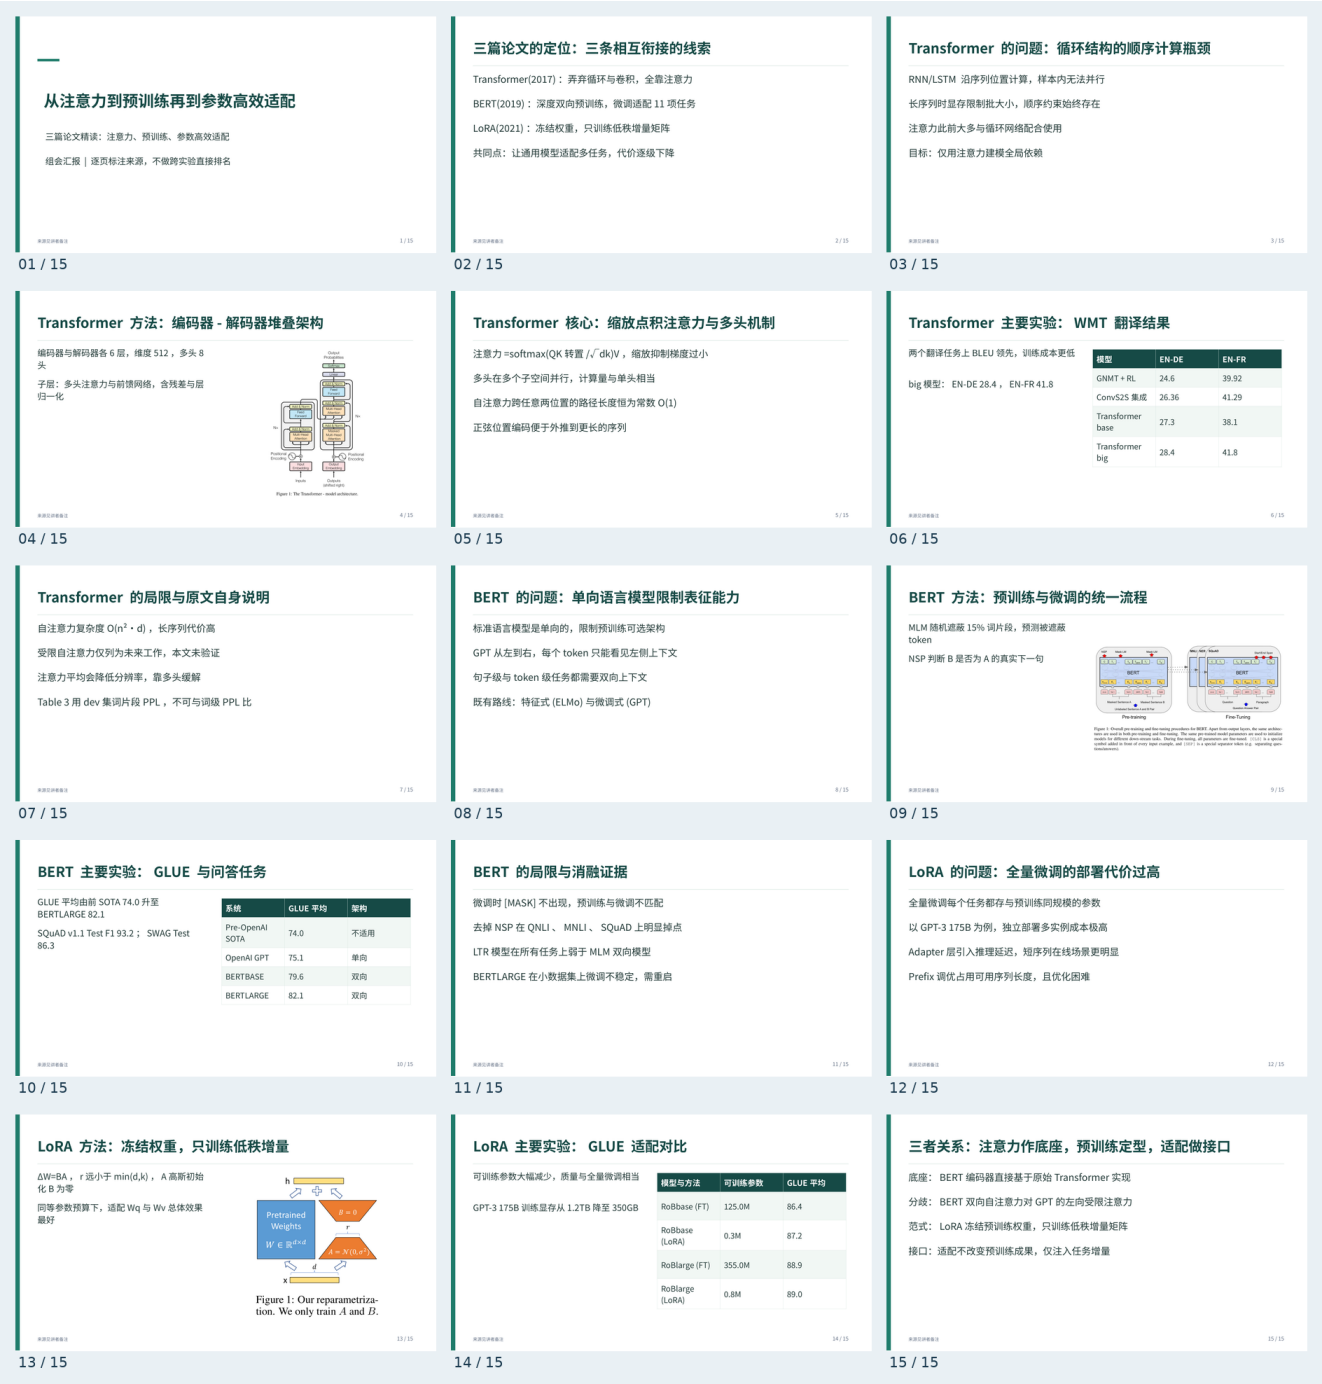
7 / E1 · 普通 DSH · 全部页面

第二轮固定全量展示 / run bef76b6630fb445f832e98bc3d521349 / 原实验成品，无后期润色

三篇论文 / 15 页组会；来源：Transformer、BERT、LoRA。

真实请求 27；全部 token 1,268,858；估费 $0.056057；辅助审查：需要修订。

原稿保留问题：正文称三者共同点是让通用模型适配多任务、代价逐级下降。三篇研究不同阶段、模型、任务与实验条件，没有共同成本实验支撑Transformer→BERT→LoRA代价逐级下降。notes标为汇报者归纳不能补足证据，且该表述会造成禁止跨实验排名所要避免的误导。；LoRA有问题、方法和实验，但没有明确LoRA方法局限；页14 notes仅说明FT历史基线条件不同，…



本图包含全部 15 页，按页号排列。高分辨率整图见随包 contact-sheets/E1-steps_baseline-all-pages.png；单页细节请打开原始 PPTX / PDF。

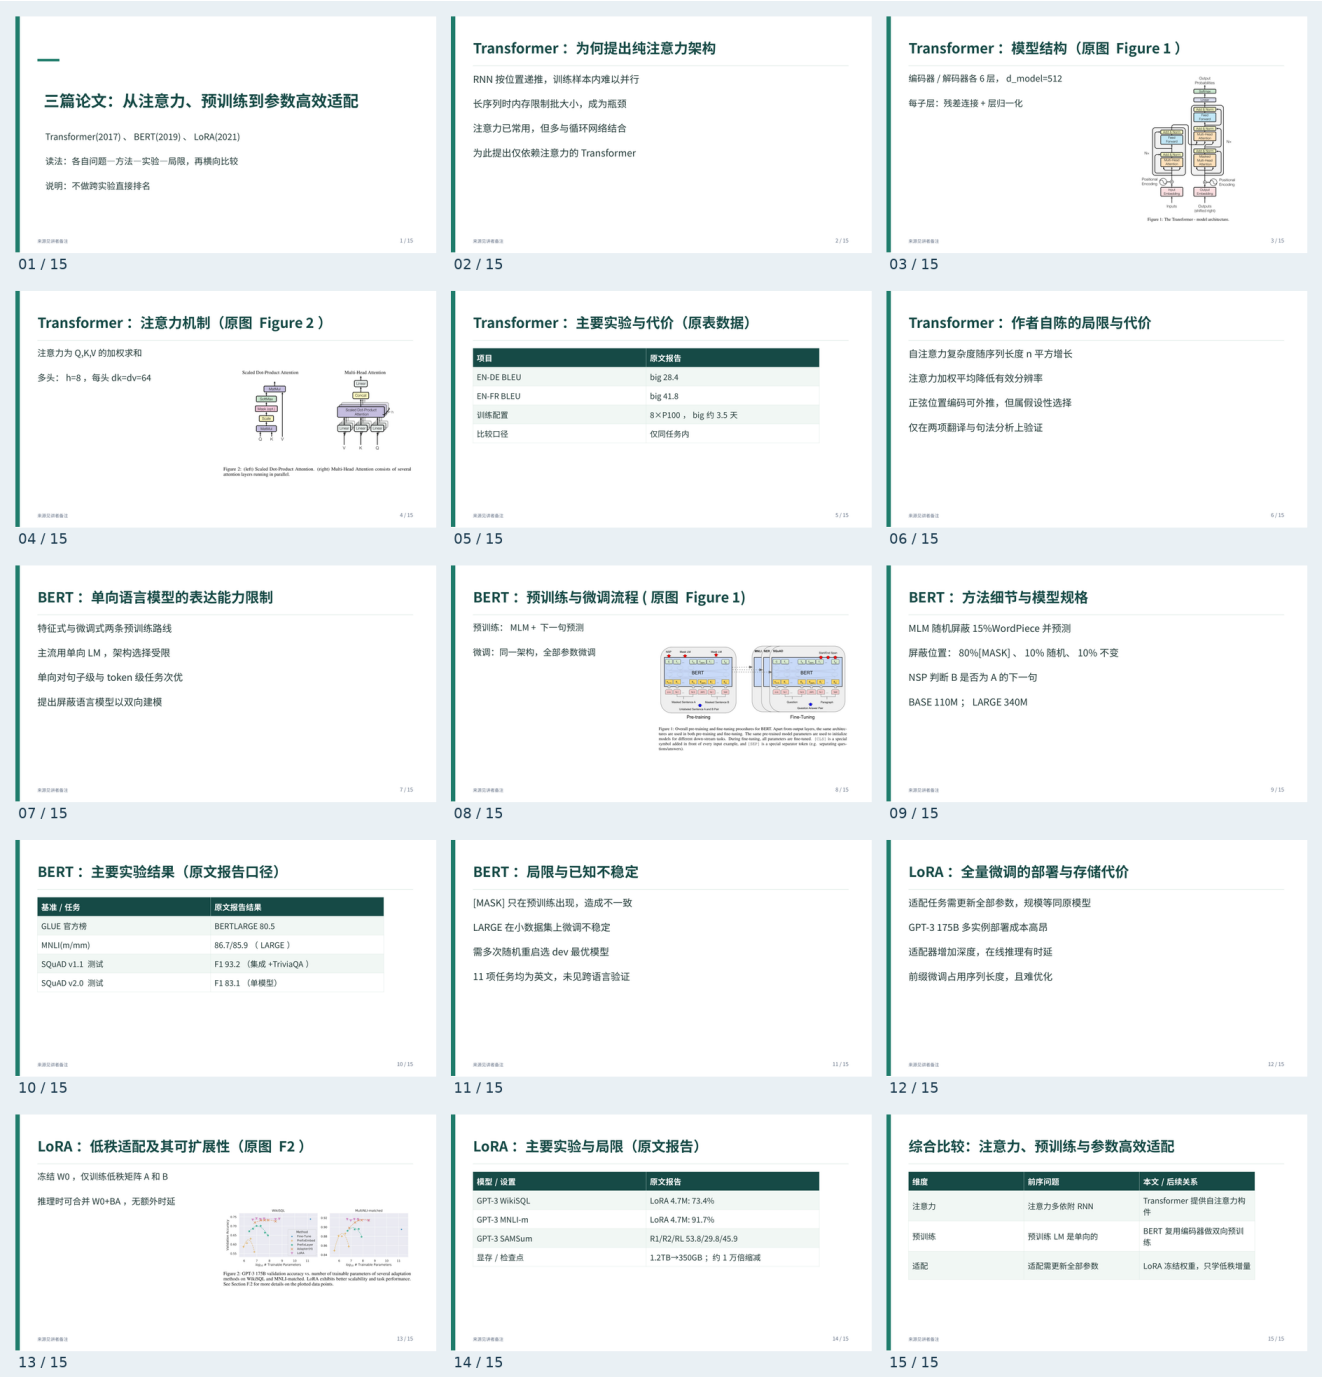
7 / E1 · 组合脚本 · 全部页面

第二轮固定全量展示 / run c62786d385d444ac8241f24d11985601 / 原实验成品，无后期润色

三篇论文 / 15 页组会；来源：Transformer、BERT、LoRA。

真实请求 18；全部 token 698,618；估费 $0.039521；辅助审查：需要修订。

原稿保留问题：LoRA Figure2真实且完整，但该页冻结W0/仅训A和B/合并无额外时延的方法文字只引用第8页曲线图；notes虽说来自第4节，实际来源列表没有方法页。图件支持可扩展性，不直接支撑这些方法细节。；SQuAD数字及集成+TriviaQA/单模型口径正确，但来源列表仅有BERT第1、6页；83.1单模型与93.2完整对照表在第7页Table2/3，no…



本图包含全部 15 页，按页号排列。高分辨率整图见随包 contact-sheets/E1-composed-all-pages.png；单页细节请打开原始 PPTX / PDF。

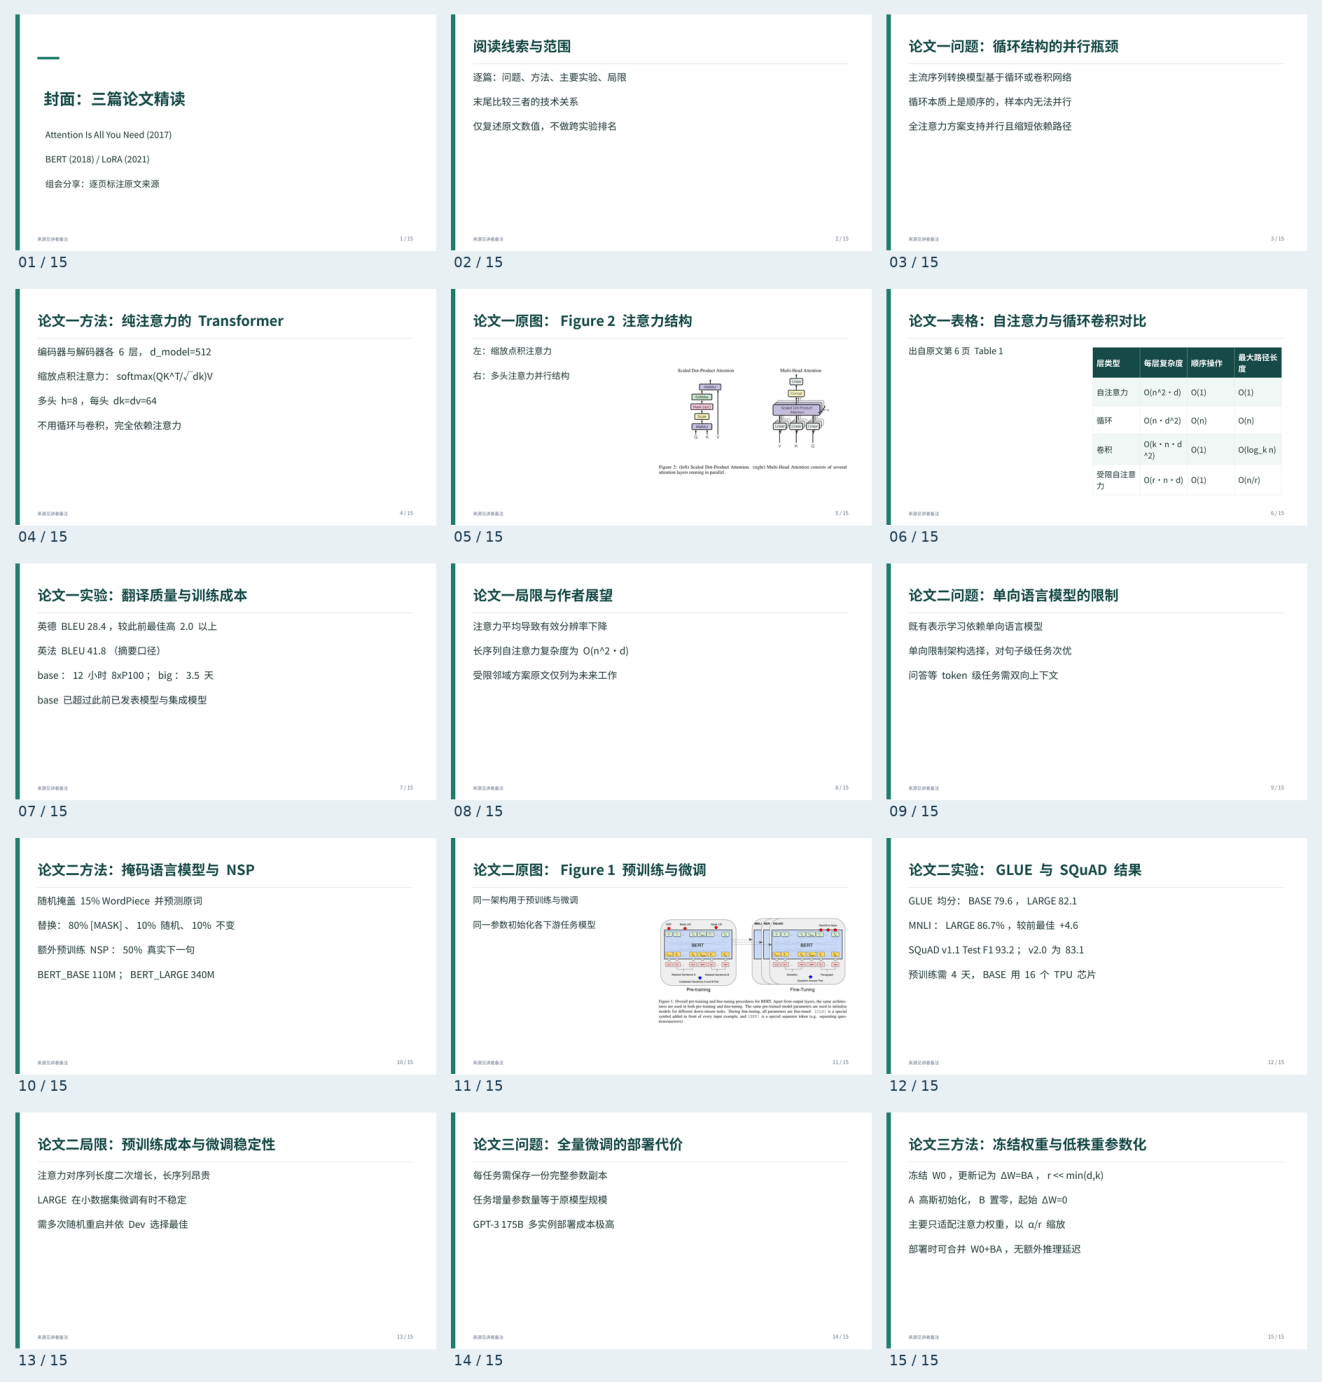
7 / E1 · DSH + Motif · 全部页面

第二轮固定全量展示 / run de52e46d43e54c848e186746a76a7e0c / 原实验成品，无后期润色

三篇论文 / 15 页组会；来源：Transformer、BERT、LoRA。

真实请求 16；全部 token 719,797；估费 $0.046462；辅助审查：需要修订。

原稿保留问题：页1–8为Transformer、9–13为BERT；LoRA仅页14问题与页15方法便结束。完全缺LoRA主要实验、LoRA局限与最后注意力/预训练/参数高效适配关系比较，后者也与页2承诺相矛盾。生成15页及程序passed不等于完成该任务。；SQuADv1.1 93.2和v2.0 83.1数字正确，但没有标出前者Ensemble+TriviaQA、后…



本图包含全部 15 页，按页号排列。高分辨率整图见随包 contact-sheets/E1-motif-all-pages.png；单页细节请打开原始 PPTX / PDF。

7 / E2 · 普通 DSH · 全部页面

第二轮固定全量展示 / run c754d1ff6ded4713a81e91d70ac8288a / 原实验成品，无后期润色

两篇论文 / 8 页方法比较；来源：ResNet、DDPM。

真实请求 40；全部 token 2,142,931；估费 $0.087001；辅助审查：无确认成品。

没有确认 PPT 成品可展示

普通 DSH 到达 40 步仍未确认交付，失败费用与全部请求保留。未拿后来修订稿、其他组 PPT 或未验证输出补做 baseline 成品。

同题组合组与 Motif 组原稿在后两页完整展示。该任务不能进入双方有成品的四题配对，也不能用来证明同质量下降。

7 / E2 · 组合脚本 · 全部页面

第二轮固定全量展示 / run d35ae9424b1c4d3b99739eaed0199ead / 原实验成品，无后期润色

两篇论文 / 8 页方法比较；来源：ResNet、 DDPM。

真实请求 23；全部 token 820,254；估费 $0.044733；辅助审查：未见重大问题。

未观察到重大问题仍不等于专家认证；细节和现场可读性待用户审阅。



本图包含全部 8 页，按页号排列。高分辨率整图见随包 contact-sheets/E2-composed-all-pages.png；单页细节请打开原始 PPTX / PDF。

7 / E2 · DSH + Motif · 全部页面

第二轮固定全量展示 / run eba9b7fc335546859db11aa7d85799b4 / 原实验成品，无后期润色

两篇论文 / 8 页方法比较；来源：ResNet、 DDPM。

真实请求 18；全部 token 510,165；估费 $0.024436；辅助审查：需要修订。

未观察到重大问题仍不等于专家认证；细节和现场可读性待用户审阅。



本图包含全部 8 页，按页号排列。高分辨率整图见随包 contact-sheets/E2-motif-all-pages.png；单页细节请打开原始 PPTX / PDF。

7 / E3 · 普通 DSH · 全部页面

第二轮固定全量展示 / run 9688e19318f74644b71f2d8123d88c0d / 原实验成品，无后期润色

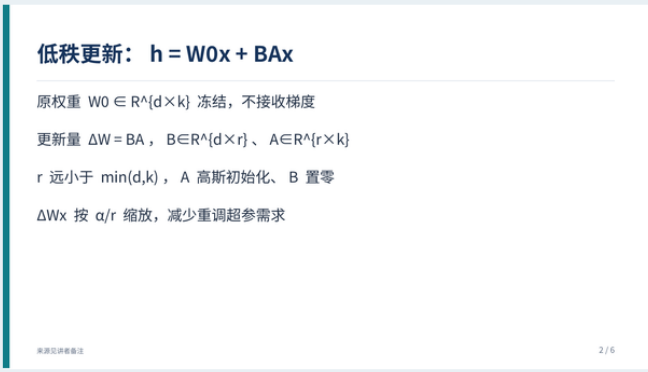
单篇论文 / 6 页短讲；来源：LoRA。

真实请求 16；全部 token 349,214；估费 $0.016784；辅助审查：需要修订。

原稿保留问题：notes称前两条均是第5页明确局限，但权重矩阵选择依赖经验启发式实际在第13页未来工作第3条，第5页只支持混批限制。现有来源列表没有第13页。内容本身正确，定位不准确。；正文跨语言等需更大rank把思想实验写成确定需求。第10页脚注6只说不同语言下全量重训可能优于小rank，不是本文实际跨语言比较。



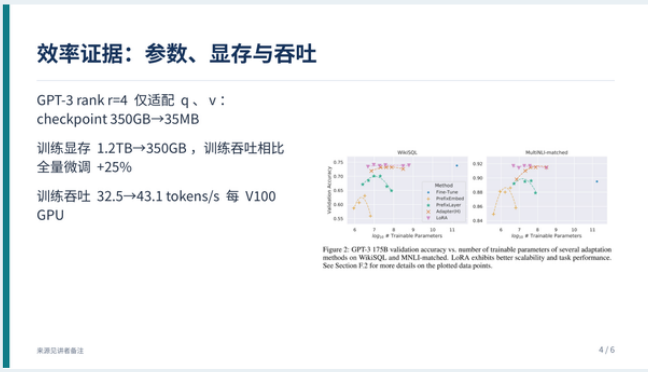
01 / 06



02 / 06



03 / 06



04 / 06



05 / 06



06 / 06

本图包含全部 6 页，按页号排列。高分辨率整图见随包 contact-sheets/E3-steps_baseline-all-pages.png；单页细节请打开原始 PPTX / PDF。

7 / E3 · 组合脚本 · 全部页面

第二轮固定全量展示 / run 9b38b7e194b147c897ef31a01ab3060b / 原实验成品，无后期润色

单篇论文 / 6 页短讲；来源：LoRA。

真实请求 31；全部 token 1,045,059；估费 $0.048721；辅助审查：需要修订。

原稿保留问题：效率数字都能在第5页找到，但350GB→35MB检查点缩减没有保留r=4且仅适配query/value这一配置条件。脚注仍需350GB预训练基座也未说明，易把35MB当作整个部署模型大小。；notes给出Table1短序列小批量adapter延迟+20.7%–30.3%，数字正确，但来源列表只有第8/5页，没有实际Table1所在第4页，也没有batch…



01 / 06



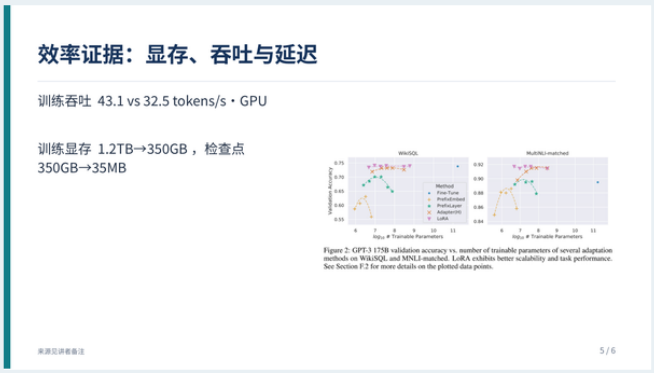
02 / 06



03 / 06



04 / 06



05 / 06



06 / 06

本图包含全部 6 页，按页号排列。高分辨率整图见随包 contact-sheets/E3-composed-all-pages.png；单页细节请打开原始 PPTX / PDF。

7 / E3 · DSH + Motif · 全部页面

第二轮固定全量展示 / run f6b52bcf66b440a98335d009583a65a4 / 原实验成品，无后期润色

单篇论文 / 6 页短讲；来源：LoRA。

真实请求 19；全部 token 456,027；估费 $0.019260；辅助审查：需要修订。

原稿保留问题：正文实验中只适配Wq/Wv过于绝对。第6页是most experiments；第10页Table5研究Wq/Wk/Wv/Wo等位置，第20页给rv=2配置。；正文GPT-3序列长384没有限定WikiSQL，notes正确补为WikiSQL384/MNLI768/SAMSum2048。重要实验条件正文与备注范围不一致，虽非数字捏造，应改正文。



01 / 06



02 / 06



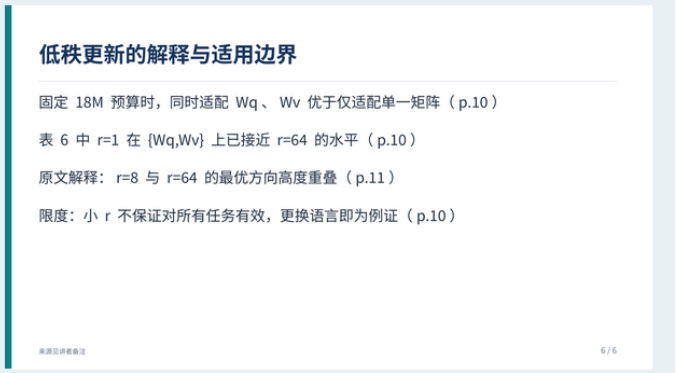
03 / 06



04 / 06



05 / 06



06 / 06

本图包含全部 6 页，按页号排列。高分辨率整图见随包 contact-sheets/E3-motif-all-pages.png；单页细节请打开原始 PPTX / PDF。

7 / E4 · 普通 DSH · 全部页面

第二轮固定全量展示 / run 12a3c1a5292246f994f3a81c2daa9fc6 / 原实验成品，无后期润色

已有 PPT / 6 页学术风格；来源：冻结的旧 6 页 PPTX。

真实请求 8；全部 token 39,758；估费 $0.003547；辅助审查：未见重大问题。

未观察到重大问题仍不等于专家认证；细节和现场可读性待用户审阅。



01 / 06



02 / 06



03 / 06



04 / 06



05 / 06



06 / 06

本图包含全部 6 页，按页号排列。高分辨率整图见随包 contact-sheets/E4-steps_baseline-all-pages.png；单页细节请打开原始 PPTX / PDF。

7 / E4 · 组合脚本 · 全部页面

第二轮固定全量展示 / run b000eaa60aba41e4b6aea2b9347603c3 / 原实验成品，无后期润色

已有 PPT / 6 页学术风格；来源：冻结的旧 6 页 PPTX。

真实请求 8；全部 token 42,829；估费 $0.003575；辅助审查：未见重大问题。

未观察到重大问题仍不等于专家认证；细节和现场可读性待用户审阅。



01 / 06



02 / 06



03 / 06



04 / 06



05 / 06



06 / 06

本图包含全部 6 页，按页号排列。高分辨率整图见随包 contact-sheets/E4-composed-all-pages.png；单页细节请打开原始 PPTX / PDF。

7 / E4 · DSH + Motif · 全部页面

第二轮固定全量展示 / run f4da4e96db314f218e1e5d633a2e88b2 / 原实验成品，无后期润色

已有 PPT / 6 页学术风格；来源：冻结的旧 6 页 PPTX。

真实请求 7；全部 token 35,891；估费 $0.003081；辅助审查：未见重大问题。

未观察到重大问题仍不等于专家认证；细节和现场可读性待用户审阅。



01 / 06



02 / 06



03 / 06



04 / 06



05 / 06



06 / 06

本图包含全部 6 页，按页号排列。高分辨率整图见随包 contact-sheets/E4-motif-all-pages.png；单页细节请打开原始 PPTX / PDF。

7 / E5 · 普通 DSH · 全部页面

第二轮固定全量展示 / run 284d9caa63f04c3ebddb7bf376315ec5 / 原实验成品，无后期润色

旧 PPT + 论文 / 10 页更新；来源：同一旧 PPTX、BERT。

真实请求 13；全部 token 272,496；估费 $0.017873；辅助审查：需要修订。

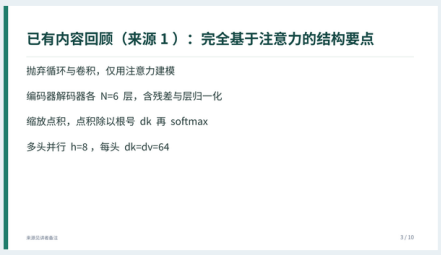
原稿保留问题：正弦位置编码可外推到更长序列与已有PPT第5页表述一致，但把原论文may allow写成确定效果。该错误继承于输入PPT，本次更新未校准来源强度，不能简单归为新造的幻觉。；GLUE80.5与+7.7来自摘要，数字正确，但平均80.5容易与论文Table1的排WNLI平均82.1混淆。这里引用的是官方GLUE榜单得分。



01 / 10



02 / 10



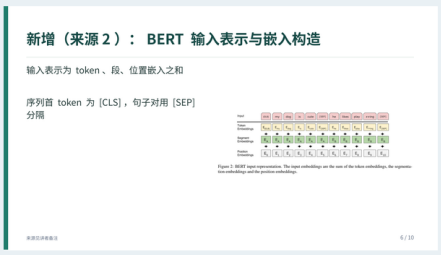
03 / 10



04 / 10



05 / 10



06 / 10



07 / 10



08 / 10



09 / 10



10 / 10

本图包含全部 10 页，按页号排列。高分辨率整图见随包 contact-sheets/E5-steps_baseline-all-pages.png；单页细节请打开原始 PPTX / PDF。

7 / E5 · 组合脚本 · 全部页面

第二轮固定全量展示 / run 5a65bfb38a9f423981a19bd94563f57f / 原实验成品，无后期润色

旧 PPT + 论文 / 10 页更新；来源：同一旧 PPTX、BERT。

真实请求 10；全部 token 171,108；估费 $0.015215；辅助审查：需要修订。

原稿保留问题：总结称BERT沿用Transformer编码器并改为双向。原Transformer编码器本就每个位置可关注全部输入位置；因果mask用于解码器。BERT的双向预训练差异应相对GPT左到右受限注意力说明，不能说把原编码器从单向改为双向。这影响本任务核心要求——解释BERT与Transformer的关系。；SQuADDevF1 88.5→77.8数据正确，但…



01 / 10



02 / 10



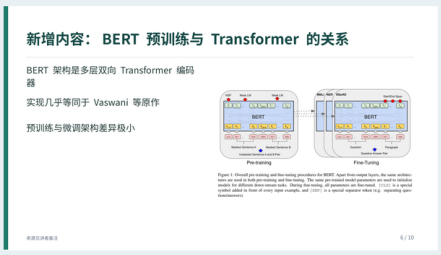
03 / 10



04 / 10



05 / 10



06 / 10



07 / 10



08 / 10



09 / 10



10 / 10

本图包含全部 10 页，按页号排列。高分辨率整图见随包 contact-sheets/E5-composed-all-pages.png；单页细节请打开原始 PPTX / PDF。

7 / E5 · DSH + Motif · 全部页面

第二轮固定全量展示 / run 62c046b034e94aada5f84a7f814a4ae7 / 原实验成品，无后期润色

旧 PPT + 论文 / 10 页更新；来源：同一旧 PPTX、BERT。

真实请求 11；全部 token 225,149；估费 $0.016267；辅助审查：需要修订。

原稿保留问题：自然语言推理、问答等token级任务把NLI并列成token级任务；NLI是句子/句对级分类，问答是token/片段级。；比较标题单向LTR与双向MLM，但左侧实际LTR & No NSP、右侧完整BERTBASE包含NSP。77.8/77.5与88.5/86.7/84.4都正确，notes也指出左侧身份；页面仍可能把全部性能差异归于双向性。



01 / 10



02 / 10



03 / 10



04 / 10



05 / 10



06 / 10



07 / 10



08 / 10



09 / 10



10 / 10

本图包含全部 10 页，按页号排列。高分辨率整图见随包 contact-sheets/E5-motif-all-pages.png；单页细节请打开原始 PPTX / PDF。

8 / 学习成本、复现与适用范围

当前支持可执行原型及局部节省；尚未证明独立用户同质量成果总成本下降。

两次训练轨迹 + 一次独立认证共 40 请求、代理估费 $0.046320936；RSI 另花 $0.003636780，最终无新规则收益。准备费用必须计入采用成本，不能藏入免费阶段。

情景摊销 / 非效果证明	学习摊销 / USD	Motif 执行均费 + 学习 / USD
4 次相似任务尝试	0.011580	0.032848
100 次相似任务尝试	0.000463	0.021731
1000 次相似任务尝试	0.000046	0.021314

若四个成品配对的平均执行估费差 $0.002298 在未来保持不变，约需 21 次同类尝试抵消学习/认证费用；这包含需修订稿，不是合格交付回本证据。学习 + 四次 Motif 执行约 $0.131390244，高于四次普通约 $0.094260864，且未含开发、RSI与人工费用。

冻结环境与最短入口

实际实验：Linux / Python 3.12.15 / Node 22.23.2 / Python DSH SDK 0.1.5rc1 / LibreOffice 7.3.7.2。公共配置与工具契约位于 scenarios/research_ppt/；原模型为 deepseek-flash，reasoning_effort=off，记录 reasoningTokens=0，入口压缩关闭，structural-only 匹配，无语义 embedding。

服务器：cd /root/autodl-tmp/xjj
source .local/activate.sh
python -m scenarios.research_ppt.cli prepare --input PAPER.pdf --instruction 用户要求 --slides 6 --template academic --operation generate --allow-output
python -m scenarios.research_ppt.cli run --job JOB.json --mode baseline --execution steps --budget-usd 1 --max-steps 40

默认 run 只预览。预算明确获授权后增加 --call-model；组合用 --execution composed，Motif 用 --mode execute --manifest 已认证清单。每次用新的日志与产物目录；密钥仅留私有环境，原始材料不随报告分发。

复现与范围限制

服务器代码基线 883ee5c，实验含未提交改动；R1/R2 有各自 config 快照与代码哈希，不能只按 HEAD 复现。R2 上限每 run $1、40步、输出6000，矩阵守卫 $15，串行间隔30秒。实际模型面向 schema 哈希、provider 内部重试、人工评审及账单仍缺失。

当前输入支持 1–8 份 PDF/PPTX、1–30 页与 academic/lab。复杂扫描件/OCR、任意母版、动画/SmartArt 和多人前瞻使用尚未验证。下一步先人工盲评与修订计时，再加直接代码/缓存对照、重复任务和更复杂素材；本次整理报告新增 DeepSeek 请求为 0。