科研 PPT 设计，有界的结构复用

V5 综合实验报告 / 同伴结构版 / 2026-10-10

cohort：research-ppt-v5-design-rsi-20261010-2b9512aa

总的结果

本轮将可分发的科研设计 Skill 接入同一个 Agent，增加短结论区和原生可编辑方法流程，再让真实 DeepSeek 从训练渲染反馈提出受限布局策略。三组分别是相同 Skill 下的普通 DSH、认证 Motif、Motif 加冻结 RSI 策略；没有用模拟 Provider 替代本轮的真实实验。

设计 Skill 是本场景独立编写的固定科研规范，吸收 harness-anything 的 MIT 工作方式：内容与渲染分离、统一层级、等比图像、真实预览和分项校对；没有调用其 WPS COM，没有把开发端专用 Skill 当作服务器已集成。实际加载 SHA 与固定上游 ref 见随包设计规则及 provenance。

记录指标	设计 Skill + 普通 DSH	相同 Skill + Motif	相同 Skill + Motif + RSI
确认成品 / 排程	5/5	5/5	5/5
真实上游请求	96	103	81
全部 token	3,281,023	4,461,354	2,958,970
API 代理估费	$0.182436	$0.227095	$0.165130
verified 整次请求旁路	0	5	5
记录运行时间	7.33 分钟	9.02 分钟	7.22 分钟

仅双方确认有成品的 5 个任务：相同 Skill + Motif 相对普通组，记录请求增加7.29%，token 增加35.97%，代理估费增加24.48%。这只是成品子集统计，尚未建立相同质量，也不是因果归因。

仅双方确认有成品的 5 个任务：相同 Skill + Motif + RSI 相对普通组，记录请求减少15.62%，token 减少9.82%，代理估费减少9.49%。这只是成品子集统计，尚未建立相同质量，也不是因果归因。

RSI 提案次数 1；独立机械认证：通过。本轮布局学习记录 3 次真实请求，代理估费 $0.002021。机械/几何目标不能证明审美质量；新 Skill 和策略也不称学得 Motif。

人工盲评、修订分钟、开发与维护人力、实际账单均须另核。所有未交付、失败、跳过和缺失计量在后文逐项展示；旧实验与历史失败没有被本轮覆盖。

1 / 数据集与真实任务

本 cohort 包含 5 个自定义科研 PPT 任务、5 个来源版本，每题输入份数为 1 / 2 / 4；不是仓库 18 项合成科研决定中的任务子集。论文文件先下载本机再传服务器，任务、来源、工具和配置均保留版本哈希。重复来源按 SHA 去重计数，不能把题目数当作完全独立来源集合。

任务 / 来源	交付	真实任务要求
V1 / RAG 方法组会 rag.pdf	8 页 / lab / generate	为了解生成模型但尚未实现检索增强的同学制作8页中文组会汇报，约10分钟。围绕为什么加入检索、检索与生成如何连接、论文证据和局限组织；至少一页可编辑的方法流程，至少一张经图注定位的论文原图，讲清实验指标与对照条件。封面也计入8页，具体叙事和各页内容由你根据原文决定，不编造数字。
V2 / QLoRA 工程决策 qlora.pdf	7 页 / academic / generate	制作7页中文工程决策汇报，回答有限显存时QLoRA如何使大模型微调可行。解释量化、适配器与优化器的关系，使用可编辑流程和一张真实原图；如果引用显存或效果数值，保留模型规模、硬件、指标和比较条件。最后给出适用条件与原文未证明的边界，避免把训练结论直接说成推理加速。
V3 / RLHF 与 DPO 比较 instructgpt.pdf、dpo.pdf	10 页 / lab / generate	为正在选择偏好对齐训练路线的研究同学制作10页中文方法比较汇报。比较InstructGPT中的RLHF流程与DPO的直接偏好优化：训练阶段、数据要求、优化目标、成本来源和限制。用可编辑流程及统一维度的比较页面，至少引用一张相关原图。不同模型、数据和评测条件不能拼成统一效果排行榜；明确哪些比较只是机制分析。
V4 / T5 与 RAG 知识职责 t5.pdf、rag.pdf	9 页 / academic / generate	制作9页中文研究讨论PPT，围绕知识密集型任务中参数内知识与外部检索各承担什么职责。从T5统一text-to-text框架和RAG方法提取证据，解释训练与使用时的信息流及更新方式；至少一张真实原图、一页可编辑流程和一页适用条件比较。两篇论文并非同条件替代实验，不把跨论文数字视为公平优劣结论；用清楚短结论推进讨论。
V5 / 多论文研究方案评审 rag.pdf、qlora.pdf、instructgpt.pdf、dpo.pdf	12 页 / lab / generate	为课题组规划一个知识问答助手，制作12页中文研究方案评审PPT。根据这四篇论文讨论检索增强、低显存微调和偏好对齐分别解决的问题，说明模块如何组合、RLHF与DPO何时需要选择、哪些组合只是待验证的设计推论。包含可编辑总流程、至少两篇论文的相关原图、可复算或可验证的评测计划及风险。保留所有事实的来源和条件，不能暗示论文已经实测了这套完整组合系统。

训练、认证与前瞻 API 评测分别记录

布局训练和认证读取历史真实 DeepSeek 页面计划，再用当前渲染器实际执行，属于历史确定性重放；它不新增论文理解请求。训练至少两条正常计划，留出认证采用不同来源运行，认证结果不能继续反馈给同一候选调参。本 cohort 新 API 结果另记；不把旧计划重放和新云 API 对照合并成一次试验。

当前题面由研究者自定义。每题每组一次运行，只是实际 API 工程实验，不支持统计显著性或课题组长期使用收益。

2 / 让模型在结果出现之后做决定

模型仍负责理解原文、选材、叙事、实验条件与图件解释。工具返回真实 source_id、文本、图注候选和校验反馈后，模型再决定后续动作；图件不能仅按位置猜测，跨论文数值不能被包装成同条件排名。

阶段	实际执行 / 决定	责任
输入与来源选择	用户 PDF/PPTX 与要求 → 模型决定 pin_source	大模型
结构化来源衔接	pin_source 返回 source_id → 版本/证据守卫 → read_source	认证 Motif 图边
阅读与科研叙事	读回文本/图注后，决定页面内容、条件、原图与局限	大模型
可编辑生成	JSON 契约 → 字号、留白、短结论、原生流程/图表 → PPTX	确定性代码
实际质量反馈	LibreOffice → PDF/PNG、页数、文字、notes、来源、SHA	真实工具与代码
失败恢复	守卫不成立回交模型；候选布局失败保留并回退默认策略	有界回退
最终交付	再次核对文件及预览证据，确认后登记交付	MCP

RSI 的结果后学习

DeepSeek 读取训练草稿的真实渲染诊断，在七字段布局协议内提出完整 JSON：媒体方位/面积、正文列数/字号、表格字号和间距。每次失败也消耗持久化三次提案配额。候选只改变布局，保持文字、事实、页数、来源和 notes；训练成功不自动启用，另在冻结留出上核验。

提案	训练判定	真实反馈摘要
1	True	{"passed": true, "baseline": {"cases": 2, "failed": 0, "image_count": 5, "mean_image_area": 18.9529485733999}, " candidate": {"cases": 2, "failed": 0, "image_count": 5, "mean_image_area": 22.38322557034213}, " content_unchanged": true, "image_area_gain": 0.18098909431731158, "objective": " geometry_proxy_only_not_aesthetic_certification"}

任何模型调用前已选好的路线不能冒称科研决定已自动完成。当前 RSI 是受限布局策略学习，未生成新工具，未生成新的 Motif/code node。

独立门槛	冻结证据的机械结果
训练	{"passed": true, "baseline": {"cases": 2, "failed": 0, "image_count": 5, "mean_image_area": 18.9529485733999}, " candidate": {"cases": 2, "failed": 0, "image_count": 5, "mean_image_area": 22.38322557034213}, " content_unchanged": true, "image_area_gain": 0.18098909431731158, "objective": " geometry_proxy_only_not_aesthetic_certification"}
留出认证	{"passed": true, "baseline": {"cases": 2, "failed": 0, "image_count": 2, "mean_image_area": 27.16283333206607}, " candidate": {"cases": 2, "failed": 0, "image_count": 2, "mean_image_area": 33.0104111660588}, "content_unchanged": true, "image_area_gain": 0.21527864057869062, "objective": "geometry_proxy_only_not_aesthetic_certification"}

mean_image_area 的单位为渲染器画布平方英寸；image_area_gain 是媒体面积相对变化，不能解释为审美评分。失败率下降或训练平均原图面积至少增加 10% 是预先固定的机械目标；留出只检查不回归。

3 / 与普通 DSH 的流程对比

维度	普通 DSH	Motif	Motif + RSI
设计规范	相同独立科研设计 Skill	相同 Skill	相同 Skill
在线来源读取	模型在 pin 结果后决定 read	认证短边绑定本次句柄后实际读取	相同读取 Motif
科研理解 / 内容	DeepSeek	DeepSeek	DeepSeek
渲染布局	新版默认策略	相同默认策略	冻结机械认证候选；失败回退默认
工具集合/顺序	同一批准 MCP 集合	相同集合	相同集合
思考 / 压缩	off / 默认关闭	相同	相同

哪些是 graph、code 与模型

graph 是历史真实轨迹独立认证的 pin_source → read_source 依赖、参数来源及版本证据；它实际跳过一次来源读取调度请求，读取工具仍执行。n 份文档可以触发多次该短边，不能固定说每个多文档任务只旁路一次。code 是导入清洗、图件提取、契约校验、可编辑渲染与预览交付。模型是科研判断与从真实反馈提出布局策略。Skill 是提示规则，七字段策略是受限配置，均不当作 Motif 核心机制。

普通组也有相同设计 Skill 和新版渲染器，因此三组成本差不测量“旧模板 → 新版设计”的总体收益。历史旧/新草稿回放只能辅助观察布局；新 API 三组才验证实际云请求成本。运行间随机生成与失败重试都能改变调用总量，不能把全部差额归于认证旁路。

4 / 费用比较

组别	命中输入	未命中输入	输出	代理估费
设计 Skill + 普通 DSH	3,006,720	183,076	91,227	$0.182436
相同 Skill + Motif	4,131,200	215,419	114,735	$0.227095
相同 Skill + Motif + RSI	2,697,600	183,000	78,370	$0.165130

累计口径与失败成本

上表统计本矩阵所有已启动模型的运行，包含未交付、重试与恢复，不把失败费用删掉。跳过或尚未启动的组不伪填零；缺失账本保留“未知”。学习费用另列，没有摊入少量评测成果来宣称收费或投资回报。

费用项	真实请求	API 代理估费	人力 / 实付
新 API 三组矩阵	280	$0.574660	未知
本轮 RSI 学习	3	$0.002021	未知
历史草稿真实重放 / 本报告	0 新增模型请求	0 新增云请求费用	渲染算力与辅助人力未计价
人工盲评 / 人工修订	不适用	未采集	未知
模型账单核对	待核	上表不是账单	实际支付未知

双方确认成品子集：相同 Skill + Motif 对照 5 题，估费 $0.182436 → $0.227095；运行时间 7.33 分钟 → 9.02 分钟。尚未同质量合格，不能称为合格成果总成本下降。

双方确认成品子集：相同 Skill + Motif + RSI 对照 5 题，估费 $0.182436 → $0.165130；运行时间 7.33 分钟 → 7.22 分钟。尚未同质量合格，不能称为合格成果总成本下降。

稳定系统提示前缀与工具顺序有助于缓存，但本报告只记录实际缓存 token；Provider 面向请求的完整 schema 哈希和内部重试策略若入口未采集，仍列缺失。不能用总 token 等比例替代真实费用。

5 / 调用次数与全部运行记录

全部矩阵排程均展示；“会话完成”“程序交付”“质量合格”是不同条件。下表不隐藏错误、未运行或缺少布局认证的第三组。完整匿名化 CSV/JSON 与文件哈希随包提供，原始账本与模型轨迹继续留在服务器保护目录。

任务 / 组	状态 / 成品	请求 / 旁路	token	估费
V1 / 设计 Skill + 普通 DSH	会话完成 有确认成品	29 / 0	947,827	$0.047874
V1 / 相同 Skill + Motif	会话完成 有确认成品	20 / 1	524,642	$0.018519
V1 / 相同 Skill + Motif + RSI	会话完成 有确认成品	20 / 1	544,221	$0.024245
V2 / 设计 Skill + 普通 DSH	会话完成 有确认成品	17 / 0	405,047	$0.025194
V2 / 相同 Skill + Motif	会话完成 有确认成品	19 / 1	541,400	$0.024010
V2 / 相同 Skill + Motif + RSI	会话完成 有确认成品	10 / 1	182,937	$0.011919
V3 / 设计 Skill + 普通 DSH	会话完成 有确认成品	17 / 0	645,560	$0.034657
V3 / 相同 Skill + Motif	会话完成 有确认成品	24 / 1	1,137,016	$0.062402
V3 / 相同 Skill + Motif + RSI	会话完成 有确认成品	23 / 1	1,073,386	$0.054295
V4 / 设计 Skill + 普通 DSH	会话完成 有确认成品	19 / 0	692,206	$0.039474
V4 / 相同 Skill + Motif	会话完成 有确认成品	18 / 1	607,544	$0.028575
V4 / 相同 Skill + Motif + RSI	会话完成 有确认成品	15 / 1	520,669	$0.038564
V5 / 设计 Skill + 普通 DSH	会话完成 有确认成品	14 / 0	590,383	$0.035237
V5 / 相同 Skill + Motif	会话完成 有确认成品	22 / 1	1,650,752	$0.093589
V5 / 相同 Skill + Motif + RSI	会话完成 有确认成品	13 / 1	637,757	$0.036107

本矩阵记录候选布局回退 7 次。失败的候选目录和诊断保留在服务器；本包只交付已确认原稿，不用辅助修订稿替换模型初稿。矩阵停止原因：未记录停止原因。

6 / 报告质量与评审边界

机械门槛检查可编辑文字、页数、来源页码、notes、预览实际文件和版本完整性；布局机械认证检查内容保持、真实渲染失败率以及媒体几何面积。它们不能替代科学事实正确、实验条件充分、故事连贯和审美质量。

门槛	能验证	不能代替
来源 / 哈希 / notes	文件来源和引用追溯、版本一致	事实支持关系、结论是否过强
实际 PDF / PNG 渲染	文件可打开、页数和文字在画布范围	远距离投影可读、排版精美
布局 RSI 独立认证	七字段规则、内容保持、几何代理与真实执行	美学、科研质量或请求下降
AI 辅助逐页审查	可定位错图、遗漏和明显视觉问题	独立人工盲评和实测修订分钟
人工统一质量门槛	待独立使用者审阅	当前尚未建立同质量成本证据

任务 / 组	目前审查	明确问题
V1 / 设计 Skill + 普通 DSH	AI 辅助审查：需要修订	页 1：封面长标题把“知识库”的“库”孤立到第二行，视觉不均衡；可缩短标题，保持主题和来源。未观察到遮挡或越界。 页 3：流程把查询、检索、生成与“联合微调”串成单向五步，未区分训练与推理，初学者可能理解为每次生成后都更新参数。原文第3–4页区分生成/解码与训练，文档编码器固定；notes虽提到固定索引，正文流程应明确训练阶段及仅更新查询编码器和生成器。 页 4：notes称两种模型“训练设定相同、差异仅在边缘化粒度，得分差异可归因于该设计选择”过强。原文附录A第17页，QA测试RAG-Token检索15篇、RAG-Sequence检索50篇，并使用不同解码方式；不能将全部性能差异归因于单一设计。正文机制比较可保留，须修正notes的因果归因与条件。 页 5：Figure 1裁图含完整架构和图注，来源与主题相符，但在文字右侧小区域中，图内分支标签和长英文图注很小，不适合直接投影讲解细节；建议扩大图件或减少同页文字，再用实际投影大小核验。 页 6：takeaway写“验证集指标”，notes写“Table 1测试集Exact Match”，与原文第6页表题Open-Domain QA Test Scores冲突。表中数值属于测试结果，应统一正文、notes及EM百分比单位，不能混用验证集与测试集。 页 6：“生成式RAG超过抽取式DPR”缺少模型/数据集限定：本页CT列RAG-Token为50.0，低于DPR50.6；RAG-Sequence为52.2。应写清最佳RAG-Sequence或具体比较范围。DPR检索预训练、不同测试检索数等比较条件只在notes中，正文应至少给出影响解读的条件。 页 7：“三元组多样性”易被理解为知识图谱三元组，原文Table 5第8页指标为不同三词n-gram/总三词n-gram的比例；83.5%/70.7%属于MS-MARCO的RAG-Sequence/BART。人工42.7%/7.1%则是Jeopardy上452对生成中更符合事实的偏好比例，不是绝对事实准确率。notes有部分说明，但正文需标明任务、RAG变体及评价口径。 页 8：NQ 44.0→41.2及BM25 31.8来自第8页Table 6开发集，正文未标注开发集，前页刚展示Table 1测试集，容易被串作同一口径。notes已正确标明dev，应在正文补充“开发集EM，RAG-Sequence”，保留BM25在FEVER更好的边界。

任务 / 组	目前审查	明确问题
V1 / 相同 Skill + Motif	AI 辅助审查：需要修订	页 1：封面把“证据”的“据”孤立到第二行，英文文献名正文也偏长；标题可收短或主动按完整词组分行。未观察到文字越界。 页 4：“RAG-Sequence通常保留更多多样性”应限定为论文Table 5的MS-MARCO和Jeopardy实验观察，避免把两种形式的经验差异写成普遍性质；本页sources未列该指标实际所在第7–8页。 页 5：正文“由生成器A边际化输出答案”中的A不对应Figure 1符号，图中生成器为pθ/BART；应修正文字符号。原图包含完整方法架构和图注，未观察到用正文片段冒充原图。 页 5：Figure 1在右侧小区域的内部标签及图注字体偏小，正文留白较多；可提高图件占用面积或改为以图为主的页面，实际投影可读性尚需人工核验。 页 7：本页正文讲冻结检索器与索引热替换，却展示Figure 3检索文档数K对性能/召回的曲线；该图不是冻结检索器或跨年份索引的直接证据。notes清楚区分Figure 3、Table 6与热替换，但正文和视觉需对应：更换证据，或将可见解读改为K、召回及BLEU/Rouge权衡。三子图的坐标/图例也很小。 页 8：正文称“NQ/TQA/WQ/CT上取得当时最优”，notes却正确说摘要仅有三个QA任务；原文第2页明确SOTA为NQ、WQ、CT。第6页Table 1标准TQA列DPR57.9高于RAG-Sequence56.8、RAG-Token55.2，不能把TQA-Wiki与标准TQA合并后声称四题均最优。 页 8：正文“检索监督、段落级召回指标等作者未报告”过于笼统且有反证：第3页明确DPR初始化在NQ/TriviaQA上受过答案文档检索训练，第8页Figure 3报告NQ Answer Recall@K；本稿自己的notes还记录第7页FEVER金标文章top-1/top-10重叠71%/90%。应区分RAG微调不加直接文档监督、已有预训练监督、答案召回与精确证据段落召回，不能把已报告检索证据说成缺失。
V1 / 相同 Skill + Motif + RSI	AI 辅助审查：需要修订	页 2：takeaway“查依据无门”把原文“难以直接解释预测、provenance仍是开放问题”加强为绝对不可能，宜改成“依据难追溯”。notes的T5/RAG参数规模证据引用第18–19页，而sources仅列第1–2页，需补齐实际引用页。 页 6：takeaway“三个数据集的EM上RAG均高于闭卷与抽取式对照”不被本页TQA-Wiki列支持：DPR该列为“—”，没有抽取式对照数值；原文Table 1的DPR57.9属于另一套标准TQA测试集，不能挪列比较。应限定为三个数据集高于所列闭卷T5，NQ/WQ高于所列DPR。 页 6：表格与标题写EM但可见页面未注明测试集、百分比单位或不同检索K；notes已正确解释Token15篇/Sequence50篇及TQA-Wiki条件。应把影响比较的最小条件显式标在表旁，避免把结果看成严格同预算对照。 页 7：Figure 3与正文“更多文档并不必然更好”吻合，左图趋势、坐标类型与原文一致，未观察到伪造数值；相较Motif组图件更大，但三子图坐标和图例仍偏小，尤其右图同时四条曲线，应增加局部放大或提供可供投影核验的清晰解读。 页 8：正文“4.3%/2.7%差距含监督差异”未指明FEVER三分类/二分类，也未用“个百分点”。原文第6–7页分别对照使用中间检索监督的三分类流水线与获得金标证据的二分类模型，条件并不相同；应写清任务、点差和两类条件，不能把点差定量归因于监督差异。

任务 / 组	目前审查	明确问题
V2 / 设计 Skill + 普通 DSH	AI 辅助审查：需要修订	页 2：5048MB、26MB、567MB和18MB/序列的数值与原文第4页一致，但正文只注明7B示例，将7B LLaMA、FLAN v2、batch size 1及LoRA约0.2%等关键测量条件全部移入notes。工程显存决策应在页内保留同一实验的配置，不能把这些值当任意7B模型的通用需求。 页 6：标题写“列3见备注”，实际表只有报告项和数值两列，主动隐藏比较条件。99.3%和97.8%的相对ChatGPT分母及GPT-4评判协议只在notes；53.1也没有页内注明准确率百分比、Alpaca/FLAN v2训练来源及BF16 53.0比较值。原文第8–10页要求连同指标与基准读取，当前正文不能支持“追平16位”的比较。 页 7：全稿正文展示了65B全量微调>780GB的困难，却没有展示QLoRA实现65B在单张48GB GPU上微调的成功端点；33B/24GB与65B/48GB配置只在本页notes。这是原文第1–2、6页支撑有限显存可行性决策的关键条件，应出现在正文，且明确属于训练/微调需求。
V2 / 相同 Skill + Motif	AI 辅助审查：需要修订	页 7：正文把“NF4+双量化可复现16位LoRA/全量微调基准”和“FP4约低1个百分点”合并为概括，但低1个百分点具体是原文Table 4的LLaMA 7–65B、Alpaca/FLAN v2、5-shot MMLU结果，相关条件与53.1/53.0/52.2比较值仅在notes。全量微调直接对照是RoBERTa/T5较小模型的另一组实验，7–65B组对照16位LoRA。应在页内区分实验与比较对象，避免把同一数值推广到全部任务和全量微调。
V2 / 相同 Skill + Motif + RSI	AI 辅助审查：需要修订	页 6：模型规模、位宽、Vicuna相对ChatGPT百分比均与原文Table 6相符，但41/21/10/5GB属于部署/推理显存，表头只写“显存”，正文也未区分训练与部署，区分仅藏在notes。当前工程微调主题下容易误读为微调训练所需显存。应把表头改为部署/推理显存，并在页内注明GPT-4评分及置信区间较宽，不能把99.3%当无不确定性的质量等价结论。 页 4：“反量化回16-bit”步骤写“恢复计算精度”，容易被理解为恢复未量化权重的原始精度。原文第4–5页区分NF4存储与BF16计算类型，并没有消除量化误差；建议写成使用BF16执行矩阵计算、量化误差仍存在。0.5→0.127 bit应继续明确是每参数的量化常数开销。 页 7：约7.5%神经元非正态这一数字可在原文第25页附录找到，但本页sources仅引用第5、6、10页，notes也未给出第25页来源定位。数字本身未见错误，应补充准确来源页以便追溯，并可保留其为5%显著性检验结果的限定。
V3 / 设计 Skill + 普通 DSH	AI 辅助审查：需要修订	页 4：奖励重参数化先写r=βlog(π/πref)，随后说配分函数抵消，省略了推导中常数项出现的步骤。DPO原文第4页式5为r(x,y)=βlog(πr/πref)+βlogZ(x)，在同一提示的偏好差值中常数项才抵消；第5–6页也允许选用去掉提示相关常数的奖励等价类代表。此页可明确写完整式5再说明抵消，或标注所写公式是等价类代表，避免让听众以为式5本来没有Z(x)。 页 5：正文把DPO Figure 1写成“上方为既有方法、下方为DPO”，但本页实际图件为左侧RLHF、右侧DPO，与原文第2页Figure 1一致。方法描述基本正确，但方向指认有错，需改为左/右并核对图中标签。裁图包含完整两条流程与图注，未观察到用正文片段冒充原图。 页 5：DPO流程图在文字右侧的区域中内部步骤标签和英文图注偏小，虽然整页正文可读，但不适合投影细讲图中连接关系。建议减少同页文字或扩大图件，并以实际投影大小核验。图为方法示意，本任务不涉及该页数值曲线坐标校验。 页 8：正文“其成本主要来自人工标注与多模型训练”属于未经量化的成本构成判断。InstructGPT原文第17页确实报告175B SFT 4.9、PPO-ptx 60、GPT-3 3640 petaflops/s-days，但没有在这里给人工标注与各模型训练的可比账单占比；DPO也未给同口径算力或费用。建议改为“成本来源包含人工标注与多模型训练”，保留本页已正确说明的不可换算成统一预算边界。

任务 / 组	目前审查	明确问题
V3 / 相同 Skill + Motif	AI 辅助审查：需要修订	页 5：InstructGPT Figure 2来源和三阶段含义相符，完整保留流程与图注，但在右侧小区域中三列内部标签及英文图注很小；主要适合示意，不便投影逐项阅读。建议扩大图件或另设以原图为主的页面，再人工核验投影可读性。 页 5：takeaway把“关键成本”定位到步骤2、3之间反复采样与人工排序。原文第6页支持步骤2/3可迭代及实际比较数据来自SFT/部分PPO策略，DPO第2页支持环内采样与多模型训练带来计算成本，但未提供人工排序、采样和其他训练成本的占比。宜写成“可迭代的采样与排序是成本来源之一”，不要把机制解释写成实测成本主导结论。 页 6：步骤3写“隐式奖励即策略本身”过于直接。DPO原文第5页的隐式奖励为βlog(πθ(y|x)/πref(y|x))，由策略、固定参考策略和β共同定义，而相应最优策略才是πθ。上一行虽提到对数比，仍应把这一行改成“隐式奖励由策略相对参考策略的对数比定义”，避免混同奖励标量与策略分布。 页 7：正文和takeaway“DPO只要成对偏好”需限定为偏好优化阶段。第3页及本页notes已正确交代固定参考策略/SFT，故未据此判断整套PPT完全遗漏该基础；但本页独立对照易被读作无需SFT/参考模型。DPO原文第5页说明有SFT时用πSFT，缺失时对preferred completions做最大似然拟合参考策略。建议显式写“给定参考策略后，偏好优化只需离线成对偏好数据”。 页 8：DPO列“无需从策略采样”宜加“优化环内”限定。第6页已经正确写“微调中不必采样”，原文第5页outline的离线数据构造仍包含从参考策略采样，并允许复用公开数据。此处属于范围澄清，不表示DPO所有阶段或推理都无需采样。
V3 / 相同 Skill + Motif + RSI	AI 辅助审查：需要修订	页 5：InstructGPT Figure 2完整且与三阶段讲解相符，但流程内部标签与原英文图注仍偏小，图件受可用高度限制，较Motif版本未观察到明显的可读性提升。建议减少同页文字或采用以图为主的排版，实际投影可读性仍需人工核验；不能以图片像素更大替代该核验。 页 6：正文写“上方为既有方法、下方为DPO”，实际DPO原文第2页Figure 1及本页图件为左侧RLHF、右侧DPO。需改成左右方向并核对图标签。图件相较baseline更大且包含完整流程/图注，但长英文图注仍很小。takeaway“差值”在此应为“差别”。 页 8：InstructGPT列将“混入预训练梯度”写成RLHF共同属性，应限定为PPO-ptx。原文第9页明确在目标中加入预训练梯度的模型称PPO-ptx，γ=0的模型称PPO；notes已提PPO-ptx但可见正文未区分。建议正文直接写“PPO-ptx额外混入预训练梯度”，保留纯PPO路线。 页 8：DPO列“不需采样与大量调参”需将采样限定为策略优化环内，并把少量调参表述为该论文报告的设置。第4页和本页notes已有微调环内限定，DPO原文第5页仍有离线采样构造偏好数据，因此本页不宜用无范围的“不要采样”。 页 9：可比性表把DPO的“评测方式”统一写成GPT-4代理、把“报告数值”统一写成对参考回答胜率，却同时列IMDb、TL;DR和HH。DPO原文第7–8页：IMDb情感控制用已知情感分类器作为真值奖励，报告奖励–KL前沿；TL;DR/HH才主要报告GPT-4相对参考回复胜率，第10页另有人评校验。notes正确区分但正文表格仍过度概括。建议将表格标成“摘要/对话评测示例”，或分开列IMDb与TL;DR/HH指标；InstructGPT列也可标主偏好指标示例，避免暗示论文仅有一种指标。

任务 / 组	目前审查	明确问题
V4 / 设计 Skill + 普通 DSH	AI 辅助审查：需要修订	页 8：表中57.2/47.5、56.7/47.3、56.5/46.9被标成FEVER-3 (B-1/R-L)，正文与notes也重复这一归属。RAG原文第8页Table 6中这些数值实际属于MSMARCO，指标顺序为Rouge-L/Bleu-1；FEVER是分类任务，指标为Label Accuracy，FVR-3对应学习检索74.5、冻结检索72.9、BM25 75.1。NQ/TQA列数值正确，但当前FEVER列的任务归属和指标口径均错误，必须更正后才能据此解读消融。 页 7：正文展示2016索引回答2016领导人70%，却把82名在2016至2018年间发生职位变化的世界领导人、NQ RAG模型及另一匹配/错配条件全部留在notes。RAG原文第7—8页仅以该有限问答实验支持索引可更新知识；建议在页内注明实验范围，避免将这一结果理解成任意知识替换的准确性保证。
V4 / 相同 Skill + Motif	AI 辅助审查：未观察到重大问题	页 5：四组数值与T5原文第14页Table 1相符，但正文缺少指标名称和验证集口径：CNNDM是ROUGE-2-F、SQuAD是Exact Match、GLUE/SuperGLUE是官方子任务均分，均为验证集结果。正文“同一模型与步数”应明确为相同下游训练步数2^18；预训练组还额外经历2^19步预训练，并非总训练步数或计算成本相同。notes已解释这些条件，建议移入表注以便独立阅读。 页 8：70、68、12、4与RAG原文第8页索引交换实验相符，但实际图面未显示纵轴指标名与百分比单位，类别仅用16/18年份缩写。82名换届世界领导人、NQ RAG模型和2016/2018维基索引的范围只在notes。应在图面写清回答准确率(%)、年份全称和实验范围；plan中的y_label/unit并未在该图面上呈现。
V4 / 相同 Skill + Motif + RSI	AI 辅助审查：需要修订	页 4：标题称“一次前向信息流”，但第四步将概率边际化与“两端端到端微调”合并为推理链末端，混淆使用期前向计算与训练期参数更新。RAG原文第3—4页规定：训练只更新查询编码器与BART生成器，文档编码器和索引固定；该职责划分只在本页notes，下一页正文也仅泛称检索器与生成器联合微调。应将推理路径和训练路径分开，并在正文标出哪些组件更新、哪些固定，避免误解每次回答都会微调或整个索引参与联合训练。 页 8：索引更新页只给出“替换整个索引即可更新世界知识”的定性概括，把70%/68%匹配准确率、12%/4%错配准确率及82名换届领导人的NQ RAG问答范围全部留在notes。原文第7—8页支持的是该受限实验内的知识更新效果；建议正文保留至少实验范围与匹配/错配证据，供读者判断可迁移条件。
V5 / 设计 Skill + 普通 DSH	AI 辅助审查：需要修订	页 4：780GB→48GB微调标题没有在可见正文列65B模型端点，限定仅在notes；性能匹配的任务/指标也应在正文交代，不能泛化为所有任务。 页 7：“规模与在线迭代需求偏向RLHF”是本方案选择建议，应标明推论；各论文最大验证规模不等于当前方法适用规模上限，不能据175B与6B直接决定。 页 9：标题称四个环节却实际画5步；训练微调/偏好调优与回答推理同线，应显式区分阶段以免被读成每次回答均训练。 页 11：可复算评测计划正文未给具体数据集、指标单位与质量门槛，notes罗列文献口径仍不足以复制本方案。应补可执行方案或明确尚待决定。 页 8：原图完整、语义对应，但内部标注与图注细字偏小；投影阅读仍需人工核验。

任务 / 组	目前审查	明确问题
V5 / 相同 Skill + Motif	AI 辅助审查：需要修订	页 10：notes把85±3%偏好率归给1.3B InstructGPT相对175B GPT-3，原文PDF第3页明确该数值属于175B InstructGPT对175B GPT-3。1.3B胜过175B的结论没有给该数值，必须修正模型规模归属。 页 8：表中RLHF用奖励模型6B与DPO试验策略至多6B不是同一个比较维度；notes却写模型规模对齐。应分别列奖励/策略模型规模，选择建议标为本方案推论。 页 5：量化基座与适配器复现16-bit性能的可见结论未列具体基准与条件，notes才说明GLUE/SNI/MMLU，宜补正文范围。 页 6：RLHF原图完整并对应三步训练，但细字较小，应扩大或重点标注实际讲解区域并保留完整出处。
V5 / 相同 Skill + Motif + RSI	AI 辅助审查：需要修订	页 3：验证条件表将QLoRA概括为“单卡4-bit”，缺65B/48GB微调端点；第5页补充了65B与显存，表内仍宜列清条件。四篇不是共同基准，正文已正确声明。 页 5：NF4+DQ与BF16的MMLU相当在正文未标LLaMA 7–65B、Alpaca/FLAN v2及53.1/53.0均值；notes含这些限定。应避免将MMLU结果概括为所有任务的精度匹配。 页 6：1.3B输出偏好超过175B GPT-3的可见陈述缺测试提示来源及人工评判口径，notes转而给175B版偏好率，没有直接补齐1.3B端点。本页原图流程完整，但细字很小，需人工投影核验。 页 7：标题“变成一次分类式训练”可能被理解为一次更新即可完成；DPO是以成对偏好分类目标进行多步训练，宜写“直接优化分类式目标”。原图左右流程正确完整。 页 10：评测表新旧索引一致/冻结检索器并非严格对应的知识更新时间实验；RAG Table6冻结检索器是微调消融，跨年索引实验对比匹配/错配年份。Top-K命中金标还需区分FEVER文章重叠与NQ答案召回。应将本方案新增指标明确标为设计选择并指定可复算定义。 页 11：实体型任务不优于BM25是从FEVER事实核验消融推广，宜直接写FEVER开发集，保留任务限定。

未评审就写未评审。没有人工评审者、统一评审记录和修订时间，本报告不会生成“质量等价”“更优美已被证明”或“可收费”的结论。

7 / 逐题展示：全部页面原稿

每个任务的三组原稿用全页拼图展示，连续页号对应复制的真实 PNG。index.html 同时提供逐页并排、PPTX、PDF 与高清拼图；页面顺序相同不意味着生成内容一一相同。失败和跳过保留空位。

V1 / RAG 方法组会
设计 Skill + 普通 DSH

运行 1377c614e72f471f9bd7c55a787c34a8 · 会话完成 · 请求 29 · token 947,827 · 估费 $0.047874

AI 辅助审查：需要修订

RESEARCH BRIEF

检索增强生成：在参数记忆之外加一个可查的知识库

核心问题：生成模型为何需要一个可外部更新的知识来源

- 面向尚未实现检索增强的同学的组会汇报
- 基于 Lewis 等 RAG 论文原文整理

01 / 08

纯参数模型的三个短板

缺的不是更多参数，而是可修订、可查看、可替换的知识来源

- 知识存在参数里，难以扩展或修订
- 难以说明预测依据来自哪里
- 可能产生幻觉，知识密集任务上落后于专用架构

02 / 08

检索与生成如何连接

检索器与生成器端到端联合微调，不需文档级检索监督

1	查询编码	BERT 查询编码器把输入 x 编码为向量 q(x)
2	向量检索	MIPS 在维基百科索引中取 top-K 文档 z
3	拼接条件	把 z 与输入 x 拼接后送入 BART 生成器
4	边缘化	z 作隐变量，自回归生成输出
5	联合微调	最小化负边缘对数似然，联合更新编码器与生成器

03 / 08

两种边缘化方式的区别

同一条检索链路，接法不同决定生成能用几篇文档

RAG-Sequence

- 整条输出序列共用同一篇检索文档
- 按整句在文档间做边缘化
- 在 MS-MARCO 生成上表现更好

RAG-Token

- 每个输出 token 可用不同文档
- 可组合多篇文档内容作答
- 在 Jeopardy 问题生成上更好

04 / 08

论文原图：检索器与生成器的联合结构

查询经 MIPS 取 top-K 文档，再由生成器条件化产出 y

- 检索到的文档被当作隐变量处理
- 同一架构可迁移到问答与事实验证

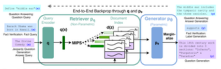


Figure 1: Overview of our approach. We combine a pre-trained retriever (*Query Encoder + Document Index*) with a pre-trained seq2seq model (*Generator*) and fine-tune end-to-end. For query x, we use Maximum Inner Product Search (MIPS) to find the top-K documents z_i. For final prediction y, we treat z as a latent variable and marginalize over seq2seq predictions given different documents.

05 / 08

开放域问答：超过抽取式基线

验证集指标：生成式 RAG 超过抽取式 DPR

模型	NQ	WQ	CT
T5-11B 闭卷	34.5	37.4	—
T5+SSM 闭卷	36.6	44.7	—
DPR 抽取式	41.5	41.1	50.6
RAG-Token	44.1	45.5	50.0
RAG-Seq.	44.5	45.2	52.2

06 / 08

生成质量指标与人工评价

在各任务内，RAG 的事实性与多样性指标高于 BART

- MS-MARCO Rouge-L： RAG 40.8 对 BART 38.2
- Jeopardy Q-BLEU-1： RAG 22.2 对 BART 19.7
- 三元组多样性： RAG 83.5% 对 BART 70.7%
- 人工评价： RAG 42.7% 更符合事实， BART 7.1%

07 / 08

消融与局限

学习检索多数任务有增益，条件变化会改变适用范围

- 冻结检索器后 NQ 从 44.0 降至 41.2
- 换成 BM25 后 NQ 仅 31.8
- 事实验证上 BM25 反而更好
- 只替换索引即可更新知识，错配时准确率大跌

08 / 08

8 页 / 原 PPTX SHA256 857d5397af853c09493e… / 完整文件与高清逐页证据见随包导航

V1 / RAG 方法组会
相同 Skill + Motif

运行 4c54ae3af54649afb9b588b1042b68d2 · 会话完成 · 请求 20 · token 524,642 · 估费 $0.018519

AI 辅助审查：需要修订

RESEARCH BRIEF

检索增强生成（RAG）：为什么检索、如何连接证据

- 组会汇报 · 面向了解生成模型、尚未实现检索增强的同学
- 依据 Lewis 等《Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks》2020-2021

01 / 08

纯参数记忆在知识密集型任务上的三个缺口

参数记忆本身强，但难以更新、追溯和验证

- 知识写入参数，难以扩充或修订
- 难以给出决策依据，且可能产生幻觉
- 知识密集型任务上落后于专用架构

02 / 08

一条从输入到生成再到答案的端到端链路

查询编码	BERT 双编码器对输入 x 编码为查询向量 q(x)
稠密检索	与文档向量做最大内积检索 MIPS，取 top-k 文档 z
输入拼接	把检索到的文本 z 与原始输入 x 拼接后送入 BART 生成器
边际化生成	以 z 为隐变量对 top-k 的生成概率求和（逐序列或逐 token）

03 / 08

检索与生成如何连接：两种边际化方式

同一份检索结果，按句使用还是按词使用

RAG-Sequence	RAG-Token
整条输出共享同一篇文档 z	每个输出 token 可换用不同文档
在文档层面边际化一次	逐 token 边际化并生成分布
通常保留更多多样性	更擅长合并多篇文档内容

04 / 08

论文方法总览：检索器与生成器共同微调

- 输入 x→ 查询编码→ MIPS 检索 top-k 文档
- 文档 z 与 x 拼接后由生成器 A 边际化输出答案

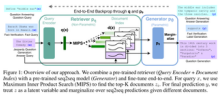


Figure 1: Overview of our approach. We combine a pre-trained retriever ($Query$ $Encoder$ + $Document$ $Index$) with a pre-trained seq2seq model ($Generator$) and fine-tune end-to-end. For query x, we use Maximum Inner Product Search (MIPS) to find the top-K documents z_i. For final prediction y, we treat z as a latent variable and marginalize over seq2seq predictions given different documents.

05 / 08

实验指标与对照条件：先对齐口径再看分数

任务 / 数据集	指标	参照与条件
开放域问答 NQ/TQA/WQ/CT	Exact Match	与闭卷 T5-11B 、开放书 REALM/DPR 比较
MS-MARCO / Jeopardy 生成	Bleu-1 / Q-BLEU-1	与 BART-large 基线比较
事实核查 FEVER	标签准确率	不使用检索监督，与流水线系统比较

06 / 08

检索真的有用：对照实验与可更新知识库

- 训练时冻结检索器，各任务成绩下降
- 换索引即可更新世界知识，无需重训

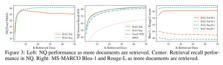


Figure 3: Left: NQ performance as more documents are retrieved. Center: Retrieval recall performance in NQ. Right: MS-MARCO Bleu-1 and Rouge-L as more documents are retrieved.

07 / 08

收益与局限：证据支持到哪一步

结论限于文中数据集与评测条件，不能推广为通用优势

- 开放域问答在 NQ/TQA/WQ/CT 上取得当时最优
- FEVER 三分类距当时最优流水线 4.3 个百分点
- 检索监督、段落级召回指标等作者未报告
- 覆盖仅限英文维基，提示词敏感度未报告

08 / 08

8 页 / 原 PPTX SHA256 7dab863559c81ad22f9e… / 完整文件与高清逐页证据见随包导航

V1 / RAG 方法组会
相同 Skill + Motif + RSI

运行 8092b9c0ae994d6aaa75813b35b09ae3 · 会话完成 · 请求 20 · token 544,221 · 估费 $0.024245

AI 辅助审查：需要修订

RESEARCH BRIEF

检索增强生成：把外部证据接进生成模型

- 来源： RAG for Knowledge-Intensive NLP Tasks （arXiv:2005.11401v4）
- 面向：了解生成模型、未实现检索增强的同学
- 组会汇报 | 8 页 | 约 10 分钟

01 / 08

纯参数记忆的四个限制：更新、溯源、幻觉与规模

纯参数模型把知识写在权重里，改知识要重训、查依据无门。

- 记忆难扩展或修订
- 可能产生“幻觉”
- 预测依据难以解释
- 知识密集型任务落后专用架构

02 / 08

RAG 四步：从问题到有依据的生成

1 问题编码	输入 x 经查询编码器得到向量 q(x)
2 MIPS 检索	在 21M 篇维基块索引中取 top-K
3 拼接生成	输入 x 与检索文档 z 拼接后交给 BART
4 边缘化	对 top-K 文档加权求和

03 / 08

两种连接方式：同一文档 vs 每 token 换文档

同一批检索文档，差别在边缘化粒度与解码代价。

RAG-Sequence	RAG-Token
检索 top-K 文档	检索同样的 top-K 文档
整条输出用同一文档	每个 token 可换文档
序列级边缘化	能拼合多文档内容

04 / 08

原图：检索器—索引—生成器与端到端微调

- 同一流程覆盖问答、事实验证与问答生成
- 查询 x 经 MIPS 取 top-K 文档 z
- 生成时把 z 视为隐变量做边缘化

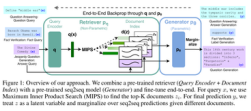


Figure 1: Overview of our approach. We combine a pre-trained retriever (*Query Encoder + Document Index*) with a pre-trained seq2seq model (*Generator*) and fine-tune end-to-end. For query x, we use Maximum Inner Product Search (MIPS) to find the top-K documents z_i. For final prediction y, we treat z as a latent variable and marginalize over seq2seq predictions given different documents.

05 / 08

证据：开放域问答的精确匹配（EM）分数

三个数据集的 EM 上 RAG 均高于闭卷与抽取式对照。

- RAG 无需重排序器或抽取式阅读器
- 闭卷 T5-11B 不使用检索

模型	NQ	TQA-Wiki	WQ
T5-11B 闭卷	34.5	50.1	37.4
DPR 抽取式	41.5	—	41.1
RAG-Token	44.1	66.1	45.5
RAG-Seq.	44.5	68.0	45.2

06 / 08

更多检索文档并不必然更好

- RAG-Sequence： 取更多文档， NQ EM 单调上升
- RAG-Token： 约 10 篇后不再提升

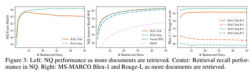


Figure 3: Left: NQ performance as more documents are retrieved. Center: Retrieval recall performance in NQ. Right: MS-MARCO Bleu-1 and Rouge-L as more documents are retrieved.

07 / 08

边界与局限：可比条件、失败模式与研究空白

RAG 的优势依赖数据集与检索器条件，未解决的条件仍存在。

- TQA 两套测试集不可直接比较
- 生成任务上检索可能“塌缩”
- 4.3%/2.7% 差距含监督差异
- 评测以维基知识为边界

08 / 08

8 页 / 原 PPTX SHA256 16078324d30e9de7b429… / 完整文件与高清逐页证据见随包导航

V2 / QLoRA 工程决策
设计 Skill + 普通 DSH

运行 0013ebbb519e408790159e436fe8cf0b · 会话完成 · 请求 17 · token 405,047 · 估费 $0.025194

AI 辅助审查：需要修订

RESEARCH BRIEF

有限显存下的 QLoRA 微调：可行性与适用边界

- 问题： 65B 级模型 16 位全量微调需 >780GB 显存
- 证据来自 QLoRA 原文（arXiv:2305.14314v1）
- 含方法、显存、效果数值与原文未证明的边界

1 / 7

01 / 07

显存瓶颈来自哪三块：权重、适配器、优化器状态

瓶颈在基座权重与激活梯度，而非可训练适配器参数

- 16 位全量微调 65B 模型需超过 780GB 显存
- 7B 示例中 4 位基座权重占 5,048MB
- LoRA 参数仅 26MB，输入梯度 567MB
- 梯度检查点后输入梯度约 18MB/ 序列

2 / 7

02 / 07

量化、适配器、优化器如何配合降低显存

量化省权重、适配器省梯度、分页优化器吸收显存尖峰

- 4 位 NF4 量化冻结基座，仅存低比特权重
- BF16 计算时反量化，矩阵乘法仍在 16 位
- LoRA 只训练低秩适配器，不更新基座权重
- 分页优化器把优化器状态按需换出到 CPU 内存

3 / 7

03 / 07

从 4 位权重到适配器更新的可编辑流程

冻结 4 位基座，只更新 16 位适配器参数

4 位 NF4 量化存储	预训练权重按块量化为 NF4 并冻结，双重量化压缩量化常数
反量化到 BF16	前向与反向计算时把存储类型转成 BF16 计算类型再乘
梯度回传到适配器	梯度穿过冻结的量化权重进入 LoRA，4 位权重不算权重梯度
分页优化器更新	只更新 BF16 适配器；显存峰值时优化器状态换出到 CPU 内存

4 / 7

04 / 07

QLoRA 相对 LoRA 与全量微调的显存与精度取舍

- 原文图比较不同微调方法的显存需求
- QLoRA 在 LoRA 基础上再引入 4 位量化与分页优化器

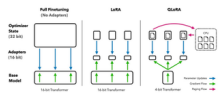


Figure 1: Different finetuning methods and their memory requirements. QLoRA improves over LoRA by quantizing the transformer model to 4-bit precision and using paged optimizers to handle memory spikes.

5 / 7

05 / 07

效果数值与操作条件对照（列 3 见备注）

4 位 NF4 在原文基准上追平 16 位，结论限于该基准与条件

- 均为原文报告值，条件不同不可直接横向排名

报告项	数值
65B 16 位全量微调	>780GB 显存
7–65B MMLU 5-shot 均值	NF4+DQ 53.1
Guanaco 65B Vicuna	99.3%
Guanaco 33B Vicuna	97.8%

6 / 7

06 / 07

决策适用条件与原文未证明的边界

适用条件（原文支持）

- 以 4 位存储加 16 位适配器训练
- 适配器需覆盖全部线性层
- 需分页优化器应对显存尖峰

边界与原文未证明

- 未定位性能—精度折中点
- 分页优化器缺硬性测量
- 未外推到推理加速或延迟
- 自动与人工评判仅中等一致

7 / 7

07 / 07

7 页 / 原 PPTX SHA256 b5d19b20e95a8e934fc7… / 完整文件与高清逐页证据见随包导航

V2 / QLoRA 工程决策
相同 Skill + Motif

运行 00a8573e10f440239f7241ac9eacdfac · 会话完成 · 请求 19 · token 541,400 · 估费 $0.024010

AI 辅助审查：需要修订

RESEARCH BRIEF

有限显存下的大模型微调： QLoRA 如何使可行

- 决策问题： 单卡显存不足时，如何微调 7B–65B 大模型
- 依据文献： QLoRA: Efficient Finetuning of Quantized LLMs

1 / 7

01 / 07

16 位全量微调 65B 需 780GB 以上显存

QLoRA 把 65B 微调显存从 >780GB 降到 <48GB，性能不降

常规 16 位全量微调	QLoRA 4 位微调
LLaMA 65B 需 >780GB GPU 显存	65B 可在一张 48GB GPU 上完成
单机单卡通常无法承载	对比基线为 16 位全量微调
显存是可行性的第一约束	报告未观测到任务性能退化

2 / 7

02 / 07

量化、适配器与优化器各解决一处瓶颈

存储靠量化、学习靠适配器、尖峰靠分页优化器

- 量化：权重存为 4 位，计算时反量化回 16 位
- 适配器：基座冻结，只训练低秩权重
- 优化器：分页优化器用统一内存应对显存尖峰

3 / 7

03 / 07

4 位微调如何走完前向与反向

1 **4 位存权重**	基座权重以 NF4 存储，块大小 64，配合双量化压缩常数
2 **反量化到 16 位**	计算时临时还原为 BFloat16，用于前向与反向的矩阵乘
3 **前向经适配器**	Y 等于 XW 加 s 乘 X 乘 L1 乘 L2，基座项冻结，只有适配器项可训练
4 **只更新适配器**	梯度穿过冻结的量化权重，只对适配器算梯度并更新优化器状态

4 / 7

04 / 07

显存构成：权重之外，激活梯度占大头

省 LoRA 参数几乎不省显存，瓶颈在激活梯度

组成部分	显存	条件
4 位基座模型	5048 MB	7B LLaMA， FLAN v2
LoRA 参数	26 MB	约原模型权重的 0.2%
LoRA 输入梯度	567 MB	batch size 1
输入梯度（梯度检查点）	平均 18 MB/ 序列	开启梯度检查点

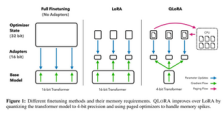
5 / 7

05 / 07

原文 Figure 1： 不同微调方法的显存需求

图形呈现的是微调方法间显存关系，不是推理速度

- QLoRA 在 LoRA 之上加 4 位量化与分页优化器



6 / 7

06 / 07

适用条件、代价与原文未证明的边界

结论限定在微调显存与评测基准，不能外推为推理加速

- NF4+ 双量化可复现 16 位 LoRA/ 全量微调基准， FP4 约低 1 个百分点
- 达标依赖 LoRA 覆盖全部线性层；默认只加 q 、 v 无法对齐
- 分页优化器速度结论来自 65B/48GB 、 batch 16，未系统刻画降速
- 原文未报告推理加速；省显存不等于推理更快

7 / 7

07 / 07

7 页 / 原 PPTX SHA256 20853017babf68c0e112… / 完整文件与高清逐页证据见随包导航

V2 / QLoRA 工程决策
相同 Skill + Motif + RSI

运行 66d2d4fd299f4fd2afbbd4d5ee13edd5 · 会话完成 · 请求 10 · token 182,937 · 估费 $0.011919

AI 辅助审查：需要修订



01 / 07



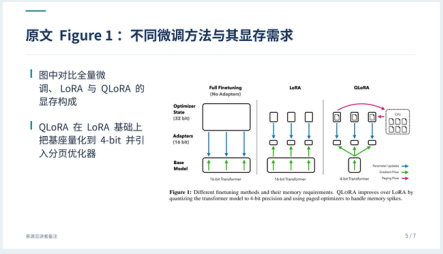
02 / 07



03 / 07



04 / 07



05 / 07



06 / 07



07 / 07

7 页 / 原 PPTX SHA256 8b742de09c290a1ae6ab… / 完整文件与高清逐页证据见随包导航

V3 / RLHF 与 DPO 比较
设计 Skill + 普通 DSH

运行 8c2ee16c50dc4ba9b7f9af20936fd935 · 会话完成 · 请求 17 · token 645,560 · 估费 $0.034657

AI 辅助审查：需要修订

RESEARCH BRIEF

偏好对齐训练路线比较： RLHF 与 DPO

- 两种路线都从人类偏好中学习
- 本稿比较训练阶段、数据要求、优化目标、成本来源与限制
- 不同论文的模型规模与评测条件不同，不构成统一排行榜

1 / 10

01 / 10

共同起点：预训练不直接等于服从用户意图

两篇论文都定位同一问题：预训练之后的偏好学习阶段

- InstructGPT 认为语言建模目标与「有用、安全地遵循指令」不同
- DPO 指出无监督预训练带来广泛知识，但精确控制行为仍困难
- 两条路线都在预训练之后增加偏好学习阶段

2 / 10

02 / 10

InstructGPT 的 RLHF：三个阶段

RLHF 在策略训练中闭环采样并由奖励模型提供标量奖励

01	02	03
监督微调 SFT	奖励模型 RM	PPO 强化学习
用标注者示范数据微调 GPT-3，得到监督策略；并作为后续初始点	在同一提示上让标注者对 K=4–9 个回复排序，训练 RM 预测被偏好回复	以 RM 输出为标量奖励，用 PPO 微调监督策略，并加逐 token KL 惩罚

3 / 10

03 / 10

DPO 的做法：把偏好损失写成策略的函数

DPO 不做显式奖励建模与 RL 循环，只优化一个二分类交叉熵损失

01	02	03
采样并标注偏好对	奖励重参数化	直接优化策略
对每个提示由参考策略采样 y1,y2，人工标注构成离线数据集 D	由 KL 约束最优解推出 r=βlog(π/πref)，代回 Bradley-Terry 后配分函数抵消	用二元交叉熵损失 L_DPO 训练 πθ，隐式奖励由策略与参考模型共同定义

4 / 10

04 / 10

DPO 论文原图：偏好学习流程的两种结构

该图刻画的是流程结构差异，不是效果差距

- 上方为既有方法：先拟合奖励模型，再用 RL 求最大化奖励的策略
- 下方为 DPO：用简单分类目标直接优化策略
- 隐式奖励对应的最优策略可闭式提取

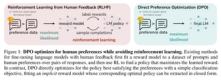


Figure 1: DPO optimizes for human preferences while avoiding reinforcement learning. Existing methods for fine-tuning language models with human feedback first fit a reward model to a dataset of prompts and human preferences over pairs of responses, and then use RL to find a policy that maximizes the learned reward. In contrast, DPO directly optimizes for the policy best satisfying the preferences with a simple classification objective, fitting an implicit reward model whose corresponding optimal policy can be extracted in closed form.

5 / 10

05 / 10

数据要求：三类数据 vs 一类偏好对

InstructGPT / RLHF	DPO
约 13k 提示用于 SFT	偏好对 (x, yw, yl)，离线训练
约 33k 提示用于训练 RM	可复用公开偏好数据集
约 31k 提示无标签，仅作 PPO 输入	需参考模型 πref，通常取 πSFT

6 / 10

06 / 10

优化目标：同一约束目标，求解方式不同

RLHF （PPO）	DPO
最大化 RM 奖励并加 KL 约束	隐式优化同一约束目标
目标含策略采样，不可微	奖励重参数化为 βlog(πθ/πref)
用 PPO 最大化奖励减 KL 项	用二元交叉熵直接训练策略
RM 用比较数据单独训练	无单独奖励模型与 RL 循环

7 / 10

07 / 10

成本来源：预训练之外的支出结构不同

两文的成本陈述口径不同，不能换算成同一预算

- InstructGPT： 175B SFT 约 4.9 、 PPO-ptx 约 60 petaflops/s-days ， GPT-3 为 3640
- 其成本主要来自人工标注与多模型训练
- DPO 把成本集中在离线偏好数据与监督式训练
- DPO 称更易实现、无需大量超参调优

8 / 10

08 / 10

限制：两篇论文各自承认的边界条件

InstructGPT 的限制	DPO 的限制
对齐的是约 40 名标注者的偏好	分布外泛化只有初步结果
标注者一致率约 73%	奖励过度优化尚不明确
数据几乎全为英文	实验模型最大 6B
仍会编造事实并服从有害指令	GPT-4 评判受提示词影响

9 / 10

09 / 10

结论：本稿比较限于机制层面

可迁移的是流程结构与成本来源，不是分数高低

- 机制上确定： DPO 省去显式奖励模型与训练中采样
- 两文未在相同模型、数据与评测下直接对照
- DPO 的 6B 内结论与 InstructGPT 的 175B 内结论各自成立
- 先评估偏好数据可得性与算力预算，再选流程

10 / 10

10 / 10

10 页 / 原 PPTX SHA256 8fc458211aa67bb46d30… / 完整文件与高清逐页证据见随包导航

V3 / RLHF 与 DPO 比较
相同 Skill + Motif

运行 526d8f0fd0894b0fa5c466a214a1b900 · 会话完成 · 请求 24 · token 1,137,016 · 估费 $0.062402

AI 辅助审查：需要修订

RESEARCH BRIEF

偏好对齐路线选择： RLHF 与 DPO 怎么选

- 面向正在选择对齐训练路线的研究同学
- 比较对象： InstructGPT 的 RLHF 与 DPO
- 比较维度：训练阶段、数据、目标、成本、限制

1 / 10

01 / 10

两份论文共同回答：如何从偏好数据训练可控模型

两者共用同一 KL 约束奖励最大化目标，但一为 RL 求解，一为闭式改写

- 目标一致：用人类偏好做奖励信号微调语言模型
- InstructGPT： SFT 后拟合奖励模型再用 PPO 优化
- DPO： 换元把偏好损失写成策略的损失，免显式奖励
- 机制趋同但实现路径与数据依赖不同

2 / 10

02 / 10

共享前提： Bradley-Terry 偏好模型与 SFT 起点

KL 约束防止模型偏离奖励模型可靠的分布并避免模式崩塌

- 偏好假设： Bradley-Terry 模型刻画成对偏好概率
- 奖励可用最大似然拟合，本质是二分类损失
- 参考策略通常为 SFT 模型，约束偏离幅度
- DPO 未获得 SFT 时，用偏好完成项拟合参考模型

3 / 10

03 / 10

RLHF 流程：三阶段串行，比较数据可迭代回流

SFT 监督微调	在标注者示范上微调 GPT-3，得到监督策略与参考模型
奖励模型训练	标注者对同一提示的多个输出排序，训练标量奖励模型
PPO 强化学习	以奖励模型输出为奖励，用 PPO 微调 SFT 策略
比较数据回流	在最新策略上继续采集比较数据，迭代新奖励模型与新策略

4 / 10

04 / 10

InstructGPT 三阶段流程图（原文第 3 页图 2）

流程的关键成本在步骤 2、3 之间反复采样与人工排序

- 三阶段： SFT、奖励模型训练、PPO 优化
- 蓝色箭头表示该数据用于训练其中一个模型



5 / 10

05 / 10

DPO 把奖励到策略的映射换成闭式，单阶段训练

梯度增大偏好回答的似然、降低非偏好回答，并按排序错误程度加权

构造离线偏好集	用参考策略采样成对回答，由人类标注偏好，得到离线数据
换元改写偏好损失	奖励写成策略与参考策略对数比，配分函数在成对差分中抵消
最小化二分类损失	以交叉熵直接优化策略，隐式奖励即策略本身
无需环内采样	微调中不必从语言模型采样，也无需大量超参搜索

6 / 10

06 / 10

训练阶段与数据要求：两条路线对照

数据形态不同： RLHF 需示范 + 比较 + 无标签提示， DPO 只要成对偏好

InstructGPT （RLHF）

- 三阶段：示范微调、奖励建模、 PPO
- 训练环内需采样且多模型并存
- 需示范、比较与无标签三类数据

DPO

- 单阶段：直接优化策略
- 无显式奖励模型与环内采样
- 只需成对偏好数据

7 / 10

07 / 10

优化目标与成本来源：同目标不同求解代价

成本差异来自求解方式：环内采样与多模型训练 vs 单阶段离线优化

RLHF

- 奖励最大化 + KL 约束
- 不可微，需 RL 求解
- 需策略、奖励与价值模型

DPO

- 隐式目标与 RLHF 相同
- 二分类交叉熵，可直接优化
- 无需从策略采样

8 / 10

08 / 10

限制与适用边界：各自未解决的问题

两者都未给出可直接推广的通用结论，边界条件仍需在自有场景验证

InstructGPT 的限制

- 偏好来自特定标注者
- 标注者一致率约 73%
- 仍会顺从错误前提

DPO 的限制

- 大规模模型扩展性未验证
- 分布外泛化仅有初步证据
- 奖励过度优化仍待研究

9 / 10

09 / 10

结论：按条件选路线，避免把机制比较当成效果排名

先明确偏好数据形态与算力预算，再决定走 RLHF 还是 DPO

- 已有成对偏好数据、算力有限时， DPO 的离线单阶段更易落地
- 需要重复采集在线比较数据时， RLHF 的迭代回流更直接
- 两篇论文的模型、数据与评测口径不同，不能拼成统一排行榜
- 本稿的阶段、数据与成本比较属机制分析，非受控效果对比

10 / 10

10 / 10

10 页 / 原 PPTX SHA256 b831be8c9d3f922de1f8… / 完整文件与高清逐页证据见随包导航

V3 / RLHF 与 DPO 比较
相同 Skill + Motif + RSI

运行 6fc49db827994b95a6abb1d2130744db · 会话完成 · 请求 23 · token 1,073,386 · 估费 $0.054295

AI 辅助审查：需要修订

RESEARCH BRIEF

偏好对齐路线选择： RLHF 与 DPO

- 围绕同一问题：从人类偏好出发训练策略，两条路线在阶段、数据、目标、成本与限制上有何差别
- 材料： InstructGPT （RLHF 三段式）与 DPO （免强化学习的直接偏好优化）

01 / 10

要在两条路线之间作出的判断

两条路线优化同一类受 KL 约束的偏好目标，差别在于如何求解

- 共同前提：先有预训练模型，再用人类偏好数据塑造行为
- RLHF 路径：演示数据 → 奖励模型 → 用 PPO 优化策略
- DPO 路径：把奖励改写成策略的函数，用分类损失直接训练策略
- 本页之后的比较只针对机制与公开报告的实验条件

02 / 10

InstructGPT 的 RLHF 三段流程

奖励模型是独立训练的中间件，策略通过采样在训练环内更新

01	02	03
SFT 监督微调	奖励模型训练	PPO 强化学习
用标注者演示数据微调 GPT-3，得到初始策略	标注者排序模型输出，训练 RM 预测人类偏好	以 RM 为奖励，加逐 token KL 惩罚优化策略

03 / 10

DPO 的两步直接优化流程

无需单独奖励模型，也无需在训练环内从语言模型采样

01	02
构造偏好数据集	优化策略
对每个提示采样两条回答，用人类偏好离线标注	用二分类交叉熵损失直接训练语言模型本身

04 / 10

RLHF 流程的原始图示

该图展示数据如何在三步之间流动，而非效果排名

- 三个方框对应 SFT 、 RM 训练与 PPO 三步
- 图中 A–D 是被标注者排序的模型样本

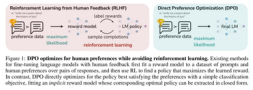


05 / 10

两条流水线的结构差异对照图

图注说明差值在于是否显式拟合奖励并跑强化学习循环

- 上方为既有方法：先拟合奖励模型，再用强化学习优化
- 下方为 DPO：用简单分类目标直接优化策略



06 / 10

统一维度对照：训练阶段与数据要求

InstructGPT RLHF	DPO 直接偏好优化
SFT 、 RM 、 PPO 三步	偏好数据、直接优化两步
演示数据约 13k 提示	核心是离线成对偏好数据
比较数据 33k 提示	可复用公开偏好数据集
PPO 数据 31k 提示	有 SFT 模型时用作参考策略

07 / 10

统一维度对照：优化目标与成本来源

InstructGPT RLHF	DPO 直接偏好优化
最大化奖励，受 KL 约束	同一 KL 约束目标
混入预训练梯度	改写为策略形式直接优化
多模型训练与采样	离线数据与监督式训练
奖励模型仅用 6B	不需采样与大量调参

08 / 10

可比性边界：哪些条件不可合并

比较维度	InstructGPT RLHF	DPO
模型规模	1.3B 至 175B	直到 6B
偏好数据	API 提示，英文为主	IMDb 、 TL;DR 、 HH
评测方式	标注者偏好率	GPT-4 代理评测
报告数值	相对 175B SFT 胜率	对参考回答的胜率

09 / 10

各自的限制与选择建议

先按数据可得性与算力预算选路线，再用与自己数据同源的评测验证

- RLHF： 标注者群体较小且以英语为主，模型仍会生成有害或有偏内容
- RLHF： 多数比较仅由一名标注者标注，存在无法代表全部用户的风险
- DPO： 分布外泛化与奖励过度优化仍是待解问题，最大规模只到 6B
- DPO： 自动评测结果受提示词影响，人工校验只覆盖部分样本

10 / 10

10 页 / 原 PPTX SHA256 218bac50d65bbd0ab98f… / 完整文件与高清逐页证据见随包导航

V4 / T5 与 RAG 知识职责
设计 Skill + 普通 DSH

运行 0f2f78c81afe434a823d6f030895021a · 会话完成 · 请求 19 · token 692,206 · 估费 $0.039474

AI 辅助审查：需要修订

RESEARCH BRIEF

参数内知识与外部检索各承担什么职责

- 以 T5 统一 text-to-text 框架与 RAG 为两条证据线
- 关注训练与使用时的信息流，以及知识如何更新
- 两篇论文并非同条件替代实验，结论限于各自设定

01 / 09

RESEARCH / SECTION

两条证据线：统一框架与混合记忆

02 / 09

T5：全部任务统一为文本进、文本出

统一格式让参数内知识在不同任务间共享同一套训练与解码流程

- 任务前缀指明任务，输出即目标文本
- 同一模型、目标与解码流程复用

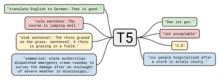


Figure 1: A diagram of our text-to-text framework. Every task we consider—including translation, question answering, and classification—is cast as feeding our model text as input and training it to generate some target text. This allows us to use the same model, loss function, hyperparameters, etc. across our diverse set of tasks. It also provides a standard testbed for the methods included in our empirical survey. "T5" refers to our model, which we dub the "Text-to-Text Transfer Transformer".

03 / 09

T5 的信息流：预训练积攒知识，微调注入任务

T5 的知识更新方式是重新训练或微调参数

1	**无标注语料预训练**	在 C4 上以去噪目标训练，习得通用语言能力
2	**多任务混合预训练**	混合多项任务的监督数据，再在单任务上微调
3	**下游监督微调**	更新全部参数，把任务知识写进参数
4	**统一解码生成**	同一解码流程对各类任务输出目标文本

04 / 09

RAG 的信息流：检索证据，再生成答案

检索把外部证据显式带入生成，参数记忆与外部记忆共同作用

- 查询编码后用 MIPS 取回 top-K 文档
- 生成器以输入加检索段落为条件

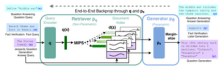


Figure 1: Overview of our approach. We combine a pre-trained retriever (*Query Encoder* + *Document Index*) with a pre-trained seq2seq model (*Generator*) and fine-tune end-to-end. For query x, we use Maximum Inner Product Search (MIPS) to find the top-K documents z_i. For final prediction y, we treat z as a latent variable and marginalize over seq2seq predictions given different documents.

05 / 09

两种 RAG 公式：整段共享还是逐词切换证据

是否允许逐词更换证据，决定了解码方式与可否跨文档拼接内容

RAG-Sequence	RAG-Token
整条输出用同一篇检索文档	每个目标词可用不同文档
文档作为单一隐变量被边缘化	逐词对文档分布做边缘化
解码需先按文档分别做束搜索	可接入标准束搜索解码

06 / 09

更新方式：换索引可更新知识，改参数需再训练

RAG 论文报告换索引即可更新知识，纯参数模型则需再训练

非参数记忆（RAG）	参数记忆（T5 等）
替换文档索引即可更新知识	世界变化需继续训练才更新
无需重新训练即可生效	知识写在参数中，不可直接编辑
2016 索引答 2016 领导人 70%	预训练规模大，更新成本高

07 / 09

检索确实在用：消融与替代检索的差异

学习式检索多数任务优于冻结检索与 BM25 替代

- 数值来自该论文同一组消融设置
- FEVER 列并列 B-1 与 R-L 两个指标

设置	NQ (EM)	TQA (EM)	FEVER-3 (B-1/R-L)
RAG-Sequence	44.0	55.8	57.2 / 47.5
检索器冻结	41.2	52.1	56.7 / 47.3
换作 BM25 检索	31.8	44.1	56.5 / 46.9

08 / 09

适用条件与比较边界：何时外接检索

分工依据是任务是否依赖可核验、可更新的外部证据

- 封闭式生成：答案主要来自参数记忆
- 开放式问答：需检索并合成答案
- 多跳拼接：逐词更换证据可拼合多篇文档
- 跨论文数字不可视为公平优劣排名

09 / 09

9 页 / 原 PPTX SHA256 33fb6ae35022be602c1f… / 完整文件与高清逐页证据见随包导航

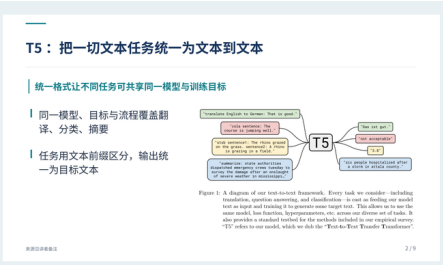
V4 / T5 与 RAG 知识职责
相同 Skill + Motif

运行 b509d8b1fa7449c2b1977f4e06a5a752 · 会话完成 · 请求 18 · token 607,544 · 估费 $0.028575

AI 辅助审查：未观察到重大问题



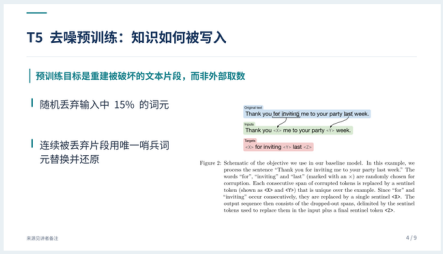
01 / 09



02 / 09



03 / 09



04 / 09



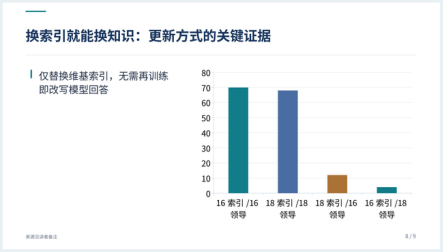
05 / 09



06 / 09



07 / 09



08 / 09



09 / 09

9 页 / 原 PPTX SHA256 4754469d43b3f8b0448f… / 完整文件与高清逐页证据见随包导航

V4 / T5 与 RAG 知识职责
相同 Skill + Motif + RSI

运行 c08dae2caaee419680b8e3c97606fea3 · 会话完成 · 请求 15 · token 520,669 · 估费 $0.038564

AI 辅助审查：需要修订

RESEARCH BRIEF

参数内知识与外部检索各承担什么职责

- T5：统一 text-to-text 与参数内知识
- RAG：参数记忆 + 外部稠密索引

01 / 09

T5：把所有文本任务统一成 text-to-text

统一格式使不同迁移学习方案可在同一测试台上比较

- 任务前缀标明指令，输出统一为文本
- 同一模型、损失与超参跨任务复用

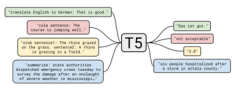


Figure 1: A diagram of our text-to-text framework. Every task we consider—including translation, question answering, and classification—is cast as feeding our model text as input and training it to generate some target text. This allows us to use the same model, loss function, hyperparameters, etc. across our diverse set of tasks. It also provides a standard testbed for the methods included in our empirical survey. "T5" refers to our model, which we dub the "Text-to-Text Transfer Transformer".

02 / 09

T5 的知识写在参数里：预训练加微调

参数内知识扩容靠数据与规模，不靠外部索引

- 用约 750GB 清洗后英文文本 C4 做无监督预训练
- 微调把预训练能力迁移到各下游任务
- 预训练与微调共用同一最大似然目标
- 世界知识随参数固化，更新需再训练

03 / 09

RAG：检索与生成组合成一次前向信息流

检索结果作为潜变量被边际化，而非直接拼贴到答案里

查询编码	查询 x 经 BERT 查询编码器得 q(x)
检索 top-K 文档	MIPS 在 21M 维基片段索引中取前 K 篇
拼接并生成	检索文档 z 与输入拼接后生成 y
边际化与联合训练	对 z 求边际，两端端到端微调

04 / 09

RAG 原文 Figure 1：两类记忆的接口

非参数记忆提供依据，参数记忆负责组织成流畅输出

- 检索器与生成器端到端联合微调
- 检索文档按 top-K 边际化后生成

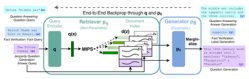


Figure 1: Overview of our approach. We combine a pre-trained retriever ($\text{Query Encoder} + \text{Document Index}$) with a pre-trained seq2seq model (Generator) and fine-tune end-to-end. For query x, we use Maximum Inner Product Search (MIPS) to find the top-K documents z_i. For final prediction y, we treat z as a latent variable and marginalize over seq2seq predictions given different documents.

05 / 09

两种边际化假设：RAG-Sequence 与 RAG-Token

差别在于「谁为哪个词负责」这一假设，而非检索规模

RAG-Sequence

- 整条输出共用同一篇文档
- 对文档求和的序列概率
- 解码需逐文档束搜索

RAG-Token

- 每个词可来自不同文档
- 逐步对文档边际化取词
- 可组合多篇文档内容

06 / 09

分工：检索给依据，参数知识完成表述

两类知识互补：一类提供事实依据，一类提供表达与泛化

- 检索引导生成，参数知识补全细节表述
- 正确答案不在任何检索文档中时仍可生成
- 无检索监督也能在 FEVER 上接近强流水线

07 / 09

更新方式：换索引即时更新，改参数需再训练

非参数记忆把「知识更新」从训练问题变成替换问题

- 替换整个索引即可更新世界知识
- 索引与提问时期匹配时准确率高
- 索引与提问时期错配时准确率大幅下降
- 参数化模型如 T5 需再训练才改变行为

08 / 09

适用条件：两类知识来源各自成立的前提

先对齐条件再比较，才谈得上分工与取舍

参数内知识（T5 式）

- 知识受预训练语料时点与覆盖限制
- 更新需重新训练，依据不易追溯
- 无在线检索开销

外部检索（RAG 式）

- 适合事实密集、需可核对依据的任务
- 答案受检索质量与索引覆盖限制
- 换索引即可更新，可检查所检索内容

09 / 09

9 页 / 原 PPTX SHA256 857d6ea6eb55ab71dfff… / 完整文件与高清逐页证据见随包导航

V5 / 多论文研究方案评审
设计 Skill + 普通 DSH

运行 c826913dca5d4726a31fcda9a76848c0 · 会话完成 · 请求 14 · token 590,383 · 估费 $0.035237

AI 辅助审查：需要修订

RESEARCH BRIEF

课题组知识问答助手：研究方案评审

- 以 RAG 、 QLoRA 、 InstructGPT 、 DPO 四篇论文为证据基础
- 待评审的是模块组合设计，而非已验证的完整系统

01 / 12

四个模块各自回答一个不同的问题

每个模块解决的是不同来源的失效，不是同一问题的替代方案

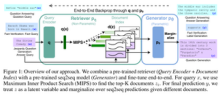
- 检索：知识可更新、可追溯，减少幻觉
- 低显存微调：以 4-bit 量化在单卡上训练大模型
- 偏好对齐：让输出符合指令与人类偏好
- 三者的失败模式针对不同环节，不能互相替代

02 / 12

检索增强：用可替换的索引替代重训练

非参数记忆让知识可更新且可追溯，代价是引入检索质量这一变量

- 检索器 + 生成器端到端联合微调
- 文档索引可热替换，知识无需重训练更新

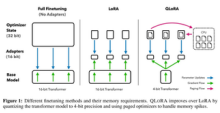


03 / 12

低显存微调：把显存门槛从 780GB 降到 48GB

在多项学术基准上，4-bit NF4 微调复现了 16-bit 全量微调表现

- 4-bit 量化基座 + LoRA 适配器反向传播
- NF4 、双重量化、分页优化器共同省显存



04 / 12

偏好对齐：为什么需要 RLHF 与 DPO

DPO 去掉的是奖励建模与 RL 循环，不是对齐问题本身

- RLHF：先训奖励模型，再用 PPO 优化策略
- DPO：把偏好损失写成策略函数，无需 RL
- 两者目标同为带 KL 约束的奖励最大化
- DPO 论文称其 6B 内规模上匹配或优于 PPO

05 / 12

偏好对齐的两条训练路径

路径差异在工程复杂度与稳定性，不在最终目标函数

- RLHF：奖励模型 + 策略采样循环
- DPO：单一分类损失直接优化策略



06 / 12

RLHF 还是 DPO：按条件选择而非排名

规模与在线迭代需求偏向 RLHF，离线偏好与工程成本偏向 DPO

RLHF / PPO	DPO
需奖励模型与 RL 采样循环	无奖励模型与 RL 循环
可用新偏好数据持续迭代	需已有离线偏好数据集
论文验证规模达 175B	论文验证规模最高 6B

07 / 12

原图流程与拟议组合系统的差别

本页原图是 RLHF 三步流程，不是本方案的组合系统

- 原图分别只覆盖检索侧或偏好侧
- 尚未有论文实测四模块整体串联



08 / 12

拟议组合流程：知识问答助手的四个环节

知识切块与索引	文档切块并建立向量索引，作为可替换的非参数记忆
检索与拼装上下文	按问题召回 top-K 片段，与问题拼接送入生成器
低显存适配微调	4-bit 量化基座 + LoRA 适配器，单卡完成领域微调
偏好对齐调优	按是否有在线偏好数据选择 RLHF 或 DPO
引用与拒答约束	答案附来源，证据不足时拒答而非编造

09 / 12

哪些组合有论文依据，哪些只是设计推论

仅前两行为论文直接支持的组件结论

组合	状态
检索 + 生成联合微调	论文实测
4-bit 量化 + LoRA 适配器	论文实测
QLoRA + 偏好对齐	待验证
RAG + RLHF/DPO 串联	待验证
四模块完整系统	待验证

10 / 12

可复算评测计划与风险

所有指标需预先冻结口径，避免把不同论文的数字直接相减

- 基准：知识问答端到端指标 + 复现对照
- 消融：四模块逐项加回，定位各自增益
- 显存与吞吐：记录单卡可行规模与耗时
- 风险：不可比口径与评测者偏差

11 / 12

结论：可交付的组合与必须先回答的问题

建议先做两两组合的消融，再决定是否上完整系统

- 检索与低显存微调可先行落地并单独评测
- 对齐路径选择取决于是否具备离线偏好数据
- 四模块整体收益须由本组消融实验证明
- 评审需确认知识范围、受众与合规边界

12 / 12

12 页 / 原 PPTX SHA256 a7226a258e2a8c3d7356… / 完整文件与高清逐页证据见随包导航

V5 / 多论文研究方案评审
相同 Skill + Motif

运行 6994060d92fc41e58e16c6f93e374a7e · 会话完成 · 请求 22 · token 1,650,752 · 估费 $0.093589

AI 辅助审查：需要修订

RESEARCH BRIEF

知识问答助手：四个模块如何组合成可验证的系统

- 面向课题组知识问答，评审组合设计与验证边界
- 四个来源分别解决检索、显存、对齐与算法选择

01 / 12

四篇论文各自解决一个独立问题

四篇各解决一环，组合系统本身尚无来源实测

- 四篇来源任务与条件不同，不能直接排名
- 组合可行性是本方案的推论

来源	解决的问题	关键条件
RAG	知识不可查证	稠密向量索引
QLoRA	微调显存过大	4-bit 量化加适配器
InstructGPT	不遵循用户意图	偏好排序加 PPO
DPO	对齐流程复杂	离线偏好加分类

02 / 12

四个模块共同面对的问题：控制与追溯

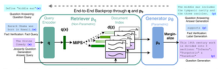
- 参数化知识无法便捷修订，也难提供判断依据
- 单纯增大模型并不必然提升对用户意图的遵循
- 偏好对齐流程复杂且计算成本高
- 全量微调显存门槛限制了可实验的规模

03 / 12

RAG：用非参数记忆补足可追溯的知识

检索提供可查证来源，参数化模型组织答案

- 输入先检索 top-K 文档，再据此生成答案
- 索引可替换，实现知识更新而无需重训

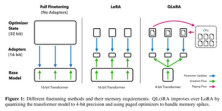


04 / 12

QLoRA：把大模型微调的显存门槛降下来

量化基座加适配器可复现 16-bit 微调性能

- 冻结 4-bit 量化权重，只训练 LoRA 适配器
- 65B 微调显存从超 780GB 降至 48GB 内



05 / 12

偏好对齐：RLHF 用奖励模型加强化学习

闭环奖励建模可对齐，但需采样与额外训练

- 先监督微调，再用排序数据训练奖励模型
- 最后用 PPO 按奖励模型优化策略



06 / 12

DPO：用分类损失直接优化偏好

同一目标可改写为策略上的二分类损失

- 跳过显式奖励模型与强化学习循环
- 损失提高优选回复相对概率并加权纠错



07 / 12

RLHF 与 DPO 的选择条件

可离线、算力受限选 DPO；需在线迭代奖励选 RLHF

RLHF 与 PPO

- 需奖励模型与采样
- 在线闭环可迭代
- 奖励模型用 6B

DPO

- 无需显式奖励模型
- 离线偏好数据
- 试验规模至多 6B

08 / 12

模块组合流程：从检索到可追溯回答

该组合是本方案的待验证设计推论，四篇论文均未实测

1	知识入库	文档切块建向量索引，可替换的非参数记忆
2	检索片段	按查询取 top-K 片段，保留引用位置
3	低显存适配	基座 4-bit 量化，只训练 LoRA 适配器
4	偏好对齐	离线偏好对优化风格，需参考策略与 KL 约束
5	回答与引用	生成答案附来源，未覆盖时说明不确定

09 / 12

评测计划：可复算的分层指标与基线

以同口径消融替代跨论文排名

- 先固定语料与切块，再逐项替换单一模块

层面	指标	对照条件
检索	Recall@K	固定 K 与索引
回答	EM 、 Rouge-L	同批问题与参考策略
成本	显存、时长	同 GPU 与批量
偏好	成对胜率	同提示与顺序

10 / 12

风险与待验证的设计推论

- 组合系统未经验证：四篇论文均未联合实验
- QLoRA 实验用监督微调，未含偏好对齐
- 偏好数据规模小或单一，易过拟合标注群体
- 非参数与参数记忆可能冲突，需检索消融确认

11 / 12

评审请求：请确认验证边界与资源投入

评审通过前，组合收益只能表述为待验证假设

- 确认模块组合假设与消融矩阵是否可接受
- 确认评测语料、基线及人工评审人力
- 确认偏好数据来源与标注伦理审查
- 确认显存预算与实验结果可复现范围

12 / 12

12 页 / 原 PPTX SHA256 d843eb326e6ce9b740fe… / 完整文件与高清逐页证据见随包导航

V5 / 多论文研究方案评审
相同 Skill + Motif + RSI

运行 227fb9dd2acd4928b893a34b6a4f9f6b · 会话完成 · 请求 13 · token 637,757 · 估费 $0.036107

AI 辅助审查：需要修订

RESEARCH BRIEF

知识问答助手研究方案评审

- 围绕 RAG 、 QLoRA 、 RLHF 与 DPO 四篇论文
- 本方案为设计推论，尚未整体实测
- 组会评审：请重点质疑组合假设

01 / 12

我们要回答的三个评审问题

方案只承诺可验证的部分，未测组合单独标注

- 检索、低显存微调、偏好对齐分别解决什么
- 三者能否组合、在什么条件下组合
- 哪些环节只是设计推论而非已测事实

02 / 12

四篇论文各自针对的问题与证据边界

问题互补，但证据不共享同一实验条件

- 四篇均未测同一套组合系统

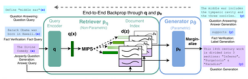
论文	解决的问题	验证条件
RAG	记忆难更新	维基 2018 索引
QLoRA	微调显存高	单卡 4-bit
InstructGPT	不跟随意图	API 提示 + 人工
DPO	RLHF 流程复杂	6B 以内

03 / 12

RAG： 用可替换的外部索引补充参数记忆

外部记忆让知识更新与溯源成为可能

- 检索器给出文档，生成器据此作答
- 替换索引即可更新知识，无需重训



04 / 12

QLoRA： 4-bit 量化把微调显存降到单卡

显存约束下仍可匹配 16-bit 微调精度

- 4-bit NF4 基座 + 低秩适配器梯度回传
- 65B 微调显存从 >780GB 降至 <48GB
- NF4+DQ 的 5-shot MMLU 均值与 BF16 相当

05 / 12

InstructGPT： RLHF 三步对齐用户意图

人类偏好可显著改变输出行为

- SFT 示范、奖励模型、PPO 三步
- 1.3B 输出偏好率超过 175B GPT-3

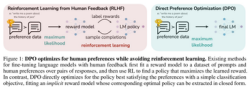


06 / 12

DPO： 把偏好对齐变成一次分类式训练

同等偏好目标可用更简单流程优化

- 用策略直接表示隐式奖励
- 省去显式奖励模型与在线采样



07 / 12

RLHF 与 DPO： 条件不同，取舍不同

流程复杂度对齐，上线风险与稳定性才是选择依据

RLHF / PPO

- 需奖励模型与训练中在线采样
- 原文指出 PPO 训练不稳定、成本高
- 可混入预训练更新缓解对齐税

DPO

- 单一分类损失，无需显式奖励模型
- 对采样温度更稳健，超参调优需求低
- 实验规模止于 6B 参数

08 / 12

模块组合的总流程（本方案设计推论）

1	索引与检索	论文原文：外部索引提供可替换知识来源
2	低显存微调	论文原文： 4-bit 适配器微调匹配 16-bit
3	偏好对齐	论文原文：按偏好调整输出行为
4	联合服务与评测	本方案推论：四者未在同一系统实测

09 / 12

可复算的评测计划与判定口径

先冻结数据与基线，再比较组合增益

- 每项指标给出可比基线

评测项	指标	基线
检索质量	Top-K 命中率	BM25
知识更新	新旧索引一致	冻结检索器
问答正确性	Exact Match	闭卷生成
输出偏好	成对胜率	SFT 模型
显存预算	峰值显存	16-bit 微调

10 / 12

风险：哪些结论还不能提前宣称

组合增益必须整体重测，不能由分项外推

- 四篇论文条件各异，增益不能直接相加
- RAG 检索在实体型任务上未必优于 BM25
- 评测选错数据集会得出相反结论
- 偏好对齐仍会事实错误与过度含糊

11 / 12

下一步：需要评审确认的三件事

请评审确认假设后再投入整机评测

- 组合顺序：先微调还是先检索索引更新
- 对齐方式：按数据与预算选 RLHF 或 DPO
- 验收门槛：哪些分项指标必须达标

12 / 12

12 页 / 原 PPTX SHA256 8147b39abe7d1a6f2e53… / 完整文件与高清逐页证据见随包导航

8 / 学习成本、复现与适用范围

本轮离线布局学习费用只包括真实 DeepSeek 提案调用。历史真实计划的训练/认证重放实际消耗服务器 CPU、LibreOffice 与文件 I/O，没有新增云模型请求。旧读取 Motif 的既有训练与认证成本属于历史资产，不能因为本轮复用而称为从零成本学到；本轮开发维护人力尚未计价。

有效配置	本次记录
experiment_id	research-ppt-v5-design-rsi-20261010
model	deepseek-flash
provider	deepseek-official
reasoning_effort	off
compression	disabled_by_public_entry_default
execution	steps
max_steps	40
max_output_tokens	6000
per_run_budget_cap_usd	0.75
total_budget_cap_usd	15.0
python	3.12.15
node	v22.23.2
libreoffice	LibreOffice 7.3.7.2 30(Build:2)

复现入口与数据

在 /root/autodl-tmp/xjj 启动项目环境；独立按 layout_learning 的 --prepare-training、cli improve、--certify 运行并冻结证据，然后使用 experiment_v5 --certificate ... --call-model 执行真实对照。无 --call-model 默认只预览，resume 不自动重复中断且费用未知的付费 run。此包包含匿名化有效配置和代码/来源哈希，原始私有轨迹、密钥和论文数据不随包分发。

适用范围与下一步

当前支持 PDF/PPTX 输入与可编辑科研 PPTX 的最小链路；source-read 短边只接管工具参数流，科学判断仍交给 DeepSeek。RSI 仅学习受限布局，未自动生成工具，也未建立通用美学裁判。下一步由用户或独立同学按统一内容和视觉门槛盲评这些原稿，记录修订分钟及真实账单，再决定是否冻结新默认布局或扩展 Motif；出现负面证据须保留与局部失效。

记录缺项：provider_facing_tool_schema_hash_and_order；provider_internal_retry_policy；provider_invoice；independent_human_blind_review；human_revision_minutes

未提交 / 未推送；本轮服务器实验与产物不代表团队仓库已同步。