科研 PPT 设计，有界的结构复用

V5 综合实验报告 / 同伴结构版 / 2026-10-10

cohort：research-ppt-v5-design-rsi-20261010-5c076f4a

本报告是 P1/P2 审查后工程试跑。任务使用已知草稿错误反馈，并采用后续修复代码；不作为新的独立留出数据集，不与原五题矩阵合并计算效果。

总的结果

本轮将可分发的科研设计 Skill 接入同一个 Agent，增加短结论区和原生可编辑方法流程，再让真实 DeepSeek 从训练渲染反馈提出受限布局策略。三组分别是相同 Skill 下的普通 DSH、认证 Motif、Motif 加冻结 RSI 策略；没有用模拟 Provider 替代本轮的真实实验。

设计 Skill 是本场景独立编写的固定科研规范，吸收 harness-anything 的 MIT 工作方式：内容与渲染分离、统一层级、等比图像、真实预览和分项校对；没有调用其 WPS COM，没有把开发端专用 Skill 当作服务器已集成。实际加载 SHA 与固定上游 ref 见随包设计规则及 provenance。

记录指标	设计 Skill + 普通 DSH	相同 Skill + Motif	相同 Skill + Motif + RSI
确认成品 / 排程	2/2	2/2	2/2
真实上游请求	41	41	37
全部 token	1,638,112	1,294,345	1,129,100
API 代理估费	$0.093625	$0.063471	$0.059278
verified 整次请求旁路	0	2	2
记录运行时间	3.76 分钟	2.61 分钟	2.51 分钟

仅双方确认有成品的 2 个任务：相同 Skill + Motif 相对普通组，记录请求减少0.00%，token 减少20.99%，代理估费减少32.21%。这只是成品子集统计，尚未建立相同质量，也不是因果归因。

仅双方确认有成品的 2 个任务：相同 Skill + Motif + RSI 相对普通组，记录请求减少9.76%，token 减少31.07%，代理估费减少36.69%。这只是成品子集统计，尚未建立相同质量，也不是因果归因。

RSI 提案次数 1；独立机械认证：通过。复用的布局学习资产原先记录 3 次真实请求，代理估费 $0.002021。机械/几何目标不能证明审美质量；新 Skill 和策略也不称学得 Motif。

人工盲评、修订分钟、开发与维护人力、实际账单均须另核。所有未交付、失败、跳过和缺失计量在后文逐项展示；旧实验与历史失败没有被本轮覆盖。

1 / 数据集与真实任务

本 cohort 包含 2 个自定义科研 PPT 任务、2 个来源版本，每题输入份数为 1；不是仓库 18 项合成科研决定中的任务子集。论文文件先下载本机再传服务器，任务、来源、工具和配置均保留版本哈希。重复来源按 SHA 去重计数，不能把题目数当作完全独立来源集合。

P1/P2 分别再次使用 RAG 和 QLoRA，题面显式加入原稿审查发现的科研条件遗漏。其用途是检查修复和用户反馈能否改善交付；可在当前相同反馈条件下进行组间对照，不能用来回补原矩阵质量，或宣称未经见过材料的泛化收益。

任务 / 来源	交付	真实任务要求
P1 / RAG 审查后工程试跑 rag.pdf	8 页 / lab / generate	为了解生成模型但尚未实现检索增强的同学制作8页中文RAG组会汇报，约10分钟，封面计入8页。至少一个原生可编辑流程、一张通过图注定位的原图、清晰结果证据和局限。根据原文组织叙事。已有草稿审查发现以下错误，本次必须独立核对而不是照搬：Table 1测试集与消融Table 6开发集不能混称；标准TriviaQA测试集并非RAG全面超过DPR，TQA-Wiki中没有DPR数字的列不能声称实测超过；不能称四个问答数据集全SOTA；DPR初始化已有监督，不能说作者未报告监督；明确文档编码器/索引固定，仅训练查询编码器和生成器；流程区分训练与推理。必要条件、指标/单位、比较范围放正文，notes补充出处。不要把不同任务的指标画成可直接比较的排行榜，不生成自评或修订过程说明。
P2 / QLoRA 审查后工程试跑 qlora.pdf	7 页 / academic / generate	制作7页中文QLoRA工程决策汇报，回答有限显存如何微调大模型。封面计入7页，包含原生可编辑机制流程和一张准确原图，解释NF4、双重量化和分页优化器的关系。已有草稿有条件遗漏，本次根据原文独立核对：正文必须明确65B模型、单GPU48GB是微调结论，训练显存与部署/推理显存严格区分；99.3%等相对分数须在正文指出ChatGPT基准和GPT-4评判方式，不能作为泛化能力百分比；所有效果数字须含对应基准与条件；FP4/NF4相对差异须指定比较条件；分页优化器避免内存峰值不能说会普遍提升训练速度。不把条件藏在notes，不写列3见备注/生成检查等制作说明。最后给出适用条件与原文未证明的边界。

训练、认证与前瞻 API 评测分别记录

布局训练和认证读取历史真实 DeepSeek 页面计划，再用当前渲染器实际执行，属于历史确定性重放；它不新增论文理解请求。训练至少两条正常计划，留出认证采用不同来源运行，认证结果不能继续反馈给同一候选调参。本 cohort 新 API 结果另记；不把旧计划重放和新云 API 对照合并成一次试验。

当前题面由研究者自定义。每题每组一次运行，只是实际 API 工程实验，不支持统计显著性或课题组长期使用收益。

2 / 让模型在结果出现之后做决定

模型仍负责理解原文、选材、叙事、实验条件与图件解释。工具返回真实 source_id、文本、图注候选和校验反馈后，模型再决定后续动作；图件不能仅按位置猜测，跨论文数值不能被包装成同条件排名。

阶段	实际执行 / 决定	责任
输入与来源选择	用户 PDF/PPTX 与要求 → 模型决定 pin_source	大模型
结构化来源衔接	pin_source 返回 source_id → 版本/证据守卫 → read_source	认证 Motif 图边
阅读与科研叙事	读回文本/图注后，决定页面内容、条件、原图与局限	大模型
可编辑生成	JSON 契约 → 字号、留白、短结论、原生流程/图表 → PPTX	确定性代码
实际质量反馈	LibreOffice → PDF/PNG、页数、文字、notes、来源、SHA	真实工具与代码
失败恢复	守卫不成立回交模型；候选布局失败保留并回退默认策略	有界回退
最终交付	再次核对文件及预览证据，确认后登记交付	MCP

RSI 的结果后学习

DeepSeek 读取训练草稿的真实渲染诊断，在七字段布局协议内提出完整 JSON：媒体方位/面积、正文列数/字号、表格字号和间距。每次失败也消耗持久化三次提案配额。候选只改变布局，保持文字、事实、页数、来源和 notes；训练成功不自动启用，另在冻结留出上核验。

提案	训练判定	真实反馈摘要
1	True	{"passed": true, "baseline": {"cases": 2, "failed": 0, "image_count": 5, "mean_image_area": 18.9529485733999}, " candidate": {"cases": 2, "failed": 0, "image_count": 5, "mean_image_area": 22.38322557034213}, " content_unchanged": true, "image_area_gain": 0.18098909431731158, "objective": " geometry_proxy_only_not_aesthetic_certification"}

任何模型调用前已选好的路线不能冒称科研决定已自动完成。当前 RSI 是受限布局策略学习，未生成新工具，未生成新的 Motif/code node。

独立门槛	冻结证据的机械结果
训练	{"passed": true, "baseline": {"cases": 2, "failed": 0, "image_count": 5, "mean_image_area": 18.9529485733999}, " candidate": {"cases": 2, "failed": 0, "image_count": 5, "mean_image_area": 22.38322557034213}, " content_unchanged": true, "image_area_gain": 0.18098909431731158, "objective": " geometry_proxy_only_not_aesthetic_certification"}
留出认证	{"passed": true, "baseline": {"cases": 2, "failed": 0, "image_count": 2, "mean_image_area": 27.16283333206607}, " candidate": {"cases": 2, "failed": 0, "image_count": 2, "mean_image_area": 33.0104111660588}, "content_unchanged": true, "image_area_gain": 0.21527864057869062, "objective": "geometry_proxy_only_not_aesthetic_certification"}

mean_image_area 的单位为渲染器画布平方英寸；image_area_gain 是媒体面积相对变化，不能解释为审美评分。失败率下降或训练平均原图面积至少增加 10% 是预先固定的机械目标；留出只检查不回归。

3 / 与普通 DSH 的流程对比

维度	普通 DSH	Motif	Motif + RSI
设计规范	相同独立科研设计 Skill	相同 Skill	相同 Skill
在线来源读取	模型在 pin 结果后决定 read	认证短边绑定本次句柄后实际读取	相同读取 Motif
科研理解 / 内容	DeepSeek	DeepSeek	DeepSeek
渲染布局	新版默认策略	相同默认策略	冻结机械认证候选；失败回退默认
工具集合/顺序	同一批准 MCP 集合	相同集合	相同集合
思考 / 压缩	off / 默认关闭	相同	相同

哪些是 graph、code 与模型

graph 是历史真实轨迹独立认证的 pin_source → read_source 依赖、参数来源及版本证据；它实际跳过一次来源读取调度请求，读取工具仍执行。n 份文档可以触发多次该短边，不能固定说每个多文档任务只旁路一次。code 是导入清洗、图件提取、契约校验、可编辑渲染与预览交付。模型是科研判断与从真实反馈提出布局策略。Skill 是提示规则，七字段策略是受限配置，均不当作 Motif 核心机制。

普通组也有相同设计 Skill 和新版渲染器，因此三组成本差不测量“旧模板 → 新版设计”的总体收益。历史旧/新草稿回放只能辅助观察布局；新 API 三组才验证实际云请求成本。运行间随机生成与失败重试都能改变调用总量，不能把全部差额归于认证旁路。

4 / 费用比较

组别	命中输入	未命中输入	输出	代理估费
设计 Skill + 普通 DSH	1,521,408	61,720	54,984	$0.093625
相同 Skill + Motif	1,196,288	68,195	29,862	$0.063471
相同 Skill + Motif + RSI	1,035,520	65,812	27,768	$0.059278

累计口径与失败成本

上表统计本矩阵所有已启动模型的运行，包含未交付、重试与恢复，不把失败费用删掉。跳过或尚未启动的组不伪填零；缺失账本保留“未知”。学习费用另列，没有摊入少量评测成果来宣称收费或投资回报。

费用项	真实请求	API 代理估费	人力 / 实付
新 API 三组矩阵	119	$0.216374	未知
共享 RSI 资产历史学习（不新增计费）	3	$0.002021	未知
历史草稿真实重放 / 本报告	0 新增模型请求	0 新增云请求费用	渲染算力与辅助人力未计价
人工盲评 / 人工修订	不适用	未采集	未知
模型账单核对	待核	上表不是账单	实际支付未知

双方确认成品子集：相同 Skill + Motif 对照 2 题，估费 $0.093625 → $0.063471；运行时间 3.76 分钟 → 2.61 分钟。尚未同质量合格，不能称为合格成果总成本下降。

双方确认成品子集：相同 Skill + Motif + RSI 对照 2 题，估费 $0.093625 → $0.059278；运行时间 3.76 分钟 → 2.51 分钟。尚未同质量合格，不能称为合格成果总成本下降。

稳定系统提示前缀与工具顺序有助于缓存，但本报告只记录实际缓存 token；Provider 面向请求的完整 schema 哈希和内部重试策略若入口未采集，仍列缺失。不能用总 token 等比例替代真实费用。

5 / 调用次数与全部运行记录

全部矩阵排程均展示；“会话完成”“程序交付”“质量合格”是不同条件。下表不隐藏错误、未运行或缺少布局认证的第三组。完整匿名化 CSV/JSON 与文件哈希随包提供，原始账本与模型轨迹继续留在服务器保护目录。

任务 / 组	状态 / 成品	请求 / 旁路	token	估费
P1 / 设计 Skill + 普通 DSH	会话完成 有确认成品	27 / 0	1,338,097	$0.074603
P1 / 相同 Skill + Motif	会话完成 有确认成品	27 / 1	930,013	$0.040823
P1 / 相同 Skill + Motif + RSI	会话完成 有确认成品	19 / 1	623,960	$0.034631
P2 / 设计 Skill + 普通 DSH	会话完成 有确认成品	14 / 0	300,015	$0.019022
P2 / 相同 Skill + Motif	会话完成 有确认成品	14 / 1	364,332	$0.022647
P2 / 相同 Skill + Motif + RSI	会话完成 有确认成品	18 / 1	505,140	$0.024648

本矩阵记录候选布局回退 1 次。失败的候选目录和诊断保留在服务器；本包只交付已确认原稿，不用辅助修订稿替换模型初稿。矩阵停止原因：未记录停止原因。

6 / 报告质量与评审边界

机械门槛检查可编辑文字、页数、来源页码、notes、预览实际文件和版本完整性；布局机械认证检查内容保持、真实渲染失败率以及媒体几何面积。它们不能替代科学事实正确、实验条件充分、故事连贯和审美质量。

门槛	能验证	不能代替
来源 / 哈希 / notes	文件来源和引用追溯、版本一致	事实支持关系、结论是否过强
实际 PDF / PNG 渲染	文件可打开、页数和文字在画布范围	远距离投影可读、排版精美
布局 RSI 独立认证	七字段规则、内容保持、几何代理与真实执行	美学、科研质量或请求下降
AI 辅助逐页审查	可定位错图、遗漏和明显视觉问题	独立人工盲评和实测修订分钟
人工统一质量门槛	待独立使用者审阅	当前尚未建立同质量成本证据

任务 / 组	目前审查	明确问题
P1 / 设计 Skill + 普通 DSH	AI 辅助审查：需要修订	页 8：标题“学习到的检索优于替换或冻结”没有限定任务，但同页FEVER-3表中BM25替换75.1高于完整RAG-Token74.5。原文第7–8页Table 6明确：学到检索相对冻结在各任务提升，而相对BM25的例外是FEVER。本页数值、开发集和准确率口径均正确，notes也记录例外；需在可见标题或短结论中保留该反例，例如“学到检索改善开放域QA；FEVER上BM25更好”，避免标题与表格冲突。 页 7：FEVER三分类与最优流水线“差4.3%”宜写“差4.3个百分点”，并标注标签准确率。原文第6页Table 2为76.8对72.5，属于百分点差；已有三分类和监督差异限定，不应据此把差距归因于监督本身。 页 6：Figure 3完整保留三子图与图注，正文对NQ EM、K=10峰值及任务不同的解释与原文第8页吻合，没有把图解读成索引热替换证据；但小坐标和四条曲线的图例仍不易在正常投影中细读。可附左图局部放大或更大原图，实际投影尚未人工核验。正文“三条曲线”宜改“三个子图”，图内实际包含多条曲线。 页 5：标题明确为推理且notes区分RAG-Token/Sequence，但逐文档生成与整序列概率相乘求和主要是在解释RAG-Sequence，未在可见页面标出变体；第4步换索引属于条件变化后的更新操作，非每次问答必经步骤。可标注“以RAG-Sequence为例，索引更新为可选操作”，保留训练/推理已分开的改进。

任务 / 组	目前审查	明确问题
P1 / 相同 Skill + Motif	AI 辅助审查：需要修订	页 5：表把Jeopardy“事实性”列成BART7.1%与RAG42.7%，却未在可见表格标明是452对生成中被评为“更事实”的比例，易被读成两模型各自的绝对事实准确率。原文第6页4.3及第8页Table 4是BART better/RAG better成对人评，RAG为Token变体，还存在Both good/Both poor/No majority等类别。notes虽写人工成对评价，正文仍应改“Jeopardy成对更事实比例（452对）”，不把这些百分比和QA EM拼成同口径质量指标。 页 5：QA表RAG列实际混用Sequence（NQ44.5、TQA56.8、CT52.2）与Token（WQ45.5）最佳分数，未标变体；NQ36.6和WQ44.7对照对应T5-11B+SSM，而非未加SSM的T5-11B。数值与原文第6页Table 1一致，但表头应标“最佳RAG变体”或逐行注明变体，并写完整T5-11B+SSM名称和EM百分比单位。notes已有CT/WQ从NQ初始化及TQA划分，建议保留这些条件。 页 7：Figure 3完整且关于K/召回/峰值的解读与原文一致；正文“RAG-Token约10篇见顶”宜加“NQ EM”，避免误解为所有生成指标都见顶，原文MS-MARCO的Rouge-L和Bleu-1变化不同。另“BM25仅在FEVER更好”来自Table 6消融，宜在可见正文加“开发集消融”，原图本身不是该结论的证据。图中小坐标/图例仍需真实投影可读性核验。 页 1：封面标题把“边界”拆为第一行末“边”和第二行“界何在”，未越界但阅读节奏不自然；可缩短标题或按完整词组主动换行。第3页标题也较长，图件内部标签与长图注偏小，可在设计修订时一并调整。
P1 / 相同 Skill + Motif + RSI	AI 辅助审查：未观察到重大问题	页 6：可见标题清楚区分推理，notes正确注明QA的Token15篇、Sequence50篇及不同解码预算，符合原文第17页；但四行用连续箭头连接Token、Sequence、Thorough、Fast，容易把不同变体/近似当作每次推理串行四步。可改成两条分支或标注“可选解码方式”，并把15/50篇放到可见页面。 页 7：正文已正确注明测试集Exact Match，表中Sequence/Token/DPR各行、标准TQA列及NQ/WQ数值均与Table 1一致；EM百分比单位只在notes，宜在可见表头补“EM（%）”。第8页开发集也宜补同一单位。未观察到测试/开发集混淆。 页 4：Figure 1完整且与检索、生成及边缘化讲解相符，未裁错图或伪造方法部件；相较文本区域图件占比更大，但原图内部示例文字仍较小。此处只观察到方法图可作总览，不确认真实投影时能细读图内全部标签；可另附高清原图或局部放大。 页 2：标题“来源不可查”和正文“无法为预测提供依据”比原文第1页“难以直接解释预测、provenance仍是开放问题”更绝对。可收敛为“来源难追溯、依据难解释”，保留混合记忆能检查/替换知识的动机，避免把一般困难写成逻辑不可能。
P2 / 设计 Skill + 普通 DSH	AI 辅助审查：需要修订	页 6：41GB/21GB/5GB/10GB及相对ChatGPT数值与原文第10页Table 6相符，正文也已给出Vicuna 80条提示与GPT-4的10分制评判，但表头仍仅写“显存”。这些数字是4-bit模型的部署/权重占用，不是本稿主题中的微调训练显存；区分仅在本页notes。第1页又称报告聚焦微调训练阶段，易使此表成为工程显存误读。应在表头直接写4-bit部署/权重显存，避免把41GB当65B微调需求。 页 2：5048MB、26MB和567MB与原文第4页一致，正文已写7B案例，但LLaMA、FLAN v2、batch size 1、LoRA约0.2%的测量条件只在notes。应补简短表注，并明确“激活/输入梯度比LoRA参数占用大”指适配器相关开销；此案例4-bit基座5048MB仍大于输入梯度567MB，不能用当前泛称让读者误解梯度大于全部权重显存。 页 6：本页对相对ChatGPT分母和非泛化能力含义已作正确限定，但Guanaco 65B的95%置信半宽±4.4%及多个模型区间重叠只在notes。原文第9—10页以此说明99.3%不能作为无不确定性的质量等价结论，建议正文保留这一简短边界。

任务 / 组	目前审查	明确问题
P2 / 相同 Skill + Motif	AI 辅助审查：需要修订	页 5：正文写“GPT-4按百分制给分”，与QLoRA原文第9页及本页notes的0—10分制矛盾。原协议是GPT-4对同一查询的ChatGPT与目标模型回答各打十分制分数，再计算相对ChatGPT得分百分比，并对两种回答顺序取均值。应纠正评分量尺，正文同时注明Vicuna的80条提示，防止将相对百分比当作GPT-4原始百分制评分。表中的114.5%、99.3%、97.8%未见数值错误。 页 5：表头称95%置信区间，却只列2.6%和4.4%这类半宽，未写±也未给区间端点。原文第10页Table 6的对应值是均值旁的置信半宽，建议表头改95% CI半宽(±)，或直接写99.3%±4.4%等，避免把4.4%误读为完整区间。正文已经保留区间较宽的说明。 页 7：本页正确否定分页优化器普遍提速，但“实测训练速度与常规优化器一致”仅在notes限定65B、48GB GPU、batch size 16。原文第6页没有对所有长序列小批次情形建立同速保证；建议把该具体测量条件移入正文，保留可能减速尚待刻画的边界。
P2 / 相同 Skill + Motif + RSI	AI 辅助审查：需要修订	页 4：原图确实定位到QLoRA第3页Figure 1且未见裁切，但正文把它描述成“横轴为各类微调方法，纵轴为显存需求”。实际图是Full Finetuning、LoRA、QLoRA的组件示意，纵向排列优化器状态、适配器和基座，箭头区分参数更新、梯度流及分页流；没有横纵坐标或定量显存刻度。应按组件与数据流解释，不能让读者按不存在的显存坐标读取数量或阶梯。 页 5：Pile CC困惑度34.34/31.07/29.48/27.41和MMLU 53.0/52.2/53.1均与原文Table 2、4一致，且已区分指标方向。但池化条件只有notes：困惑度是125M—13B的OPT/BLOOM/LLaMA/Pythia均值；MMLU是LLaMA 7/13/33/65B在Alpaca与FLAN v2上做适配器微调后的5-shot测试准确率均值。建议在正文表注保留模型与数据范围，并标MMLU为准确率(%)，避免把两组聚合结果当同一模型上的量化对照。 页 7：正文“68B/33B匹配16-bit全量微调未被证明”中的68B应为65B。原文第15页Limitations明确未建立33B和65B规模上的全量16-bit微调等价性，本页notes及takeaway都使用65B；这是正文规模笔误，应更正。训练和部署显存的区分在本轮正文已明确。 页 6：正文已正确说明Vicuna 80条提示、GPT-4评判、ChatGPT相对分母及非泛化能力含义，但Guanaco 65B的95% CI±4.4%及性能区间重叠只在notes。建议将简短不确定性说明移入正文，避免把99.3%当精确的质量等价结论。

未评审就写未评审。没有人工评审者、统一评审记录和修订时间，本报告不会生成“质量等价”“更优美已被证明”或“可收费”的结论。

7 / 逐题展示：全部页面原稿

每个任务的三组原稿用全页拼图展示，连续页号对应复制的真实 PNG。index.html 同时提供逐页并排、PPTX、PDF 与高清拼图；页面顺序相同不意味着生成内容一一相同。失败和跳过保留空位。

P1 / RAG 审查后工程试跑
设计 Skill + 普通 DSH

运行 d574acdec6564ec0961e5070376e2142 · 会话完成 · 请求 27 · token 1,338,097 · 估费 $0.074603

AI 辅助审查：需要修订

RESEARCH BRIEF

RAG：让生成模型能查资料、可追溯、可更新

- 内容依据 Lewis 等《Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks》
- 面向：已了解生成模型、尚未实现检索增强的同学

1 / 8

01 / 08

纯参数化记忆的三个缺口，引出检索这一条路

参数记忆之外，需要一个可读可写的外部知识源

- 知识难扩充难修改：改知识要重新训练
- 预测缺溯源：无法给出依据文档
- 易产生幻觉： GPT-2 等模型存在该风险
- 已有混合记忆工作只做抽取式问答

2 / 8

02 / 08

RAG 的两个部件：检索器给文档，生成器写答案

参数记忆负责生成，非参数记忆负责提供依据

- 检索器由 DPR 双编码器给出 top-K 文档
- 非参数记忆： 2018 年 12 月维基， 21M 个 100 词块
- 生成器为 BART-large，约 400M 参数
- 输入与文档拼接后送入 BART 生成

3 / 8

03 / 08

训练时文档编码器与索引固定，只更新查询编码器和生成器

文档编码器与索引保持固定，只训练查询编码器和生成器

维基切块建索引	2018 年 12 月维基切成 21M 个 100 词块，编码器离线建 FAISS 索引
查询编码器检索	查询与文档分别编码，内积取 top-K， k 在训练时取 5 或 10
生成器拼接生成	输入与每个检索文档拼接， BART 生成序列概率
按负对数似然端到端	对 top-K 边缘化后最小化目标负对数似然，仅微调查询编码器与 BART

4 / 8

04 / 08

推理沿用同一套部件，知识来自可替换的索引

换索引即可更新世界知识，参数不用重训

编码查询并检索	查询编码器编码问题，在固定 FAISS 索引中取 top-K 文档
逐文档生成	输入与每篇文档拼接， BART 生成候选序列并给出得分
按概率汇总输出	生成概率与检索先验相乘再求和，得到最终答案
换索引更新知识	只替换非参数记忆索引，无需重新训练参数

5 / 8

05 / 08

检索更多文档：结果因模型与任务而异

RAG-Sequence 的 NQ EM 随 K 单调提升， RAG-Token 约在 K=10 见顶

- 横轴为推理时检索文档数 K （10–50）
- 三条曲线任务与指标不同，不是同一排行榜

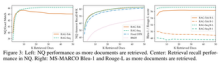


Figure 3: Left: NQ performance as more documents are retrieved. Center: Retrieval recall performance in NQ. Right: MS-MARCO Bleu-1 and Rouge-L as more documents are retrieved.

6 / 8

06 / 08

结果边界：可比范围、初始化监督来源与生成质量

成绩表述限于开放域 QA 且分划分讨论，不能作统一排名

- 测试集 Table 1 指标为 EM；检索器由 DPR 初始化，监督来自 NQ 与 TriviaQA
- 标准 TriviaQA 用公开 Web Dev 划分： RAG-Tok 55.2 低于 DPR 57.9
- TQA-Wiki 列 DPR 无对应数值，不作实测超过 DPR 的声明
- FEVER 3 类与最优流水线差 4.3%，且未用检索证据监督

7 / 8

07 / 08

消融证据：学习到的检索优于替换或冻结

- 同一口径： EM 或标签准确率，均为开发集消融

开发集任务	RAG-Token	BM25 替换	冻结检索器
NQ （EM）	43.5	29.7	37.8
TQA （EM）	54.8	41.5	50.1
FEVER-3 （准确率）	74.5	75.1	72.9

8 / 8

08 / 08

8 页 / 原 PPTX SHA256 4fe0b66871faa8b1cba2… / 完整文件与高清逐页证据见随包导航

P1 / RAG 审查后工程试跑
相同 Skill + Motif

运行 edfb0e4ad42e40468670208f140d237a · 会话完成 · 请求 27 · token 930,013 · 估费 $0.040823

AI 辅助审查：需要修订

RESEARCH BRIEF

检索增强生成（RAG）：为何有效、在哪有效、边界何在

- 面向多任务的知识密集型 NLP 统一方案
- 参数记忆 + 维基百科稠密向量索引
- 组会精读：来源与条件边界并重

1 / 8

01 / 08

参数记忆的三个缺口：这正是 RAG 要回答的问题

把维基百科做成可检索非参数记忆，来源可查、可替换

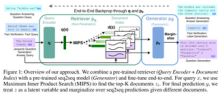
- 知识难扩写或修订，更新需再训练
- 决策链难追溯，缺少出处
- 可能输出事实错误内容

2 / 8

02 / 08

RAG 的一次问答怎么跑：先编码查询，再检索，最后由生成器写出答案

- 查询编码后做过 MIPS 近似检索
- 检索到的维基段落与问题拼接输入
- 生成器输出答案文字



3 / 8

03 / 08

训练与推理是两件事：训练只更新查询编码器和生成器

文档编码器与索引全程固定，训练只改查询编码器和生成器

任务输入输出配对	用输入输出对，最小化负边际对数似然，不监督该取哪篇文档
检索器给候选文档	沿用 DPR 预训练双编码器初始化，取 top-K；文档编码器与索引固定
生成器预测并边缘化	BART-large 拼接输入与文档；按整句或按 token 边缘化，训练回传查询编码器
推理分两种解码	RAG-Token 接常规 beam；RAG-Sequence 逐文档 beam，可选 Thorough 或 Fast 解码

4 / 8

04 / 08

结果分任务看：问答测试分数与人工评价

四个问答集里三个刷新 SOTA，TriviaQA 常规划分除外

- 标准 TriviaQA 上 RAG 未超 DPR
- 指标口径不同，勿拼排行榜

任务与指标	对照	RAG
NQ EM	T5 36.6	44.5
TQA 常规 EM	DPR 57.9	56.8
WQ EM	T5 44.7	45.5
CT EM	DPR 50.6	52.2
Jeopardy 事实性	BART 7.1%	RAG 42.7%

5 / 8

05 / 08

抽取式与生成式：RAG 省掉了什么，代价是什么

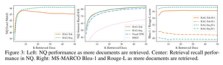
抽取式路线（如 DPR 系统）	RAG 生成式路线
从检索文档抽取答案片段	直接生成答案文本
需重排序器与抽取式阅读器	无需重排序器与阅读器
依赖文档含答案原文	答案不在文档中也答对

6 / 8

06 / 08

检索文档越多越好吗：收益与拐点同在

- 更多文档利好召回，生成端有拐点
- RAG-Token 在约 10 篇时见顶
- BM25 仅在 FEVER 优于稠密检索



7 / 8

07 / 08

能做什么、不能声称什么

换知识不必改模型，但真假仍取决于外部知识源

- 四个问答集并非全面 SOTA：TriviaQA 常规划分低于 DPR
- 索引可热替换，但改不了生成器本身的错
- 部分任务检索坍塌后性能退回 BART 水平

8 / 8

08 / 08

8 页 / 原 PPTX SHA256 ade7e643bb33820cb96a… / 完整文件与高清逐页证据见随包导航

P1 / RAG 审查后工程试跑
相同 Skill + Motif + RSI

运行 e81d41a7e1a54f8ea504957ebde953ee · 会话完成 · 请求 19 · token 623,960 · 估费 $0.034631

AI 辅助审查：未观察到重大问题



8 页 / 原 PPTX SHA256 d6f63817fe4e081287b3… / 完整文件与高清逐页证据见随包导航

P2 / QLoRA 审查后工程试跑
设计 Skill + 普通 DSH

运行 d6e01e993f494a9c9852ec4fb3f75fa8 · 会话完成 · 请求 14 · token 300,015 · 估费 $0.019022

AI 辅助审查：需要修订

QLoRA： 单卡 48GB 微调 65B 模型的证据与边界

报告聚焦微调训练阶段，不与推理显存混用

- 结论范围： 65B 参数模型、单张 48GB GPU
- 训练显存降到 48GB 以下，非部署显存
- 适用于 LoRA 适配器微调，不改动基座权重

01 / 07

常规 16-bit 微调为何在单卡上不可行

训练显存瓶颈是激活与梯度，不是可训练参数

- 16-bit 全量微调 65B 需超过 780GB 显存
- 训练显存主要来自激活梯度而非适配器
- 7B 案例：基座 4-bit 占 5048MB
- LoRA 参数仅 26MB ，输入梯度 567MB

02 / 07

三层机制： NF4 、双重量化与分页优化器

三者分别压缩权重、压缩量化常数、吸收峰值

NF4 量化权重	对零均值正态权重按分位数离散为 4-bit
计算时反量化	存储 4-bit ，前向反向反量化到 BF16 做矩阵乘
双重量化常数	再量化 32-bit 量化常数，按 64 块降至 0.127 bits
分页优化器兜峰	优化器状态用统一内存， OOM 时换出到 CPU 内存

03 / 07

第 3 页 Figure 1： 各微调方法的显存需求

显存下降来自 4-bit 量化与峰值处理两步

- 图示 16-bit 、 LoRA 、 QLoRA 的显存阶梯
- QLoRA 再降 4-bit 量化与显存峰值

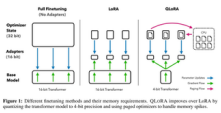


Figure 1: Different finetuning methods and their memory requirements. QLoRA improves over LoRA by quantizing the transformer model to 4-bit precision and using paged optimizers to handle memory spikes.

04 / 07

NF4 对 FP4 的差距必须限定比较条件

该差距是 MMLU 单口径均值，非普遍能力差距

- 条件： LLaMA 7-65B ， Alpaca 与 FLAN v2
- 5-shot MMLU 均值： BF16 53.0 ， FP4 52.2
- NF4+DQ 53.1 ，与 BF16 持平
- FP4 整体落后约一个百分点

05 / 07

99.3% 是相对 ChatGPT 的偏好分数

相对分数衡量偏好，不表示泛化能力的百分比

- Vicuna 80 条 prompt ， GPT-4 按 10 分制打分后取 ChatGPT 得分占比

模型	显存	相对 ChatGPT
GPT-4	-	114.5%
Guanaco 65B	41 GB	99.3%
Guanaco 33B	21 GB	97.8%
Guanaco 7B	5 GB	87.0%
Alpaca 13B	10 GB	69.4%

06 / 07

适用条件与原文未证明的边界

显存可行性与速度收益需按各自条件分别判断

- 已证：单张 24/48GB GPU 可训 33B/65B
- 分页优化器在 batch size 16 下训练速度持平，未测更广情形
- 训练显存降低不等于推理显存或成本降低
- 原文未给出分页普遍提速结论

07 / 07

7 页 / 原 PPTX SHA256 5f44a7fae2b7a92b65bc… / 完整文件与高清逐页证据见随包导航

P2 / QLoRA 审查后工程试跑
相同 Skill + Motif

运行 4b1045ea19e24b62a92ea1efa4e0597f · 会话完成 · 请求 14 · token 364,332 · 估费 $0.022647

AI 辅助审查：需要修订

RESEARCH BRIEF

QLoRA 工程决策：有限显存下微调大模型

- 围绕 65B 模型单卡 48GB 的微调可行性
- 依据原文 QLoRA 论文独立核对机制与数据

1 / 7

01 / 07

三件机制分别解决量化精度与显存峰值

NF4 管精度，双重量化管常数开销，分页优化器管峰值

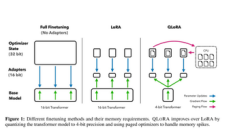
4-bit NF4 量化	对零均值正态权重做分位量化，比 FP4/Int4 精度更高
双重量化常数	把第一次量化的常数再用 FP8 量化，减少常数开销
前向反传去量化	4-bit 存储权重去量化为 BF16，再做 16-bit 矩阵乘
分页优化器	优化器状态用统一内存，显存不足时换出到 CPU

2 / 7

02 / 07

原文图：不同微调方法与显存需求对比

- 显存需求随方法变化，QLoRA 在 65B 上保持单卡可行



3 / 7

03 / 07

NF4 相对 FP4 的优势有明确比较条件

- 同为 LLaMA 7–65B 、 Alpaca 与 FLAN v2 上的 5-shot MMLU 均值
- FP4 一致落后 16-bit 基线约 1 个百分点

数据格式	平均 5-shot MMLU 准确率
BFloat16 基线	53.0
Float4 (FP4)	52.2
NFloat4 + 双重量化	53.1

4 / 7

04 / 07

99.3% 是 ChatGPT 基准下的相对分数

- GPT-4 按百分制给分，再换算为 ChatGPT 得分的百分比
- 该分数可超过 100%，且置信区间宽

系统	相对 ChatGPT 得分	95% 置信区间
GPT-4	114.5%	2.6%
Guanaco 65B	99.3%	4.4%
Guanaco 33B	97.8%	4.4%
ChatGPT	100%（基准）	—

5 / 7

05 / 07

训练显存与部署显存必须分开看

微调（训练）显存	部署（推理）显存
65B： >780GB 降至 <48GB	65B： 41 GB
单卡 48GB 可微调 65B	33B： 21 GB
33B： 24GB 卡、12 小时内	13B： 10 GB； 7B： 5 GB

6 / 7

06 / 07

适用条件与原文未证明的边界

分页优化器避免显存峰值，不等于普遍提速

- 结论限于 65B 级模型、单卡 48GB 的 4-bit 适配器微调与学术基准评测
- 分页优化器无硬测量：仅长序列小批次触发，且实测训练速度与常规优化器一致
- 因此它避免显存峰值导致 OOM，未证明普遍提升训练速度
- 原文未证明性能—精度权衡临界点，也提示当前基准可信度有限

7 / 7

07 / 07

7 页 / 原 PPTX SHA256 a4fcf9df861d3870f073… / 完整文件与高清逐页证据见随包导航

P2 / QLoRA 审查后工程试跑
相同 Skill + Motif + RSI

运行 26040c8776b7400bbd56f3561a374745 · 会话完成 · 请求 18 · token 505,140 · 估费 $0.024648

AI 辅助审查：需要修订



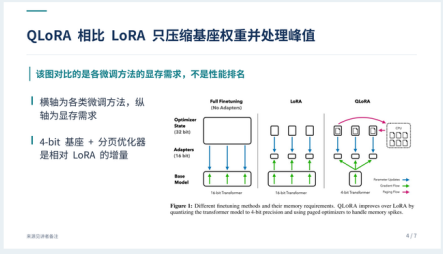
01 / 07



02 / 07



03 / 07



04 / 07



05 / 07



06 / 07



07 / 07

7 页 / 原 PPTX SHA256 b18ad44aabde2c22a712… / 完整文件与高清逐页证据见随包导航

8 / 学习成本、复现与适用范围

本 pilot 复用已有冻结布局资产，所列学习请求不是新增 pilot 费用。历史真实计划的训练/认证重放实际消耗服务器 CPU、LibreOffice 与文件 I/O，没有新增云模型请求。旧读取 Motif 的既有训练与认证成本属于历史资产，不能因为本轮复用而称为从零成本学到；本轮开发维护人力尚未计价。

有效配置	本次记录
experiment_id	research-ppt-v5-design-rsi-20261010
model	deepseek-flash
provider	deepseek-official
reasoning_effort	off
compression	disabled_by_public_entry_default
execution	steps
max_steps	40
max_output_tokens	6000
per_run_budget_cap_usd	0.75
total_budget_cap_usd	15.0
python	3.12.15
node	v22.23.2
libreoffice	LibreOffice 7.3.7.2 30(Build:2)

复现入口与数据

在 /root/autodl-tmp/xjj 启动项目环境；独立按 layout_learning 的 --prepare-training、cli improve、--certify 运行并冻结证据，然后使用 experiment_v5 --certificate ... --call-model 执行真实对照。无 --call-model 默认只预览，resume 不自动重复中断且费用未知的付费 run。此包包含匿名化有效配置和代码/来源哈希，原始私有轨迹、密钥和论文数据不随包分发。

适用范围与下一步

当前支持 PDF/PPTX 输入与可编辑科研 PPTX 的最小链路；source-read 短边只接管工具参数流，科学判断仍交给 DeepSeek。RSI 仅学习受限布局，未自动生成工具，也未建立通用美学裁判。下一步由用户或独立同学按统一内容和视觉门槛盲评这些原稿，记录修订分钟及真实账单，再决定是否冻结新默认布局或扩展 Motif；出现负面证据须保留与局部失效。

记录缺项：provider_facing_tool_schema_hash_and_order；provider_internal_retry_policy；provider_invoice；independent_human_blind_review；human_revision_minutes

未提交 / 未推送；本轮服务器实验与产物不代表团队仓库已同步。