科研 PPT Agent
跨重启交付与来源 Motif 实验

总的结果 / V7 / 2026-10-11

实际确认交付 14 份 PPT，共 74 页。两题各比较普通DSH与来源Motif，包含初稿、MCP进程退出和局部修订后交付。工具RSI的9个候选没有晋级，不能称本轮实现了新工具闭环。

评测组	真实请求	总token	代理估费	verified整请求旁路
普通 DSH	49	1,185,381	$0.068310	0
来源读取 Motif	76	2,682,129	$0.135886	5

上述比较仅为本次观察，科研质量未完成人工盲评，账单实付、人工修订时间、开发维护和服务器成本未知；不能宣称同质量合格总成本已下降。

E2来源Motif原始初稿失败：17次请求后未交付，实际反复提交7页而任务要求6页，却误归因于渲染器。后续有界恢复为工程端机械定位反馈介入，另存稿件，费用全部计入；原受控运行仍是失败，不能把额外恢复计成RSI成果或公平成功对照。

1 / 数据集与真实任务

角色	真实论文	任务与划分
工具训练	RAG / QLoRA	历史真实DeepSeek轨迹，公开论文，功能oracle全页
正常训练	ViT / DDPM	两项独立科研介绍，分别5页；续写不是新决定
独立轨迹认证	CLIP	5页视觉语言研究讨论
E1	MobileNetV2	5页倒残差/线性瓶颈与部署边界
E2	ConvNeXt + ResNet	6页机制与适用条件比较，无跨配置排行榜

新增论文先下载本机再上传服务器。来源均固定SHA；没有把5篇论文强制合成一个PPT。训练/认证与评测任务分开，重复任务只标为同一决定的修订。

2 / 让模型在结果出现之后做决定

开发端固定机械功能和独立oracle；DeepSeek真实提炼历史操作并生成TypeScript，执行AST检查、tsc和Node训练，失败结果反馈给模型。前两配置因JSON/语法和上下文错误停止；第三配置的最后候选通过真实PDF训练，却在非重叠重复摘录反例上失败。9候选上限耗尽，未accept、未解析隐藏BERT、未获认证、未用于新任务。没有手写候选替代模型。

配置	候选 / 编译通过	请求	总token	代理估费	结果
tool-learning-01	3 / 0	3	33,110	$0.011399	未晋级
tool-prompt-v2-01	3 / 1	3	33,476	$0.010891	未晋级
tool-functional-v3-01	3 / 1	3	38,106	$0.009657	未晋级

三配置是结果后工程迭代，费用全部计入，不能包装成预注册纯对照。原job、计数、源码和失败记录保留。RSI本轮提供了真实提案/失败反馈与拒绝机制的证据；没有新工具成功闭环或新的结构类型发现证据。

3 / 与普通 DSH 的流程对比

部分	实现	是否为Motif
解析、裁图、模板、可编辑渲染、验证、导出	确定性Python/TypeScript与MCP代码	否
重启恢复、局部修订、非目标页审计	版本绑定checkpoint与实际OOXML/LibreOffice检查	否
来源句柄的参数连接	新正常轨迹→离线参数边编译→独立认证→在线核验	是；拓扑仍是已有pin_source→read_source
论文理解、选材、科研主张和叙事	真实DeepSeek语义决策	继续需要模型
新证据工具	模型候选经过真实测试但未认证	未晋级，也不是Motif code_node

普通流程由模型决定pin后用哪个来源句柄读文本；来源Motif在工具参数、schema和来源版本证据满足时执行读取，并在真实结果复核后记录跳过整次请求。渲染或恢复的普通脚本能力不能计为Motif收益。

4 / 费用比较

任务	组	生成+修订请求	总token	代理估费
MobileNetV2	普通 DSH	23	453,441	$0.031267
MobileNetV2	来源读取 Motif	23	455,493	$0.028400
ConvNeXt + ResNet	普通 DSH	26	731,940	$0.037043
ConvNeXt + ResNet	来源读取 Motif	53	2,226,636	$0.107487

本轮全部已记录模型费用（包含工具失败、正常任务学习/认证、生成/修订和已运行的AI复核）：$0.368849；请求221。缓存命中、输出与失败重试影响估费，不能以总token代替账单。人评与修订分钟未知，学习成本尚不能计算合格任务上的可靠摊销。

5 / 调用次数与全部运行记录

任务/阶段	组	请求	缓存未命中 / 命中 / 输出	耗时秒	verified旁路
T1-vit/generation	普通 DSH	13	31,794/248,832/5,530	45.844	0
T1-vit/revision	普通 DSH	9	23,376/153,472/3,497	30.890	0
T2-ddpm/generation	普通 DSH	19	28,065/503,552/12,967	108.161	0
T2-ddpm/revision	普通 DSH	15	19,146/235,904/6,549	69.389	0
H1-clip/generation	普通 DSH	14	30,838/308,992/4,003	47.860	0
H1-clip/revision	普通 DSH	14	24,455/247,936/3,057	37.935	0
E1-mobile/generation	普通 DSH	14	19,870/285,824/12,175	62.950	0
E1-mobile/revision	普通 DSH	9	14,895/117,504/3,173	26.663	0
E2-convnext-resnet/generation	普通 DSH	13	47,275/440,960/7,355	48.123	0
E2-convnext-resnet/revision	普通 DSH	13	21,608/211,712/3,030	29.105	0
E1-mobile/generation	来源读取 Motif	11	20,469/195,584/5,886	40.546	1
E1-mobile/revision	来源读取 Motif	12	18,350/209,152/6,052	41.044	1
E2-convnext-resnet/generation	来源读取 Motif	17	50,248/796,160/19,804	85.089	1
E2-convnext-resnet/generation_recovery	来源读取 Motif	15	36,365/505,856/16,610	79.085	1
E2-convnext-resnet/revision	来源读取 Motif	21	42,226/748,672/10,695	70.577	1

CSV保存每次任务run ID与配置SHA；learning-review-run-index.json保存工具学习与辅助审查run及统计。原控制器因大写决定ID被公共协议拒绝，已另记修复并复用原初稿，未重跑付费生成；旧失败记录不覆盖。基线和Motif受控任务各只运行一次，E2有额外工程反馈恢复，顺序/缓存/随机性仍是限制。

6 / 报告质量与评审边界

工程诊断	状态	检查数量	付费请求
recovery-diagnostic-01	通过	19	0
stdio-diagnostic-01	通过	33	0

真实Node、LibreOffice和独立MCP进程诊断验证状态恢复、素材和完整计划、局部修订非目标页保持、来源/产物变化拒绝与旧验证撤销。它们不认证科学主张。

已付费任务的事后修订证据链核验：7 / 7。逐run检查真实恢复标记、revise_deck的新稿父链、最后页实际变化、非目标页OOXML、最终交付及checkpoint绑定；仅重交付旧稿不能算局部修订成功。

最终稿	AI辅助结论	问题数量
E1-mobile/普通 DSH	needs_revision	6
E1-mobile/来源读取 Motif	needs_revision	6
E2-convnext-resnet/来源读取 Motif	needs_revision	8
E2-convnext-resnet/普通 DSH	needs_major_revision	8

辅助模型返回稿件覆盖 4 / 4；缺失稿件不视作通过。模型审查意见也须人工核原文，不能直接当作已证实的科学错误。

AI辅助事实审查盲化分组和成本，并核查原文投影；不是独立人工盲评。精确摘录核对只是来源定位。视觉由另行逐页预览检查，审美及真实用户修订时间仍需用户评价。

E1-mobile/普通 DSH 第3页 [moderate] 图文版面页依赖“按真实图注几何候选提取的Figure 3整图”，但已声明 image_semantics=not_visually_reviewed；稿件同时把图注作为主张C03证据并把C04（扩张比>1）挂在同一图页说明中，图件本身含义与完整性未做视觉核验，却在正文中以图支撑结构差异主张。；原文第3页：“Figure 3: The difference between residual block [8, 30] and inverted residual. Diagonally hatched layers do not use non-linearities. ... Note how classical residuals connects the layers with high number of channels, whereas the inverted residuals connect the bottlenecks.” 与同页“when the expansion ratio is smaller than 1”相关段落分属第3/4页两处。

E1-mobile/普通 DSH 第5页 [moderate] 该页从原Table 4数值表改为“适用条件/待验证”文字页，但sources仍含第7页，且标题“这些结论在瓶颈信息假设成立且算力引擎相当时才适用”缺乏原文逐字支持；同时把“t在2到5以外的取值”与“其它分辨率下限”列为待验证，原文仅说“It remains to be seen if special framework level optimization may lead to further runtime improvements”，并未给出“2到5以外未验证”或分辨率物化内存下限的表述。；原文第6页：“We find that this approach is the most helpful to be used with t being a small constant between 2 and 5.” 与 “It remains to be seen if special framework level optimization may lead to further runtime improvements.”

E1-mobile/普通 DSH 第5页 [moderate] “适用：扩张比大于1、瓶颈间连接，内存由瓶颈张量主导”与原文条件存在过度泛化风险：原文说该内存论证是在把bottleneck residual block视为单一算子、把内部卷积视为可丢弃张量的前提下成立，并以“would be dominated”措辞陈述，并非对所有块无条件成立。；原文第6页：“if we treat a bottleneck residual block as a single operation (and treat inner convolution as a disposable tensor), the total amount of memory would be dominated by the size of bottleneck tensors”

E1-mobile/普通 DSH 第2页 [minor] 第一条bullet“ReLU后流形仍有非零体积，该部分只等价于线性变换”由notes中第3页性质列表支持，但正文bullet未在该行标注来源页码，读者容易将两条性质一并归入第2页。；原文第3页：“1. If the manifold of interest remains non-zero volume after ReLU transformation, it corresponds to a linear transformation.”

E1-mobile/普通 DSH 第4页 [minor] 步骤“1×1线性扩张”与原文Table 1里扩张层配ReLU6不一致：Table 1第一行含“1x1 conv2d , ReLU6”，流程条目标注“线性扩张”虽可由“两端1×1保持线性”语境理解，但标签本身与算子描述不符。；原文第4页：“h×w×k 1x1 conv2d , ReLU6 h×w× (tk)”

E1-mobile/普通 DSH 第5页 [minor] notes引用第5页Table 2来支撑“首个bottleneck的t=1、末层为1×1卷积与7×7平均池化”，但sources列表只列第6、5、7页顺序（第5页确有列入）；正文bullet未标注该数字来自Table 2而非Table 4，存在表号与页码对应不清。；原文第5页：“1122× 32 bottleneck 1 16 1 1” 与 “72× 1280 avgpool 7x7 - - 1 -”

E1-mobile/来源读取 Motif 第3页 [moderate] 与draft-A同类问题：图文页使用Figure 3的图注几何候选裁图，明确声明科学含义待人工审阅，但正文仍以该图作为连接点差异主张的版面性证据。；原文第3页：“Figure 3: The difference between residual block [8, 30] and inverted residual. ... classical residuals connects the layers with high number of channels, whereas the inverted residuals connect the bottlenecks.”

E1-mobile/来源读取 Motif 第5页 [major] 表格对比未交代关键比较条件：表内并列MobileNetV1/V2各条目取自Table 4同一表，但Top-1与MAdds对应不同配置文件（含宽度倍率差异），表格未标注每个条目的分辨率/宽度倍率，也未说明MobileNetV2 (1.4)使用224输入，读者容易把“参数量—MAdds—精度”当作可直接横向排序。；原文第7页：“MobileNetV1 70.6 4.2M 575M 113ms ... MobileNetV2 72.0 3.4M 300M 75ms MobileNetV2 (1.4) 74.7 6.9M 585M 143ms” 与 “Table 4: Performance on ImageNet, comparison for different networks.”

E1-mobile/来源读取 Motif 第5页 [moderate] notes引用第8页“the inference strategies, including multi-scale inputs and adding left-right flipped images, significantly increase the MAdds and thus are not suitable for on-device applications”来支撑“用户目标硬件延迟/内存上限需自行实测”，该原文讨论的是分割任务的多尺度/翻转推理策略，与“用户硬件延迟与内存上限”不是同一命题，存在跨任务外推。；原文第8页：“the inference strategies, including multi-scale inputs and adding left-right flipped images, significantly increase the MAdds and thus are not suitable for on-device applications”

E1-mobile/来源读取 Motif 第4页 [minor] 流程步骤“ReLU6把k通道按扩张因子t升到tk”把ReLU6写在升维描述里，而Table 1第一行是“1x1 conv2d , ReLU6”，ReLU6位于卷积之后，措辞顺序可能被读成ReLU6参与升维运算。；原文第4页：“h×w×k 1x1 conv2d , ReLU6 h×w× (tk)”

E1-mobile/来源读取 Motif 第4页 [minor] notes将“步长为1且通道一致时才相加”的依据归到第3页“we use shortcuts directly between the bottlenecks”与第4页identity说明，但原文第3页Footnote 3只说shortcut存在时信息损失更弱，未给出通道/步长匹配规则；该要点属推断。；原文第3页：“3We note that in the presence of shortcuts the information loss is actually less strong.”

E1-mobile/来源读取 Motif 第1页 [minor] bullet“在ImageNet分类、COCO检测、VOC分割上评测”与原文一致，但notes未注明原文用的是VOC“image segmentation”而第8页实验为PASCAL VOC 2012验证集mIOU；若读者追问评测口径，页内缺少任务级条件说明。；原文第1页：“We measure our performance on ImageNet [1] classification, COCO object detection [2], VOC image segmentation [3].”

E2-convnext-resnet/来源读取 Motif 第2页 [moderate] 流程步骤声称“AdamW与更强增广，300轮，作为固定基线”，但同页把该基线的证据页限定为doc_1第3页与第6页；第6页并不含300轮/AdamW配方原文，固定配方的原文出处是第3页2.1节。来源页与断言不完全对应。；原文第3页：“The training is extended to 300 epochs from the original 90 epochs for ResNets. We use the AdamW optimizer [46]…”（第3页）；该原文未出现在所列第6页。

E2-convnext-resnet/来源读取 Motif 第3页 [moderate] 正文与备注称“表2为10-crop测试，且比较的两组网络参数量一致”，并在同一bullet中给出ResNet 18层27.88与34层25.03。原文表2条件确为10-crop，但“参数量一致”的逐字依据在第5页“they have no extra parameter compared to the plain counterparts”，第5页文本中该表述紧接在ResNet-18/34对照描述处，用词为“no extra parameter”，而本页文字扩写为“参数量一致”，且未标注该条件的原文页码来源。；原文第5页：“Here the ResNets have no extra parameter compared to their plain counterparts.”（Table 2图注，第5页）；“So they have no extra parameter compared to the plain counterparts.”（第5页正文）

E2-convnext-resnet/来源读取 Motif 第4页 [major] 左栏写“始终使用BN与SGD，迭代至60×10^4次”“训练配方在两版网络中完全一致”，但所给来源只有doc_2第4页与doc_1第3页。第4页确实含SGD、60×10^4迭代、BN表述；但“两版网络中完全一致”的对象在原文中指plain/residual对照（第3页“fairly compare plain/residual networks that simultaneously have the same number of parameters, depth, width, and computational cost”），而本页sources未列第3页，读者无法从给定来源页核验该“完全一致”的适用对象。；原文第3页：“We can fairly compare plain/residual networks that simultaneously have the same number of parameters, depth, width, and computational cost (except for the negligible element-wise addition).”

E2-convnext-resnet/来源读取 Motif 第5页 [major] 表格把“81.5（减少归一化层）”归类为“单归一化层与LN”，并把“82.0”标为“独立下采样后”，但表格同时用“Swin-T为81.3”放在“单一GELU”行的同区间参考列，容易读成81.3是该步的对照结果；原文中81.3%的Swin-T是复用结果，“practically matching the performance of Swin-T”出现在fewer activations之后，而“surpassing Swin-T’s result”出现在fewer norms之后。跨列映射会把不同步骤与Swin-T的关系混在一起。；原文第5页：“This process improves the result by 0.7% to 81.3%, practically matching the performance of Swin-T.”；“This further boosts the performance to 81.4%, already surpassing Swin-T’s result.”（第5页）

E2-convnext-resnet/来源读取 Motif 第5页 [moderate] 表格把“初始基线(AdamW) 78.8”与“阶段比例后79.4”并列为一行的“同区间参考”，但78.8是增强配方后的基线，79.4是改变阶段配比后的结果；同时该表声称数值来自“第3至6页”，而78.8与79.4的原文依据只在第3页，第4页只支持79.5（patchify stem），第6页支持82.0，表格未逐行标注页码，无法按行核验。；原文第3页：“this enhanced training recipe increased the performance of the ResNet-50 model from 76.1% [1] to 78.8% (+2.7%)”；“This improves the model accuracy from 78.8% to 79.4%.”（第3页）

E2-convnext-resnet/来源读取 Motif 第6页 [moderate] 正文主张“规模放大到22K仍可信”，并引用ConvNeXt-XL 87.8%原文。原文该句为“a decent improvement over ConvNeXt-L at 3842”，未说明22K预训练；87.8%确实出现在第7页表1的“ImageNet-22K pre-trained models”区块中ConvNeXt-XL 384²行，因此结论可支持，但本页正文未在bullet中标出384²与22K预训练后微调的口径，条件只写在备注里。；原文第7页：“• ConvNeXt-XL 3842 350M 179.0G 30.2 87.8”（表1，ImageNet-22K pre-trained models区块）；“our ConvNeXt-XL model achieves an accuracy of 87.8% — a decent improvement over ConvNeXt-L at 3842”（第7页正文）

E2-convnext-resnet/来源读取 Motif 第6页 [minor] 备注称“同页表1该组22K行与同样22K预训练的EfficientNetV2并列，故EfficientNetV2-L在1K直接训练的85.7%不能与1K现代化步骤混排”。原文第7页确实同时存在EffNetV2-L 480² 85.7（ImageNet-1K trained models）与86.8（ImageNet-22K pre-trained models）两个数字；表述本身可核验，但“85.7”是480²/53.0G口径，本页未注明分辨率与FLOPs即作为反例引用。；原文第7页：“• EffNetV2-L [72] 480 2 120M 53.0G 83.7 85.7”（ImageNet-1K trained models）；“• EffNetV2-L [72] 480 2 120M 53.0G 83.7 86.8”（ImageNet-22K pre-trained models）

E2-convnext-resnet/来源读取 Motif 第1页 [minor] 封面备注称“两篇论文的图像均取自各自PDF的图注几何候选”，但本页image_present为false，且未列出任何图像候选ID；同稿第3页才给出crop_7d4d2d4fe61145f5。第1页的“图像均取自图注几何候选”在所给来源页中无对应证据。；原文第1页：所给doc_1第1页文本含“Figure 1. ImageNet-1K classification results for• ConvNets and◦ vision Transformers…”图注，但无任何候选裁图ID或几何候选记录；doc_2第1页文本含Figure 1图注亦无候选ID。

E2-convnext-resnet/普通 DSH 第1页 [moderate] 主张C01的原文摘录被截断后丢失了紧跟其后的限定句“Unexpectedly, such degradation is not caused by overfitting”，而notes又以“该结论基于ImageNet与CIFAR-10上的实验”概括；原文摘录本身未含任何数据集限定，notes未给出该限定的页码与逐字证据，属于把未引原文的条件补在主张旁。；原文第1页：原著第1页：“When deeper networks are able to start converging, a degradation problem has been exposed: with the network depth increasing, accuracy gets saturated (which might be unsurprising) and then degrades rapidly. Unexpectedly, such degradation is not caused by overfitting”

E2-convnext-resnet/普通 DSH 第2页 [moderate] 该页sources仅列doc_2第6页与第3页，但notes同时引用了doc_2第3页的公平对照句与第6页图注，并声称图示是“对应的几何候选裁图”；页码与图示存在，但图像未经视觉评审，notes中“56×56 feature maps”对应ResNet-34的判定无法在本稿内核实。issue：图注引用正确，但页面把未评审的图像与其来源页并列作为机制证据，且未在页面上标注视觉未评审。；原文第6页：原著第6页：“Figure 5. A deeper residual function F for ImageNet. Left: a building block (on 56×56 feature maps) as in Fig. 3 for ResNet-34. Right: a “bottleneck” building block for ResNet-50/101/152.”

E2-convnext-resnet/普通 DSH 第3页 [moderate] 标题写“从ResNet-50逐步改造为纯卷积ConvNeXt”，流程步骤与notes条件限定却写“步骤中的数值均来自PDF第11页表10与第3页正文”，而步骤文字（如“基线升至78.8%”“7×7后收益饱和”“独立下采样后达82.0%”）未逐条给出页码与逐字摘录；其中“换用Transformer式训练，300轮AdamW等，基线升至78.8%”对应doc_1第3页正文的76.1%→78.8%，与表10的78.82一致，评估页与数值未错，但流程页缺少逐字支撑。；原文第11页：原著第11页表10：“separate d.s. conv (ConvNeXt-T) 81.97± 0.06 4.49”“Swin-T [45] 81.30 4.50”；第3页正文：“By itself, this enhanced training recipe increased the performance of the ResNet-50 model from 76.1% [1] to 78.8% (+2.7%)”

E2-convnext-resnet/普通 DSH 第4页 [major] 右侧写“ImageNet-1K top-1准确率82.1%（T档）”，notes以doc_1第7页表1的“ConvNeXt-T 2242 29M 4.5G 774.7 82.1”为依据；但左侧写“ImageNet验证集单模型top-1错误率21.43%”，notes混用doc_2第6页表3与表4：表3为10-crop，表4才是单模型结果（ResNet-152 19.38/4.49）。页面上把21.43标为“单模型”，与所引表3“10-crop testing”不符。；原文第6页：原著第6页表3标题：“Table 3. Error rates (%, 10-crop testing) on ImageNet validation.”；同页表4标题：“Table 4. Error rates (%) of single-model results on the ImageNet validation set (except † reported on the test set).”其中表4为“ResNet-152 19.38 4.49”，表3为“ResNet-152 21.43 5.71”

E2-convnext-resnet/普通 DSH 第4页 [moderate] notes称ResNet-152为“11.3G FLOPs”，该值来自doc_2第5页表1的列表值，但页面sources只列了第6、第5、第7页；FLOPs所在页与正确，页面文字未把“11.3G”与其来源页并列，且ResNet-152的FLOPs为乘法-加法计数，与ConvNeXt-T的“4.5G”GFLOPs定义/计量来源不同，跨表并列未说明定义差异。；原文第5页：原著第5页表1：“FLOPs 1.8×109 3.6×109 3.8×109 7.6×109 11.3×109”，列头为18-layer/34-layer/50-layer/101-layer/152-layer

E2-convnext-resnet/普通 DSH 第5页 [minor] 主张C07的摘录用于支持“ConvNeXt的现代化探索在小规模下尚不充分”成立，原文紧接其后有“but vision Transformers’ scaling behavior is what truly distinguishes them.”被省略；省略不改变结论方向，但notes称“作者随后用ImageNet-22K预训练与下游评测补充证据”未给出页码/逐字摘录，无法在页面内核实。；原文第6页：原著第6页：“These findings are encouraging but not yet completely convincing — our exploration thus far has been limited to a small scale, but vision Transformers’ scaling behavior is what truly distinguishes them.”

E2-convnext-resnet/普通 DSH 第6页 [moderate] notes称“ConvNeXt在鲁棒性评测中未使用专门的模块或额外微调流程（PDF第10页表8说明）”，但本页sources与提供的来源投影均未包含doc_1第10页，页面上也未出现该逐字摘录；该断言目前没有可核验来源。；原文第6页：本稿doc_1可用页仅含第1、3、6、7、11、12页；第5页notes引用的“PDF第10页表8说明”在本稿不存在对应原文，可核对的最近文本为第6页“These findings are encouraging but not yet completely convincing”与第12页“ConvNeXt, employed with standard ConvNet modules and simple in design, could be practically more efficient models on modern hardwares.”

E2-convnext-resnet/普通 DSH 第6页 [moderate] notes称“A100吞吐优势为TF32与channel-last下的实测结果”，该限定正确；但页面“适用：可复现现代配方，且算力允许原生卷积实现”与“待验证：多模态等跨模态交互场景，卷积未必合适”是原文未做的方案推断，页面未在视觉呈现层面区分“原文结论”与“设计推论”。notes有声明，bullets没有。；原文第12页：原著第12页：“We employ PyTorch [50] version 1.10 to use the latest “Channel Last” memory layout [22] for further speedup.”与“A case in point is multi-modal learning, in which a cross-attention module may be preferable for modeling feature interactions across many modalities.”

7 / 逐题展示

下面拼图覆盖所有实际交付页面；初稿与重启修订稿均保留。可编辑PPTX、PDF和逐页PNG在HTML中并排浏览。图件存在不等于图意已正确解释。

ViT / 普通 DSH / 初稿

RESEARCH BRIEF

ViT：把图像切成块，交给标准 Transformer

- 图像分类不再必须依赖卷积结构
- 预训练数据规模决定结论适用范围
- 本页汇报依据 ICLR 2021 原文

来源见讲者备注 1 / 5

01 / 05

从图像到序列：ViT 的四个真实步骤

1. **切分为定长块** 图像按 (P,P) 切块，块数 $N=HW/P^2$ 即序列长度
2. **线性投影得块嵌入** 展平后用可训练线性投影映射到恒定维度 D
3. **前置分类标记** 类似 BERT 的 [class] 标记置于序列首位
4. **加入位置嵌入后编码** 加 1D 可学习位置嵌入，输入标准编码器

来源见讲者备注 2 / 5

02 / 05

预训练数据规模改变了可比较的条件

与 ResNet 比较时，胜负随预训练数据规模改变。

- 小数据集：大模型未必胜出
- 大规模预训练：ViT 反超 ResNet
- 比较条件须标明预训练数据

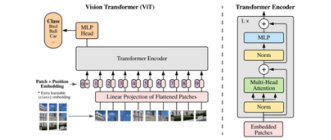


Figure 1: Model overview. We split an image into fixed-size patches, linearly embed each of them, add position embeddings, and feed the resulting sequence of vectors to a standard Transformer encoder. In order to perform classification, we use the standard approach of adding an extra learnable "classification token" to the sequence. The illustration of the Transformer encoder was inspired by Vaswani et al. (2017).

来源见讲者备注 3 / 5

03 / 05

何时采用 ViT：论文支持的适用场景

论文支持的条件是“大预训练数据 + 中分辨率分类”。

- 数据规模足够大时，ViT 更值得一试
- 算力受限时可先看混合结构
- 低数据迁移仍属待验证方向

来源见讲者备注 4 / 5

04 / 05

论文没有证明什么：结论的边界

- 不等于检测与分割任务同样适用
- 自监督预训练仍明显落后于监督
- 架构优势未与全部训练设定解耦
- 未证明中等数据下也全面领先

来源见讲者备注 5 / 5

05 / 05

5页；稿件SHA fbd5d9e91c6295b36d2f；实际run 5939fac0d0c04466ad74ec4008145ce3

ViT / 普通 DSH / 重启修订稿

RESEARCH BRIEF

ViT： 把图像切成块，交给标准 Transformer

- 图像分类不再必须依赖卷积结构
- 预训练数据规模决定结论适用范围
- 本页汇报依据 ICLR 2021 原文

来源见讲者备注 1 / 5

01 / 05

从图像到序列： ViT 的四个真实步骤

1	**切分为定长块**	图像按 (P,P) 切块，块数 $N=HW/P^2$ 即序列长度
2	**线性投影得块嵌入**	展平后用可训练线性投影映射到恒定维度 D
3	**前置分类标记**	类似 BERT 的 [class] 标记置于序列首位
4	**加入位置嵌入后编码**	加 1D 可学习位置嵌入，输入标准编码器

来源见讲者备注 2 / 5

02 / 05

预训练数据规模改变了可比较的条件

与 ResNet 比较时，胜负随预训练数据规模改变。

- 小数据集：大模型未必胜出
- 大规模预训练： ViT 反超 ResNet
- 比较条件须标明预训练数据

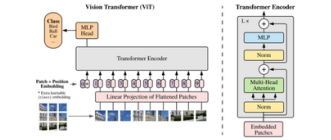


Figure 1: Model overview. We split an image into fixed-size patches, linearly embed each of them, add position embeddings, and feed the resulting sequence of vectors to a standard Transformer encoder. In order to perform classification, we use the standard approach of adding an extra learnable "classification token" to the sequence. The illustration of the Transformer encoder was inspired by Vaswani et al. (2017).

来源见讲者备注 3 / 5

03 / 05

何时采用 ViT： 论文支持的适用场景

论文支持的条件是“大预训练数据 + 中分辨率分类”。

- 数据规模足够大时， ViT 更值得一试
- 算力受限时可先看混合结构
- 低数据迁移仍属待验证方向

来源见讲者备注 4 / 5

04 / 05

边界结论：大预训练数据下分类可替代卷积，但迁移与架构因果仍未证实

原文限定在大规模预训练与图像分类；迁移与因果未证实。

- 何时适用：大规模预训练加中分辨率图像分类
- 大规模监督预训练是原文结论成立的前提
- 待验证：检测、分割等其它视觉任务尚未检验
- 待验证：低数据迁移与自监督仍落后监督预训练

来源见讲者备注 5 / 5

05 / 05

5页；稿件SHA e44f030ad4d6b4e57cd6；实际run 1c8985bb1bf541f5a0785d42c5bc98fe

DDPM / 普通 DSH / 初稿

RESEARCH BRIEF

DDPM 组会精读：加噪反向组合、训练目标与采样代价

- 论文： Ho, Jain, Abbeel, NeurIPS 2020 （arXiv:2006.11239v2）
- 固定前向加噪链与可学习高斯反向链的组合
- 报告范围为无条件 CIFAR10 与 256x256 LSUN

来源见讲者备注 1 / 5

01 / 05

固定加噪链给出可采样的训练信号

闭式加噪把变分界变成可随机梯度优化的目标。

- q(xt|xt-1) 固定已知，无学习参数
- 任意 t 可闭式采 $x_t = \sqrt{\bar{\alpha}_t} \cdot x_0 + \sqrt{(1-\bar{\alpha}_t)} \cdot \epsilon$
- 故可随机抽 t 做随机梯度下降
- 优化的是负对数似然变分上界 L

来源见讲者备注 2 / 5

02 / 05

前向加噪与反向学习为何必须组合

固定加噪是已知监督，反向只是学它的条件均值。

1 固定加噪链	按方差表逐步加高斯噪声，无学习参数，信号完全已知
2 闭式边缘采样	任取 t 由 x0 与噪声直接采得 xt，无需逐步模拟
3 以噪声预测参数化	将反向均值改写为预测所加噪声 εθ 的函数
4 反向逐步去噪采样	按 $1/\sqrt{\alpha_t} \cdot (x_t - \beta_t/\sqrt{(1-\bar{\alpha}_t)} \cdot \epsilon_\theta) + \sigma_t \cdot z$ 迭代去噪

来源见讲者备注 3 / 5

03 / 05

训练目标与参数化消融：样本质量口径

简化目标换取样本质量，而非更好的似然。

- ϵ 参数化配真变分界与配简化目标近似持平
- 换用简化目标后 FID 由 13.51 降至 3.17

来源见讲者备注 4 / 5

04 / 05

论文原图与采样成本边界

质量指标在 FID 3.17 与 T=1000 步采样条件下成立。

- 左为 CelebA-HQ 256×256，右为无条件 CIFAR10
- 自 xT 需 T=1000 次网络评估



Figure 1: Generated samples on CelebA-HQ 256 × 256 (left) and unconditional CIFAR10 (right)

来源见讲者备注 5 / 5

05 / 05

5页；稿件SHA 6d335d83fa4d6ed93edd；实际run fc35968fcbc34fd59877407817eb1986

DDPM / 普通 DSH / 重启修订稿

RESEARCH BRIEF

DDPM 组会精读：加噪反向组合、训练目标与采样代价

- 论文： Ho, Jain, Abbeel, NeurIPS 2020 （arXiv:2006.11239v2）
- 固定前向加噪链与可学习高斯反向链的组合
- 报告范围为无条件 CIFAR10 与 256x256 LSUN

来源见讲者备注 1 / 5

01 / 05

固定加噪链给出可采样的训练信号

闭式加噪把变分界变成可随机梯度优化的目标。

- q(xt|xt-1) 固定已知，无学习参数
- 任意 t 可闭式采 $x_t = \sqrt{\bar{\alpha}_t} \cdot x_0 + \sqrt{(1-\bar{\alpha}_t)} \cdot \epsilon$
- 故可随机抽 t 做随机梯度下降
- 优化的是负对数似然变分上界 L

来源见讲者备注 2 / 5

02 / 05

前向加噪与反向学习为何必须组合

固定加噪是已知监督，反向只是学它的条件均值。

1	**固定加噪链**	按方差表逐步加高斯噪声，无学习参数，信号完全已知
2	**闭式边缘采样**	任取 t 由 x0 与噪声直接采得 xt，无需逐步模拟
3	**以噪声预测参数化**	将反向均值改写为预测所加噪声 εθ 的函数
4	**反向逐步去噪采样**	按 $1/\sqrt{\alpha_t} \cdot (x_t - \beta_t/\sqrt{(1-\bar{\alpha}_t)} \cdot \epsilon_\theta) + \sigma_t \cdot z$ 迭代去噪

来源见讲者备注 3 / 5

03 / 05

训练目标与参数化消融：样本质量口径

简化目标换取样本质量，而非更好的似然。

- ϵ 参数化配真变分界与配简化目标近似持平
- 换用简化目标后 FID 由 13.51 降至 3.17

来源见讲者备注 4 / 5

04 / 05

适用边界： CIFAR10 、训练集口径与 T=1000

质量指标在 FID 3.17 与 T=1000 步采样条件下成立。

- 适用：无条件 CIFAR10，训练集口径 FID
- 待验证：测试集 FID 5.24 与部署时延

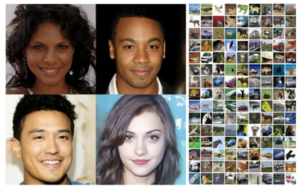


Figure 1: Generated samples on CelebA-HQ 256 × 256 (left) and unconditional CIFAR10 (right)

来源见讲者备注 5 / 5

05 / 05

5页；稿件SHA 0bc959269b4cbf7b5b6c；实际run ef2800c74cc24b9abb0a8bfef5cdbdbf

CLIP / 普通 DSH / 初稿

RESEARCH BRIEF

本页问题：图像识别为何要转向语言监督

- 视觉系统通常只预测固定的预设类别
- 新增视觉概念需额外的标注数据指定
- CLIP 改用自然语言作为训练信号

来源见讲者备注 1 / 5

01 / 05

训练信息流：从图像文本配对到共享嵌入空间

- 图像编码器与文本编码器联合训练
- 在批次内预测哪段文本配哪张图
- 最大化真实配对余弦相似度

来源见讲者备注 2 / 5

02 / 05

竞争目标如何改变训练效率

换用对比目标后，零样本迁移效率再提升约 4 倍

01	02	03
图像字幕预测	**词袋预测**	**对比目标**
联合训练图像与文本预测字幕，扩缩困难	只预测文本词袋编码，效率优于语言模型	只判断文本整体与哪张图配对

来源见讲者备注 3 / 5

03 / 05

零样本识别：文本编码器生成分类器

- 零样本 CLIP 在 16/27 数据集胜过监督基线
- 但仅在部分数据集接近全监督水平

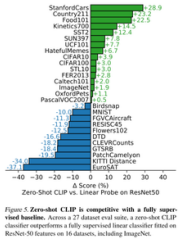


Figure 5. **Zero-shot CLIP is competitive with a fully supervised baseline.** Across a 27 dataset eval suite, a zero-shot CLIP classifier outperforms a fully supervised linear classifier fitted on ResNet-50 features on 16 datasets, including ImageNet.

来源见讲者备注 4 / 5

04 / 05

实验条件与泛化边界

- 零样本仅在 5 个数据集接近全监督
- 鲁棒性提升伴随任务特定性能下降
- 结果基于 WIT 与指定评测套件

来源见讲者备注 5 / 5

05 / 05

5页；稿件SHA 732f236dda67784cb5dc；实际run 1b8d54c8c2b2434895a82e81127823a3

CLIP / 普通 DSH / 重启修订稿

RESEARCH BRIEF

本页问题：图像识别为何要转向语言监督

- 视觉系统通常只预测固定的预设类别
- 新增视觉概念需额外的标注数据指定
- CLIP 改用自然语言作为训练信号

来源见讲者备注 1 / 5

01 / 05

训练信息流：从图像文本配对到共享嵌入空间

- 图像编码器与文本编码器联合训练
- 在批次内预测哪段文本配哪张图
- 最大化真实配对余弦相似度

来源见讲者备注 2 / 5

02 / 05

竞争目标如何改变训练效率

换用对比目标后，零样本迁移效率再提升约 4 倍

01	02	03
图像字幕预测	**词袋预测**	**对比目标**
联合训练图像与文本预测字幕，扩缩困难	只预测文本词袋编码，效率优于语言模型	只判断文本整体与哪张图配对

来源见讲者备注 3 / 5

03 / 05

零样本识别：文本编码器生成分类器

- 零样本 CLIP 在 16/27 数据集胜过监督基线
- 但仅在部分数据集接近全监督水平

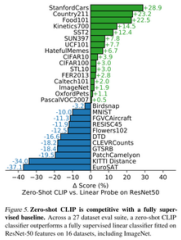


Figure 5. **Zero-shot CLIP is competitive with a fully supervised baseline.** Across a 27 dataset eval suite, a zero-shot CLIP classifier outperforms a fully supervised linear classifier fitted on ResNet-50 features on 16 datasets, including ImageNet.

来源见讲者备注 4 / 5

04 / 05

零样本 CLIP 何时可用：适用条件与待验证项

接近全监督仅见于部分任务，多数数据集仍差 10–25 个百分点

- 适用：类别可由文本命名且表示质量高的任务
- 适用：零样本在 5 个数据集接近全监督，均超 90%
- 待验证：细粒度、计数、近随机的新任务能否改善
- 待验证：数据重叠与分布偏移对泛化的影响

来源见讲者备注 5 / 5

05 / 05

5页；稿件SHA 1c0fe3db763edefa2202；实际run 181f821abdc54428b37f8952398bd962

MobileNetV2 / 普通 DSH / 初稿

组会问题：为什么把残差接在瓶颈上

残差接瓶颈、窄层去非线性，是同一套设计的两面

- 原文模块：低维输入先扩张，再深度可分离卷积，线性投影回低维
- 扩张层只提供非线性，瓶颈层才是承载信息的部分
- 难点：窄层加非线性会破坏流形，需用实验判断

来源见讲者备注 1 / 5

01 / 05

线性瓶颈：窄层不加非线性的理由

低维子空间假设，是线性瓶颈成立的前提而非普适结论

- ReLU 后流形仍有非零体积，该部分只等价于线性变换
- ReLU 会压掉通道信息；通道足够多时信息可分散保留
- 若兴趣流形本就在低维子空间，加线性瓶颈即可保信息

来源见讲者备注 2 / 5

02 / 05

倒残差：把捷径从宽层挪到瓶颈

瓶颈被认为已含全部必要信息，扩张只是实现细节

- 普通残差连接高通道层，倒残差连接瓶颈层
- 扩张比小于 1 时，该结构退化为经典残差块
- 原文实验：瓶颈用 ReLU6 会掉几个百分点

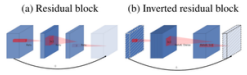


Figure 3: The difference between residual block [8, 30] and inverted residual. Diagonally hatched layers do not use non-linearities. We use thickness of each block to indicate its relative number of channels. Note how classical residuals connects the layers with high number of channels, whereas the inverted residuals connect the bottlenecks. Best viewed in color.

来源见讲者备注 3 / 5

03 / 05

一个倒残差瓶颈块的前向顺序

扩张层是非线性来源，两端 1×1 保持线性

1	**低维输入**	瓶颈张量作为块输入与捷径端点
2	**1×1 线性扩张**	按扩张比 t 放大通道数，如 t=6
3	**逐通道非线性**	3×3 深度卷积加 ReLU6，只在扩张层
4	**1×1 线性投影**	压回低维输出，此处不加非线性
5	**短路相加**	与输入瓶颈相加，步长与通道需一致

来源见讲者备注 4 / 5

04 / 05

原文指标与部署边界：先对齐配置再读

省内存来自结构，延迟数字绑定特定手机与引擎

- V2 1.4 与 1.0 为不同算力点
- 同表数字同属 ImageNet 分类

模型	Top1(%)	MAdds	Pixel1 延迟
V1	70.6	575M	113ms
ShuffleNet 1.5	71.5	292M	未报告
V2	72.0	300M	75ms
V2(1.4)	74.7	585M	143ms

来源见讲者备注 5 / 5

05 / 05

5页；稿件SHA b6f6be7d56be55490a8a；实际run 36da622504f743c99c3c716bb01d95d9

MobileNetV2 / 普通 DSH / 重启修订稿

组会问题：为什么把残差接在瓶颈上

残差接瓶颈、窄层去非线性，是同一套设计的两面

- 原文模块：低维输入先扩张，再深度可分离卷积，线性投影回低维
- 扩张层只提供非线性，瓶颈层才是承载信息的部分
- 难点：窄层加非线性会破坏流形，需用实验判断

来源见讲者备注 1 / 5

01 / 05

线性瓶颈：窄层不加非线性的理由

低维子空间假设，是线性瓶颈成立的前提而非普适结论

- ReLU 后流形仍有非零体积，该部分只等价于线性变换
- ReLU 会压掉通道信息；通道足够多时信息可分散保留
- 若兴趣流形本就在低维子空间，加线性瓶颈即可保信息

来源见讲者备注 2 / 5

02 / 05

倒残差：把捷径从宽层挪到瓶颈

瓶颈被认为已含全部必要信息，扩张只是实现细节

- 普通残差连接高通道层，倒残差连接瓶颈层
- 扩张比小于 1 时，该结构退化为经典残差块
- 原文实验：瓶颈用 ReLU6 会掉几个百分点

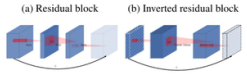


Figure 3: The difference between residual block [8, 30] and inverted residual. Diagonally hatched layers do not use non-linearities. We use thickness of each block to indicate its relative number of channels. Note how classical residuals connects the layers with high number of channels, whereas the inverted residuals connect the bottlenecks. Best viewed in color.

来源见讲者备注 3 / 5

03 / 05

一个倒残差瓶颈块的前向顺序

扩张层是非线性来源，两端 1×1 保持线性

1	**低维输入**	瓶颈张量作为块输入与捷径端点
2	**1×1 线性扩张**	按扩张比 t 放大通道数，如 t=6
3	**逐通道非线性**	3×3 深度卷积加 ReLU6，只在扩张层
4	**1×1 线性投影**	压回低维输出，此处不加非线性
5	**短路相加**	与输入瓶颈相加，步长与通道需一致

来源见讲者备注 4 / 5

04 / 05

这些结论在瓶颈信息假设成立且算力引擎相当时才适用

省内存只在逐通道与形状比条件下成立，延迟绑定特定硬件

- 适用：追求移动端低内存推理，且层内变换为逐通道
- 适用：扩张比大于 1 、瓶颈间连接，内存由瓶颈张量主导
- 待验证：t 在 2 到 5 以外的取值与其它分辨率下限
- 待验证：其它框架与硬件上的延迟，本次未实测

来源见讲者备注 5 / 5

05 / 05

5页；稿件SHA 9e4d2e8ad4167d19f098；实际run 19a55eb667e74e41b6e4ca286b13c418

ConvNeXt + ResNet / 普通 DSH / 初稿

决策问题：残差学习是否已足够，还是需要现代化卷积结构

讨论目标：判断是否值得改用现代化 ConvNet

- ResNet 以恒等捷径缓解深层退化，是通用骨架
- ConvNeXt 沿用 ResNet 微观结构并借鉴 Transformer 设计
- 两文训练数据、规模、目标不同，数字不可拼成排行榜

来源见讲者备注 1 / 6

01 / 06

残差学习机制：让堆叠层拟合残差而非原始映射

残差路径让深层网络更容易优化

- 恒等捷径不增加参数与计算量
- 维度不匹配时用投影捷径对齐
- 目标是缓解退化而非提升表达能力



Figure 5. A deeper residual function $\mathcal{F}$ for ImageNet. Left: a building block (on 56×56 feature maps) as in Fig. 3 for ResNet-34. Right: a "bottleneck" building block for ResNet-50/101/152.

来源见讲者备注 2 / 6

02 / 06

现代化路径：从 ResNet-50 逐步改造为纯卷积 ConvNeXt

改造主体是训练配方与结构细节，无需注意力模块

升级训练配方	换用 Transformer 式训练， 300 轮 AdamW 等，基线升至 78.8%
宏观与分组设计	调整阶段配比与 patchify 骨干，再引入深度卷积并加宽
倒置瓶颈与大卷积核	倒置维度并上移深度卷积， 7×7 后收益饱和
微观与下采样设计	减少激活与归一化并改 LN ，独立下采样后达 82.0%

来源见讲者备注 3 / 6

03 / 06

适用条件对比：残差骨架与现代化卷积骨架

ResNet 残差骨架	ConvNeXt 现代化骨架
恒等捷径缓解退化，深度可加到 152 层	深度卷积加倒置瓶颈， 7×7 核后饱和
ImageNet 验证集单模型 top-1 错误率 21.43%	ImageNet-1K top-1 准确率 82.1%（T 档）
训练为 90 轮 SGD ，未用现代增强配方	300 轮 AdamW 加混合增强，需 EMA 等技巧

来源见讲者备注 4 / 6

04 / 06

未证实的边界：可迁移的设计推论与尚缺证据

现代化收益有条件，不等于残差学习被取代

- ConvNeXt 结论限于分类与下游微调的评测范围
- 退化机制的解释仍属推测，原文未定论
- 跨论文性能差不能归因于单一结构因素

来源见讲者备注 5 / 6

05 / 06

决策建议：在同等数据与算力下再评估是否替换骨架

决策应先对齐数据与算力，再比较架构

- 已有现代训练与算力预算：可试点 ConvNeXt
- 强调简单可复现与低依赖：保留 ResNet 骨架
- 先在同数据同算力下重做对照再决定替换

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 9cc7dc05068410d7641d；实际run e29999fd239942c6b4ba52f3d79a60b2

ConvNeXt + ResNet / 普通 DSH / 重启修订稿

决策问题：残差学习是否已足够，还是需要现代化卷积结构

讨论目标：判断是否值得改用现代化 ConvNet

- ResNet 以恒等捷径缓解深层退化，是通用骨架
- ConvNeXt 沿用 ResNet 微观结构并借鉴 Transformer 设计
- 两文训练数据、规模、目标不同，数字不可拼成排行榜

来源见讲者备注 1 / 6

01 / 06

残差学习机制：让堆叠层拟合残差而非原始映射

残差路径让深层网络更容易优化

- 恒等捷径不增加参数与计算量
- 维度不匹配时用投影捷径对齐
- 目标是缓解退化而非提升表达能力



Figure 5. A deeper residual function $\mathcal{F}$ for ImageNet. Left: a building block (on 56×56 feature maps) as in Fig. 3 for ResNet-34. Right: a "bottleneck" building block for ResNet-50/101/152.

来源见讲者备注 2 / 6

02 / 06

现代化路径：从 ResNet-50 逐步改造为纯卷积 ConvNeXt

改造主体是训练配方与结构细节，无需注意力模块

1	升级训练配方	换用 Transformer 式训练， 300 轮 AdamW 等，基线升至 78.8%
2	宏观与分组设计	调整阶段配比与 patchify 骨干，再引入深度卷积并加宽
3	倒置瓶颈与大卷积核	倒置维度并上移深度卷积， 7×7 后收益饱和
4	微观与下采样设计	减少激活与归一化并改 LN ，独立下采样后达 82.0%

来源见讲者备注 3 / 6

03 / 06

适用条件对比：残差骨架与现代化卷积骨架

ResNet 残差骨架	ConvNeXt 现代化骨架
恒等捷径缓解退化，深度可加到 152 层	深度卷积加倒置瓶颈， 7×7 核后饱和
ImageNet 验证集单模型 top-1 错误率 21.43%	ImageNet-1K top-1 准确率 82.1%（T 档）
训练为 90 轮 SGD ，未用现代增强配方	300 轮 AdamW 加混合增强，需 EMA 等技巧

来源见讲者备注 4 / 6

04 / 06

未证实的边界：可迁移的设计推论与尚缺证据

现代化收益有条件，不等于残差学习被取代

- ConvNeXt 结论限于分类与下游微调的评测范围
- 退化机制的解释仍属推测，原文未定论
- 跨论文性能差不能归因于单一结构因素

来源见讲者备注 5 / 6

05 / 06

何时采用现代化 ConvNet：先对齐数据与算力，未验证条件仍须试点

先对齐数据与算力做对照，再决定是否替换骨架

- 适用：可复现现代配方，且算力允许原生卷积实现
- 适用：任务是分类或常规检测、分割，可自行微调
- 待验证：多模态等跨模态交互场景，卷积未必合适
- 待验证：小数据训练是否同样获益，原文未给证据

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 8d025ebcfa9f2fbdd91f；实际run 4611df01a75e42abb13c2e3e00751d00

MobileNetV2 / 来源读取 Motif / 初稿

MobileNetV2 要解决的问题：移动端精度与算力 / 内存的取舍

移动端限制来自算力与内存，而非单一精度指标

- 面向移动与资源受限环境的专用架构
- 主贡献：倒残差 + 线性瓶颈这一层模块
- 在 ImageNet 分类、 COCO 检测、 VOC 分割上评测
- 权衡维度：精度、 MAdds 、延迟与参数量

来源见讲者备注 1 / 5

01 / 05

为什么先扩维再压回：低维流形上 ReLU 会丢信息

窄层保线性、宽层加非线性，是组合的直接动机

- ReLU 把通道置零会不可避免丢失该通道信息
- 低维子空间中的流形才可能被 ReLU 完整保留
- 故在窄层去除非线性以维持表示能力
- 扩张层用逐通道卷积提供非线性

来源见讲者备注 2 / 5

02 / 05

倒残差与普通残差：连接点从宽层换到瓶颈

同一残差思想，连接位置相反

- 普通残差连接高通道层，倒残差连接瓶颈
- 瓶颈承载信息，扩张层只是实现细节
- 扩张比为 1 以下时退化为经典残差块

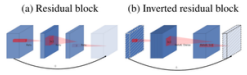


Figure 3: The difference between residual block [8, 30] and inverted residual. Diagonally hatched layers do not use non-linearities. We use thickness of each block to indicate its relative number of channels. Note how classical residuals connects the layers with high number of channels, whereas the inverted residuals connect the bottlenecks. Best viewed in color.

来源见讲者备注 3 / 5

03 / 05

单块的前向流程：从瓶颈扩维再投影回瓶颈

扩张层负责表达力，瓶颈负责容量

1	**1×1 升维**	ReLU6 把 k 通道按扩张因子 t 升到 tk
2	**3×3 逐通道卷积**	按步长 s 下采样，逐通道提供非线性
3	**1×1 线性投影**	降到 k' 通道，此层不含非线性
4	**瓶颈间加残差**	步长为 1 且通道一致时才相加

来源见讲者备注 4 / 5

04 / 05

原文指标与比较条件，以及移动部署边界

峰值精度来自更大配置，与主配置不可直接并列排序

- 同表内仅比较已列配置，不跨表排名
- 延迟为 Pixel 1 单大核 TF-Lite 结果

模型	Top-1	参数	MAdds
MobileNet V1	70.6	4.2M	575M
MobileNet V2	72.0	3.4M	300M
MobileNet V2(1.4)	74.7	6.9M	585M
NasNet-A	74.0	5.3M	564M

来源见讲者备注 5 / 5

05 / 05

5页；稿件SHA 0a8ef64059731426a152；实际run 8ffc85d6e8cc472bb9a060cf55fff589

MobileNetV2 / 来源读取 Motif / 重启修订稿

MobileNetV2 要解决的问题：移动端精度与算力 / 内存的取舍

移动端限制来自算力与内存，而非单一精度指标

- 面向移动与资源受限环境的专用架构
- 主贡献：倒残差 + 线性瓶颈这一层模块
- 在 ImageNet 分类、 COCO 检测、 VOC 分割上评测
- 权衡维度：精度、 MAdds 、延迟与参数量

来源见讲者备注 1 / 5

01 / 05

为什么先扩维再压回：低维流形上 ReLU 会丢信息

窄层保线性、宽层加非线性，是组合的直接动机

- ReLU 把通道置零会不可避免丢失该通道信息
- 低维子空间中的流形才可能被 ReLU 完整保留
- 故在窄层去除非线性以维持表示能力
- 扩张层用逐通道卷积提供非线性

来源见讲者备注 2 / 5

02 / 05

倒残差与普通残差：连接点从宽层换到瓶颈

同一残差思想，连接位置相反

- 普通残差连接高通道层，倒残差连接瓶颈
- 瓶颈承载信息，扩张层只是实现细节
- 扩张比为 1 以下时退化为经典残差块

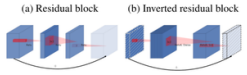


Figure 3: The difference between residual block [8, 30] and inverted residual. Diagonally hatched layers do not use non-linearities. We use thickness of each block to indicate its relative number of channels. Note how classical residuals connects the layers with high number of channels, whereas the inverted residuals connect the bottlenecks. Best viewed in color.

来源见讲者备注 3 / 5

03 / 05

单块的前向流程：从瓶颈扩维再投影回瓶颈

扩张层负责表达力，瓶颈负责容量

1	**1×1 升维**	ReLU6 把 k 通道按扩张因子 t 升到 tk
2	**3×3 逐通道卷积**	按步长 s 下采样，逐通道提供非线性
3	**1×1 线性投影**	降到 k' 通道，此层不含非线性
4	**瓶颈间加残差**	步长为 1 且通道一致时才相加

来源见讲者备注 4 / 5

04 / 05

何时适用：小模型精度—算力可换，但需同表同口径比较

同表同口径可比；跨硬件不能排序

- 适用移动端：精度与算力可用分辨率 / 宽度倍率调
- 延迟仅限单大核 Pixel 1 + TF-Lite ，未在用户硬件实测

模型	Top-1	参数量	MAdds
MobileNet V1	70.6	4.2M	575M
MobileNet V2	72.0	3.4M	300M
MobileNet V2 (1.4)	74.7	6.9M	585M

来源见讲者备注 5 / 5

05 / 05

5页；稿件SHA 589d98c379d6986c1b50；实际run d8a7c5732e8547d0a6c8f3ffb5e40a0c

ConvNeXt + ResNet / 来源读取 Motif / 工程反馈后恢复稿

RESEARCH BRIEF

是否采用现代化 ConvNet： 先看两篇原文的证据边界

本次决策只采纳各自论文内部的可比对照，不跨论文排名

- ResNet 提供残差学习与退化问题的实验证据
- ConvNeXt 以 ResNet 为起点做有对照的现代化改造
- 两类实验的数据、规模与评测条件不同，不作横向排名

来源见讲者备注 1 / 6

01 / 06

ConvNeXt 把 ResNet 当作起点：五类设计逐步改造

全部改造均改编自视觉 Transformer，多数组件在过去十年已被分别研究

1	**训练配方现代化**	AdamW 与更强增广， 300 轮，作为固定基线
2	**宏观设计对齐**	阶段比例 1:1:3:1 加 patchify 主干
3	**ResNeXt 化**	深度卷积并扩宽，再改倒置瓶颈
4	**大卷积核**	深度卷积上移，核增至 7×7
5	**微观设计调整**	激活与归一化精简，下采样层独立

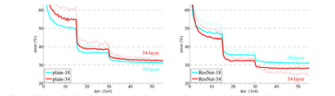
来源见讲者备注 2 / 6

02 / 06

退化问题与被翻转的现象： ResNet 的核心证据

加入恒等捷径后， 34 层 ResNet 优于 18 层 ResNet，而 plain 网络相反

- 训练误差曲线表明更深的网络反而更难优化



来源见讲者备注 3 / 6

03 / 06

设计相同、训练配方不同时，对照组不能直接比

两篇论文的 ResNet 数字训练条件不同，不能直接比较

ResNet 论文的对照

- 始终使用 BN 与 SGD，迭代至 60×10^4 次
- 训练配方在两版网络中完全一致

ConvNeXt 的 ResNet-50 基线

- 训练从 90 轮延长到 300 轮，改用 AdamW 与增广
- 同一网络精度由 76.1% 提升到 78.8%

来源见讲者备注 4 / 6

04 / 06

同一固定配方下的精度轨迹：中间步骤并非等计算量

同一配方下逐步改造到 82.0%，但中间步骤 FLOPs 有波动，不等于等计算量比较

改造步骤	Top-1 精度 (%)	同区间参考
初始基线 (AdamW)	78.8	阶段比例后 79.4
深度卷积并扩宽	80.5	倒置瓶颈后 80.6
深度卷积上移	79.9	7×7 核后 80.6
单一 GELU	81.3	Swin-T 为 81.3
单归一化层与 LN	81.5	独立下采样后 82.0

来源见讲者备注 5 / 6

05 / 06

结论与不可外推的边界：是否采用现代化 ConvNet

证据支持在相同复杂度区间内采用现代化设计，不构成跨论文排名

- 若追求同复杂度下更好精度且需全卷积部署，可采用 ConvNeXt 设计
- 残差捷径仍是通用基础， ConvNeXt 块本身建立在残差结构上
- 跨论文数字不可排名：数据、轮数、增广与评测口径均不同
- 原文未证实：核 7×7 以上收益、以及非视觉任务的适用性

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 64eedd68ae007129ffa1；实际run c3b5bf5ccd894aeebb0b4c2a989bc47e

ConvNeXt + ResNet / 来源读取 Motif / 重启修订稿

RESEARCH BRIEF

是否采用现代化 ConvNet： 先看两篇原文的证据边界

本次决策只采纳各自论文内部的可比对照，不跨论文排名

- ResNet 提供残差学习与退化问题的实验证据
- ConvNeXt 以 ResNet 为起点做有对照的现代化改造
- 两类实验的数据、规模与评测条件不同，不作横向排名

来源见讲者备注 1 / 6

01 / 06

ConvNeXt 把 ResNet 当作起点：五类设计逐步改造

全部改造均改编自视觉 Transformer，多数组件在过去十年已被分别研究

1	**训练配方现代化**	AdamW 与更强增广， 300 轮，作为固定基线
2	**宏观设计对齐**	阶段比例 1:1:3:1 加 patchify 主干
3	**ResNeXt 化**	深度卷积并扩宽，再改倒置瓶颈
4	**大卷积核**	深度卷积上移，核增至 7×7
5	**微观设计调整**	激活与归一化精简，下采样层独立

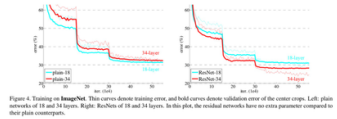
来源见讲者备注 2 / 6

02 / 06

退化问题与被翻转的现象： ResNet 的核心证据

加入恒等捷径后，34 层 ResNet 优于 18 层 ResNet，而 plain 网络相反

- 训练误差曲线表明更深的网络反而更难优化



来源见讲者备注 3 / 6

03 / 06

设计相同、训练配方不同时，对照组不能直接比

两篇论文的 ResNet 数字训练条件不同，不能直接比较

ResNet 论文的对照

- 始终使用 BN 与 SGD，迭代至 60×10^4 次
- 训练配方在两版网络中完全一致

ConvNeXt 的 ResNet-50 基线

- 训练从 90 轮延长到 300 轮，改用 AdamW 与增广
- 同一网络精度由 76.1% 提升到 78.8%

来源见讲者备注 4 / 6

04 / 06

同一固定配方下的精度轨迹：中间步骤并非等计算量

同一配方下逐步改造到 82.0%，但中间步骤 FLOPs 有波动，不等于等计算量比较

改造步骤	Top-1 精度 (%)	同区间参考
初始基线 (AdamW)	78.8	阶段比例后 79.4
深度卷积并扩宽	80.5	倒置瓶颈后 80.6
深度卷积上移	79.9	7×7 核后 80.6
单一 GELU	81.3	Swin-T 为 81.3
单归一化层与 LN	81.5	独立下采样后 82.0

来源见讲者备注 5 / 6

05 / 06

适用边界：同复杂度区间内可用

证据支持的是同复杂度区间内替换，跨论文排名不在范围内

何时适用

- 同复杂度区间内替骨干
- 需全卷积部署时可用
- 规模放大到 22K 仍可信

还需验证

- 超过 7×7 核已饱和
- 非视觉任务仅为预期
- 跨论文排名不成立

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA f16f107cc4bbf0379811；实际run 0b67767b711b4b1faf3e168de745a13f

8 / 学习成本、复现与适用范围

服务器目录先激活已有环境。私有V7目录保存有效配置、完整账本、输入SHA、实际MCP schema/顺序、代码版本、编译证据、失败候选和结果；test-logs保存诊断和模型阶段日志。总预算不限授权，每阶段仍有$2/40步失控保护，思考与压缩关闭。未改公共代码或Git分支，未commit/push/PR。

适用范围：本场景生成并保存完整计划的科研PPT，可以同job、同权限、同依赖版本跨MCP重启继续局部修订。任意外部复杂PPT内容编辑、全自主新工具生成成功率、通用动态anchor、人工科学/视觉合格总成本和Windows真实运行均未证实。

下一步最小验证：保留本轮反例改进工具生成协议；独立人工逐页核事实和可读性并记录修订分钟；在质量合格条件下重复新论文对照并核账单。需要新增功能时从真实缺口与轨迹提出，不能把固定DAG或Skill当作学得Motif。