科研 PPT Agent
真实交付、有限组合与轨迹 Motif

总的结果 / V8 / 2026-10-11

矩阵状态：evaluation_finished_quality_not_human_reviewed。报告类型：completed_stage_report。真实确认交付 18 份，共 120 页；初稿与局部修订分开保存。

评测组	已记录请求	已记录总token	代理估费	verified整请求旁路
A 普通 DSH	44	888,355	$0.066312	0
B 普通组合脚本	47	937,339	$0.062148	0
C 认证 Motif	50	1,151,375	$0.078624	2

未执行C组的0请求/0费用仅表示没有运行，不能与完成任务比节省。辅助审查、工程通过与实际旁路均不证明科学质量等价；人工盲评、账单、修订分钟及开发/服务器成本未知，尚未建立同质量总成本下降。

B 普通组合脚本相对普通组的本次总量变化：请求+6.82%, 总token+5.51%, 代理估费-6.28%。仅为已记录运行的描述性对比，不证明因果或同质量收益。

C 认证 Motif相对普通组的本次总量变化：请求+13.64%, 总token+29.61%, 代理估费+18.57%。仅为已记录运行的描述性对比，不证明因果或同质量收益。

工具学习记录 2 轮，晋级 0 轮；矩阵实际加载新claim工具：False。独立Motif认证状态：independent_trace_certified_quality_not_reviewed。

1 / 数据集与真实任务

角色	资料	真实任务
正常训练T1	LoRA	6页适配研究讨论 + 第6页局部修订
正常训练T2	QLoRA	6页有限显存方案 + 第6页局部修订；该论文有历史使用
独立认证C1	Prefix-Tuning	候选/配置冻结后首次认证；实际是否打开见记录
新评测E1	FlashAttention-2	6页方法、条件与V100待验证边界 + 第6页修订
新评测E2	Mistral 7B + Mixtral	两篇输入、8页密集/MoE决定 + 第8页修订
工具机械训练/隐藏认证	历史RAG/QLoRA轨迹 / BERT	与C1独立；失败则不打开BERT

五项PPT任务共六篇论文，不是把五篇合成一个PPT；与仓库18题合成诊断无关。新来源先本机下载再上传，逐项SHA固定。生成和同稿修订属于一个研究决定，训练/认证/评测不混算。训练仅用两项独立任务的正常修订工具轨迹，生成费用仍计入。

训练结果后恢复明确使用混合配置：原LoRA因输出上限失败，另立V8c提高输出上限并收紧notes/修订范围后重新完成；原完整QLoRA决定保留原提示/上限与job并复用，没有重付。候选支持不是统一训练配置的纯对照，认证和后续三组使用新的统一配置。旧LoRA失败仍计一次，旧QLoRA按原run ID去重只计一次。

2 / 让模型在结果出现之后做决定

DeepSeek从历史真实使用需求提出并编写TypeScript候选，开发端限定协议、受限AST、真实编译/Node/PDF宿主及独立oracle。模型看到真实结果后只能 revise / accept / stop；开发者不写替代候选，不为晋级放宽反例。新反馈配置另立实验ID，失败成本累计。

学习轮	候选 / 编译通过	真实请求	总token	代理估费	结果 / 隐藏资料已解析
tool-learning-01	3 / 1	3	38,500	$0.011248	no_accepted_candidate_within_limit / False
tool-learning-02	3 / 0	3	41,480	$0.012523	no_accepted_candidate_within_limit / False

候选未认证时不用于正常任务，字段generated_motif只是兼容运行标签，不能据名称称新生成工具已生效。精确摘录命中认证只验证定位和上下文机械能力，不认证科研主张支持关系。

tool-learning-01失败依据：候选1: ['AST 拒绝: [{"column":7,"kind":"WhileStatement","line":9,"message":"Syntax is outside the pure JSON subset"}]']; 候选2: ['AST 拒绝: [{"column":7,"kind":"WhileStatement","line":10,"message":"Syntax is outside the pure JSON subset"}]']; 候选3: 真实PDF训练=True，工程反例=False，失败项=['literal_newlines_and_unicode']

tool-learning-02失败依据：候选1: ['AST 拒绝: [{"column":45,"kind":"ElementAccessExpression","line":44,"message":"Computed property access is forbidden; use named fields or a literal numeric index"}]']; 候选2: ['AST 拒绝: [{"column":88,"kind":"ElementAccessExpression","line":28,"message":"Computed property access is forbidden; use named fields or a literal numeric index"},{"column":145,"kind":"AsExpression","line":28,"message":"Syntax is outside the pure JSON subset"},{"column":86,"kind":"ElementAccessExpression","line":31,"message":"Computed property access is forbidden; use named fields or a literal numeric index"},{"column":62,"kind":"CallExpression","line":42,"message":"Arbitrary function calls are forbidden"}]']; 候选3: ['候选须为 name/description/input_schema/code；name 使用 read_pinned_ 前缀']

正常轨迹冻结：候选1个，digest c7a9e8fc8d758934ba8e4cfc78e825b2fdd8a22d199c93495063a774eaaf5ec0。独立认证：independent_trace_certified_quality_not_reviewed。只有预先冻结的候选通过C1，再在新评测实际执行，才能报告该结构复用闭环。

3 / 与普通 DSH 的流程对比

组/职责	实际实现与边界
A 普通DSH	保留原有全部基础MCP和build_delivery，模型正常决定工具；没有撤去已有组合能力
B 普通组合脚本	TS有限render/inspect/validate/deliver与revise组合；模型明确选页后的计划投影
C 认证Motif	与B同提示、schema/顺序和证书状态；只追加认证manifest execute；无manifest就不运行
Graph	轨迹见证的返回句柄→后继工具参数依赖与版本/证据守卫；来源读取或明确选页后读取
Code	解析、裁图、可编辑布局、PDF/PNG检查、恢复、有限组合与投影；普通代码收益单独归因
大模型	论文理解、相关选材、叙事、条件判断、选页与语义修订仍由真实DeepSeek完成

Skill/模板帮助设计，不是Motif。按页计划投影节省上下文属于普通工程优化；学得读取旁路仅省结构性工具选择的整次模型请求。B/C对照范围较窄，A/B与A/C是能力整包比较，各条件仅一次仍受随机性、缓存/顺序影响。

B/C实际配置核验	两组已运行	提示/schema/共同限制相同	差异字段
e1_flashattention2/初稿	True	True	无/尚未双组运行
e1_flashattention2/跨重启修订稿	True	True	无/尚未双组运行
e2_mistral_mixtral/初稿	True	True	无/尚未双组运行
e2_mistral_mixtral/跨重启修订稿	True	True	无/尚未双组运行

e2_mistral_mixtral/C 认证 Motif/跨重启修订稿：verified批次sss-batch-5d8d7d92-98af-458a-b125-b00bc3a1ce73，工具mcp__ppt__read_pinned_deck_pages，跳过1整次请求；code_nodes=[]。

e2_mistral_mixtral/C 认证 Motif/跨重启修订稿：verified批次sss-batch-dcbb1bf0-8fa4-4746-b844-0bd2de155736，工具mcp__ppt__read_pinned_deck_pages，跳过1整次请求；code_nodes=[]。

4 / 费用比较

任务	组	整任务请求	总token	代理估费	verified	状态	完成情况
FlashAttention-2	A 普通 DSH	22	388,338	$0.025673	0	normal_task_completed	两阶段完成
FlashAttention-2	B 普通组合脚本	25	462,496	$0.027043	0	normal_task_completed	两阶段完成
FlashAttention-2	C 认证 Motif	23	471,092	$0.030236	0	normal_task_completed	两阶段完成
Mistral 7B + Mixtral	A 普通 DSH	22	500,017	$0.040639	0	normal_task_completed	两阶段完成
Mistral 7B + Mixtral	B 普通组合脚本	22	474,843	$0.035105	0	normal_task_completed	两阶段完成
Mistral 7B + Mixtral	C 认证 Motif	27	680,283	$0.048388	2	normal_task_completed	两阶段完成

成本范围	请求	总token	代理估费	已记录阶段耗时
正常任务训练	94	2,614,516	$0.121673	333.0 秒
独立轨迹认证	27	557,397	$0.029775	86.9 秒
新任务评测	141	2,977,069	$0.207084	661.0 秒
tool-learning-01	3	38,500	$0.011248	44.8 秒
tool-learning-02	3	41,480	$0.012523	44.0 秒
aux-review-01	6	173,643	$0.055149	未知
aux-review-coverage-02	2	59,041	$0.015128	未知

全部现有记录合计请求 276、token 6,461,646、代理估费 $0.452580。含两轮工具失败、正常训练、认证、评测及已提供的辅助评审；缺失记录/计数保留未知，不把预算上限当费用。

每任务以生成+重启修订聚合，失败/恢复费用不可抹去。当前阶段耗时不等于包含准备/等待/人工工作的完整端到端时间；账单实付、人工和维护成本未知。缓存命中、未命中输入和输出分别计账，token下降不自动等于费用下降。

原失败额外开销保留：t1_lora/generation，run efc5f9a0450f4051b141a292080182fc，9请求、157,197token、$0.016992；原状态incomplete。

5 / 调用次数与全部运行记录

任务/阶段	组	run ID	请求	未命中 / 命中 / 输出	状态
t1_lora/初稿	B 普通组合脚本	c0e25abc67764432b7a87ad24074c9ca	12	24,214/227,328/6,196	done
t1_lora/跨重启修订稿	B 普通组合脚本	016fe42e35a347009aee597fe6efb48b	13	22,644/224,000/3,837	done
t2_qlora/初稿	B 普通组合脚本	bf61d27208b641d2ae61d16db5d83243	19	28,286/544,128/23,009	done
t2_qlora/跨重启修订稿	B 普通组合脚本	7792e5ade38b4488a4e80c3e0f7c3b88	41	46,499/1,294,848/12,330	done
c1_prefix_tuning/初稿	B 普通组合脚本	31b0a161fa2444eb95bf07efe0f466aa	15	29,007/340,480/7,602	done
c1_prefix_tuning/跨重启修订稿	B 普通组合脚本	98ffb1934a824bf9a33db7a33c3ebf67	12	16,796/160,256/3,256	done
e1_flashattention2/初稿	A 普通 DSH	7b48acbf9a824f2985bb6c03c20dc6a5	13	25,546/245,504/7,893	done
e1_flashattention2/跨重启修订稿	A 普通 DSH	37fb884ffa5c4f08bb57763735da2958	9	10,141/96,384/2,870	done
e1_flashattention2/初稿	B 普通组合脚本	7d6b5e4e2791492d9eda338a31946e52	12	22,540/209,024/5,079	done
e1_flashattention2/跨重启修订稿	B 普通组合脚本	0c00c76bff16423095b670a48d778af8	13	18,124/202,496/5,233	done
e1_flashattention2/初稿	C 认证 Motif	79b8eda253af4d60bd36a7099c7efdde	15	20,914/333,696/12,554	done
e1_flashattention2/跨重启修订稿	C 认证 Motif	a0f4d1c87769486bb256a8add6264013	8	9,663/91,392/2,873	done

任务/阶段	组	run ID	请求	未命中 / 命中 / 输出	状态
e2_mistral_mixtral/初稿	C 认证 Motif	2f9779d1fbaf4a94bc84c127f1c94edc	14	25,913/425,984/21,296	done
e2_mistral_mixtral/跨重启修订稿	C 认证 Motif	20dd8f06f27d4681a768ea1834af289d	13	13,112/187,776/6,202	done
e2_mistral_mixtral/初稿	B 普通组合脚本	eea7923b444f4d81af69d8124e83a987	12	32,944/291,072/12,774	done
e2_mistral_mixtral/跨重启修订稿	B 普通组合脚本	9c849aaf61b049a5b885b3ce19259d32	10	13,866/121,472/2,715	done
e2_mistral_mixtral/初稿	A 普通 DSH	6f4e1767b03748cdb31a4c6e8cdedd31	12	25,899/302,848/17,239	done
e2_mistral_mixtral/跨重启修订稿	A 普通 DSH	7c83889fe51d4c9693a715e3df15e304	10	14,704/135,040/4,287	done
t1_lora/初稿	B 普通组合脚本	efc5f9a0450f4051b141a292080182fc	9	24,129/125,568/7,500	incomplete

all-running-records.csv列全部阶段与学习汇总，学习逐模型call另标detail_excluded_from_totals，避免双计。summary.json保留配置/提示/schema/代码/来源SHA、工具顺序和verified批次摘要。原始API事件、账本和test-logs另存私有备份，不放交付包。

6 / 报告质量与评审边界

工程诊断	记录状态	检查数	付费请求
adapter-diagnostic-01	True	27	0
adapter-diagnostic-01	True	28	0

初稿/修订真实文件比较	状态	目标页实际变化
t1_lora/B 普通组合脚本	passed_actual_file_comparison	[6]
t2_qlora/B 普通组合脚本	passed_actual_file_comparison	[6]
c1_prefix_tuning/B 普通组合脚本	passed_actual_file_comparison	[6]
e1_flashattention2/A 普通 DSH	passed_actual_file_comparison	[6]
e1_flashattention2/B 普通组合脚本	passed_actual_file_comparison	[6]
e1_flashattention2/C 认证 Motif	passed_actual_file_comparison	[6]
e2_mistral_mixtral/C 认证 Motif	passed_actual_file_comparison	[8]
e2_mistral_mixtral/B 普通组合脚本	passed_actual_file_comparison	[8]
e2_mistral_mixtral/A 普通 DSH	passed_actual_file_comparison	[8]

事后文件比较核非目标页OOXML、notes、媒体/图表/样式依赖及目标页实际变化，不仅比较ZIP SHA；它不独立认证恢复过程父链或科研质量。两阶段交付成功与人工科学/视觉合格分开。全页拼图便于浏览，不能替代原分辨率逐页原图、数字表头行列及全文/附录核验。

辅助评审稿件	判断	SHA绑定	仍需人工核验
e1_flashattention2/baseline/revision	needs_revision	有效	是
e1_flashattention2/composed/revision	needs_revision	有效	是
e1_flashattention2/generated_motif/revision	needs_revision	有效	是

辅助评审稿件	判断	SHA绑定	仍需人工核验
e2_mistral_mixtral/generated_motif/revision	needs_revision	有效	是
e2_mistral_mixtral/baseline/revision	needs_revision	有效	是
e2_mistral_mixtral/composed/revision	needs_revision	有效	是

已提供、唯一SHA绑定的辅助审查 6 条；未绑定 0 条不得当作本稿验收。未提供辅助结果时质量未知；Codex视觉/模型事实审查不能称独立人工盲评，导出审查包也不等于评审完成。

7 / 逐题展示

每份实际确认稿下方展示全部页面。HTML按同题、同阶段并排A/B/C；点击可看逐页PNG、原始可编辑PPTX与PDF，初稿及修订稿均保留。缺少确认交付不会用文件夹中看似完成的文件补齐。

LoRA / B 普通组合脚本 / 初稿 / 版本1

LoRA 冻结基模型、只训练低秩增量

低秩分支与主干并联，训练只更新增量

- 冻结 W0，只训练 A、B 两个低秩矩阵
- 原论文图 1：A 高斯初始化、B 置零

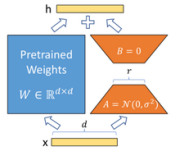


Figure 1: Our reparametrization. We only train A and B.

来源见讲者备注 1 / 6

01 / 06

增量被约束为 BA，秩 r 远小于模型维度

可训练参数由 2× 矩阵数 ×d_model×r 决定

- W0 冻结不接收梯度，A、B 承载全部可训练参数
- W0 与 BA 作用于同一输入，输出逐坐标相加
- 增量按 α/r 缩放，便于换秩时少调超参
- GPT-3 上 r 取 1 或 2，d 可达 12,288

来源见讲者备注 2 / 6

02 / 06

方法流程：冻结、注入、训练与合并部署

1. **冻结预训练权重** — W0 不接收梯度，基座可被多任务共享
2. **注入 A 与 B 低秩分支** — A 高斯初始化、B 置零，起始增量 BA 为零
3. **只优化 A 与 B** — 需为增量矩阵保存优化器状态
4. **合并 W=W0+BA 后推理** — 合并后按常规前向计算，不额外增加延迟

来源见讲者备注 3 / 6

03 / 06

一种具体实验口径：GPT-3 175B 的低秩预算

同口径下低秩预算可与全量微调持平或略优

- 配对条件：同样 AdamW、2 轮、批 128
- 序列长度按数据集 384/768/2048 设定
- LoRA 两种预算 4.7M 与 37.7M 可训练参数
- 基线为全量微调 175,255.8M 参数

来源见讲者备注 4 / 6

04 / 06

原论文结果：LoRA 在三个任务上对齐或超过全量微调

4.7M 参数已达 73.4%，与全量微调 73.8% 接近

- 同一验证集口径：WikiSQL 逻辑形式验证准确率

方法（GPT-3 175B）	可训练参数	WikiSQL 准确率 %	MNLI-m 准确率 %
全量微调	175,255.8M	73.8	89.5
BitFit	14.2M	71.3	91.0
AdapterH	40.1M	73.2	91.5
LoRA	4.7M	73.4	91.7
LoRA	37.7M	74.0	91.6

来源见讲者备注 5 / 6

05 / 06

区分参数节省、训练显存与运行时间

存储与显存

- 检查点 350GB→35MB（r=4，仅 q、v）
- 训练显存 1.2TB→350GB（约省 2/3）
- 节省源于不存冻结参数优化器状态

训练吞吐与推理延迟

- 训练 32.5→43.1 tokens/s 每 V100（GPT-3）
- 合并后推理与全量微调相同，按构造无额外延迟
- 适配器在批 1、序列 128 时延迟 +20.7%

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 28c83ef95b53553d6df72becf0f3d15cfb3af1a56ac2341f7d126b58f045813f；run c0e25abc67764432b7a87ad24074c9ca

LoRA / B 普通组合脚本 / 跨重启修订稿 / 版本1

LoRA 冻结基模型、只训练低秩增量

低秩分支与主干并联，训练只更新增量

- 冻结 W0，只训练 A、B 两个低秩矩阵
- 原论文图 1：A 高斯初始化、B 置零

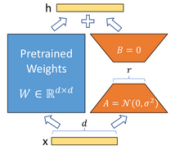


Figure 1: Our reparametrization. We only train A and B.

01 / 06

增量被约束为 BA，秩 r 远小于模型维度

可训练参数由 2× 矩阵数 ×d_model×r 决定

- W0 冻结不接收梯度，A、B 承载全部可训练参数
- W0 与 BA 作用于同一输入，输出逐坐标相加
- 增量按 α/r 缩放，便于换秩时少调超参
- GPT-3 上 r 取 1 或 2，d 可达 12,288

02 / 06

方法流程：冻结、注入、训练与合并部署

1. **冻结预训练权重** W0 不接收梯度，基座可被多任务共享
2. **注入 A 与 B 低秩分支** A 高斯初始化、B 置零，起始增量 BA 为零
3. **只优化 A 与 B** 需为增量矩阵保存优化器状态
4. **合并 W=W0+BA 后推理** 合并后按常规前向计算，不额外增加延迟

03 / 06

一种具体实验口径：GPT-3 175B 的低秩预算

同口径下低秩预算可与全量微调持平或略优

- 配对条件：同样 AdamW、2 轮、批 128
- 序列长度按数据集 384/768/2048 设定
- LoRA 两种预算 4.7M 与 37.7M 可训练参数
- 基线为全量微调 175,255.8M 参数

04 / 06

原论文结果：LoRA 在三个任务上对齐或超过全量微调

4.7M 参数已达 73.4%，与全量微调 73.8% 接近

- 同一验证集口径：WikiSQL 逻辑形式验证准确率

方法（GPT-3 175B）	可训练参数	WikiSQL 准确率 %	MNLI-m 准确率 %
全量微调	175,255.8M	73.8	89.5
BitFit	14.2M	71.3	91.0
AdapterH	40.1M	73.2	91.5
LoRA	4.7M	73.4	91.7
LoRA	37.7M	74.0	91.6

05 / 06

采用建议：适用条件、论文证据与待实测

论文支持省显存与存储，本组速度仍需自测

- 适用：全量微调不可行或多任务需共享基座时
- 原论文证据：显存与检查点大幅下降，质量持平
- 待实测：本组 V100 的延迟、显存与吞吐
- 待实测：未合并权重的多任务批处理

06 / 06

6页；稿件SHA a91be2ef6c3a7f99fd36c69eb849c34d12e05a19d688f3d6dacd685685e68159；run 016fe42e35a347009aee597fe6efb48b

QLoRA / B 普通组合脚本 / 初稿 / 版本1

RESEARCH BRIEF

QLoRA： 显存受限下的模型适配方案讨论

- 4-bit 冻结基座 + LoRA 适配器训练
- NF4 / Double Quantization / Paged Optimizers 各自解决什么
- 论文结论成立的模型、任务与评测条件

来源见讲者备注 1 / 6

01 / 06

4-bit 冻结基座与适配器：省的是存储，不是算力

量化省存储；训练精度与激活开销不由 4-bit 决定

- 存储用 4-bit NF4 ，计算仍用 BFloat16
- 用到权重时先反量化再做 16-bit 矩阵乘
- 冻结点：仅 LoRA 权重的梯度被更新
- 7B 案例： 4-bit 基座占 5048 MB ， LoRA 参数仅 26 MB

来源见讲者备注 2 / 6

02 / 06

NF4 、 Double Quantization 、 Paged Optimizers 解决的问题

三者分别管精度、常数开销与长序列显存尖峰

1. **量化存储而非算力** 4-bit 冻结基座 + LoRA 适配器训练
2. **NF4 解决精度** NF4： 同一分布下优于 4-bit Float 与 Int4
3. **Double Quantization 省常** 32 位常数用 8-bit 块大小 256 再量化
4. **Paged Optimizers** 优化器状态分页，显存不足时换出 CPU 兜尖峰

来源见讲者备注 3 / 6

03 / 06

内存构成：省下来的是哪一块

量化压的是基座；尖峰要靠分页而非继续压参数

- 对比不同微调方法的显存需求
- 4-bit 量化基座加 Paged Optimizers 处理尖峰

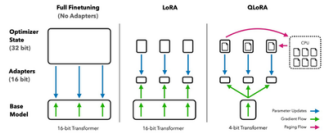


Figure 1: Different finetuning methods and their memory requirements. QLoRA improves over LoRA by quantizing the transformer model to 4-bit precision and using paged optimizers to handle memory spikes.

来源见讲者备注 4 / 6

04 / 06

各结论的模型、任务与评测口径

NF4+DQ 复现 16-bit； FP4 偏低，差距不可忽略

口径	条件	结果
GLUE 准确率	RoBERTa-large	BF16 88.6 / FP4 88.6
NaturalInstructions	T5 80M–11B	BF16 40.1–62.0
MMLU 5-shot	LLaMA 7–65B	BF16 53.0 / NF4 53.1
Vicuna 相对 ChatGPT	Guanaco 65B 4-bit	99.3% ， CI 4.4%

来源见讲者备注 5 / 6

05 / 06

结论边界：这套数字成立的条件

把单卡个案当作能力上限前，先逐项对齐模型、任务与硬件

- 原文仅在 3B 以内证明与 16-bit 全量微调持平
- 33B/65B 单卡结论绑定 24GB/48GB 显卡与块大小 64
- 小数据集也可能反超大数据集，数据质量优先
- Paged Optimizers 的分页阈值与减速条件未刻画

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA b4b5c2171f5c7014b8357f169eea6dc545491b465b0e80ec4731e2c2add32b3c；run bf61d27208b641d2ae61d16db5d83243

QLoRA / B 普通组合脚本 / 跨重启修订稿 / 版本1

RESEARCH BRIEF

QLoRA： 显存受限下的模型适配方案讨论

- 4-bit 冻结基座 + LoRA 适配器训练
- NF4 / Double Quantization / Paged Optimizers 各自解决什么
- 论文结论成立的模型、任务与评测条件

来源见讲者备注 1 / 6

01 / 06

4-bit 冻结基座与适配器：省的是存储，不是算力

量化省存储；训练精度与激活开销不由 4-bit 决定

- 存储用 4-bit NF4 ，计算仍用 BFloat16
- 用到权重时先反量化再做 16-bit 矩阵乘
- 冻结点：仅 LoRA 权重的梯度被更新
- 7B 案例： 4-bit 基座占 5048 MB ， LoRA 参数仅 26 MB

来源见讲者备注 2 / 6

02 / 06

NF4 、 Double Quantization 、 Paged Optimizers 解决的问题

三者分别管精度、常数开销与长序列显存尖峰

1. **量化存储而非算力** 4-bit 冻结基座 + LoRA 适配器训练
2. **NF4 解决精度** NF4： 同一分布下优于 4-bit Float 与 Int4
3. **Double Quantization 省常** 32 位常数用 8-bit 块大小 256 再量化
4. **Paged Optimizers** 优化器状态分页，显存不足时换出 CPU 兜尖峰

来源见讲者备注 3 / 6

03 / 06

内存构成：省下来的是哪一块

量化压的是基座；尖峰要靠分页而非继续压参数

- 对比不同微调方法的显存需求
- 4-bit 量化基座加 Paged Optimizers 处理尖峰

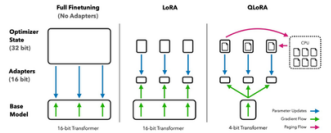


Figure 1: Different finetuning methods and their memory requirements. QLoRA improves over LoRA by quantizing the transformer model to 4-bit precision and using paged optimizers to handle memory spikes.

来源见讲者备注 4 / 6

04 / 06

各结论的模型、任务与评测口径

NF4+DQ 复现 16-bit； FP4 偏低，差距不可忽略

口径	条件	结果
GLUE 准确率	RoBERTa-large	BF16 88.6 / FP4 88.6
NaturalInstructions	T5 80M–11B	BF16 40.1–62.0
MMLU 5-shot	LLaMA 7–65B	BF16 53.0 / NF4 53.1
Vicuna 相对 ChatGPT	Guanaco 65B 4-bit	99.3% ， CI 4.4%

来源见讲者备注 5 / 6

05 / 06

本地待验证的容量、时间与质量指标

先把硬件与配置对齐，再比显存、时间与质量

- 论文数字均有配置前提，本地需同条件实测

指标	论文值与条件	本地量法
显存	65B 全量 >780GB； QLoRA<48GB	同配置记录峰值与构成
时间	65B 单卡 >24h； 33B 卡 <12h	每步耗时与是否换页
质量	MMLU5-shot BF16 53.0/NF4 53.1	同口径并报置信区间

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 93a7386aa80f27366eba8b0e6b414a0f2edce1c3ca5d2f5e9ae30586efb9afa7；run 7792e5ade38b4488a4e80c3e0f7c3b88

Prefix-Tuning / B 普通组合脚本 / 初稿 / 版本1

RESEARCH BRIEF

Prefix-Tuning： 只训练前缀以适配生成任务

- 冻结预训练语言模型，仅优化连续前缀
- 基于 Li & Liang 2021 （arXiv:2101.00190v1）
- 面向选择参数高效适配方法的研究讨论

来源见讲者备注 1 / 6

01 / 06

冻结主干，前缀从左侧上下文影响后续激活

不改变主干参数，仅靠左侧上下文引导生成

- 前 N 个时刻的激活取自可训练矩阵 Pθ
- 其后 token 仍可把前缀当作“虚拟 token”注意力



Figure 1: Fine-tuning (top) updates all Transformer parameters (the red Transformer box) and requires storing a full model copy for each task. We propose prefix-tuning (bottom), which freezes the Transformer parameters and only optimizes the prefix (the red prefix blocks). Consequently, we only need to store the prefix for each task, making prefix-tuning modular and space-efficient. Note that each vertical block denote transformer activations at one time step.

来源见讲者备注 2 / 6

02 / 06

训练时只有前缀参数更新，主干被固定

φ 固定、 θ 可训练，参数集决定信息流

1	**拼接前缀**	z=[PREFIX;x;y]； 编码器 - 解码器再加 PREFIX’（第 4 页）
2	**取用前缀激活**	Pθ 为 |Pidx|×dim(hi) 矩阵， i∈Pidx 时 hi=Pθ[i,:]（第 4 页）
3	**重参数化稳定训练**	Pθ=MLPθ(P’θ)，直接优化不稳定且略降（第 4 页）
4	**仅存前缀交付**	训练后可丢弃重参数化，只保存 Pθ （第 5 页）

来源见讲者备注 3 / 6

03 / 06

全数据下表到文可比，摘要略有下降

前缀方法在表到文可比，摘要仍略低于微调

- E2E/WebNLG/DART 为表到文（GPT-2），XSUM 为摘要（BART）

任务与指标	微调	前缀 0.1%
E2E BLEU ↑	68.5	70.3
WebNLG BLEU ↑	65.3	63.4
XSUM ROUGE-L ↑	37.25	35.05

来源见讲者备注 4 / 6

04 / 06

数据越少优势越明显，差距随规模收敛

优势出现在数据有限，而非所有条件都更优

- 低数据：前缀平均高出微调 2.9 BLEU
- 低数据下微调更易出现与表格不符的表述
- XSUM 样本量约为表到文数据集的 4 倍
- 文章输入平均长度约为线性化表格的 17 倍

来源见讲者备注 5 / 6

05 / 06

未证明的范围，与尚待验证的问题

边界条件明确：收益限于已报任务的指标

- 未比较显存、吞吐或推理延迟收益
- 新主题外推更好，但原因仍未解释
- 超出阈值的前缀长度反而略降
- 作者称可扩展到 GPT-3，但未做实验

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA b5217ed28f5e14e6a2645dc8865952f27d2aaf6f9c1f80d6503a5a5505777351；run 31b0a161fa2444eb95bf07efe0f466aa

Prefix-Tuning / B 普通组合脚本 / 跨重启修订稿 / 版本1

RESEARCH BRIEF

Prefix-Tuning： 只训练前缀以适配生成任务

- 冻结预训练语言模型，仅优化连续前缀
- 基于 Li & Liang 2021 （arXiv:2101.00190v1）
- 面向选择参数高效适配方法的研究讨论

来源见讲者备注 1 / 6

01 / 06

冻结主干，前缀从左侧上下文影响后续激活

不改变主干参数，仅靠左侧上下文引导生成

- 前 N 个时刻的激活取自可训练矩阵 Pθ
- 其后 token 仍可把前缀当作“虚拟 token” 注意力



Figure 1: Fine-tuning (top) updates all Transformer parameters (the red Transformer box) and requires storing a full model copy for each task. We propose prefix-tuning (bottom), which freezes the Transformer parameters and only optimizes the prefix (the red prefix blocks). Consequently, we only need to store the prefix for each task, making prefix-tuning modular and space-efficient. Note that each vertical block denote transformer activations at one time step.

来源见讲者备注 2 / 6

02 / 06

训练时只有前缀参数更新，主干被固定

φ 固定、 θ 可训练，参数集决定信息流

拼接前缀	z=[PREFIX;x;y]； 编码器 - 解码器再加 PREFIX’（第 4 页）
取用前缀激活	Pθ 为 |Pidx|×dim(hi) 矩阵， i∈Pidx 时 hi=Pθ[i,:]（第 4 页）
重参数化稳定训练	Pθ=MLPθ(P’θ)，直接优化不稳定且略降（第 4 页）
仅存前缀交付	训练后可丢弃重参数化，只保存 Pθ （第 5 页）

来源见讲者备注 3 / 6

03 / 06

全数据下表到文可比，摘要略有下降

前缀方法在表到文可比，摘要仍略低于微调

- E2E/WebNLG/DART 为表到文（GPT-2），XSUM 为摘要（BART）

任务与指标	微调	前缀 0.1%
E2E BLEU ↑	68.5	70.3
WebNLG BLEU ↑	65.3	63.4
XSUM ROUGE-L ↑	37.25	35.05

来源见讲者备注 4 / 6

04 / 06

数据越少优势越明显，差距随规模收敛

优势出现在数据有限，而非所有条件都更优

- 低数据：前缀平均高出微调 2.9 BLEU
- 低数据下微调更易出现与表格不符的表述
- XSUM 样本量约为表到文数据集的 4 倍
- 文章输入平均长度约为线性化表格的 17 倍

来源见讲者备注 5 / 6

05 / 06

采用条件、原文证据与仍需实测的事项

论文结论限于已报指标，资源收益未被验证

- 冻结适配在表到文与低数据下可比或更好
- 摘要全数据下前缀仍略低于微调
- 前缀长度存在阈值，超出后测试指标略降
- 可训练参数少不等于省显存或更高吞吐

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 9998117cbad6e7f245c29d0cde5713c2619a67b890154f33f4f8970d340a0074；run 98ffb1934a824bf9a33db7a33c3ebf67

FlashAttention-2 / A 普通 DSH / 初稿 / 版本1

FlashAttention-2：为何改、改了什么

它改的是划分方式，不改变注意力结果

- 原版仅达理论峰值 25–40%，落后于 GEMM
- 根因：线程块与 warp 间 work partitioning 不优
- 三项改动：减少非 matmul、序列维并行、warp 分块
- 结果不近似，O 与标准注意力一致

来源见讲者备注 1 / 6

01 / 06

原图：前向按行块并行，反向按列块并行

- 改动集中在 thread block 与 warp 两级划分

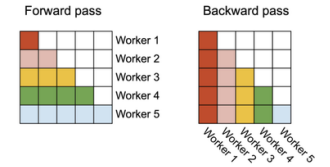


Figure 2: In the forward pass (left), we parallelize the workers (thread blocks) where each worker takes care of a block of rows of the attention matrix. In the backward pass (right), each worker takes care of a block of columns of the attention matrix.

来源见讲者备注 2 / 6

02 / 06

相对原版的三个具体改动

不改变输出	仍为精确注意力，仅减少非 matmul FLOPs
序列维并行	长序列小 batch 时新增行 / 列块并行，提高占用率
warp 改分 Q	原版拆 K/V 需共享内存同步；改为拆 Q，warp 间无须通信
反向避 split-K	仍有同步，但减少共享内存读写
端到端训练	GPT 1.3B/2.7B，2k/8k，8×A100，最高 225 TFLOPs/s

来源见讲者备注 3 / 6

03 / 06

论文实测：训练吞吐与硬件 / 配置条件

- 同硬件同模型下，8k 上下文收益大于 2k

配置 (8×A100)	无 FA	FA	FA-2
GPT3-1.3B, 2k	142	189	196
GPT3-1.3B, 8k	72	170	220
GPT3-2.7B, 2k	149	189	205
GPT3-2.7B, 8k	80	175	225

来源见讲者备注 4 / 6

04 / 06

算法精确性与内核性能、端到端收益不是一回事

原文直接支持

- 输出与标准注意力一致，无近似
- 增量内存 O(N) 而非 $O(N^2)$
- 前向峰值从 40% 提至 50–73%

有条件，不能外推

- 内核与端到端数据均取自 A100
- H100 数据未用 TMA 与四代张量核
- 全文未给 V100 实测
- 序列维并行思路源自 Triton

来源见讲者备注 5 / 6

05 / 06

回到 V100：可迁移的改动与未复现的收益

先在 V100 实测内核，再决定是否全量采用

- A100 上 225 TFLOPs/s 未在 V100 复现
- 机制改动针对划分，不依赖 A100 专属指令
- 可先验证 1.7–3.0× 内核倍数是否在 V100 成立
- V100 与 A100 张量核代际条件不同，需实测

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 41510e479bd8f5dd754fbf5ca0dbe95a060ba6ab5018ea793eb2fa68d6ef557d；run 7b48acbf9a824f2985bb6c03c20dc6a5

FlashAttention-2 / A 普通 DSH / 跨重启修订稿 / 版本1

FlashAttention-2：为何改、改了什么

它改的是划分方式，不改变注意力结果

- 原版仅达理论峰值 25–40%，落后于 GEMM
- 根因：线程块与 warp 间 work partitioning 不优
- 三项改动：减少非 matmul、序列维并行、warp 分块
- 结果不近似，O 与标准注意力一致

来源见讲者备注 1 / 6

01 / 06

原图：前向按行块并行，反向按列块并行

- 改动集中在 thread block 与 warp 两级划分

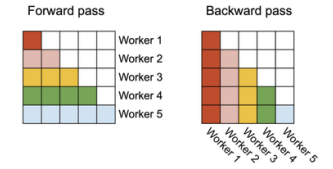


Figure 2: In the forward pass (left), we parallelize the workers (thread blocks) where each worker takes care of a block of rows of the attention matrix. In the backward pass (right), each worker takes care of a block of columns of the attention matrix.

来源见讲者备注 2 / 6

02 / 06

相对原版的三个具体改动

不改变输出	仍为精确注意力，仅减少非 matmul FLOPs
序列维并行	长序列小 batch 时新增行 / 列块并行，提高占用率
warp 改分 Q	原版拆 K/V 需共享内存同步；改为拆 Q，warp 间无须通信
反向避 split-K	仍有同步，但减少共享内存读写
端到端训练	GPT 1.3B/2.7B，2k/8k，8×A100，最高 225 TFLOPs/s

来源见讲者备注 3 / 6

03 / 06

论文实测：训练吞吐与硬件 / 配置条件

- 同硬件同模型下，8k 上下文收益大于 2k

配置 (8×A100)	无 FA	FA	FA-2
GPT3-1.3B, 2k	142	189	196
GPT3-1.3B, 8k	72	170	220
GPT3-2.7B, 2k	149	189	205
GPT3-2.7B, 8k	80	175	225

来源见讲者备注 4 / 6

04 / 06

算法精确性与内核性能、端到端收益不是一回事

原文直接支持

- 输出与标准注意力一致，无近似
- 增量内存 O(N) 而非 $O(N^2)$
- 前向峰值从 40% 提至 50–73%

有条件，不能外推

- 内核与端到端数据均取自 A100
- H100 数据未用 TMA 与四代张量核
- 全文未给 V100 实测
- 序列维并行思路源自 Triton

来源见讲者备注 5 / 6

05 / 06

三条判断：采用前提、V100 空白与最小验证

先在 V100 复现内核倍数，再决定是否全量采用

- 采用前提：关注内核级加速且硬件条件与论文一致
- 论文未测 V100，225 TFLOPs/s 与 1.7–3.0× 不可直接外推
- 论文以 A100 的 16× 非 matmul/matmul 比解释开销

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 4ad7f92fdaba01618faf3775d65b167201dfcb988f58d56f4af2f91d1d065063；run 37fb884ffa5c4f08bb57763735da2958

FlashAttention-2 / B 普通组合脚本 / 初稿 / 版本1

是否采用 FlashAttention-2： 先分清三层收益

本报告按算法精确性、内核性能、端到端收益三层核对证据

- 论文报告：相对 FlashAttention 约 2× 加速，非端到端训练加速
- 内核实测硬件为 A100 80GB SXM4 / 8×A100 80GB SXM
- 算法输出不变、无近似；但我们用 V100 ，收益未在该卡复现
- 端到端加速还依赖模型规模、序列长度与精度选择

来源见讲者备注 1 / 6

01 / 06

并行： FlashAttention 按批与头划分，长序列占用不足

并行度不足来自网格规模，不是算术量本身

- v1 每头一个 thread block ，总数 = 批大小 × 头数
- A100 有 108 个 SM ，块数≥ 80 时才接近用满
- 长序列常伴随小批小头数，易出现低占用
- 所以 v1 在长序列区间并非算力受限

来源见讲者备注 2 / 6

02 / 06

FlashAttention-2 的三处改动

三处改动分别针对非矩阵乘开销、并行度与共享内存通信

01
减少非矩阵乘 FLOP
输出不再每步重缩放，只保存 logsumexp ；输出不变

→

02
沿序列长度分块
在批与头之外再切序列，块数随之增加

→

03
warp 内划分工作量
前向按 Q 切分，避免 split-K ，减少共享内存读写

来源见讲者备注 3 / 6

03 / 06

非矩阵乘开销为何关键： A100 上相差 16 倍

在 A100 上每个非矩阵乘 FLOP 的代价约为矩阵乘的 16 倍

- A100 理论峰值： FP16/BF16 矩阵乘 312 TFLOPs/s
- 非矩阵乘 FP32 仅 19.5 TFLOPs/s ，低约 16 倍
- 同一算子内，非矩阵乘 FLOP 耗时更贵
- 故减少它们比减少总 FLOP 更影响吞吐

来源见讲者备注 4 / 6

04 / 06

内核实测： A100 、头维 64/128 、无掩码前向

- 头维 128 、序列 16k： FA 平均 122 ， FA2 达 223 TFLOPs/s
- 头维 64 、序列 16k： FA2 为 155 ， FA 平均约 155
- 总 token 固定 16k ，批大小随序列长度调整

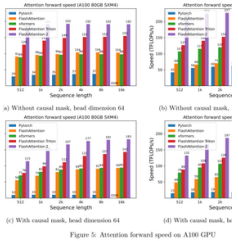


Figure 5: Attention forward speed on A100 GPU

来源见讲者备注 5 / 6

05 / 06

端到端训练收益： 8×A100 ， 1.3B/2.7B ， 2k/8k

增益随序列长度增大而增大， 2k 时仅约 1.04–1.14×

配置（ 8×A100 ）	不用 FA	FlashAttention	FlashAttention-2
1.3B ， 2k	142 TFLOPs/s	189	196
1.3B ， 8k	72 TFLOPs/s	170	220
2.7B ， 2k	149 TFLOPs/s	189	205
2.7B ， 8k	80 TFLOPs/s	175	225

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 09bc18ce2c1aa3601e2d94e4a0dca0f3e34985e099070ee886f98cf918c5d933；run 7d6b5e4e2791492d9eda338a31946e52

FlashAttention-2 / B 普通组合脚本 / 跨重启修订稿 / 版本1

是否采用 FlashAttention-2： 先分清三层收益

本报告按算法精确性、内核性能、端到端收益三层核对证据

- 论文报告：相对 FlashAttention 约 2× 加速，非端到端训练加速
- 内核实测硬件为 A100 80GB SXM4 / 8×A100 80GB SXM
- 算法输出不变、无近似；但我们用 V100，收益未在该卡复现
- 端到端加速还依赖模型规模、序列长度与精度选择

来源见讲者备注 1 / 6

01 / 06

并行： FlashAttention 按批与头划分，长序列占用不足

并行度不足来自网格规模，不是算术量本身

- v1 每头一个 thread block，总数 = 批大小 × 头数
- A100 有 108 个 SM，块数≥ 80 时才接近用满
- 长序列常伴随小批小头数，易出现低占用
- 所以 v1 在长序列区间并非算力受限

来源见讲者备注 2 / 6

02 / 06

FlashAttention-2 的三处改动

三处改动分别针对非矩阵乘开销、并行度与共享内存通信

01
减少非矩阵乘 FLOP
输出不再每步重缩放，只保存 logsumexp；输出不变

→

02
沿序列长度分块
在批与头之外再切序列，块数随之增加

→

03
warp 内划分工作量
前向按 Q 切分，避免 split-K，减少共享内存读写

来源见讲者备注 3 / 6

03 / 06

非矩阵乘开销为何关键： A100 上相差 16 倍

在 A100 上每个非矩阵乘 FLOP 的代价约为矩阵乘的 16 倍

- A100 理论峰值： FP16/BF16 矩阵乘 312 TFLOPs/s
- 非矩阵乘 FP32 仅 19.5 TFLOPs/s，低约 16 倍
- 同一算子内，非矩阵乘 FLOP 耗时更贵
- 故减少它们比减少总 FLOP 更影响吞吐

来源见讲者备注 4 / 6

04 / 06

内核实测： A100 、头维 64/128 、无掩码前向

- 头维 128 、序列 16k： FA 平均 122， FA2 达 223 TFLOPs/s
- 头维 64 、序列 16k： FA2 为 155， FA 平均约 155
- 总 token 固定 16k，批大小随序列长度调整

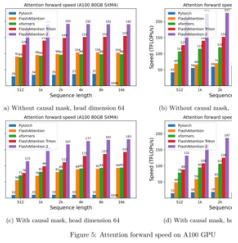


Figure 5: Attention forward speed on A100 GPU

来源见讲者备注 5 / 6

05 / 06

结论与验证：论文支持什么 ,V100 仍待验证

论文支持 A100 收益 ;V100 需同口径复跑验证

- A100 已实测 ;V100 未报告数据
- 建议先同口径复跑 1.3B 2k/8k

8×A100	不用 FA	FA	FA-2
1.3B 2k	142	189	196
1.3B 8k	72	170	220
2.7B 2k	149	189	205
2.7B 8k	80	175	225

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA b4fe3bbbfe3d228004a3232602e2c5c35d43533738690b6ca22b982beac05a96；run 0c00c76bff16423095b670a48d778af8

FlashAttention-2 / C 认证 Motif / 初稿 / 版本1

RESEARCH BRIEF

是否采用 FlashAttention-2： 证据与适用条件

先确认收益条件，再决定是否在我们集群推广

- 解析论文：官方报告 v1 （2023-07-17）
- 优点：更好的并行与工作划分（A100 基准）
- 边界：本组使用 V100，尚未实测复现

来源见讲者备注 1 / 6

01 / 06

它改了什么：算法精确性未变的三项调整

三项调整都不改变输出，不放宽精确性

01 少做非矩阵乘运算
不缩放输出两项，只保存 logsumexp （第 5 页）

→

02 沿序列长度并行
在 batch 与头维度之外增加切分，提高占用率（第 8 页）

→

03 warp 间分工
按 Q 切分 warp，避免 split-K 与共享内存往返（第 9 页）

来源见讲者备注 2 / 6

02 / 06

前向 warp 分工：为何不再需要 split-K

同一步骤顺序改变，消除了 warp 间通信

- 左：旧版按 K/V 分割，需共享内存加和
- 右：新版按 Q 分割，各 warp 直接得输出切片

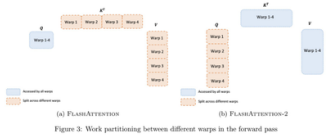


Figure 3: Work partitioning between different warps in the forward pass

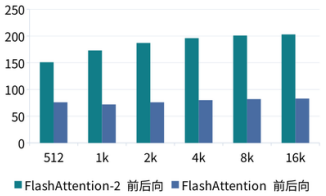
来源见讲者备注 3 / 6

03 / 06

A100 实测：同条件下前向与反向吞吐对比

该子图条件下吞吐约翻倍

- 仅重绘论文部分子图：无 causal 、头维 128
- 同图另有 PyTorch 与 Triton 曲线，此处未列全

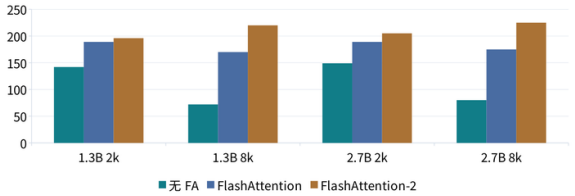


来源见讲者备注 4 / 6

04 / 06

端到端训练吞吐： FA-2 最高 225 TFLOPs/s （A100）

端到端收益在 8×A100 上测得，非 V100



来源见讲者备注 5 / 6

05 / 06

采用判断：收益分三类， V100 待自测

先做 V100 小规模实测，再决定是否全面采用

论文已证	我们待证
A100 上内核与端到端吞吐提升	V100 上并行与占用率是否受益
仍是精确算法，无近似输出	当前算子的数据类型与头维覆盖
只存 logsumexp 省显存	端到端训练时长是否改善

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA ae1df684bc9bacca212631879c2f4adf8f53164fad1873affbaca8545a422bf7；run 79b8eda253af4d60bd36a7099c7efdde

FlashAttention-2 / C 认证 Motif / 跨重启修订稿 / 版本1

RESEARCH BRIEF

是否采用 FlashAttention-2： 证据与适用条件

先确认收益条件，再决定是否在我们集群推广

- 解析论文：官方报告 v1 （2023-07-17）
- 优点：更好的并行与工作划分（A100 基准）
- 边界：本组使用 V100，尚未实测复现

来源见讲者备注 1 / 6

01 / 06

它改了什么：算法精确性未变的三项调整

三项调整都不改变输出，不放宽精确性

01 少做非矩阵乘运算
不缩放输出两项，只保存 logsumexp （第 5 页）

→

02 沿序列长度并行
在 batch 与头维度之外增加切分，提高占用率（第 8 页）

→

03 warp 间分工
按 Q 切分 warp，避免 split-K 与共享内存往返（第 9 页）

来源见讲者备注 2 / 6

02 / 06

前向 warp 分工：为何不再需要 split-K

同一步骤顺序改变，消除了 warp 间通信

- 左：旧版按 K/V 分割，需共享内存加和
- 右：新版按 Q 分割，各 warp 直接得输出切片

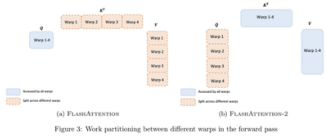


Figure 3: Work partitioning between different warps in the forward pass

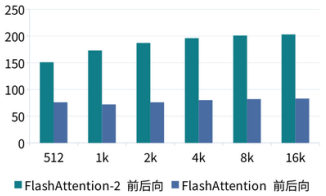
来源见讲者备注 3 / 6

03 / 06

A100 实测：同条件下前向与反向吞吐对比

该子图条件下吞吐约翻倍

- 仅重绘论文部分子图：无 causal 、头维 128
- 同图另有 PyTorch 与 Triton 曲线，此处未列全

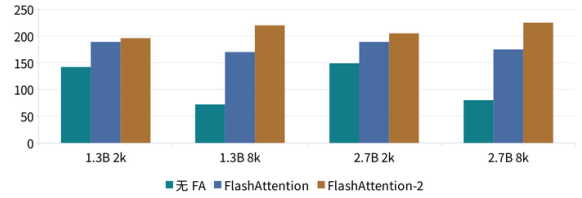


来源见讲者备注 4 / 6

04 / 06

端到端训练吞吐： FA-2 最高 225 TFLOPs/s （A100）

端到端收益在 8×A100 上测得，非 V100



来源见讲者备注 5 / 6

05 / 06

三条判断：论文已证、 V100 待验、先做小测

收益未在 V100 复现，先小规模实测再决定采用

01 论文已证
精确注意力； A100 上内核与端到端吞吐提升

→

02 V100 待验
并行占用率、数据类型覆盖、端到端时长均需自测

→

03 最小实测
在 V100 上按头维调块大小，先比内核吞吐与显存

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 74e5b8ef775c89b2f7ed24b787c12dde531f00747c711567f2ad9e5f1cb0174f；run a0f4d1c87769486bb256a8add6264013

Mistral 7B + Mixtral / C 认证 Motif / 初稿 / 版本1

RESEARCH BRIEF

资源受限时：密集模型还是稀疏 MoE

限制在算力侧还是容量侧决定选择

- 两篇原论文：Mistral 7B 与 Mixtral 8x7B
- 资源受限时如何选型
- 标清口径，不做跨协议排名

来源见讲者备注 1 / 8

01 / 08

先分清两篇论文各证明了什么

可比的是方法口径，不是跨论文分数

- 两文均用自家流水线重跑基线
- 协议样本数不同，分数不可拼榜

维度	Mistral 7B	Mixtral 8x7B
结构	密集 FFN + GQA/SWA	8 个专家，选 2 个
计算参数	7B 全激活	13B 激活 / 47B 总
训练上下文	8k 配置	32k 上下文
评测协议	0/3/4/8-shot	0/3/4/5/8-shot

来源见讲者备注 2 / 8

02 / 08

Mistral 的注意力设计： GQA + 滑动窗口

固定窗口是缓存与成本受控的来源

1. **GQA 分组查询** — 32 个查询头共享 8 个 KV 头，降低解码显存
2. **滑动窗口注意力** — 位置 i 只看上一层 i−W 到 i， W=4096
3. **滚动缓冲区缓存** — KV 存在 i mod W ，缓存固定为 W
4. **预填充与分块** — 长提示按窗口切块预填充

来源见讲者备注 3 / 8

03 / 08

Mistral 滑动窗口的原文示意

单层视野有限，多层叠加扩大有效跨度

- 图中 W=3： 每个 token 只回看 3 个位置
- 窗口外 token 经多层间接影响预测

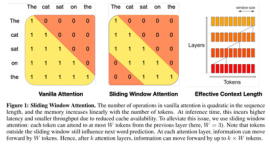


Figure 1: Sliding Window Attention. The number of operations in vanilla attention is quadratic in the sequence length, and the memory increases linearly with the number of tokens. At inference time, this incurs higher latency and smaller throughput due to reduced cache availability. To alleviate this issue, we use sliding window attention: each token can attend to at most W tokens from the previous layer (here, $W = 3$). Note that tokens outside the sliding window still influence next word prediction. At each attention layer, information can move forward by W tokens. Hence, after k attention layers, information can move forward by up to $k \times W$ tokens.

来源见讲者备注 4 / 8

04 / 08

Mixtral 路由：每 token 只过 2 个专家

总参数随专家数增长，计算量由 Top-K 决定

1. **门控打分** — 线性层 Wg 对 8 个专家计算 logits
2. **Top-2 选择** — 取 top-2 logits 做 softmax，其余置零
3. **专家计算与相加** — 两个 SwiGLU 专家按权重相加
4. **并行与均衡** — 专家并行路由 token，负载须均衡

来源见讲者备注 5 / 8

05 / 08

MoE 层的原文结构示意

专家是标准 FFN 块，稀疏性来自门控选择

- 输入向量经路由分给 8 个专家中的 2 个
- 层输出是两个专家输出的加权和

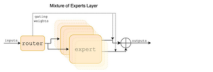


Figure 1: Mixture of Experts Layer. Each input vector is assigned to 2 of the 8 experts by a router. The layer's output is the weighted sum of the outputs of the two selected experts. In Mistral, an expert is a standard feedforward block as in a vanilla transformer architecture.

来源见讲者备注 6 / 8

06 / 08

两文结果：口径完整但互不可比

报告分数须同时给出 shot 数与条件

- 各列只在本论文内可比
- 70B 对标仅限激活参数口径

结果项	Mistral 7B	Mixtral 8x7B
MMLU	60.1%	70.6%
GSM8K	52.2%	74.4%
MBPP	47.5%	60.7%
模型规模	7B 密集	13B 激活 / 47B 总
对标基线	Llama 2 7B/13B	Llama 2 70B 、GPT-3.5

来源见讲者备注 7 / 8

07 / 08

同维度对照与选型边界

用户硬件上的显存与吞吐均待实测

Mistral 7B （密集）

- 7B 参数逐 token 全参与
- KV 缓存固定为 W
- 对标 Llama 2 7B/13B

Mixtral 8x7B （稀疏 MoE ）

- 8 专家选 2， 13B/47B
- 内存按 47B 稀疏参数计
- 路由有额外开销

来源见讲者备注 8 / 8

08 / 08

8页；稿件SHA 8c3891f91034378cf2d2f061c0c6e241d1ca3a36bcd3660d0aa29f6afd3be252；run 2f9779d1fbaf4a94bc84c127f1c94edc

Mistral 7B + Mixtral / C 认证 Motif / 跨重启修订稿 / 版本1

RESEARCH BRIEF

资源受限时：密集模型还是稀疏 MoE

限制在算力侧还是容量侧决定选择

- 两篇原论文：Mistral 7B 与 Mixtral 8x7B
- 资源受限时如何选型
- 标清口径，不做跨协议排名

来源见讲者备注 1 / 8

01 / 08

先分清两篇论文各证明了什么

可比的是方法口径，不是跨论文分数

- 两文均用自家流水线重跑基线
- 协议样本数不同，分数不可拼榜

维度	Mistral 7B	Mixtral 8x7B
结构	密集 FFN + GQA/SWA	8 个专家，选 2 个
计算参数	7B 全激活	13B 激活 / 47B 总
训练上下文	8k 配置	32k 上下文
评测协议	0/3/4/8-shot	0/3/4/5/8-shot

来源见讲者备注 2 / 8

02 / 08

Mistral 的注意力设计： GQA + 滑动窗口

固定窗口是缓存与成本受控的来源

1. **GQA 分组查询** — 32 个查询头共享 8 个 KV 头，降低解码显存
2. **滑动窗口注意力** — 位置 i 只看上一层 i−W 到 i， W=4096
3. **滚动缓冲区缓存** — KV 存在 i mod W ，缓存固定为 W
4. **预填充与分块** — 长提示按窗口切块预填充

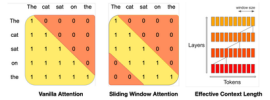
来源见讲者备注 3 / 8

03 / 08

Mistral 滑动窗口的原文示意

单层视野有限，多层叠加扩大有效跨度

- 图中 W=3： 每个 token 只回看 3 个位置
- 窗口外 token 经多层间接影响预测



来源见讲者备注 4 / 8

04 / 08

Mixtral 路由：每 token 只过 2 个专家

总参数随专家数增长，计算量由 Top-K 决定

1. **门控打分** — 线性层 Wg 对 8 个专家计算 logits
2. **Top-2 选择** — 取 top-2 logits 做 softmax，其余置零
3. **专家计算与相加** — 两个 SwiGLU 专家按权重相加
4. **并行与均衡** — 专家并行路由 token，负载须均衡

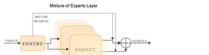
来源见讲者备注 5 / 8

05 / 08

MoE 层的原文结构示意

专家是标准 FFN 块，稀疏性来自门控选择

- 输入向量经路由分给 8 个专家中的 2 个
- 层输出是两个专家输出的加权和



来源见讲者备注 6 / 8

06 / 08

两文结果：口径完整但互不可比

报告分数须同时给出 shot 数与条件

- 各列只在本论文内可比
- 70B 对标仅限激活参数口径

结果项	Mistral 7B	Mixtral 8x7B
MMLU	60.1%	70.6%
GSM8K	52.2%	74.4%
MBPP	47.5%	60.7%
模型规模	7B 密集	13B 激活 / 47B 总
对标基线	Llama 2 7B/13B	Llama 2 70B 、GPT-3.5

来源见讲者备注 7 / 8

07 / 08

选型建议：四类判断依据与来源归属

内存与服务负载定门槛，最终须实测

判断依据	Mistral 7B	Mixtral 8x7B
总内存约束	7B 密集参数	47B 稀疏参数
服务负载	逐 token 全参与	路由 / 多专家开销
质量证据	MMLU 60.1%	MMLU 70.6%
评估口径	口径不同，不可比	不可拼排行榜
待实测指标	显存 / 吞吐 / 延迟	原文未给

来源见讲者备注 8 / 8

08 / 08

8页；稿件SHA 039b3a2659722d450985fc4fff63004f0515aa362e3e62b710e760564ca7bbd2；run 20dd8f06f27d4681a768ea1834af289d

Mistral 7B + Mixtral / B 普通组合脚本 / 初稿 / 版本1

RESEARCH BRIEF

受限服务资源下：选密集 7B 还是稀疏 MoE

- 两篇原论文的机制、评测口径与决策边界
- 面向组会：算力预算固定时如何选型

01 / 08

决策问题：预算受限时约束落在哪一层？

- **先分清算力约束与显存约束，再谈选型**
- 两模型同基线架构，差异在注意力与 FFN
- 计算量随激活参数走，显存随参数量走
- 原文未给显存 / 吞吐 / 延迟，须待实测

02 / 08

Mistral 7B ： 滑窗注意力与 GQA 换长序列效率

- GQA ： 32 个查询头配 8 个 KV 头，降解码期内存
- SWA ： 每层最多回看 W=4096 个 token
- 32 层理论依赖跨度约 131K token
- 16K 序列下实测 2x 提速（对比 vanilla ）

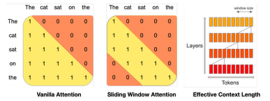


Figure 1: Sliding Window Attention. The number of operations in vanilla attention is quadratic in the sequence length, and the memory increases linearly with the number of tokens. At inference time, this incurs higher latency and smaller throughput due to reduced cache availability. To alleviate this issue, we use sliding window attention: each token can attend to at most W tokens from the previous layer (here, $W = 3$). Note that tokens outside the sliding window still influence next word prediction. At each attention layer, information can move forward by W tokens. Hence, after k attention layers, information can move forward by up to $k \times W$ tokens.

03 / 08

Mixtral ： 47B 总参数，每 token 只激活 13B

1	**路由打分**	每层每 token 对 8 个专家算门控 logits
2	**取 Top-2**	K=2 ，保留前两名专家做 softmax
3	**加权求和**	输出为两专家输出的加权和
4	**跳过其余**	门控为零的专家不参与计算

04 / 08

专家层结构： MoE 替换前馈块，每 token 选 2 个专家

- 门控网络从 8 个专家中选 2 个
- 输出为两专家输出的加权和



Figure 1: Mixture of Experts Layer. Each input vector is assigned to 2 of the 8 experts by a router. The layer's output is the weighted sum of the outputs of the two selected experts. In Mistral, an expert is a standard feedforward block as in a vanilla transformer architecture.

05 / 08

同源指标并置：各自完整评测口径与可比边界

- 两表同源指标定义相同，但对照组不同

口径项	Mistral 7B	Mixtral 8x7B
评测框架	自有 pipeline 重跑	自有 pipeline 重跑
MMLU(5-shot)	60.1%	70.6%
GSM8K(8-shot maj@8)	52.2%	74.4%
HumanEval(0-shot)	30.5%	40.2%
MBPP(3-shot)	47.5%	60.7%

06 / 08

同维度对照：参数口径、计算来源与序列机制

密集 Mistral 7B	稀疏 Mixtral 8x7B
总参数 = 激活参数 =7B	总参 47B ，每 token 激活 13B
计算与参数同增，无路由开销	服务显存随 47B 稀疏参数
长序列效率靠 SWA 与 GQA	路由与多专家带来额外开销
16K 序列报 2x 提速	小 batch 更快、大 batch 吞吐更高

07 / 08

结论与待实测清单

- **约束落在算力还是显存，决定选型，且二者需分别实测**
- 小 batch 算力受限：稀疏激活更少，但需实测路由开销
- 显存受限：按 47B 稀疏参数粗估上限，非按 13B
- 专家并行下负载不均可能削弱稀疏收益
- 本稿未验证：用户硬件显存 / 吞吐 / 延迟与公平复跑

08 / 08

8页；稿件SHA 16d377b0f22a04d42772a83fe6334454566b7d0caf13e3042c00e6c9be8d9c56；run eea7923b444f4d81af69d8124e83a987

Mistral 7B + Mixtral / B 普通组合脚本 / 跨重启修订稿 / 版本1

RESEARCH BRIEF

受限服务资源下：选密集 7B 还是稀疏 MoE

- 两篇原论文的机制、评测口径与决策边界
- 面向组会：算力预算固定时如何选型

来源见讲者备注 1 / 8

01 / 08

决策问题：预算受限时约束落在哪一层？

- 先分清算力约束与显存约束，再谈选型
- 两模型同基线架构，差异在注意力与 FFN
- 计算量随激活参数走，显存随参数量走
- 原文未给显存 / 吞吐 / 延迟，须待实测

来源见讲者备注 2 / 8

02 / 08

Mistral 7B： 滑窗注意力与 GQA 换长序列效率

- GQA： 32 个查询头配 8 个 KV 头，降解码期内存
- SWA： 每层最多回看 W=4096 个 token
- 32 层理论依赖跨度约 131K token
- 16K 序列下实测 2x 提速（对比 vanilla ）

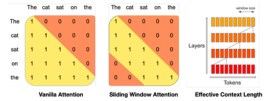


Figure 1: Sliding Window Attention. The number of operations in vanilla attention is quadratic in the sequence length, and the memory increases linearly with the number of tokens. At inference time, this incurs higher latency and smaller throughput due to reduced cache availability. To alleviate this issue, we use sliding window attention: each token can attend to at most W tokens from the previous layer (here, W = 3). Note that tokens outside the sliding window still influence next word prediction. At each attention layer, information can move forward by W tokens. Hence, after k attention layers, information can move forward by up to k × W tokens.

来源见讲者备注 3 / 8

03 / 08

Mixtral： 47B 总参数，每 token 只激活 13B

1. **路由打分** — 每层每 token 对 8 个专家算门控 logits
2. **取 Top-2** — K=2 ，保留前两名专家做 softmax
3. **加权求和** — 输出为两专家输出的加权和
4. **跳过其余** — 门控为零的专家不参与计算

来源见讲者备注 4 / 8

04 / 08

专家层结构： MoE 替换前馈块，每 token 选 2 个专家

- 门控网络从 8 个专家中选 2 个
- 输出为两专家输出的加权和

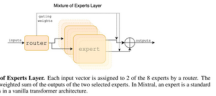


Figure 1: Mixture of Experts Layer. Each input vector is assigned to 2 of the 8 experts by a router. The layer's output is the weighted sum of the outputs of the two selected experts. In Mistral, an expert is a standard feedforward block as in a vanilla transformer architecture.

来源见讲者备注 5 / 8

05 / 08

同源指标并置：各自完整评测口径与可比边界

- 两表同源指标定义相同，但对照组不同

口径项	Mistral 7B	Mixtral 8x7B
评测框架	自有 pipeline 重跑	自有 pipeline 重跑
MMLU(5-shot)	60.1%	70.6%
GSM8K(8-shot maj@8)	52.2%	74.4%
HumanEval(0-shot)	30.5%	40.2%
MBPP(3-shot)	47.5%	60.7%

来源见讲者备注 6 / 8

06 / 08

同维度对照：参数口径、计算来源与序列机制

密集 Mistral 7B	稀疏 Mixtral 8x7B
总参数 = 激活参数 =7B	总参 47B ，每 token 激活 13B
计算与参数同增，无路由开销	服务显存随 47B 稀疏参数
长序列效率靠 SWA 与 GQA	路由与多专家带来额外开销
16K 序列报 2x 提速	小 batch 更快、大 batch 吞吐更高

来源见讲者备注 7 / 8

07 / 08

选型建议：四类决策输入与待实测清单

- 论文事实定口径与质量，硬件结论仍是设计推论，须实测
- 总内存：按 47B 稀疏参数规划，不可按 13B 激活参数
- 服务负载：单条快、批量吞吐高，路由有额外开销
- 质量： Mixtral 在多类目超 Llama2-70B ，激活参数少 5 倍
- 待实测：用户硬件显存 / 吞吐 / 延迟与负载不均

来源见讲者备注 8 / 8

08 / 08

8页；稿件SHA e5f248a399766575ca076619e4dca87cb98a49f28dacba5c7e8f13c56ce2aa35；run 9c849aaf61b049a5b885b3ce19259d32

Mistral 7B + Mixtral / A 普通 DSH / 初稿 / 版本1

RESEARCH BRIEF

受限服务资源下：密集模型还是稀疏 MoE

- Mistral 7B 与 Mixtral 8x7B 原论文方案讨论
- 面向：研究同学组会，8 页

01 / 08

决策问题：受限资源下先锁定可核算的约束

激活参数只对应算力，不等价于加载显存

- 服务资源可核算项：显存占用、推理算力、吞吐与延迟
- Mistral 7B：7B 参数密集，逐 token 全量使用
- Mixtral 8x7B：总参数 47B，每 token 激活 13B
- 现缺条件：显存 / 吞吐 / 延迟只写待实测

02 / 08

Mistral 7B：注意力与缓存如何压低推理开销

W=4096 时理论注意跨度约 131K tokens

- 原图 Figure 1：滑动窗口注意力，W=3
- 窗口固定使缓存有界，长序列开销受控

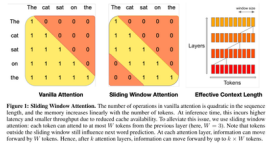


Figure 1: Sliding Window Attention. The number of operations in vanilla attention is quadratic in the sequence length, and the memory increases linearly with the number of tokens. At inference time, this incurs higher latency and smaller throughput due to reduced cache availability. To alleviate this issue, we use sliding window attention: each token can attend to at most W tokens from the previous layer (here, $W = 3$). Note that tokens outside the sliding window still influence next word prediction. At each attention layer, information can move forward by W tokens. Hence, after k attention layers, information can move forward by up to $k \times W$ tokens.

03 / 08

Mixtral：路由只激活 top-2 专家，算力与容量解耦

每 token 可见 47B 参数，推理仅用 13B 激活

- 原图 Figure 1：路由器从 8 个专家中选 2 个
- 输出为两个被选专家输出的加权和



Figure 1: Mixture of Experts Layer. Each input vector is assigned to 2 of the 8 experts by a router. The layer's output is the weighted sum of the outputs of the two selected experts. In Mistral, an expert is a standard feedforward block as in a vanilla transformer architecture.

04 / 08

Mixtral 如何路由与激活专家

1	线性层打分	对每个 token 计算专家 logits
2	TopK 取前二	写作 G(x):=Softmax(TopK(x · Wg))
3	选 2 个专家	每个专家是 SwiGLU 前馈块
4	加权求和输出	按门控权重相加被选专家输出

05 / 08

架构对照：同口径项与单篇专有项

项	Mistral 7B	Mixtral 8x7B
层数 / dim	32 / 4096	32 / 4096
头数 / kv 头	32 / 8	32 / 8
hidden / vocab	14336 / 32000	14336 / 32000
仅单篇给出	window 4096，ctx 8192	ctx 32768，专家 8 选 2
参数口径	7B 密集全量	47B 总 / 13B 激活

06 / 08

结果阅读：两篇论文各自的口径不可直接拼分

跨论文同分数不等于公平对比

- Mistral：HellaSwag 81.3%、MMLU 60.1%、GSM8K 52.2%
- Mixtral：MMLU 70.6%、HumanEval 40.2%、GSM8K 74.4%
- 两文协议差异：MBPP 用手工核验子集、TriviaQA 不给维基上下文
- 故只能各自与自身基线比，不跨论文排名

07 / 08

结论与待验证：决策所需证据清单

倾向 Mistral 7B 密集

- 参数口径单一，容量与算力一致
- SWA+GQA 明确降低推理开销
- 知识类基准压缩率更低（1.9x）
- 显存 / 吞吐 / 延迟：待实测

倾向 Mixtral 8x7B 稀疏

- 总 47B、激活 13B，算力与容量解耦
- 多语言与数学代码结果更强
- 内存按 47B 计，且有路由开销
- 显存 / 吞吐 / 延迟：待实测

08 / 08

8页；稿件SHA a446866e0fd8e6754d7de3558532419acf58ef5d56477446f97afc5526fb6e0b；run 6f4e1767b03748cdb31a4c6e8cdedd31

Mistral 7B + Mixtral / A 普通 DSH / 跨重启修订稿 / 版本1

RESEARCH BRIEF

受限服务资源下：密集模型还是稀疏 MoE

- Mistral 7B 与 Mixtral 8x7B 原论文方案讨论
- 面向：研究同学组会， 8 页

01 / 08

决策问题：受限资源下先锁定可核算的约束

激活参数只对应算力，不等价于加载显存

- 服务资源可核算项：显存占用、推理算力、吞吐与延迟
- Mistral 7B： 7B 参数密集，逐 token 全量使用
- Mixtral 8x7B： 总参数 47B，每 token 激活 13B
- 现缺条件：显存 / 吞吐 / 延迟只写待实测

02 / 08

Mistral 7B： 注意力与缓存如何压低推理开销

W=4096 时理论注意跨度约 131K tokens

- 原图 Figure 1： 滑动窗口注意力， W=3
- 窗口固定使缓存有界，长序列开销受控

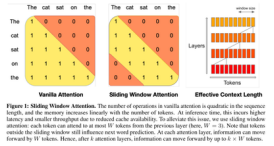


Figure 1: Sliding Window Attention. The number of operations in vanilla attention is quadratic in the sequence length, and the memory increases linearly with the number of tokens. At inference time, this incurs higher latency and smaller throughput due to reduced cache availability. To alleviate this issue, we use sliding window attention: each token can attend to at most W tokens from the previous layer (here, $W = 3$). Note that tokens outside the sliding window still influence next word prediction. At each attention layer, information can move forward by W tokens. Hence, after k attention layers, information can move forward by up to $k \times W$ tokens.

03 / 08

Mixtral： 路由只激活 top-2 专家，算力与容量解耦

每 token 可见 47B 参数，推理仅用 13B 激活

- 原图 Figure 1： 路由器从 8 个专家中选 2 个
- 输出为两个被选专家输出的加权和

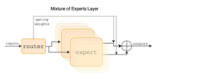


Figure 1: Mixture of Experts Layer. Each input vector is assigned to 2 of the 8 experts by a router. The layer's output is the weighted sum of the outputs of the two selected experts. In Mixtral, an expert is a standard feedforward block as in a vanilla transformer architecture.

04 / 08

Mixtral 如何路由与激活专家

1	线性层打分	对每个 token 计算专家 logits
2	TopK 取前二	写作 G(x):=Softmax(TopK(x · Wg))
3	选 2 个专家	每个专家是 SwiGLU 前馈块
4	加权求和输出	按门控权重相加被选专家输出

05 / 08

架构对照：同口径项与单篇专有项

项	Mistral 7B	Mixtral 8x7B
层数 / dim	32 / 4096	32 / 4096
头数 / kv 头	32 / 8	32 / 8
hidden / vocab	14336 / 32000	14336 / 32000
仅单篇给出	window 4096， ctx 8192	ctx 32768，专家 8 选 2
参数口径	7B 密集全量	47B 总 / 13B 激活

06 / 08

结果阅读：两篇论文各自的口径不可直接拼分

跨论文同分数不等于公平对比

- Mistral： HellaSwag 81.3%、 MMLU 60.1%、 GSM8K 52.2%
- Mixtral： MMLU 70.6%、 HumanEval 40.2%、 GSM8K 74.4%
- 两文协议差异： MBPP 用手工核验子集、 TriviaQA 不给维基上下文
- 故只能各自与自身基线比，不跨论文排名

07 / 08

最终选择建议：四类证据与归属

总内存按 47B 与 7B 锁定，其余待实测

维度	Mistral 7B	Mixtral 8x7B	归属
总内存	按 7B 全量	按 47B 总量	原文 / 第 4 页
服务负载	算力即 7B	激活 13B，含路由开销	原文 / 第 1、 4 页
质量证据	自身 MMLU 60.1%	自身 MMLU 70.6%	原文 / 各自口径
待实测	显存 / 吞吐 / 延迟	显存 / 吞吐 / 延迟	待实测

08 / 08

8页；稿件SHA f0d176450c37368d845d9ca5c4fa1ae16e2898aac61a709477f2f56cacda3fdf；run 7c83889fe51d4c9693a715e3df15e304

8 / 学习成本、复现与适用范围

工具提案失败+正常轨迹训练+独立认证的已记录学习成本：请求 127、token 3,251,893、代理估费 $0.175220；工具失败不能从学习成本移除。没有合格任务净节省证据，不给出虚假的盈亏平衡或摊销收益。

有效配置：deepseek-flash，reasoning=off，压缩=False；每阶段预算$2.0、48步、8000输出，总防失控守卫$20.0。48步是限制而非目标请求数。只服务器运行，本轮无commit/push/PR。

复现入口：同目录driver_v8.py prepare/run与matrix_v8.py --stage train/certify/evaluate；使用新的私有运行目录，训练冻结后才能打开一次认证。API只从服务器私有配置取值，报告不会包含密钥。脚本文件与实际运行版本/来源/工具schema由摘要SHA绑定，原始日志另外下载。

适用范围：本场景批准的PDF/PPTX科研PPT生成与同job有限局部修订。本轮未证明通用PPT复杂编辑、完全自主新工具成功率、Windows真实场景、人工同质量降本或整套跨应用产品。Zotero/Obsidian/分析/Quarto等仓库新主线仍需各自真实任务证据。

下一步由独立人工逐页验事实、图意、可读性及任务完成，记录修订分钟；仅比较同门槛合格稿的实际成本并核账单。若简单组合脚本更好就采用它，按真实证据缩小RSI/Motif主张；本轮不覆盖V7负面结果。