科研 PPT Agent
真实交付、有限组合与轨迹 Motif

总的结果 / V8 / 2026-10-11

矩阵状态：evaluation_finished_quality_not_human_reviewed。报告类型：completed_stage_report。真实确认交付 18 份，共 120 页；初稿与局部修订分开保存。

评测组	已记录请求	已记录总token	代理估费	verified整请求旁路
A 普通 DSH	44	888,355	$0.066312	0
B 普通组合脚本	47	937,339	$0.062148	0
C 认证 Motif	50	1,151,375	$0.078624	2

未执行C组的0请求/0费用仅表示没有运行，不能与完成任务比节省。辅助审查、工程通过与实际旁路均不证明科学质量等价；人工盲评、账单、修订分钟及开发/服务器成本未知，尚未建立同质量总成本下降。

B 普通组合脚本相对普通组的本次总量变化：请求+6.82%, 总token+5.51%, 代理估费-6.28%。仅为已记录运行的描述性对比，不证明因果或同质量收益。

C 认证 Motif相对普通组的本次总量变化：请求+13.64%, 总token+29.61%, 代理估费+18.57%。仅为已记录运行的描述性对比，不证明因果或同质量收益。

工具学习记录 2 轮，晋级 0 轮；矩阵实际加载新claim工具：False。独立Motif认证状态：independent_trace_certified_quality_not_reviewed。

1 / 数据集与真实任务

角色	资料	真实任务
正常训练T1	LoRA	6页适配研究讨论 + 第6页局部修订
正常训练T2	QLoRA	6页有限显存方案 + 第6页局部修订；该论文有历史使用
独立认证C1	Prefix-Tuning	候选/配置冻结后首次认证；实际是否打开见记录
新评测E1	FlashAttention-2	6页方法、条件与V100待验证边界 + 第6页修订
新评测E2	Mistral 7B + Mixtral	两篇输入、8页密集/MoE决定 + 第8页修订
工具机械训练/隐藏认证	历史RAG/QLoRA轨迹 / BERT	与C1独立；失败则不打开BERT

五项PPT任务共六篇论文，不是把五篇合成一个PPT；与仓库18题合成诊断无关。新来源先本机下载再上传，逐项SHA固定。生成和同稿修订属于一个研究决定，训练/认证/评测不混算。训练仅用两项独立任务的正常修订工具轨迹，生成费用仍计入。

训练结果后恢复明确使用混合配置：原LoRA因输出上限失败，另立V8c提高输出上限并收紧notes/修订范围后重新完成；原完整QLoRA决定保留原提示/上限与job并复用，没有重付。候选支持不是统一训练配置的纯对照，认证和后续三组使用新的统一配置。旧LoRA失败仍计一次，旧QLoRA按原run ID去重只计一次。

2 / 让模型在结果出现之后做决定

DeepSeek从历史真实使用需求提出并编写TypeScript候选，开发端限定协议、受限AST、真实编译/Node/PDF宿主及独立oracle。模型看到真实结果后只能 revise / accept / stop；开发者不写替代候选，不为晋级放宽反例。新反馈配置另立实验ID，失败成本累计。

学习轮	候选 / 编译通过	真实请求	总token	代理估费	结果 / 隐藏资料已解析
tool-learning-01	3 / 1	3	38,500	$0.011248	no_accepted_candidate_within_limit / False
tool-learning-02	3 / 0	3	41,480	$0.012523	no_accepted_candidate_within_limit / False

候选未认证时不用于正常任务，字段generated_motif只是兼容运行标签，不能据名称称新生成工具已生效。精确摘录命中认证只验证定位和上下文机械能力，不认证科研主张支持关系。

tool-learning-01失败依据：候选1: ['AST 拒绝: [{"column":7,"kind":"WhileStatement","line":9,"message":"Syntax is outside the pure JSON subset"}]']; 候选2: ['AST 拒绝: [{"column":7,"kind":"WhileStatement","line":10,"message":"Syntax is outside the pure JSON subset"}]']; 候选3: 真实PDF训练=True，工程反例=False，失败项=['literal_newlines_and_unicode']

tool-learning-02失败依据：候选1: ['AST 拒绝: [{"column":45,"kind":"ElementAccessExpression","line":44,"message":"Computed property access is forbidden; use named fields or a literal numeric index"}]']; 候选2: ['AST 拒绝: [{"column":88,"kind":"ElementAccessExpression","line":28,"message":"Computed property access is forbidden; use named fields or a literal numeric index"},{"column":145,"kind":"AsExpression","line":28,"message":"Syntax is outside the pure JSON subset"},{"column":86,"kind":"ElementAccessExpression","line":31,"message":"Computed property access is forbidden; use named fields or a literal numeric index"},{"column":62,"kind":"CallExpression","line":42,"message":"Arbitrary function calls are forbidden"}]']; 候选3: ['候选须为 name/description/input_schema/code；name 使用 read_pinned_ 前缀']

正常轨迹冻结：候选1个，digest c7a9e8fc8d758934ba8e4cfc78e825b2fdd8a22d199c93495063a774eaaf5ec0。独立认证：independent_trace_certified_quality_not_reviewed。只有预先冻结的候选通过C1，再在新评测实际执行，才能报告该结构复用闭环。

3 / 与普通 DSH 的流程对比

组/职责	实际实现与边界
A 普通DSH	保留原有全部基础MCP和build_delivery，模型正常决定工具；没有撤去已有组合能力
B 普通组合脚本	TS有限render/inspect/validate/deliver与revise组合；模型明确选页后的计划投影
C 认证Motif	与B同提示、schema/顺序和证书状态；只追加认证manifest execute；无manifest就不运行
Graph	轨迹见证的返回句柄→后继工具参数依赖与版本/证据守卫；来源读取或明确选页后读取
Code	解析、裁图、可编辑布局、PDF/PNG检查、恢复、有限组合与投影；普通代码收益单独归因
大模型	论文理解、相关选材、叙事、条件判断、选页与语义修订仍由真实DeepSeek完成

Skill/模板帮助设计，不是Motif。按页计划投影节省上下文属于普通工程优化；学得读取旁路仅省结构性工具选择的整次模型请求。B/C对照范围较窄，A/B与A/C是能力整包比较，各条件仅一次仍受随机性、缓存/顺序影响。

B/C实际配置核验	两组已运行	提示/schema/共同限制相同	差异字段
e1_flashattention2/初稿	True	True	无/尚未双组运行
e1_flashattention2/跨重启修订稿	True	True	无/尚未双组运行
e2_mistral_mixtral/初稿	True	True	无/尚未双组运行
e2_mistral_mixtral/跨重启修订稿	True	True	无/尚未双组运行

e2_mistral_mixtral/C 认证 Motif/跨重启修订稿：verified批次sss-batch-5d8d7d92-98af-458a-b125-b00bc3a1ce73，工具mcp__ppt__read_pinned_deck_pages，跳过1整次请求；code_nodes=[]。

e2_mistral_mixtral/C 认证 Motif/跨重启修订稿：verified批次sss-batch-dcbb1bf0-8fa4-4746-b844-0bd2de155736，工具mcp__ppt__read_pinned_deck_pages，跳过1整次请求；code_nodes=[]。

4 / 费用比较

任务	组	整任务请求	总token	代理估费	verified	状态	完成情况
FlashAttention-2	A 普通 DSH	22	388,338	$0.025673	0	normal_task_completed	两阶段完成
FlashAttention-2	B 普通组合脚本	25	462,496	$0.027043	0	normal_task_completed	两阶段完成
FlashAttention-2	C 认证 Motif	23	471,092	$0.030236	0	normal_task_completed	两阶段完成
Mistral 7B + Mixtral	A 普通 DSH	22	500,017	$0.040639	0	normal_task_completed	两阶段完成
Mistral 7B + Mixtral	B 普通组合脚本	22	474,843	$0.035105	0	normal_task_completed	两阶段完成
Mistral 7B + Mixtral	C 认证 Motif	27	680,283	$0.048388	2	normal_task_completed	两阶段完成

成本范围	请求	总token	代理估费	已记录阶段耗时
正常任务训练	94	2,614,516	$0.121673	333.0 秒
独立轨迹认证	27	557,397	$0.029775	86.9 秒
新任务评测	141	2,977,069	$0.207084	661.0 秒
tool-learning-01	3	38,500	$0.011248	44.8 秒
tool-learning-02	3	41,480	$0.012523	44.0 秒
aux-review-01	6	173,643	$0.055149	未知
aux-review-coverage-02	2	59,041	$0.015128	未知

全部现有记录合计请求 276、token 6,461,646、代理估费 $0.452580。含两轮工具失败、正常训练、认证、评测及已提供的辅助评审；缺失记录/计数保留未知，不把预算上限当费用。

每任务以生成+重启修订聚合，失败/恢复费用不可抹去。当前阶段耗时不等于包含准备/等待/人工工作的完整端到端时间；账单实付、人工和维护成本未知。缓存命中、未命中输入和输出分别计账，token下降不自动等于费用下降。

原失败额外开销保留：t1_lora/generation，run efc5f9a0450f4051b141a292080182fc，9请求、157,197token、$0.016992；原状态incomplete。

5 / 调用次数与全部运行记录

任务/阶段	组	run ID	请求	未命中 / 命中 / 输出	状态
t1_lora/初稿	B 普通组合脚本	c0e25abc67764432b7a87ad24074c9ca	12	24,214/227,328/6,196	done
t1_lora/跨重启修订稿	B 普通组合脚本	016fe42e35a347009aee597fe6efb48b	13	22,644/224,000/3,837	done
t2_qlora/初稿	B 普通组合脚本	bf61d27208b641d2ae61d16db5d83243	19	28,286/544,128/23,009	done
t2_qlora/跨重启修订稿	B 普通组合脚本	7792e5ade38b4488a4e80c3e0f7c3b88	41	46,499/1,294,848/12,330	done
c1_prefix_tuning/初稿	B 普通组合脚本	31b0a161fa2444eb95bf07efe0f466aa	15	29,007/340,480/7,602	done
c1_prefix_tuning/跨重启修订稿	B 普通组合脚本	98ffb1934a824bf9a33db7a33c3ebf67	12	16,796/160,256/3,256	done
e1_flashattention2/初稿	A 普通 DSH	7b48acbf9a824f2985bb6c03c20dc6a5	13	25,546/245,504/7,893	done
e1_flashattention2/跨重启修订稿	A 普通 DSH	37fb884ffa5c4f08bb57763735da2958	9	10,141/96,384/2,870	done
e1_flashattention2/初稿	B 普通组合脚本	7d6b5e4e2791492d9eda338a31946e52	12	22,540/209,024/5,079	done
e1_flashattention2/跨重启修订稿	B 普通组合脚本	0c00c76bff16423095b670a48d778af8	13	18,124/202,496/5,233	done
e1_flashattention2/初稿	C 认证 Motif	79b8eda253af4d60bd36a7099c7efdde	15	20,914/333,696/12,554	done
e1_flashattention2/跨重启修订稿	C 认证 Motif	a0f4d1c87769486bb256a8add6264013	8	9,663/91,392/2,873	done

任务/阶段	组	run ID	请求	未命中 / 命中 / 输出	状态
e2_mistral_mixtral/初稿	C 认证 Motif	2f9779d1fbaf4a94bc84c127f1c94edc	14	25,913/425,984/21,296	done
e2_mistral_mixtral/跨重启修订稿	C 认证 Motif	20dd8f06f27d4681a768ea1834af289d	13	13,112/187,776/6,202	done
e2_mistral_mixtral/初稿	B 普通组合脚本	eea7923b444f4d81af69d8124e83a987	12	32,944/291,072/12,774	done
e2_mistral_mixtral/跨重启修订稿	B 普通组合脚本	9c849aaf61b049a5b885b3ce19259d32	10	13,866/121,472/2,715	done
e2_mistral_mixtral/初稿	A 普通 DSH	6f4e1767b03748cdb31a4c6e8cdedd31	12	25,899/302,848/17,239	done
e2_mistral_mixtral/跨重启修订稿	A 普通 DSH	7c83889fe51d4c9693a715e3df15e304	10	14,704/135,040/4,287	done
t1_lora/初稿	B 普通组合脚本	efc5f9a0450f4051b141a292080182fc	9	24,129/125,568/7,500	incomplete

all-running-records.csv列全部阶段与学习汇总，学习逐模型call另标detail_excluded_from_totals，避免双计。summary.json保留配置/提示/schema/代码/来源SHA、工具顺序和verified批次摘要。原始API事件、账本和test-logs另存私有备份，不放交付包。

6 / 报告质量与评审边界

工程诊断	记录状态	检查数	付费请求
adapter-diagnostic-01	True	27	0
adapter-diagnostic-01	True	28	0

初稿/修订真实文件比较	状态	目标页实际变化
t1_lora/B 普通组合脚本	passed_actual_file_comparison	[6]
t2_qlora/B 普通组合脚本	passed_actual_file_comparison	[6]
c1_prefix_tuning/B 普通组合脚本	passed_actual_file_comparison	[6]
e1_flashattention2/A 普通 DSH	passed_actual_file_comparison	[6]
e1_flashattention2/B 普通组合脚本	passed_actual_file_comparison	[6]
e1_flashattention2/C 认证 Motif	passed_actual_file_comparison	[6]
e2_mistral_mixtral/C 认证 Motif	passed_actual_file_comparison	[8]
e2_mistral_mixtral/B 普通组合脚本	passed_actual_file_comparison	[8]
e2_mistral_mixtral/A 普通 DSH	passed_actual_file_comparison	[8]

事后文件比较核非目标页OOXML、notes、媒体/图表/样式依赖及目标页实际变化，不仅比较ZIP SHA；它不独立认证恢复过程父链或科研质量。两阶段交付成功与人工科学/视觉合格分开。全页拼图便于浏览，不能替代原分辨率逐页原图、数字表头行列及全文/附录核验。

辅助评审稿件	判断	SHA绑定	仍需人工核验
e1_flashattention2/baseline/revision	needs_revision	有效	是
e1_flashattention2/composed/revision	needs_revision	有效	是
e1_flashattention2/generated_motif/revision	needs_revision	有效	是

辅助评审稿件	判断	SHA绑定	仍需人工核验
e2_mistral_mixtral/generated_motif/revision	needs_revision	有效	是
e2_mistral_mixtral/baseline/revision	needs_revision	有效	是
e2_mistral_mixtral/composed/revision	needs_revision	有效	是

已提供、唯一SHA绑定的辅助审查 6 条；未绑定 0 条不得当作本稿验收。未提供辅助结果时质量未知；Codex视觉/模型事实审查不能称独立人工盲评，导出审查包也不等于评审完成。

最终评测稿唯一完整页序辅助覆盖 6/6，覆盖完整=True。格式失败和后续只补缺稿的费用仍全部累计；完整页序也不代表所有科学主张或图像已验收。

evidence_literal_found只表示审查返回的整段evidence文字经空白规范化后能否连续命中来源全文。模型把解释或多段引文写进同一字段时也会返回False，因此False不能证明论文没有证据，更不能证明稿件科学错误。下列issues全部是待人工核原文的AI意见，assessment同样不是已证实质量结论。

辅助审查 aux-review-01：状态 auxiliary_review_finished_with_gaps，返回 4 条，错误 [{'task_id': 'e2_mistral_mixtral', 'label': 'draft-01', 'reason': 'missing_duplicate_or_unknown_label', 'run_id': 'cef070165ead4f5d8c543aab2f383bb1'}, {'task_id': 'e2_mistral_mixtral', 'label': 'draft-03', 'reason': 'missing_duplicate_or_unknown_label', 'run_id': '850728469d104c118b3e054bbc4faa63'}]。

辅助审查 aux-review-coverage-02：状态 coverage_completion_finished，返回 2 条，错误 []。

e1_flashattention2/A 普通 DSH 第1页 [moderate] 第1页把『原版仅达理论峰值 25–40%』直接放在正文，引用的是第1页摘要句，但该 25–40% 具体指前向 pass 的峰值占比（与第2页 30-50%、25-35% 的分口径不同），正文未给出这是『前向』还是『前向+反向』，读者易把 25-40% 误读为整条 attention（前向+反向）的峰值，与图4/表1的端到端数字混读。；来源paper-4aa8935dfaca PDF第1页：Abstract 第1页：' FlashAttention is still not nearly as fast as optimized matrix-multiply (GEMM) operations, reaching only 25-40% of the theoretical maximum FLOPs/s.'；第2页给出分口径：'the forward pass only reaches 30-50% of the theoretical maximum FLOPs/s of the device (Fig. 5), while the backward pass ... reaching only 25-35% of maximum throughput on A100 GPU (Fig. 6).'；字面定位=False。AI意见待人工核原文。

e1_flashattention2/A 普通 DSH 第1页 [minor] 第1页正文『三项改动：减少非 matmul、序列维并行、warp 分块』未保留论文对三项改动的独立性表述（论文强调三者是并列改进方向，且第3.2节的序列维并行/循环次序调整的归属在第8页有 Triton 前提），但正文对该点未提及，风险是读者把三项全当作 FA2 首创。notes 有 C14，但第1页 notes 未提，正文也无任何限定。；来源paper-4aa8935dfaca PDF第8页：第8页：' These ideas of swapping the order of the loop ... as well as parallelizing over the sequence length dimension were first suggested and implemented by Phil Tillet in the Triton implementation.'；第3页 2.3.1 明确 tiling 与 online softmax 来自 FlashAttention/前人（[11,13]）。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/A 普通 DSH 第2页 [moderate] 第2页页面版式声明为 image，正文只有一句『改动集中在 thread block 与 warp 两级划分』，而该页实际挂载的图件仅为图注几何候选（scientific_verified=false、evidence_scope=caption_geometry_candidate），且第2页标题承诺的是『前向按行块并行，反向按列块并行』。本轮不提供图像，无法核对图内 thread block/warp 分工与箭头是否与图2一致，也无法确认图例/坐标是否原样保留。；来源paper-4aa8935dfaca PDF第8页：第8页图2图注：'In the forward pass (left), we parallelize the workers (thread blocks) where each worker takes care of a block of rows of the attention matrix. In the backward pass (right), each worker takes care of a block of columns of the attention matrix.'；稿件 figure 字段自述 'scientific_verified': false、'evidence_scope': ' caption_geometry_candidate'。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/A 普通 DSH 第2页 [moderate] 第2页正文与该页 notes 只保留前向按行块/反向按列块并行，未在正文保留『反向需用 atomic adds 跨线程块更新 dQ』这一影响判断的条件，该限定只出现在 notes 末尾；正文以 notes 藏限定条件替代正文清楚说明。；来源paper-4aa8935dfaca PDF第8页：第8页：'We use atomic adds to communicate between different thread blocks to update dQ.'；字面定位=False。AI意见待人工核原文。

e1_flashattention2/A 普通 DSH 第3页 [moderate] 第3页 process 的第5步『端到端训练：GPT 1.3B/2.7B，2k/8k，8×A100，最高225 TFLOPs/s』把 end-to-end 训练吞吐与前三步的内核/划分改动并列成同一流程步骤，且未标注硬件为 A100、比较对象缺失、量纲为 TFLOPs/s/GPU，容易被读成『这三项改动带来 225 TFLOPs/s』的直接因果链。原论文并未做分离三项改动贡献的因果实验，notes 也承认『作者未做因果实验分离各项贡献』——该限定只出现在 notes。；来源paper-4aa8935dfaca PDF第12页：第12页表1：'Training speed (TFLOPs/s/GPU) of GPT-style models on 8×A100 GPUs. FlashAttention-2 reaches up to 225

TFLOPs/s (72% model FLOPs utilization). We compare against a baseline running without FlashAttention.'；第9页仅给出内核基准的 1.7-3.0× 等对照，未做三项改动的分项消融。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/A 普通 DSH 第4页 [moderate] 第4页正文结论『同硬件同模型下，8k 上下文收益大于 2k』是作者基于表1给出的解释性比较（FA-2 相对无 FA：8k 为 220/72≈3.06、225/80≈2.81；2k 为 196/142≈1.38、205/149≈1.38），但正文未标这是『相对无 FA 基线』的比值，也未标注论文自述的最高 2.8×、1.3× 口径与硬件条件，且单位列『无 FA/FA/FA-2』表头未写 TFLOPs/s/GPU。原表表头含单位与比较对象，正文表格把单位去掉了。；来源paper-4aa8935dfaca PDF第12页：第12页表1表头含 'Training speed (TFLOPs/s/GPU) of GPT-style models on 8×A100 GPUs'，第11页：'FlashAttention-2 yields 2.8× speedup compared to a baseline without FlashAttention and 1.3× speedup compared to FlashAttention-2 [原文如此]，reaching up to 225 TFLOPs/s per A100 GPU.'；字面定位=False。AI意见待人工核原文。

e1_flashattention2/A 普通 DSH 第4页 [minor] 第4页表内数值与论文表1逐项一致，但正文未标示输入序列长度之外的条件：Table 1 未标注精度（dtype）与 head 配置，稿件 notes 已如实记录『表内未标注精度与头数』，正文未把这一条件缺项写出来，读者可能误以为这些数字带有与图4/5/6 相同的 dtype 与 head dim 条件。；来源paper-4aa8935dfaca PDF第12页：第12页表1仅给出模型规模与 context 长度两列，未列 dtype/head dim；第10页图4的 dtype 与 head dim 条件只在 attention benchmark（第10页 4.1 节）中给出：'head dimension 64 or 128'、'A100 80GB SXM4 GPU'。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/A 普通 DSH 第5页 [moderate] 第5页左栏『前向峰值从40%提至 50–73%』混合了两处不同口径的数字：原版 25-40%（第1页）与 30-50%（第2页前向）、FA2 最高 73%（第2页）与 230 TFLOPs/s 即 73%（第10页）。把原版记为 40%、FA2 记为 50–73% 会构成一个论文中不存在的区间对比，且未标比较对象（前向 pass、A100 理论峰值）。；来源paper-4aa8935dfaca PDF第2页：第2页：'the forward pass only reaches 30-50% of the theoretical maximum FLOPs/s of the device (Fig. 5)'；第1页：'reaching only 25-40% of the theoretical maximum FLOPs/s'；第2页：'reaching up to 73% of the theoretical max throughput in the forward pass'；第10页：'FlashAttention-2 reaches up to 230 TFLOPs/s, 73% of the theoretical maximum TFLOPs/s on A100 GPUs.'；字面定位=False。AI意见待人工核原文。

e1_flashattention2/A 普通 DSH 第5页 [moderate] 第5页右栏标题为『有条件，不能外推』并列『H100 数据未用 TMA 与四代张量核』，但正文该页的 notes 引用了第11页的 335 TFLOPs/s，而该数字对应的是图7（H100 80GB SXM5，前向+反向），正文右栏未给出该数字、也未标其条件为『同一实现、未使用 TMA/四代张量核』，读者无法判断该 H100 数据是何时、何配置下取得；且标题『有条件，不能外推』下缺 V100 未测的具体位置说明。；来源paper-4aa8935dfaca PDF第11页：第11页：'Just running the same implementation on H100 GPUs (using no special instructions to make use of new features such as TMA and 4th-gen Tensor Cores), we obtain up to 335 TFLOPs/s (Fig. 7). We expect that by using new instructions, we can obtain another 1.5x-2x speedup on H100 GPUs. We leave that to future work.'；第13页图7标题为 'Attention forward + backward speed (H100 80GB SXM5)'。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/A 普通 DSH 第6页 [moderate] 第6页正文标注『225 TFLOPs/s 与1.7–3.0×不可直接外推』，但 1.7–3.0× 出自内核对比（第9页，比较对象为 FlashAttention），225 TFLOPs/s 出自端到端训练（第12页，比较对象为无 FA 基线与 FA），二者口径、比较对象与量纲均不同，正文把两者并列成同一句『不可直接外推』，未区分哪个是内核算子加速、哪个是端到端训练加速，恰是本次审查要防止的『内核加速与端到端训练加速互换』。；来源paper-4aa8935dfaca PDF第9页：第9页：'We confirm that FlashAttention-2 is 1.7-3.0× faster than FlashAttention, 1.3-2.5× faster than FlashAttention in Triton, and 3-10× faster than a standard attention implementation.'（内核基准）；第12页表1与第11页 4.2 节为端到端训练吞吐 225 TFLOPs/s（'Training speed (TFLOPs/s/GPU) of GPT-style models on 8×A100 GPUs'）。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/A 普通 DSH 第6页 [moderate] 第6页正文第3条『论文以 A100 的16×非matmul/matmul比解释开销』未给出该 16× 的适用范围（A100 的 312 TFLOPs/s FP16/BF16 matmul 与 19.5 TFLOPs/s 非 matmul FP32），正文并未说明 V100 是否具备同等比值——该限制只在 notes C16 中，正文未保留。且『16×』在论文中同时用于表述『each non-matmul FLOP is 16× more expensive』，正文表述略去比较基准。；来源paper-4aa8935dfaca PDF第5页：第5页：'the A100 GPU has a max theoretical throughput of 312 TFLOPs/s of FP16/BF16 matmul, but only 19.5 TFLOPs/s of non-matmul FP32. Another way to think about this is that each non-matmul FLOP is 16× more expensive than a matmul FLOP.'；字面定位=False。AI意见待人工核原文。

e1_flashattention2/A 普通 DSH 第6页 [minor] 第6页 notes C16 称『该倍数出自第10-13页 A100/H100 内核基准，条件为 A100 80GB SXM4或H100 80GB SXM5、序列长512–16k、总token数16k、hidden dim 2048、head dim 64或128（32或16头）、带或不带causal mask』，但第10页 4.1 节的 benchmark setting 仅针对 A100 的 4.1 内核基准；H100 数据（第11、13页）系『Just running the same implementation on H100 GPUs』，论文未就 H100 重述 hidden dim/head dim/total tokens 设置，notes 将 A100 的 benchmark 条件整体套到 H100 上属未逐项核实的合并。；来源paper-4aa8935dfaca PDF第11页：第10页 4.1：'We set hidden dimension to 2048, and head dimension to be either 64 or 128 (i.e., 32 heads or 16 heads)'（A100 语境）；第11页 H100 描述仅一句：'Just running the same implementation on H100 GPUs (using no special instructions ...), we obtain up to 335 TFLOPs/s (Fig. 7).'；字面定位=False。AI意见待人工核原文。

e1_flashattention2/B 普通组合脚本 第1页 [moderate] 正文首条把“相对 FlashAttention 约 2× 加速”写为“非端到端训练加速”，但未在正文给出该 2× 的具体硬件/精度/序列与头维/比较对象条件；正文只笼统提“内核实测硬件为 A100”，而论文中“约2×”另有 2-3×（第5页）、1.7-3.0×（第9页）等不同表述范围。正文未保留 2× 对应的 dtype（FP16/BF16）与基准配置，条件仅落在 notes。；来源paper-4aa8935dfaca PDF第2页：论文第1页/第2页：“FlashAttention-2 achieves around 2× speedup over FlashAttention, reaching up to 73% of the theoretical max throughput in the forward pass, and up to 63% of the theoretical max throughput in the backward pass.” 第9页另称“1.7-3.0× faster than FlashAttention”。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/B 普通组合脚本 第1页 [minor] 正文“端到端加速还依赖模型规模、序列长度与精度选择”中“精度选择”一项缺乏论文直接证据：论文端到端实测为 FP16/BF16 的 A100，未见对不同精度的端到端加速对比；FP8 仅列为未来工作。；来源paper-4aa8935dfaca PDF第12页：第12页：“we plan to collaborate with researchers and engineers to make FlashAttention widely applicable in different kinds of devices (e.g., H100 GPUs, AMD GPUs), as well as new data types such as FP8.”（FP8 为计划，无实测）；字面定位=False。AI意见待人工核原文。

e1_flashattention2/B 普通组合脚本 第2页 [minor] 正文“v1 在长序列区间并非算力受限”是对论文解释的推衍表述，论文原文说的是长序列（通常小批小头）下调度不能有效利用多处理器、通过沿序列长度并行提升占用；“并行度不足来自网格规模，不是算术量本身”为作者解释而非原文事实，正文未标明该判定为解释性。；来源paper-4aa8935dfaca PDF第8页：第8页：“In the case of long sequences (which usually means small batch sizes or small number of heads), to make better use of the multiprocessors on the GPU, we now additionally parallelize over the sequence length dimension.”；字面定位=False。AI意见待人工核原文。

e1_flashattention2/B 普通组合脚本 第3页 [moderate] “沿序列长度分块”步骤表述为“在批与头之外再切序列，块数随之增加”，未说明这是 FA2 相对 FA1 的并行改进点，也未说明该并行思路（循环顺序交换与沿序列长度并行）最早由 Triton 实现提出，易被读作 FA2 首次发明。；来源paper-4aa8935dfaca PDF第8页：第8页：“These ideas of swapping the order of the loop … as well as parallelizing over the sequence length dimension were first suggested and implemented by Phil Tillet in the Triton implementation.”；字面定位=False。AI意见待人工核原文。

e1_flashattention2/B 普通组合脚本 第3页 [minor] 正文将算法改动（不重缩放、只存 logsumexp）与并行、warp 划分并列为“三处改动”，但未说明算法改动“不改变数学输出/仍为精确 attention、无近似”，该限定仅在 notes 中；正文标题“三处改动”易与近似/稀疏 attention 混淆。；来源paper-4aa8935dfaca PDF第7页：第7页：“Algorithm 1 returns the correct output O = softmax(QK)V (with no approximation)”。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/B 普通组合脚本 第4页 [moderate] 正文“故减少它们比减少总 FLOP 更影响吞吐”为推论性表述，论文原文只说非矩阵乘 FLOP 占比小但执行更慢、要尽量把时间用于矩阵乘；正文未标注该句为作者解释/设计推论，也未在正文保留“该 16× 为 A100 理论规格、非实测吞吐、不可照搬到 V100”的条件（该限制仅在 notes）。；来源paper-4aa8935dfaca PDF第5页：第5页：“the A100 GPU has a max theoretical throughput of 312 TFLOPs/s of FP16/BF16 matmul, but only 19.5 TFLOPs/s of non-matmul FP32 … each non-matmul FLOP is 16× more expensive than a matmul FLOP.” 第2页：“While the non-matmul FLOPs only account for a small fraction of the total FLOPs, they take longer to perform”。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/B 普通组合脚本 第5页 [major] 本页正文数值存在自我矛盾与口径不明：第二条“头维64、序列16k：FA2 为 155，FA平均约155”与 notes 自述（面板 b：FA2 223、FA 122；面板 c：头维 64 无掩码 16k 处 FlashAttention-2 为 192、Triton 为 155）不一致；正文第一条“FA 平均122，FA2 达223”又混用“平均”与“达”而对应表中为 FA 122、FA2 223 的 16k 单点值，且同页引用头维 64/128 两个不同面板数值，未在正文完整给出 dtype（FP16/BF16）、无因果掩码、序列长度轴 512–16k、总 token 16k、hidden 2048、比较对象（PyTorch/FlashAttention/xformers/FlashAttention Triton）等条件。；来源paper-4aa8935dfaca PDF第11页：第11页图5面板(b) 无掩码、head dim 128：FlashAttention-2 127/140/152/157/160/163，FlashAttention 107/115/120/122/122/122；面板(c) 无掩码、head dim 64：FlashAttention-2 178/191/193/192/192/192，FlashAttention Triton 128/141/149/152/152/155。第10页：“set hidden dimension to 2048, and head dimension to be either 64 or 128 (i.e., 32 heads or 16 heads)”“with or without causal mask”。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/B 普通组合脚本 第5页 [moderate] 图的文字解释与数值一致性未在正文给出完整图例/坐标说明：正文未点明横轴为序列长度 512–16k、纵轴为 Speed (TFLOPs/s)、曲线族为 PyTorch/FlashAttention/xformers/FlashAttention Triton/FlashAttention-2，也未说明图中含 OOM 点。按本审查不提供图像，图的图例/坐标是否符合原图无法由此文本确认。；来源paper-4aa8935dfaca PDF第11页：第11页图题“Figure 5: Attention forward speed on A100 GPU”，坐标轴“512 1k 2k 4k 8k 16k / Sequence length”“Speed (TFLOPs/s)”，图例含 Pytorch、FlashAttention、xformers、FlashAttention Triton、FlashAttention-2。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/B 普通组合脚本 第6页 [moderate] 本页正文未按修订指令给出“三条清晰判断（论文支持什么、V100 环境中仍需验证什么、怎样做最小实际验证）”：实际正文仅两句短句（“A100已实测; V100未报告数据”“建议先同口径复跑1.3B 2k/8k”）加一张表，未成三条判断结构，也未在正文保留最小验证所需的同口径条件（同一模型、序列长度、同一 FLOPs 公式、记录显存与损失曲线），这些仅见于 notes。；来源paper-4aa8935dfaca PDF第12页：第12页表1标题“Training speed (TFLOPs/s/GPU) of GPT-style models on 8×A100 GPUs”；第11页“We measure the training throughput of GPT-style models with either 1.3B or 2.7B parameters, on 8×A100 80GB SXM.”；notes C16 才写明“在V100用同一模型、序列长度与同一FLOPs公式复跑,先做1.3B 2k/8k,并同录显存与损失曲线”。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/B 普通组合脚本 第6页 [minor] 表1数值虽与论文一致，但正文表格未标出表头单位与口径（TFLOPs/s/GPU、8×A100、列名“不用FA/FA/FA-2”对应 Without FlashAttention/FlashAttention/FlashAttention-2），且未在正文说明该 FLOPs 按 Megatron-LM 公式计算、注意力项未除以 2，比较只能在同表口径内。；来源paper-4aa8935dfaca PDF第11页：第11页：“Note that we calculate the FLOPs by the formula, following Megatron-LM [16]: 6·seqlen·number of params + 12·number of layers·hidden dim·seqlen²… We choose to follow the formula from the literature (without dividing the attention FLOPs by 2) for consistency.”；字面定位=False。AI意见待人工核原文。

e1_flashattention2/B 普通组合脚本 第6页 [moderate] 正文“论文支持A100收益;V100需同口径复跑验证”未在正文写清 V100 相关的边界条件：论文仅在何处提及后续支持范围（H100、AMD GPU、FP8），以及 V100 未实测、GPU 架构与内核支持须实际验证；该边界仅在 notes 出现。；来源paper-4aa8935dfaca PDF第12页：第12页：“we plan to collaborate with researchers and engineers to make FlashAttention widely applicable in different kinds of devices (e.g., H100 GPUs, AMD GPUs), as well as new data types such as FP8.”；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第2页 [minor] 第2页正文/流程步骤把三项调整概括为“都不改变输出，不放宽精确性”。其中“不缩放输出两项、只保存logsumexp”只被notes里的第5页引用支撑，且第5页证据为公式推导片段；精确定义（最终仅对 ˜O(last) 乘 diag(ℓ(last))−1，反向只存 L(j)=m(j)+log ℓ(j)）未落到页面可见文字，读者只能从“只保存logsumexp”推断，条件不足。；来源paper-4aa8935dfaca PDF第5页：PDF第5页：'Only at the every end of the loop do we scale the final ˜O(last) by diag(ℓ(last))−1 to get the right output.' 与 'We only need to store the logsumexp L(j) = m(j) + log(ℓ(j)).'；PPT第2页可见文字仅“不

缩放输出两项，只保存logsumexp（第5页）”。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第2页 [moderate] 第2页以“三项调整都不改变输出”作为整页结论，但notes同时承认“该并行思路最初源于Triton实现（第8页脚注3）”，正文可见文字未交代这一归属，也未区分FA1已采用的IO-aware tiling/online softmax。存在把沿序列长度并行与work partitioning读成FA2首次发明的风险。；来源paper-4aa8935dfaca PDF第8页：PDF第8页脚注3与正文：'These ideas of swapping the order of the loop … as well as parallelizing over the sequence length dimension were first suggested and implemented by Phil Tillet in the Triton [17] implementation.'；PDF第3页：FA1已采用 tiling 与 online softmax 且 'with no approximation'。PPT第2页可见文字无此归属说明。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第3页 [moderate] 第3页结论文字“同一步骤顺序改变，消除了warp间通信”表述过强。论文原文只说明FA2按Q切分后warp之间无需通信即可各自得到输出切片，但未声称前向被完全消除同步；notes中“反向仍需同步与atomic adds”的限定仅存在于讲者备注，正文未保留，读者可能据此推及全流程无通信。；来源paper-4aa8935dfaca PDF第9页：PDF第9页：'In FlashAttention-2, we instead splitQ across 4 warps while keepingK and V accessible by all warps. After each warp performs matrix multiply to get a slice ofQK , they just need to multiply with their shared slice of V to get their corresponding slice of the output. There is no need for communication between warps.' 同页反向段落：'it still requires some synchronization due to the more complicated dependency'；PDF第8页：反向使用 atomic adds 更新 dQ。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第3页 [minor] 第3页正文可见文字未保留原图的图例与面板标识（(a) FlashAttention 与 (b) FlashAttention-2），也未标注论文提示“通常每块4或8个warp”。原图图例/面板语义仅存在于notes与图注，正文不足以判定图形分工与箭头是否与原图一致，需后续看原图核验。；来源paper-4aa8935dfaca PDF第9页：PDF第9页 Figure 3 图注：'Figure 3: Work partitioning between different warps in the forward pass'，并以 (a) FlashAttention、(b) FlashAttention-2 标识两子图；正文：'We typically use 4 or 8 warps per thread block.' PPT第3页可见文字仅“左：旧版按K/V分割，需共享内存加和 / 右：新版按Q分割，各warp直接得输出切片”。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第4页 [moderate] 第4页图表标题/正文以“前向与反向吞吐”表述FA-2数值，但所引数值属于 Figure 4(b)“Attention forward + backward speed”（前后向合并计时），且计算口径为前向FLOPs乘2.5；页面未在可见文字处标出该口径，也未标出隐藏维度2048/16头等条件，容易被误读为纯前向或纯反向吞吐。；来源paper-4aa8935dfaca PDF第10页：PDF第10页 Figure 4 标题为 'Attention forward + backward speed (A100 80GB SXM4)'，子图(b) 'Without causal mask, head dimension 128' 标注 151/173/187/196/201/203 与 76/72/76/80/82/83；同页口径说明：'To get the FLOPs of the backward pass, we multiply the forward pass FLOPs by 2.5'，'We set hidden dimension to 2048, and head dimension to be either 64 or 128 (i.e., 32 heads or 16 heads).' 这些口径仅在notes中出现。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第4页 [minor] 第4页仅重绘两个系列，并标注“同图另有PyTorch与Triton曲线，此处未列全”。这属于选择性重绘，页面上“约翻倍”的结论适用范围未在可见文字中限定到该子图，也未说明正文另给出1.7–3.0×的区间，存在把特定配置倍数当作一般收益的风险。；来源paper-4aa8935dfaca PDF第9页：PDF第9页：'We confirm that FlashAttention-2 is 1.7-3.0× faster than FlashAttention, 1.3-2.5× faster than FlashAttention in Triton, and 3-10× faster than a standard attention implementation.' PDF第10页：'FlashAttention-2 is around 2× faster than FlashAttention'。PPT第4页可见结论为“该子图条件下吞吐约翻倍”。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第5页 [moderate] 第5页图表与正文以“端到端训练吞吐”呈现数值，但页面可见文字未标出该表对比基线为“without FlashAttention / FlashAttention / FlashAttention-2”三类，也未标出论文未给出数据类型与头维明细。仅notes记载，正文缺失影响判断的条件。；来源paper-4aa8935dfaca PDF第12页：PDF第12页 Table 1 标题：'Training speed (TFLOPs/s/GPU) of GPT-style models on 8×A100 GPUs. FlashAttention-2 reaches up to 225 TFLOPs/s (72% model FLOPs utilization). We compare against a baseline running without FlashAttention.' 表内行：GPT3-1.3B 2k context 142/189/196；GPT3-1.3B 8k 72/170/220；GPT3-2.7B 2k 149/189/205；GPT3-2.7B 8k 80/175/225。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第5页 [minor] 第5页标题直接写“FA-2最高225 TFLOPs/s（A100）”，但其数值为模型FLOPs利用率口径下的端到端训练吞吐（72% MFU），与第4页attention kernel吞吐口径（理论最大FLOPs/s百分比）不是同一指标。页面未在可见文字处提示两种口径不可互换。；来源paper-4aa8935dfaca PDF第11页：PDF第11页：'Note that we calculate the FLOPs by the formula, following Megatron-LM: 6·seqlen·number of params+ 12·number of layers·hidden dim·seqlen2. … We choose to follow the formula from the literature (without dividing the attention FLOPs by 2) for consistency.' PDF第12页 Table 1 给出 225 TFLOPs/s 与 72% model FLOPs utilization。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第6页 [major] 第6页判断三“最小实测”在可见流程文字中未包含验证的边界条件：论文中H100试运行明确使用“no special instructions to make use of new features such as TMA and 4th-gen Tensor Cores”，且软件版本/支持范围未给出；页面对V100只给出“按头维调块大小”，未在可见正文声明GPU架构与内核支持须实际验证。仅notes含该限定，正文缺失关键边界。；来源paper-4aa8935dfaca PDF第11页：PDF第11页：'Just running the same implementation on H100 GPUs (using no special instructions to make use of new features such as TMA and 4th-gen Tensor Cores), we obtain up to 335 TFLOPs/s (Fig. 7). We expect that by using new instructions, we can obtain another 1.5x-2x speedup on H100 GPUs. We leave that to future work.' PDF第12页：'we plan to collaborate … to make FlashAttention widely applicable in different kinds of devices (e.g., H100 GPUs, AMD GPUs), as well as new data types such as FP8.'；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第6页 [moderate] 第6页判断一以“论文已证”概括，但可见文字把“算法精确性、A100内核性能、端到端收益”三类主张压缩在同一标签下，未在正文分别列出各自条件；且“225 TFLOPs/s”为端到端口径，与“精确注意力（no approximation）”为不同性质的主张，页面正文未示其分离。；来源paper-4aa8935dfaca PDF第1页：PDF第1页：'FlashAttention-2 is available…' 摘要：' we (1) tweak the algorithm to reduce the number of non-matmul FLOPs (2) parallelize the attention computation … and (3) within each thread block, distribute the work between warps…' 与 'FlashAttention-2

reaches training speed of up to 225 TFLOPs/s per A100 GPU (72% model FLOPs utilization).' PDF第7页：'Algorithm 1 returns the correct outputO = softmax(QK)V (with no approximation)'。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第6页 [minor] 第6页可见正文未写入块大小调参依据的具体范围与出处，仅notes引用原文；读者无法从页面判断“按头维调块大小”来自哪条原文及适用范围。；来源paper-4aa8935dfaca PDF第9页：PDF第9页：'Typically we choose blocks of size {64, 128}×{64, 128}, depending on the head dimension d and the device shared memory size.' 与 'We manually tune for each head dimensions since there are essentially only 4 choices for block sizes, but this could benefit from auto-tuning...' PPT第6页可见文字为“在V100上按头维调块大小，先比内核吞吐与显存”，未给出该依据。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第1页 [minor] 第1页可见正文写“官方报告v1（2023-07-17）”，与PDF页码显示日期“July 18, 2023”及arXiv时间戳“17 Jul 2023”并存。该日期差异本身不构成数值错误，但正文未说明取何口径，可能引起读者对版本/时间的不一致理解。；来源paper-4aa8935dfaca PDF第1页：PDF第1页：'July 18, 2023' 与 'arXiv:2307.08691v1 [cs.LG] 17 Jul 2023'。PPT第1页可见文字为“解析论文：官方报告v1（2023-07-17）”。；字面定位=False。AI意见待人工核原文。

e1_flashattention2/C 认证 Motif 第2页 [minor] 第2页notes称“即单个非matmul FLOP约贵16倍”，而原文对应表述为 matmul 吞吐可达非matmul吞吐的16倍、且该数值针对A100 FP16/BF16 matmul对FP32非matmul。正文可见文字未保留该硬件与精度条件。；来源paper-4aa8935dfaca PDF第5页：PDF第5页：'the A100 GPU has a max theoretical throughput of 312 TFLOPs/s of FP16/BF16 matmul, but only 19.5 TFLOPs/s of non-matmul FP32. Another way to think about this is that each non-matmul FLOP is 16× more expensive than a matmul FLOP.'；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第2页 [major] 第2页表格把 Mistral 7B 的“训练上下文”写为“8k 配置”，与 Mistral 7B 原论文 Table 1 的 context_len=8192 字面值不同，且“训练上下文”用词暗示了论文未在此处明确声称的训练设置；同时该行与 Mixtral 的“32k 上下文”并列，容易让读者以为两行是同一维度的可比对象，而 8192 是架构表里的 context_len，Mixtral 的 32768 同样是架构表里的 context_len，二者本可同维度并列，但“8k 配置”这一措辞既非原文用语又引入歧义。；来源paper-dfbac4e70353 PDF第2页：原文 Table 1：“dim 4096 / n_layers 32 / head_dim 128 / hidden_dim 14336 / n_heads 32 / n_kv_heads 8 / window_size 4096 / context_len 8192 / vocab_size 32000”；notes C03 亦引用“window_size 4096 / context_len 8192 / n_kv_heads 8”。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第2页 [moderate] “计算参数”一行把 Mistral 7B 写作“7B 全激活”，这一说法原文并未以“全激活”表述，属于对“7–billion-parameter language model”的改写；对 Mixtral 写作“13B 激活 / 47B 总”是正确的区分，但表格将两者并列在“计算参数”维度下，未在正文可见处点明 Mistral 的 7B 与 Mixtral 的 13B 激活参数是不同来源、不同报告口径（Mixtral 第4页 Table 2 的 Active Params 列），容易被读成同一协议下的计算量比较。；来源paper-f8bbf0e9d979 PDF第4页：mixtral.pdf 第4页 Table 2 列名“Active Params”，Mixtral 8x7B 行 13B；第1页原文“each token has access to 47B parameters, but only uses 13B active parameters during inference”。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第3页 [major] 流程页把“GQA 分组查询”置于“位置 i 只看上一层 i−W 到 i，W=4096”的滑动窗口步骤之前，并在标题与结论中并列为“Mistral 的注意力设计”，但正文可见处没有一句区分 GQA（降低 KV 头数量、加速推理与减少解码显存）与 SWA（限制注意力范围、控制长序列计算与缓存）各自解决什么机制问题；读者可能误把 GQA 当成稀疏化机制或把两者混为一种稀疏注意力。notes 里有区分，但正文可见内容不足以支撑该机制区分，违反“正文必须保留影响判断的条件”。；来源paper-dfbac4e70353 PDF第2页：第2页原文“GQA significantly accelerates the inference speed, and also reduces the memory requirement during decoding”；同页“SWA exploits the stacked layers of a transformer to attend information beyond the window size W”，以及 Figure 1 图注“each token can attend to at most W tokens from the previous layer”。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第3页 [moderate] 流程步骤“长提示按窗口切块预填充”与 notes C08–C10 中关于 131K 理论注意力跨度、32k 缓存降 8x、16K 序列约 2x 加速的数字条件均未出现在正文可见处；这些是影响“受限资源下选型判断”的关键数值与条件（序列长度、W、对比基线），仅藏在 notes 里，无法在幻灯片正面被读者核验。；来源paper-dfbac4e70353 PDF第2页：第2页原文“using a window size of W = 4096, we have a theoretical attention span of approximately 131K tokens”“for a sequence length of 16K and W = 4096, changes made to FlashAttention and xFormers yield a 2x speed improvement over a vanilla attention baseline”“On a sequence length of 32k tokens, this reduces the cache memory usage by 8x”。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第4页 [moderate] 图文页正文写“图中 W=3：每个 token 只回看 3 个位置”，与第3页正文的“W=4096”并列出现但正文未在同一页说明 W=3 仅为该图的示意取值、模型实际配置为 window_size=4096；读者（尤其跳过 notes 的听众）容易把 W=3 当作模型配置。；来源paper-dfbac4e70353 PDF第2页：Figure 1 图注“each token can attend to at most W tokens from the previous layer (here, W = 3)”；Table 1“window_size 4096”。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第4页 [minor] 该页 figure 记录中 scientific_verified=false、evidence_scope=caption_geometry_candidate，正文声称“原文示意”但未标明该图为图注几何候选裁图、语义与视觉未认证；同时本次文本审查未提供图像，无法核验图内几何是否为原文 Figure 1（含是否被裁切、是否保留了 W=3 的示意结构）。；来源paper-dfbac4e70353 PDF第2页：notes C11：“所嵌入图像来自 Figure 1 图注几何候选裁图……candidate 仅提供几何相关性，未做语义或视觉认证”；draft figure 字段 evidence_scope=caption_geometry_candidate, scientific_verified=false。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第5页 [major] 流程页正文与结论只写“总参数随专家数增长，计算量由 Top-K 决定”，未在正文可见处明确区分“总参数（随 n 增长的稀疏参数）”与“每 token 激活参数（随 K 增长）”，也未点明“激活参数少不等于只需加载同样少的权重”；第8页虽有“47B 稀疏参数”与“按激活参数推断加载显存不成立”，但第5页作为机制页缺少该限定，容易被误读为稀疏 MoE 在受限资源下即可只按 13B 加载。；来源paper-f8bbf0e9d979 PDF第3页：第3页原文“This motivates a distinction between the model’s total parameter count (commonly referenced as the sparse parameter count), which

grows with n, and the number of parameters used for processing an individual token (called the active parameter count), which grows with K up to n”；第4页原文“The memory costs for serving Mixtral areproportional to its sparse parameter count, 47B, which is still smaller than Llama 2 70B”。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第6页 [minor] 与第4页同：该页 figure 标记为 caption_geometry_candidate、scientific_verified=false，正文写“MoE 层的原文结构示意”但未在纸面注明该裁图未做语义与视觉认证；文本审查也无法核验图内是否完整保留 8 专家/2 选择结构与加权求和标注。；来源paper-f8bbf0e9d979 PDF第2页：notes C16：“所嵌入图像来自 Figure 1 图注几何候选裁图……候选仅提供几何相关性，未做语义与视觉认证”；draft figure 字段 scientific_verified=false。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第7页 [major] 结果表在每行分数旁未在正文可见处标注该分数对应的 shot 数与评测设置；虽然标题与结论写着“口径完整但互不可比”，但表内 MMLU/GSM8K/MBPP 三行没有任何 shot 标注，且 Mistral 的 MBPP 3-shot 与 Mixtral 的 MBPP 3-shot、MMLU 5-shot 与 5-shot 恰好相同，容易被误读为可直接并排比较；同时标题中的“口径完整”与表内无 shot 标注自相矛盾。；来源paper-f8bbf0e9d979 PDF第4页：mixtral.pdf 第4页 Table 2 行“Mixtral 8x7B 13B 70.6% … 60.7% … 74.4%”；第5页 Table 3 另列 HellaSwag(10-shot)、ARC Challenge(25-shot)、GSM-8K(5-shot) 等不同 shot 协议；mistral7b.pdf 第4页 Table 2 与第3页协议列表给出 Mistral 的 MMLU 5-shot、GSM8K 8-shot maj@8、MBPP 3-shot。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第7页 [moderate] 该页“各列只在本论文内可比 / 70B 对标仅限激活参数口径”属于较隐晦的表述，未在正文点明两篇论文的评测提示词、样本数、基线重跑流程差异导致 MMLU 60.1% 与 70.6% 不构成统一条件下的胜负；notes C17/C24 有条件说明，但按“正文必须保留影响判断的条件”的要求，正文限定不足。；来源paper-dfbac4e70353 PDF第3页：mistral7b.pdf 第3页“We compare Mistral 7B to Llama, and re-run all benchmarks with our own evaluation pipeline for fair comparison”；mixtral.pdf 第3页同样“We compare Mixtral to Llama, and re-run all benchmarks with our own evaluation pipeline”。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第8页 [moderate] 修订页把“总内存约束”“服务负载”“质量证据”“待实测指标”整理为四类依据，但正文未在可见处标明哪些来自原论文、哪些是本方设计推论；notes C24 才写“把四类并列依据属我方组织方式”，正文只以“来源见讲者备注”带过，仍以 notes 藏条件替代正文说明。；来源paper-f8bbf0e9d979 PDF第4页：mixtral.pdf 第4页原文“this analysis focuses on the active parameter count … which is directly proportional to the inference compute cost, but does not consider the memory costs and hardware utilization”；第1页“each token has access to 47B parameters”。notes C24 明确“设计推论：把总内存约束、服务负载、质量证据、待实测指标作为四类并列依据，属我方组织方式”。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第8页 [major] 该页把 Mixtral 的“服务负载”写为“路由/多专家开销”，虽方向与原论文“additional overhead due to the routing mechanism and due to the increased memory loads when running more than one expert per device”“more suitable for batched workloads”相符，但正文未保留原文“更适合能取得较高算术强度的批量负载”这一条件，也没有在正文写明该判断只针对负载形态而未给出任何硬件实测的吞吐/延迟数值；在用户硬件显存、吞吐、延迟均未给出的情况下，该行容易被读成已具备硬件部署结论。；来源paper-f8bbf0e9d979 PDF第4页：mixtral.pdf 第4页原文“the SMoEs layer introduces additional overhead due to the routing mechanism and due to the increased memory loads when running more than one expert per device. They are more suitable for batched workloads where one can reach a good degree of arithmetic intensity”。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第8页 [minor] “评估口径”一行填的是“口径不同，不可比 / 不可拼排行榜”，这是判断性文字而非该维度下 Mistral 与 Mixtral 各自的口径事实，与表格“判断依据 × 模型”的对照结构不一致（其余行均为该模型的具体事实），容易让读者以为“不可比”本身是某一模型属性。；来源paper-dfbac4e70353 PDF第3页：mistral7b.pdf 第3页协议列表（MMLU 5-shot 等）与 mixtral.pdf 第5页 Table 3（HellaSwag 10-shot、ARC Challenge 25-shot、GSM-8K 5-shot）显示两文协议不同。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第1页 [minor] 稿件 literal_quotes 中 slide 1 的两条引文 matches 为空，未建立出处匹配；同时第1页正文只写“两篇原论文：Mistral 7B 与 Mixtral 8x7B”，未在可见处给出模型版本与论文版本（Mistral 7B 与 Mixtral 8x7B 的确切论文标识），仅在 notes 提到 2023-10 至 2024-01 与 Apache 2.0。版本信息的缺位会影响后续对“总参数 7B / 47B 稀疏、13B 激活”的版本核对。；来源paper-dfbac4e70353 PDF第1页：arXiv:2310.06825v1；mixtral.pdf arXiv:2401.04088v1。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/C 认证 Motif 第2页 [minor] notes C06 写 Mixtral 第3页列 0/3/4/5/8-shot、第5页另列 10/25-shot，但第5页 Table 3 实际同时含 MMLU(MCQ in 57 subjects)、HellaSwag(10-shot)、ARC Challenge(25-shot)、WinoGrande(5-shot)、MBPP(pass@1)、GSM-8K(5-shot)、MT Bench，未标 shot 的项（MMLU、MBPP、MT Bench）与标 shot 的项混列；notes 概括与原文列示方式不完全对齐，正文若引用 notes 可能遗漏“部分指标未在该表标 shot”。；来源paper-f8bbf0e9d979 PDF第5页：mixtral.pdf 第5页 Table 3 各行标注如“HellaSwag (10-shot)”“ARC Challenge (25-shot)”“GSM-8K (5-shot)”“MT Bench (for Instruct Models)”，而 MMLU 行仅注“(MCQ in 57 subjects)”、MBPP 行仅注“(pass@1)”。；字面定位=False。AI意见待人工核原文。

e2_mistral_mixtral/A 普通 DSH 第7页 [major] 第7页正文以百分比并列Mistral与Mixtral的MMLU/GSM8K数值（MMLU 60.1% vs 70.6%、GSM8K 52.2% vs 74.4%），但未在正文写明两数出自不同论文的不同shot设置，只放在notes；正文的"两文协议差异"仅提及MBPP与TriviaQA，读者仍可能把并列数值读成排行，与页面结论"不可直接拼分"自相矛盾。；来源paper-dfbac4e70353 PDF第3页：• Math: GSM8K [10] (8-shot) with maj@8 and MATH [13] (4-shot) with maj@4；字面定位=True。AI意见待人工核原文。

e2_mistral_mixtral/A 普通 DSH 第8页 [major] 第8页把"总内存"作为已锁定结论（Mistral 按7B全量、Mixtral按47B总量），但原文仅称服务Mixtral的内存成本与其稀疏参数数（47B）成正比，未给出权重加载显存与47B数值相等或按7B/47B锁定总内存的结论；该行"归属"还标为"原文"，把推论表述成原文事实，容易直接用于显存预算。；来源paper-f8bbf0e9d979 PDF第4页：The memory costs for serving Mixtral are proportional to its sparse parameter count, 47B, which is still smaller than Llama 2 70B.；字面定位=True。AI意见待人工核原文。

e2_mistral_mixtral/A 普通 DSH 第7页 [minor] 第7页正文"故只能各自与自身基线比，不跨论文排名"使用了"公平排行榜"式的比较结论措辞，但未给出所比基线（Mistral对Llama 2 13B、Mixtral对Llama 2 70B/GPT-3.5）；同时两文的静态归属（"跨论文同分数不等于公平对比"）在正文中缺少条件句，读者可能误读为分数本身不可用。；来源paper-f8bbf0e9d979 PDF第4页：Detailed results for Mixtral, Mistral 7B and Llama 2 7B/13B/70B and Llama 1 34B2 are reported in Table 2.；字面定位=True。AI意见待人工核原文。

e2_mistral_mixtral/A 普通 DSH 第6页 [minor] 第6页架构对照表在"仅单篇给出"行把Mistral的window_size 4096、context_len 8192与Mixtral的context_len 32768、num_experts 8、top_k_experts 2合并为一行，未区分"window_size为Mistral专有"与"context_len两文取值不同但同义"，表格读法可能误认为Mixtral无滑动窗口设置。；来源paper-dfbac4e70353 PDF第2页：Parameter Value dim 4096 n_layers 32 head_dim 128 hidden_dim 14336 n_heads 32 n_kv_heads 8 window_size 4096 context_len 8192 vocab_size 32000；字面定位=True。AI意见待人工核原文。

e2_mistral_mixtral/A 普通 DSH 第2页 [minor] 第2页正文"Mistral 7B：7B 参数密集，逐 token 全量使用"引入了原文未直接出现的表述"逐token全量使用"（原文对密集模型的说明未如此用语），且"全量使用"与后文"激活参数只对应算力"的对比未给出原文出处。；来源paper-dfbac4e70353 PDF第1页：We introduce Mistral 7B, a 7–billion-parameter language model engineered for superior performance and efficiency.；字面定位=True。AI意见待人工核原文。

e2_mistral_mixtral/A 普通 DSH 第4页 [minor] 第4页将"输出为两个被选专家输出的加权和"写入正文要点，但Mixtral原文在讨论门控时区分"combine their output additively"（第1页）与公式中的加权和（第2–3页）；第4页正文未指出此为加权（Softmax门控权重）求和，也未把第4页"MoE层引入路由开销与更多显存读取"这一影响选型的条件写到正文，仅留在notes。；来源paper-f8bbf0e9d979 PDF第4页：As for device utilization, we note that the SMoEs layer introduces additional overhead due to the routing mechanism and due to the increased memory loads when running more than one expert per device.；字面定位=True。AI意见待人工核原文。

e2_mistral_mixtral/B 普通组合脚本 第6页 [moderate] 第6页表格把两篇论文各自报告的分数并列为“同源指标并置”，但表头未在正文中标出两篇的对照组不同（Mistral对Llama系列、Mixtral对Llama系列），条件仅写在notes中。正文须保留影响判断的条件，不能用notes藏限定条件替代正文说明。；来源paper-dfbac4e70353 PDF第4页：Mistral 7B outperforms Llama 2 13B on all metrics, and approaches the code performance of Code-Llama 7B without sacrificing performance on non-code benchmarks.；字面定位=True。AI意见待人工核原文。

e2_mistral_mixtral/B 普通组合脚本 第7页 [minor] 第7页对照表未注明Mixtral的“服务显存随47B稀疏参数”仅为论文对模型自身参数的说明，未给出任何实测显存；易被读成已核实的服务显存结论。；来源paper-f8bbf0e9d979 PDF第4页：The memory costs for serving Mixtral are proportional to its sparse parameter count, 47B, which is still smaller than Llama 2 70B.；字面定位=True。AI意见待人工核原文。

e2_mistral_mixtral/B 普通组合脚本 第8页 [moderate] 第8页“选型建议”以总内存、服务负载、质量、待实测四类决策输入呈现，但未按修订要求逐项标明哪些来自原论文、哪些是设计推论；正文只写“硬件结论仍是设计推论”，过于笼统。；来源paper-f8bbf0e9d979 PDF第4页：the SMoEs layer introduces additional overhead due to the routing mechanism and due to the increased memory loads when running more than one expert per device.；字面定位=True。AI意见待人工核原文。

e2_mistral_mixtral/B 普通组合脚本 第3页 [minor] 第3页正文“16K序列下实测2x提速（对比vanilla）”未在正文中点明限定条件（W=4096、依赖FlashAttention/xFormers改动），限定仅在notes中，易被当作通用加速比。；来源paper-dfbac4e70353 PDF第2页：for a sequence length of 16K andW = 4096, changes made to FlashAttention [11] and xFormers [18] yield a 2x speed improvement over a vanilla attention baseline.；字面定位=True。AI意见待人工核原文。

e2_mistral_mixtral/B 普通组合脚本 第2页 [minor] 第2页“计算量随激活参数走，显存随参数量走”表述为普适规律，但原文仅针对Mixtral的服务内存给出与稀疏参数成比例的说法，且未给出任何实测显存；作为普适陈述条件不足。；来源paper-f8bbf0e9d979 PDF第4页：Note that this analysis focuses on the active parameter count (see Section 2.1), which is directly proportional to the inference compute cost, but does not consider the memory costs and hardware utilization.；字面定位=True。AI意见待人工核原文。

e2_mistral_mixtral/B 普通组合脚本 第8页 [minor] 第8页“质量：Mixtral在多类目超Llama2-70B，激活参数少5倍”出现在“选型建议”中，但该比较是Mixtral自有pipeline对Llama系列，不等于与本稿密集候选Mistral 7B的复跑，正文未在旁标注这一边界。；来源paper-f8bbf0e9d979 PDF第4页：Mixtral outperforms or matches Llama 2 70B performance on almost all popular benchmarks while using 5x fewer active parameters during inference.；字面定位=True。AI意见待人工核原文。

独立视觉与来源复核

下面单独记录Codex查看实际逐页PNG及原论文页面后的核对结果，类型为Codex_AI_auxiliary_visual_and_source_check_not_human。它们与上面的云模型文本意见分开，按真实稿件SHA绑定；不加入云模型费用，也不改变六稿文本覆盖/重复计数。具体已观察问题和正确核对项如实保留，尚不代表整稿视觉质量通过或独立人工盲评。

e1_flashattention2/A 普通 DSH 第2页 [supported / none] 相关论文原图、方法流程和结果表均具备，基础层级清楚，拼图中未见明显正文溢出/遮挡。

实际核对依据：原图在p2（Figure2，PDF p8），process在p3，原生table计划在p4；6页拼图页序完整。此处仅确认任务结构与可见版面，未认证全部科学主张或原图语义。。来源PDF第8页，；来源版本SHA绑定=True。

e1_flashattention2/A 普通 DSH 第4页 [needs_revision / moderate] 端到端训练结果表正文未显示数值单位与每GPU口径，关键信息只在notes。

实际核对依据：实际表头为配置(8×A100)/无FA/FA/FA-2，单元格仅142/189/196等。notes写单位TFLOPs/s/GPU，原PDF p12 Table1标题为Training speed (TFLOPs/s/GPU)。建议表头或表注明确训练吞吐TFLOPs/s/GPU，不仅写硬件。。来源PDF第12页，；来源版本SHA绑定=True。

e1_flashattention2/A 普通 DSH 第3页 [needs_revision / minor] 标题承诺三个改动，但图中列五个步骤，包含精确性性质与端到端结果，信息类型混在改动列表。

实际核对依据：实际p3标题相对原版的三个具体改动；process五项为不改变输出/序列维并行/warp改分Q/反向避split-K/端到端训练。可将标题改为改动与效果，或只留三项改动，把训练结果移交p4；这不是确认算法内容错误。。来源PDF第1页，；来源版本SHA绑定=True。

e1_flashattention2/B 普通组合脚本 第5页 [blocked_visible_crop / major] Figure5右侧两个子图明显截断，不能作为题面要求的完整相关原图交付。

实际核对依据：实际1441×810整页PNG与独立查看的1346×1412原提取PNG均显示右列(b)/(d)只有左侧512/1k/2k部分，右侧4k/8k/16k、标题与子图说明在图像内部直边切断。服务器渲染原PDF p11图完整（SHA 8a407082f7b296a365fbafd22752aca28eeab8dc6cdc455154aa20065bd81871）。原提取PNG为caption_geometry_candidate、SHA d11ee49fab2f9d458148ac66145a5a2664e38585bd32a71c3a2a75f72b1dfba0，已在提取层裁断；原PDF未损坏，不是网页窗口或PPT后续排版才裁坏。。来源PDF第11页，；来源版本SHA绑定=True。

e1_flashattention2/B 普通组合脚本 第5页 [blocked_confirmed_source_mismatch / major] 正文把xformers/Triton的数值错归FlashAttention或FlashAttention-2，原文结果存在系列错配。

实际核对依据：稿写head128,16k的FA平均122，FA2 223；原PDF p11 Figure5(b)16k的FlashAttention为73、xformers为122、FA2为223。稿又写head64,16k FA2为155、FA平均约155；原Figure5(a)对应FA104、Triton155、FA2 192。原PDF全文按图例列出这些序列，实际页内原图左上16k柱标签也可见104/98/155/192，155并非紫色FA2系列。建议按图例纠正并重新核全部正文数值；保留旧错误稿。。来源PDF第11页，；来源版本SHA绑定=True。

e1_flashattention2/B 普通组合脚本 第6页 [needs_revision / moderate] 末页端到端结果表单位和每GPU口径未显示在正文；原文条件与notes较完整，仍需可见标签。

实际核对依据：实际表头8×A100/不用FA/FA/FA-2，未见TFLOPs/s/GPU；与A p4相同四行数据。正文有V100待验证和1.3B/2k/8k，不能替代结果单位。。来源PDF第12页，；来源版本SHA绑定=True。

e1_flashattention2/C 认证 Motif 第4页 [supported / none] 本页重绘柱图两系列的六个值与原Figure4(b)标注相符，不支持将其泛称为猜测数值或科学造数。

实际核对依据：C p4计划FA2=151/173/187/196/201/203，FA=76/72/76/80/82/83；原PDF p10 Figure4(b)无causal、head128同样列出上述值。notes明确A100 80GB SXM4、总token16k、hidden2048、head128与前后向合并计时；实际页显示无causal/head128及未列其他系列。仍需补可见轴/单位，且原始PDF图像完整核对待人工。。来源PDF第10页，；来源版本SHA绑定=True。

e1_flashattention2/C 认证 Motif 第4页 [needs_revision / moderate] 实际原生图未显示y轴单位和x轴变量名，计划里的unit/y_label未体现在交付预览。

实际核对依据：实际完整p4只有y轴0–250和x轴512/1k/2k/4k/8k/16k，没有TFLOPs/s或Sequence length；计划chart含unit TFLOPs/s、y_label速度(TFLOPs/s)。建议在图上可见标单位/序列长度，不能仅依据计划字段宣称结果条件已交付。。来源PDF第10页，；来源版本SHA绑定=True。

e1_flashattention2/C 认证 Motif 第3页 [supported / none] C稿已经使用完整可见原图、原生流程与两张结构化柱图，页面组织比连续项目符号更丰富。

实际核对依据：原Figure3在p3，process在p2/p6，chart在p4/p5。拼图中无明显溢出/遮挡；有清晰封面、三项改动、证据与V100待验结尾。p5标题有TFLOPs/s但没有/GPU，关键每GPU口径仍需由notes移至正文。这是可见结构与表现观察，不是Motif导致审美改进的因果证据。。来源PDF第9页，；来源版本SHA绑定=True。

e2_mistral_mixtral/A 普通 DSH 第4页 [supported / none] E2 A稿具备两篇各一张相关原图、原生方法流程和条件对照表；版面基本可读，没有拼图可见的正文阻断。

实际核对依据：Mistral Figure1在p3、Mixtral Figure1在p4，process在p5，table在p6/p8。8页完整；Mixtral图相对空白区域偏小，但不是未放原图。表内质量分数来源各论文，p7注明不跨论文排名；完整协议仍多在notes。。来源PDF第2页，；来源版本SHA绑定=True。

e2_mistral_mixtral/B 普通组合脚本 第6页 [supported / none] E2 B稿有两篇原图、原生流程和可见shot协议表，结果条件比只放数字更清楚。

实际核对依据：原图p3/p5、process p4、table p6、comparison p7。p6正文显示MMLU5-shot、GSM8K8-shot maj@8、HumanEval0-shot、MBPP3-shot；两文原PDF p3均列这些协议。数字各来自各自论文而非同次复跑，仍不能称公平对照；版面不遮挡但原图小字偏小。。来源PDF第3页，；来源版本SHA绑定=True。

e2_mistral_mixtral/C 认证 Motif 第2页 [needs_revision_confirmed_source_mismatch / moderate] Mistral协议列表漏掉5-shot，且notes将此误写成两文shot类别差异。

实际核对依据：实际p2表Mistral=0/3/4/8-shot、Mixtral=0/3/4/5/8-shot；notes C06称Mistral第3页列0/3/4/8-shot。Mistral原PDF p3明确World Knowledge(5-shot)、MMLU(5-shot)，与Mixtral p3相同。跨论文不能拼榜的谨慎结论可保留，但不能用这项不存在的shot差异作理由；所谓样本数不同在当前已核文本中亦没有明确依据。。来源PDF第3页，；来源版本SHA绑定=True。

e2_mistral_mixtral/C 认证 Motif 第7页 [needs_revision / moderate] 结果页强调口径完整、必须给shot条件，但正文结果表没有显示shot/聚合口径。

实际核对依据：实际p7短结论为报告分数须同时给出shot数与条件；表只列MMLU/GSM8K/MBPP及60.1/70.6等百分数，shot/maj@8/pass@1写在notes。建议同行标签补MMLU5-shot、GSM8K8-shot maj@8、MBPP3-shot pass@1，并写来自各论文Table2；不是因为没有notes就判数字虚构。。来源PDF第3页，；来源版本SHA绑定=True。

e2_mistral_mixtral/C 认证 Motif 第6页 [supported_with_minor_visual_issue / minor] E2 C稿结构完整、原图未见明显截断，MoE原图本体相对页面偏小，可更充分使用空白。

实际核对依据：Mistral原图p4、Mixtral原图p6、process p3/p5、table p2/p7/p8。实际完整p6 PNG能看到inputs/router/expert/outputs和图注，但图本体约占右侧一小块，细节投影可读性不足；建议放大原图并缩短重复正文或单图页。这不是原图科学含义错误，未要求产品增加内部候选标签。。来源PDF第2页，；来源版本SHA绑定=True。

7 / 逐题展示

每份实际确认稿下方展示全部页面。HTML按同题、同阶段并排A/B/C；点击可看逐页PNG、原始可编辑PPTX与PDF，初稿及修订稿均保留。缺少确认交付不会用文件夹中看似完成的文件补齐。

LoRA / B 普通组合脚本 / 初稿 / 版本1

LoRA 冻结基模型、只训练低秩增量

低秩分支与主干并联，训练只更新增量

- 冻结 W0，只训练 A、B 两个低秩矩阵
- 原论文图 1：A 高斯初始化、B 置零

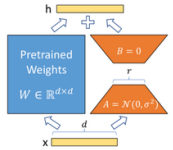


Figure 1: Our reparametrization. We only train A and B.

来源见讲者备注 1 / 6

01 / 06

增量被约束为 BA，秩 r 远小于模型维度

可训练参数由 2× 矩阵数 ×d_model×r 决定

- W0 冻结不接收梯度，A、B 承载全部可训练参数
- W0 与 BA 作用于同一输入，输出逐坐标相加
- 增量按 α/r 缩放，便于换秩时少调超参
- GPT-3 上 r 取 1 或 2，d 可达 12,288

来源见讲者备注 2 / 6

02 / 06

方法流程：冻结、注入、训练与合并部署

1 冻结预训练权重	W0 不接收梯度，基座可被多任务共享
2 注入 A 与 B 低秩分支	A 高斯初始化、B 置零，起始增量 BA 为零
3 只优化 A 与 B	需为增量矩阵保存优化器状态
4 合并 W=W0+BA 后推理	合并后按常规前向计算，不额外增加延迟

来源见讲者备注 3 / 6

03 / 06

一种具体实验口径： GPT-3 175B 的低秩预算

同口径下低秩预算可与全量微调持平或略优

- 配对条件：同样 AdamW、2 轮、批 128
- 序列长度按数据集 384/768/2048 设定
- LoRA 两种预算 4.7M 与 37.7M 可训练参数
- 基线为全量微调 175,255.8M 参数

来源见讲者备注 4 / 6

04 / 06

原论文结果： LoRA 在三个任务上对齐或超过全量微调

4.7M 参数已达 73.4%，与全量微调 73.8% 接近

- 同一验证集口径： WikiSQL 逻辑形式验证准确率

方法（GPT-3 175B）	可训练参数	WikiSQL 准确率 %	MNLI-m 准确率 %
全量微调	175,255.8M	73.8	89.5
BitFit	14.2M	71.3	91.0
AdapterH	40.1M	73.2	91.5
LoRA	4.7M	73.4	91.7
LoRA	37.7M	74.0	91.6

来源见讲者备注 5 / 6

05 / 06

区分参数节省、训练显存与运行时间

存储与显存

- 检查点 350GB→35MB （r=4，仅 q、v）
- 训练显存 1.2TB→350GB （约省 2/3）
- 节省源于不存冻结参数优化器状态

训练吞吐与推理延迟

- 训练 32.5→43.1 tokens/s 每 V100 （GPT-3）
- 合并后推理与全量微调相同，按构造无额外延迟
- 适配器在批 1、序列 128 时延迟 +20.7%

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 28c83ef95b53553d6df72becf0f3d15cfb3af1a56ac2341f7d126b58f045813f；run c0e25abc67764432b7a87ad24074c9ca

LoRA / B 普通组合脚本 / 跨重启修订稿 / 版本1

LoRA 冻结基模型、只训练低秩增量

低秩分支与主干并联，训练只更新增量

- 冻结 W0，只训练 A、B 两个低秩矩阵
- 原论文图 1：A 高斯初始化、B 置零

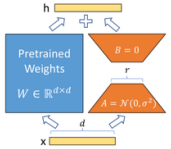


Figure 1: Our reparametrization. We only train A and B.

来源见讲者备注 1 / 6

01 / 06

增量被约束为 BA，秩 r 远小于模型维度

可训练参数由 2× 矩阵数 ×d_model×r 决定

- W0 冻结不接收梯度，A、B 承载全部可训练参数
- W0 与 BA 作用于同一输入，输出逐坐标相加
- 增量按 α/r 缩放，便于换秩时少调超参
- GPT-3 上 r 取 1 或 2，d 可达 12,288

来源见讲者备注 2 / 6

02 / 06

方法流程：冻结、注入、训练与合并部署

1. **冻结预训练权重** — W0 不接收梯度，基座可被多任务共享
2. **注入 A 与 B 低秩分支** — A 高斯初始化、B 置零，起始增量 BA 为零
3. **只优化 A 与 B** — 需为增量矩阵保存优化器状态
4. **合并 W=W0+BA 后推理** — 合并后按常规前向计算，不额外增加延迟

来源见讲者备注 3 / 6

03 / 06

一种具体实验口径： GPT-3 175B 的低秩预算

同口径下低秩预算可与全量微调持平或略优

- 配对条件：同样 AdamW、2 轮、批 128
- 序列长度按数据集 384/768/2048 设定
- LoRA 两种预算 4.7M 与 37.7M 可训练参数
- 基线为全量微调 175,255.8M 参数

来源见讲者备注 4 / 6

04 / 06

原论文结果： LoRA 在三个任务上对齐或超过全量微调

4.7M 参数已达 73.4%，与全量微调 73.8% 接近

- 同一验证集口径： WikiSQL 逻辑形式验证准确率

方法（GPT-3 175B）	可训练参数	WikiSQL 准确率 %	MNLI-m 准确率 %
全量微调	175,255.8M	73.8	89.5
BitFit	14.2M	71.3	91.0
AdapterH	40.1M	73.2	91.5
LoRA	4.7M	73.4	91.7
LoRA	37.7M	74.0	91.6

来源见讲者备注 5 / 6

05 / 06

采用建议：适用条件、论文证据与待实测

论文支持省显存与存储，本组速度仍需自测

- 适用：全量微调不可行或多任务需共享基座时
- 原论文证据：显存与检查点大幅下降，质量持平
- 待实测：本组 V100 的延迟、显存与吞吐
- 待实测：未合并权重的多任务批处理

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA a91be2ef6c3a7f99fd36c69eb849c34d12e05a19d688f3d6dacd685685e68159；run 016fe42e35a347009aee597fe6efb48b

QLoRA / B 普通组合脚本 / 初稿 / 版本1

RESEARCH BRIEF

QLoRA： 显存受限下的模型适配方案讨论

- 4-bit 冻结基座 + LoRA 适配器训练
- NF4 / Double Quantization / Paged Optimizers 各自解决什么
- 论文结论成立的模型、任务与评测条件

来源见讲者备注 1 / 6

01 / 06

4-bit 冻结基座与适配器：省的是存储，不是算力

量化省存储；训练精度与激活开销不由 4-bit 决定

- 存储用 4-bit NF4 ，计算仍用 BFloat16
- 用到权重时先反量化再做 16-bit 矩阵乘
- 冻结点：仅 LoRA 权重的梯度被更新
- 7B 案例： 4-bit 基座占 5048 MB ， LoRA 参数仅 26 MB

来源见讲者备注 2 / 6

02 / 06

NF4 、 Double Quantization 、 Paged Optimizers 解决的问题

三者分别管精度、常数开销与长序列显存尖峰

1. **量化存储而非算力** 4-bit 冻结基座 + LoRA 适配器训练
2. **NF4 解决精度** NF4： 同一分布下优于 4-bit Float 与 Int4
3. **Double Quantization 省常** 32 位常数用 8-bit 块大小 256 再量化
4. **Paged Optimizers** 优化器状态分页，显存不足时换出 CPU 兜尖峰

来源见讲者备注 3 / 6

03 / 06

内存构成：省下来的是哪一块

量化压的是基座；尖峰要靠分页而非继续压参数

- 对比不同微调方法的显存需求
- 4-bit 量化基座加 Paged Optimizers 处理尖峰

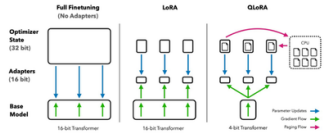


Figure 1: Different finetuning methods and their memory requirements. QLoRA improves over LoRA by quantizing the transformer model to 4-bit precision and using paged optimizers to handle memory spikes.

来源见讲者备注 4 / 6

04 / 06

各结论的模型、任务与评测口径

NF4+DQ 复现 16-bit； FP4 偏低，差距不可忽略

口径	条件	结果
GLUE 准确率	RoBERTa-large	BF16 88.6 / FP4 88.6
NaturalInstructions	T5 80M–11B	BF16 40.1–62.0
MMLU 5-shot	LLaMA 7–65B	BF16 53.0 / NF4 53.1
Vicuna 相对 ChatGPT	Guanaco 65B 4-bit	99.3% ， CI 4.4%

来源见讲者备注 5 / 6

05 / 06

结论边界：这套数字成立的条件

把单卡个案当作能力上限前，先逐项对齐模型、任务与硬件

- 原文仅在 3B 以内证明与 16-bit 全量微调持平
- 33B/65B 单卡结论绑定 24GB/48GB 显卡与块大小 64
- 小数据集也可能反超大数据集，数据质量优先
- Paged Optimizers 的分页阈值与减速条件未刻画

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA b4b5c2171f5c7014b8357f169eea6dc545491b465b0e80ec4731e2c2add32b3c；run bf61d27208b641d2ae61d16db5d83243

QLoRA / B 普通组合脚本 / 跨重启修订稿 / 版本1

RESEARCH BRIEF

QLoRA： 显存受限下的模型适配方案讨论

- 4-bit 冻结基座 + LoRA 适配器训练
- NF4 / Double Quantization / Paged Optimizers 各自解决什么
- 论文结论成立的模型、任务与评测条件

来源见讲者备注 1 / 6

01 / 06

4-bit 冻结基座与适配器：省的是存储，不是算力

量化省存储；训练精度与激活开销不由 4-bit 决定

- 存储用 4-bit NF4 ，计算仍用 BFloat16
- 用到权重时先反量化再做 16-bit 矩阵乘
- 冻结点：仅 LoRA 权重的梯度被更新
- 7B 案例： 4-bit 基座占 5048 MB ， LoRA 参数仅 26 MB

来源见讲者备注 2 / 6

02 / 06

NF4 、 Double Quantization 、 Paged Optimizers 解决的问题

三者分别管精度、常数开销与长序列显存尖峰

1. **量化存储而非算力** 4-bit 冻结基座 + LoRA 适配器训练
2. **NF4 解决精度** NF4： 同一分布下优于 4-bit Float 与 Int4
3. **Double Quantization 省常** 32 位常数用 8-bit 块大小 256 再量化
4. **Paged Optimizers** 优化器状态分页，显存不足时换出 CPU 兜尖峰

来源见讲者备注 3 / 6

03 / 06

内存构成：省下来的是哪一块

量化压的是基座；尖峰要靠分页而非继续压参数

- 对比不同微调方法的显存需求
- 4-bit 量化基座加 Paged Optimizers 处理尖峰

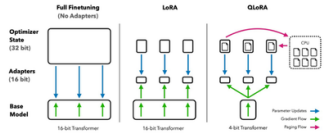


Figure 1: Different finetuning methods and their memory requirements. QLoRA improves over LoRA by quantizing the transformer model to 4-bit precision and using paged optimizers to handle memory spikes.

来源见讲者备注 4 / 6

04 / 06

各结论的模型、任务与评测口径

NF4+DQ 复现 16-bit； FP4 偏低，差距不可忽略

口径	条件	结果
GLUE 准确率	RoBERTa-large	BF16 88.6 / FP4 88.6
NaturalInstructions	T5 80M–11B	BF16 40.1–62.0
MMLU 5-shot	LLaMA 7–65B	BF16 53.0 / NF4 53.1
Vicuna 相对 ChatGPT	Guanaco 65B 4-bit	99.3% ， CI 4.4%

来源见讲者备注 5 / 6

05 / 06

本地待验证的容量、时间与质量指标

先把硬件与配置对齐，再比显存、时间与质量

- 论文数字均有配置前提，本地需同条件实测

指标	论文值与条件	本地量法
显存	65B 全量 >780GB； QLoRA<48GB	同配置记录峰值与构成
时间	65B 单卡 >24h； 33B 卡 <12h	每步耗时与是否换页
质量	MMLU5-shot BF16 53.0/NF4 53.1	同口径并报置信区间

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 93a7386aa80f27366eba8b0e6b414a0f2edce1c3ca5d2f5e9ae30586efb9afa7；run 7792e5ade38b4488a4e80c3e0f7c3b88

Prefix-Tuning / B 普通组合脚本 / 初稿 / 版本1

RESEARCH BRIEF

Prefix-Tuning： 只训练前缀以适配生成任务

- 冻结预训练语言模型，仅优化连续前缀
- 基于 Li & Liang 2021 （arXiv:2101.00190v1）
- 面向选择参数高效适配方法的研究讨论

来源见讲者备注 1 / 6

01 / 06

冻结主干，前缀从左侧上下文影响后续激活

不改变主干参数，仅靠左侧上下文引导生成

- 前 N 个时刻的激活取自可训练矩阵 Pθ
- 其后 token 仍可把前缀当作“虚拟 token” 注意力

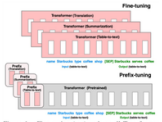


Figure 1: Fine-tuning (top) updates all Transformer parameters (the red Transformer box) and requires storing a full model copy for each task. We propose prefix-tuning (bottom), which freezes the Transformer parameters and only optimizes the prefix (the red prefix blocks). Consequently, we only need to store the prefix for each task, making prefix-tuning modular and space-efficient. Note that each vertical block denote transformer activations at one time step.

来源见讲者备注 2 / 6

02 / 06

训练时只有前缀参数更新，主干被固定

φ 固定、 θ 可训练，参数集决定信息流

1	**拼接前缀**	z=[PREFIX;x;y]； 编码器 - 解码器再加 PREFIX’（第 4 页）
2	**取用前缀激活**	Pθ 为 |Pidx|×dim(hi) 矩阵， i∈Pidx 时 hi=Pθ[i,:]（第 4 页）
3	**重参数化稳定训练**	Pθ=MLPθ(P’θ)，直接优化不稳定且略降（第 4 页）
4	**仅存前缀交付**	训练后可丢弃重参数化，只保存 Pθ （第 5 页）

来源见讲者备注 3 / 6

03 / 06

全数据下表到文可比，摘要略有下降

前缀方法在表到文可比，摘要仍略低于微调

- E2E/WebNLG/DART 为表到文（GPT-2），XSUM 为摘要（BART）

任务与指标	微调	前缀 0.1%
E2E BLEU ↑	68.5	70.3
WebNLG BLEU ↑	65.3	63.4
XSUM ROUGE-L ↑	37.25	35.05

来源见讲者备注 4 / 6

04 / 06

数据越少优势越明显，差距随规模收敛

优势出现在数据有限，而非所有条件都更优

- 低数据：前缀平均高出微调 2.9 BLEU
- 低数据下微调更易出现与表格不符的表述
- XSUM 样本量约为表到文数据集的 4 倍
- 文章输入平均长度约为线性化表格的 17 倍

来源见讲者备注 5 / 6

05 / 06

未证明的范围，与尚待验证的问题

边界条件明确：收益限于已报任务的指标

- 未比较显存、吞吐或推理延迟收益
- 新主题外推更好，但原因仍未解释
- 超出阈值的前缀长度反而略降
- 作者称可扩展到 GPT-3，但未做实验

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA b5217ed28f5e14e6a2645dc8865952f27d2aaf6f9c1f80d6503a5a5505777351；run 31b0a161fa2444eb95bf07efe0f466aa

Prefix-Tuning / B 普通组合脚本 / 跨重启修订稿 / 版本1

RESEARCH BRIEF

Prefix-Tuning： 只训练前缀以适配生成任务

- 冻结预训练语言模型，仅优化连续前缀
- 基于 Li & Liang 2021 （arXiv:2101.00190v1）
- 面向选择参数高效适配方法的研究讨论

来源见讲者备注 1 / 6

01 / 06

冻结主干，前缀从左侧上下文影响后续激活

不改变主干参数，仅靠左侧上下文引导生成

- 前 N 个时刻的激活取自可训练矩阵 Pθ
- 其后 token 仍可把前缀当作“虚拟 token” 注意力

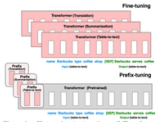


Figure 1: Fine-tuning (top) updates all Transformer parameters (the red Transformer box) and requires storing a full model copy for each task. We propose prefix-tuning (bottom), which freezes the Transformer parameters and only optimizes the prefix (the red prefix blocks). Consequently, we only need to store the prefix for each task, making prefix-tuning modular and space-efficient. Note that each vertical block denote transformer activations at one time step.

来源见讲者备注 2 / 6

02 / 06

训练时只有前缀参数更新，主干被固定

φ 固定、 θ 可训练，参数集决定信息流

1	**拼接前缀**	z=[PREFIX;x;y]； 编码器 - 解码器再加 PREFIX’（第 4 页）
2	**取用前缀激活**	Pθ 为 |Pidx|×dim(hi) 矩阵， i∈Pidx 时 hi=Pθ[i,:]（第 4 页）
3	**重参数化稳定训练**	Pθ=MLPθ(P’θ)，直接优化不稳定且略降（第 4 页）
4	**仅存前缀交付**	训练后可丢弃重参数化，只保存 Pθ （第 5 页）

来源见讲者备注 3 / 6

03 / 06

全数据下表到文可比，摘要略有下降

前缀方法在表到文可比，摘要仍略低于微调

- E2E/WebNLG/DART 为表到文（GPT-2），XSUM 为摘要（BART）

任务与指标	微调	前缀 0.1%
E2E BLEU ↑	68.5	70.3
WebNLG BLEU ↑	65.3	63.4
XSUM ROUGE-L ↑	37.25	35.05

来源见讲者备注 4 / 6

04 / 06

数据越少优势越明显，差距随规模收敛

优势出现在数据有限，而非所有条件都更优

- 低数据：前缀平均高出微调 2.9 BLEU
- 低数据下微调更易出现与表格不符的表述
- XSUM 样本量约为表到文数据集的 4 倍
- 文章输入平均长度约为线性化表格的 17 倍

来源见讲者备注 5 / 6

05 / 06

采用条件、原文证据与仍需实测的事项

论文结论限于已报指标，资源收益未被验证

- 冻结适配在表到文与低数据下可比或更好
- 摘要全数据下前缀仍略低于微调
- 前缀长度存在阈值，超出后测试指标略降
- 可训练参数少不等于省显存或更高吞吐

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 9998117cbad6e7f245c29d0cde5713c2619a67b890154f33f4f8970d340a0074；run 98ffb1934a824bf9a33db7a33c3ebf67

FlashAttention-2 / A 普通 DSH / 初稿 / 版本1

FlashAttention-2：为何改、改了什么

它改的是划分方式，不改变注意力结果

- 原版仅达理论峰值 25–40%，落后于 GEMM
- 根因：线程块与 warp 间 work partitioning 不优
- 三项改动：减少非 matmul、序列维并行、warp 分块
- 结果不近似，O 与标准注意力一致

来源见讲者备注 1 / 6

01 / 06

原图：前向按行块并行，反向按列块并行

- 改动集中在 thread block 与 warp 两级划分



Figure 2: In the forward pass (left), we parallelize the workers (thread blocks) where each worker takes care of a block of rows of the attention matrix. In the backward pass (right), each worker takes care of a block of columns of the attention matrix.

来源见讲者备注 2 / 6

02 / 06

相对原版的三个具体改动

不改变输出	仍为精确注意力，仅减少非 matmul FLOPs
序列维并行	长序列小 batch 时新增行 / 列块并行，提高占用率
warp 改分 Q	原版拆 K/V 需共享内存同步；改为拆 Q，warp 间无须通信
反向避 split-K	仍有同步，但减少共享内存读写
端到端训练	GPT 1.3B/2.7B，2k/8k，8×A100，最高 225 TFLOPs/s

来源见讲者备注 3 / 6

03 / 06

论文实测：训练吞吐与硬件 / 配置条件

- 同硬件同模型下，8k 上下文收益大于 2k

配置 (8×A100)	无 FA	FA	FA-2
GPT3-1.3B, 2k	142	189	196
GPT3-1.3B, 8k	72	170	220
GPT3-2.7B, 2k	149	189	205
GPT3-2.7B, 8k	80	175	225

来源见讲者备注 4 / 6

04 / 06

算法精确性与内核性能、端到端收益不是一回事

原文直接支持

- 输出与标准注意力一致，无近似
- 增量内存 O(N) 而非 $O(N^2)$
- 前向峰值从 40% 提至 50–73%

有条件，不能外推

- 内核与端到端数据均取自 A100
- H100 数据未用 TMA 与四代张量核
- 全文未给 V100 实测
- 序列维并行思路源自 Triton

来源见讲者备注 5 / 6

05 / 06

回到 V100：可迁移的改动与未复现的收益

先在 V100 实测内核，再决定是否全量采用

- A100 上 225 TFLOPs/s 未在 V100 复现
- 机制改动针对划分，不依赖 A100 专属指令
- 可先验证 1.7–3.0× 内核倍数是否在 V100 成立
- V100 与 A100 张量核代际条件不同，需实测

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 41510e479bd8f5dd754fbf5ca0dbe95a060ba6ab5018ea793eb2fa68d6ef557d；run 7b48acbf9a824f2985bb6c03c20dc6a5

FlashAttention-2 / A 普通 DSH / 跨重启修订稿 / 版本1

FlashAttention-2：为何改、改了什么

它改的是划分方式，不改变注意力结果

- 原版仅达理论峰值 25–40%，落后于 GEMM
- 根因：线程块与 warp 间 work partitioning 不优
- 三项改动：减少非 matmul、序列维并行、warp 分块
- 结果不近似，O 与标准注意力一致

来源见讲者备注 1 / 6

01 / 06

原图：前向按行块并行，反向按列块并行

- 改动集中在 thread block 与 warp 两级划分



Figure 2: In the forward pass (left), we parallelize the workers (thread blocks) where each worker takes care of a block of rows of the attention matrix. In the backward pass (right), each worker takes care of a block of columns of the attention matrix.

来源见讲者备注 2 / 6

02 / 06

相对原版的三个具体改动

不改变输出	仍为精确注意力，仅减少非 matmul FLOPs
序列维并行	长序列小 batch 时新增行 / 列块并行，提高占用率
warp 改分 Q	原版拆 K/V 需共享内存同步；改为拆 Q，warp 间无须通信
反向避 split-K	仍有同步，但减少共享内存读写
端到端训练	GPT 1.3B/2.7B，2k/8k，8×A100，最高 225 TFLOPs/s

来源见讲者备注 3 / 6

03 / 06

论文实测：训练吞吐与硬件 / 配置条件

- 同硬件同模型下，8k 上下文收益大于 2k

配置 (8×A100)	无 FA	FA	FA-2
GPT3-1.3B, 2k	142	189	196
GPT3-1.3B, 8k	72	170	220
GPT3-2.7B, 2k	149	189	205
GPT3-2.7B, 8k	80	175	225

来源见讲者备注 4 / 6

04 / 06

算法精确性与内核性能、端到端收益不是一回事

原文直接支持

- 输出与标准注意力一致，无近似
- 增量内存 O(N) 而非 $O(N^2)$
- 前向峰值从 40% 提至 50–73%

有条件，不能外推

- 内核与端到端数据均取自 A100
- H100 数据未用 TMA 与四代张量核
- 全文未给 V100 实测
- 序列维并行思路源自 Triton

来源见讲者备注 5 / 6

05 / 06

三条判断：采用前提、V100 空白与最小验证

先在 V100 复现内核倍数，再决定是否全量采用

- 采用前提：关注内核级加速且硬件条件与论文一致
- 论文未测 V100，225 TFLOPs/s 与 1.7–3.0× 不可直接外推
- 论文以 A100 的 16× 非 matmul/matmul 比解释开销

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 4ad7f92fdaba01618faf3775d65b167201dfcb988f58d56f4af2f91d1d065063；run 37fb884ffa5c4f08bb57763735da2958

FlashAttention-2 / B 普通组合脚本 / 初稿 / 版本1

是否采用 FlashAttention-2： 先分清三层收益

本报告按算法精确性、内核性能、端到端收益三层核对证据

- 论文报告：相对 FlashAttention 约 2× 加速，非端到端训练加速
- 内核实测硬件为 A100 80GB SXM4 / 8×A100 80GB SXM
- 算法输出不变、无近似；但我们用 V100 ，收益未在该卡复现
- 端到端加速还依赖模型规模、序列长度与精度选择

来源见讲者备注 1 / 6

01 / 06

并行： FlashAttention 按批与头划分，长序列占用不足

并行度不足来自网格规模，不是算术量本身

- v1 每头一个 thread block ，总数 = 批大小 × 头数
- A100 有 108 个 SM ，块数≥ 80 时才接近用满
- 长序列常伴随小批小头数，易出现低占用
- 所以 v1 在长序列区间并非算力受限

来源见讲者备注 2 / 6

02 / 06

FlashAttention-2 的三处改动

三处改动分别针对非矩阵乘开销、并行度与共享内存通信

01
减少非矩阵乘 FLOP
输出不再每步重缩放，只保存 logsumexp ；输出不变

→

02
沿序列长度分块
在批与头之外再切序列，块数随之增加

→

03
warp 内划分工作量
前向按 Q 切分，避免 split-K ，减少共享内存读写

来源见讲者备注 3 / 6

03 / 06

非矩阵乘开销为何关键： A100 上相差 16 倍

在 A100 上每个非矩阵乘 FLOP 的代价约为矩阵乘的 16 倍

- A100 理论峰值： FP16/BF16 矩阵乘 312 TFLOPs/s
- 非矩阵乘 FP32 仅 19.5 TFLOPs/s ，低约 16 倍
- 同一算子内，非矩阵乘 FLOP 耗时更贵
- 故减少它们比减少总 FLOP 更影响吞吐

来源见讲者备注 4 / 6

04 / 06

内核实测： A100 、头维 64/128 、无掩码前向

- 头维 128 、序列 16k： FA 平均 122 ， FA2 达 223 TFLOPs/s
- 头维 64 、序列 16k： FA2 为 155 ， FA 平均约 155
- 总 token 固定 16k ，批大小随序列长度调整

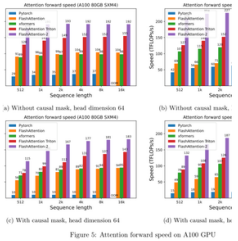


Figure 5: Attention forward speed on A100 GPU

来源见讲者备注 5 / 6

05 / 06

端到端训练收益： 8×A100 ， 1.3B/2.7B ， 2k/8k

增益随序列长度增大而增大， 2k 时仅约 1.04–1.14×

配置（ 8×A100 ）	不用 FA	FlashAttention	FlashAttention-2
1.3B ， 2k	142 TFLOPs/s	189	196
1.3B ， 8k	72 TFLOPs/s	170	220
2.7B ， 2k	149 TFLOPs/s	189	205
2.7B ， 8k	80 TFLOPs/s	175	225

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 09bc18ce2c1aa3601e2d94e4a0dca0f3e34985e099070ee886f98cf918c5d933；run 7d6b5e4e2791492d9eda338a31946e52

FlashAttention-2 / B 普通组合脚本 / 跨重启修订稿 / 版本1

是否采用 FlashAttention-2： 先分清三层收益

本报告按算法精确性、内核性能、端到端收益三层核对证据

- 论文报告：相对 FlashAttention 约 2× 加速，非端到端训练加速
- 内核实测硬件为 A100 80GB SXM4 / 8×A100 80GB SXM
- 算法输出不变、无近似；但我们用 V100，收益未在该卡复现
- 端到端加速还依赖模型规模、序列长度与精度选择

来源见讲者备注 1 / 6

01 / 06

并行： FlashAttention 按批与头划分，长序列占用不足

并行度不足来自网格规模，不是算术量本身

- v1 每头一个 thread block，总数 = 批大小 × 头数
- A100 有 108 个 SM，块数≥ 80 时才接近用满
- 长序列常伴随小批小头数，易出现低占用
- 所以 v1 在长序列区间并非算力受限

来源见讲者备注 2 / 6

02 / 06

FlashAttention-2 的三处改动

三处改动分别针对非矩阵乘开销、并行度与共享内存通信

01
减少非矩阵乘 FLOP
输出不再每步重缩放，只保存 logsumexp；输出不变

→

02
沿序列长度分块
在批与头之外再切序列，块数随之增加

→

03
warp 内划分工作量
前向按 Q 切分，避免 split-K，减少共享内存读写

来源见讲者备注 3 / 6

03 / 06

非矩阵乘开销为何关键： A100 上相差 16 倍

在 A100 上每个非矩阵乘 FLOP 的代价约为矩阵乘的 16 倍

- A100 理论峰值： FP16/BF16 矩阵乘 312 TFLOPs/s
- 非矩阵乘 FP32 仅 19.5 TFLOPs/s，低约 16 倍
- 同一算子内，非矩阵乘 FLOP 耗时更贵
- 故减少它们比减少总 FLOP 更影响吞吐

来源见讲者备注 4 / 6

04 / 06

内核实测： A100 、头维 64/128 、无掩码前向

- 头维 128 、序列 16k： FA 平均 122， FA2 达 223 TFLOPs/s
- 头维 64 、序列 16k： FA2 为 155， FA 平均约 155
- 总 token 固定 16k，批大小随序列长度调整

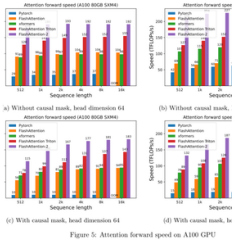


Figure 5: Attention forward speed on A100 GPU

来源见讲者备注 5 / 6

05 / 06

结论与验证：论文支持什么 ,V100 仍待验证

论文支持 A100 收益 ;V100 需同口径复跑验证

- A100 已实测 ;V100 未报告数据
- 建议先同口径复跑 1.3B 2k/8k

8×A100	不用 FA	FA	FA-2
1.3B 2k	142	189	196
1.3B 8k	72	170	220
2.7B 2k	149	189	205
2.7B 8k	80	175	225

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA b4fe3bbbfe3d228004a3232602e2c5c35d43533738690b6ca22b982beac05a96；run 0c00c76bff16423095b670a48d778af8

FlashAttention-2 / C 认证 Motif / 初稿 / 版本1

RESEARCH BRIEF

是否采用 FlashAttention-2： 证据与适用条件

先确认收益条件，再决定是否在我们集群推广

- 解析论文：官方报告 v1 （2023-07-17）
- 优点：更好的并行与工作划分（A100 基准）
- 边界：本组使用 V100，尚未实测复现

来源见讲者备注 1 / 6

01 / 06

它改了什么：算法精确性未变的三项调整

三项调整都不改变输出，不放宽精确性

01 少做非矩阵乘运算
不缩放输出两项，只保存 logsumexp （第 5 页）

→

02 沿序列长度并行
在 batch 与头维度之外增加切分，提高占用率（第 8 页）

→

03 warp 间分工
按 Q 切分 warp，避免 split-K 与共享内存往返（第 9 页）

来源见讲者备注 2 / 6

02 / 06

前向 warp 分工：为何不再需要 split-K

同一步骤顺序改变，消除了 warp 间通信

- 左：旧版按 K/V 分割，需共享内存加和
- 右：新版按 Q 分割，各 warp 直接得输出切片

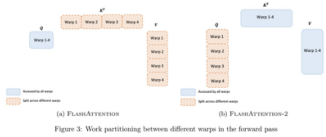


Figure 3: Work partitioning between different warps in the forward pass

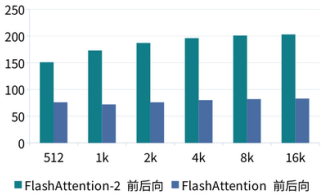
来源见讲者备注 3 / 6

03 / 06

A100 实测：同条件下前向与反向吞吐对比

该子图条件下吞吐约翻倍

- 仅重绘论文部分子图：无 causal 、头维 128
- 同图另有 PyTorch 与 Triton 曲线，此处未列全

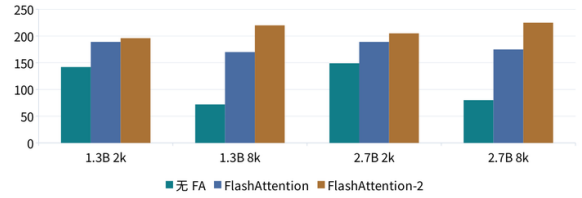


来源见讲者备注 4 / 6

04 / 06

端到端训练吞吐： FA-2 最高 225 TFLOPs/s （A100）

端到端收益在 8×A100 上测得，非 V100



来源见讲者备注 5 / 6

05 / 06

采用判断：收益分三类， V100 待自测

先做 V100 小规模实测，再决定是否全面采用

论文已证
- A100 上内核与端到端吞吐提升
- 仍是精确算法，无近似输出
- 只存 logsumexp 省显存

我们待证
- V100 上并行与占用率是否受益
- 当前算子的数据类型与头维覆盖
- 端到端训练时长是否改善

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA ae1df684bc9bacca212631879c2f4adf8f53164fad1873affbaca8545a422bf7；run 79b8eda253af4d60bd36a7099c7efdde

FlashAttention-2 / C 认证 Motif / 跨重启修订稿 / 版本1

RESEARCH BRIEF

是否采用 FlashAttention-2： 证据与适用条件

先确认收益条件，再决定是否在我们集群推广

- 解析论文：官方报告 v1 （2023-07-17）
- 优点：更好的并行与工作划分（A100 基准）
- 边界：本组使用 V100，尚未实测复现

来源见讲者备注 1 / 6

01 / 06

它改了什么：算法精确性未变的三项调整

三项调整都不改变输出，不放宽精确性

01 少做非矩阵乘运算
不缩放输出两项，只保存 logsumexp （第 5 页）

→

02 沿序列长度并行
在 batch 与头维度之外增加切分，提高占用率（第 8 页）

→

03 warp 间分工
按 Q 切分 warp，避免 split-K 与共享内存往返（第 9 页）

来源见讲者备注 2 / 6

02 / 06

前向 warp 分工：为何不再需要 split-K

同一步骤顺序改变，消除了 warp 间通信

- 左：旧版按 K/V 分割，需共享内存加和
- 右：新版按 Q 分割，各 warp 直接得输出切片

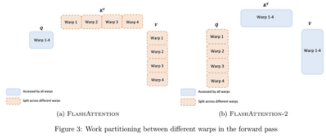


Figure 3: Work partitioning between different warps in the forward pass

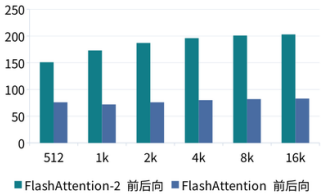
来源见讲者备注 3 / 6

03 / 06

A100 实测：同条件下前向与反向吞吐对比

该子图条件下吞吐约翻倍

- 仅重绘论文部分子图：无 causal 、头维 128
- 同图另有 PyTorch 与 Triton 曲线，此处未列全

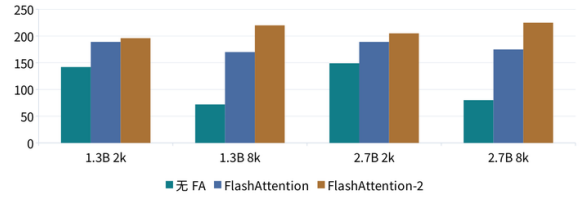


来源见讲者备注 4 / 6

04 / 06

端到端训练吞吐： FA-2 最高 225 TFLOPs/s （A100）

端到端收益在 8×A100 上测得，非 V100



来源见讲者备注 5 / 6

05 / 06

三条判断：论文已证、 V100 待验、先做小测

收益未在 V100 复现，先小规模实测再决定采用

01 论文已证
精确注意力； A100 上内核与端到端吞吐提升

→

02 V100 待验
并行占用率、数据类型覆盖、端到端时长均需自测

→

03 最小实测
在 V100 上按头维调块大小，先比内核吞吐与显存

来源见讲者备注 6 / 6

06 / 06

6页；稿件SHA 74e5b8ef775c89b2f7ed24b787c12dde531f00747c711567f2ad9e5f1cb0174f；run a0f4d1c87769486bb256a8add6264013

Mistral 7B + Mixtral / C 认证 Motif / 初稿 / 版本1

RESEARCH BRIEF

资源受限时：密集模型还是稀疏 MoE

限制在算力侧还是容量侧决定选择

- 两篇原论文：Mistral 7B 与 Mixtral 8x7B
- 资源受限时如何选型
- 标清口径，不做跨协议排名

来源见讲者备注 1 / 8

01 / 08

先分清两篇论文各证明了什么

可比的是方法口径，不是跨论文分数

- 两文均用自家流水线重跑基线
- 协议样本数不同，分数不可拼榜

维度	Mistral 7B	Mixtral 8x7B
结构	密集 FFN + GQA/SWA	8 个专家，选 2 个
计算参数	7B 全激活	13B 激活 / 47B 总
训练上下文	8k 配置	32k 上下文
评测协议	0/3/4/8-shot	0/3/4/5/8-shot

来源见讲者备注 2 / 8

02 / 08

Mistral 的注意力设计： GQA + 滑动窗口

固定窗口是缓存与成本受控的来源

1. **GQA 分组查询** — 32 个查询头共享 8 个 KV 头，降低解码显存
2. **滑动窗口注意力** — 位置 i 只看上一层 i−W 到 i， W=4096
3. **滚动缓冲区缓存** — KV 存在 i mod W ，缓存固定为 W
4. **预填充与分块** — 长提示按窗口切块预填充

来源见讲者备注 3 / 8

03 / 08

Mistral 滑动窗口的原文示意

单层视野有限，多层叠加扩大有效跨度

- 图中 W=3 ： 每个 token 只回看 3 个位置
- 窗口外 token 经多层间接影响预测

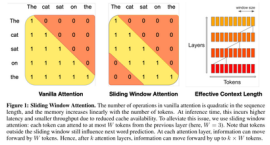


Figure 1: Sliding Window Attention. The number of operations in vanilla attention is quadratic in the sequence length, and the memory increases linearly with the number of tokens. At inference time, this incurs higher latency and smaller throughput due to reduced cache availability. To alleviate this issue, we use sliding window attention: each token can attend to at most W tokens from the previous layer (here, $W = 3$). Note that tokens outside the sliding window still influence next word prediction. At each attention layer, information can move forward by W tokens. Hence, after k attention layers, information can move forward by up to $k \times W$ tokens.

来源见讲者备注 4 / 8

04 / 08

Mixtral 路由：每 token 只过 2 个专家

总参数随专家数增长，计算量由 Top-K 决定

1. **门控打分** — 线性层 Wg 对 8 个专家计算 logits
2. **Top-2 选择** — 取 top-2 logits 做 softmax ，其余置零
3. **专家计算与相加** — 两个 SwiGLU 专家按权重相加
4. **并行与均衡** — 专家并行路由 token ，负载须均衡

来源见讲者备注 5 / 8

05 / 08

MoE 层的原文结构示意

专家是标准 FFN 块，稀疏性来自门控选择

- 输入向量经路由分给 8 个专家中的 2 个
- 层输出是两个专家输出的加权和

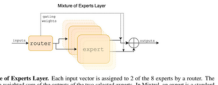


Figure 1: Mixture of Experts Layer. Each input vector is assigned to 2 of the 8 experts by a router. The layer's output is the weighted sum of the outputs of the two selected experts. In Mistral, an expert is a standard feedforward block as in a vanilla transformer architecture.

来源见讲者备注 6 / 8

06 / 08

两文结果：口径完整但互不可比

报告分数须同时给出 shot 数与条件

- 各列只在本论文内可比
- 70B 对标仅限激活参数口径

结果项	Mistral 7B	Mixtral 8x7B
MMLU	60.1%	70.6%
GSM8K	52.2%	74.4%
MBPP	47.5%	60.7%
模型规模	7B 密集	13B 激活 / 47B 总
对标基线	Llama 2 7B/13B	Llama 2 70B 、GPT-3.5

来源见讲者备注 7 / 8

07 / 08

同维度对照与选型边界

用户硬件上的显存与吞吐均待实测

Mistral 7B （密集）

- 7B 参数逐 token 全参与
- KV 缓存固定为 W
- 对标 Llama 2 7B/13B

Mixtral 8x7B （稀疏 MoE ）

- 8 专家选 2 ， 13B/47B
- 内存按 47B 稀疏参数计
- 路由有额外开销

来源见讲者备注 8 / 8

08 / 08

8页；稿件SHA 8c3891f91034378cf2d2f061c0c6e241d1ca3a36bcd3660d0aa29f6afd3be252；run 2f9779d1fbaf4a94bc84c127f1c94edc

Mistral 7B + Mixtral / C 认证 Motif / 跨重启修订稿 / 版本1

RESEARCH BRIEF

资源受限时：密集模型还是稀疏 MoE

限制在算力侧还是容量侧决定选择

- 两篇原论文：Mistral 7B 与 Mixtral 8x7B
- 资源受限时如何选型
- 标清口径，不做跨协议排名

来源见讲者备注 1 / 8

01 / 08

先分清两篇论文各证明了什么

可比的是方法口径，不是跨论文分数

- 两文均用自家流水线重跑基线
- 协议样本数不同，分数不可拼榜

维度	Mistral 7B	Mixtral 8x7B
结构	密集 FFN + GQA/SWA	8 个专家，选 2 个
计算参数	7B 全激活	13B 激活 / 47B 总
训练上下文	8k 配置	32k 上下文
评测协议	0/3/4/8-shot	0/3/4/5/8-shot

来源见讲者备注 2 / 8

02 / 08

Mistral 的注意力设计： GQA + 滑动窗口

固定窗口是缓存与成本受控的来源

1. **GQA 分组查询** — 32 个查询头共享 8 个 KV 头，降低解码显存
2. **滑动窗口注意力** — 位置 i 只看上一层 i−W 到 i， W=4096
3. **滚动缓冲区缓存** — KV 存在 i mod W ，缓存固定为 W
4. **预填充与分块** — 长提示按窗口切块预填充

来源见讲者备注 3 / 8

03 / 08

Mistral 滑动窗口的原文示意

单层视野有限，多层叠加扩大有效跨度

- 图中 W=3： 每个 token 只回看 3 个位置
- 窗口外 token 经多层间接影响预测

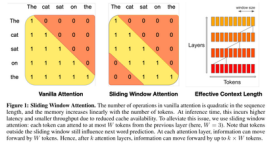


Figure 1: Sliding Window Attention. The number of operations in vanilla attention is quadratic in the sequence length, and the memory increases linearly with the number of tokens. At inference time, this incurs higher latency and smaller throughput due to reduced cache availability. To alleviate this issue, we use sliding window attention: each token can attend to at most W tokens from the previous layer (here, $W = 3$). Note that tokens outside the sliding window still influence next word prediction. At each attention layer, information can move forward by W tokens. Hence, after k attention layers, information can move forward by up to $k \times W$ tokens.

来源见讲者备注 4 / 8

04 / 08

Mixtral 路由：每 token 只过 2 个专家

总参数随专家数增长，计算量由 Top-K 决定

1. **门控打分** — 线性层 Wg 对 8 个专家计算 logits
2. **Top-2 选择** — 取 top-2 logits 做 softmax，其余置零
3. **专家计算与相加** — 两个 SwiGLU 专家按权重相加
4. **并行与均衡** — 专家并行路由 token，负载须均衡

来源见讲者备注 5 / 8

05 / 08

MoE 层的原文结构示意

专家是标准 FFN 块，稀疏性来自门控选择

- 输入向量经路由分给 8 个专家中的 2 个
- 层输出是两个专家输出的加权和

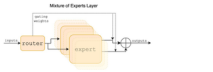


Figure 1: Mixture of Experts Layer. Each input vector is assigned to 2 of the 8 experts by a router. The layer's output is the weighted sum of the outputs of the two selected experts. In Mistral, an expert is a standard feedforward block as in a vanilla transformer architecture.

来源见讲者备注 6 / 8

06 / 08

两文结果：口径完整但互不可比

报告分数须同时给出 shot 数与条件

- 各列只在本论文内可比
- 70B 对标仅限激活参数口径

结果项	Mistral 7B	Mixtral 8x7B
MMLU	60.1%	70.6%
GSM8K	52.2%	74.4%
MBPP	47.5%	60.7%
模型规模	7B 密集	13B 激活 / 47B 总
对标基线	Llama 2 7B/13B	Llama 2 70B 、GPT-3.5

来源见讲者备注 7 / 8

07 / 08

选型建议：四类判断依据与来源归属

内存与服务负载定门槛，最终须实测

判断依据	Mistral 7B	Mixtral 8x7B
总内存约束	7B 密集参数	47B 稀疏参数
服务负载	逐 token 全参与	路由 / 多专家开销
质量证据	MMLU 60.1%	MMLU 70.6%
评估口径	口径不同，不可比	不可拼排行榜
待实测指标	显存 / 吞吐 / 延迟	原文未给

来源见讲者备注 8 / 8

08 / 08

8页；稿件SHA 039b3a2659722d450985fc4fff63004f0515aa362e3e62b710e760564ca7bbd2；run 20dd8f06f27d4681a768ea1834af289d

Mistral 7B + Mixtral / B 普通组合脚本 / 初稿 / 版本1

RESEARCH BRIEF

受限服务资源下：选密集 7B 还是稀疏 MoE

- 两篇原论文的机制、评测口径与决策边界
- 面向组会：算力预算固定时如何选型

01 / 08

决策问题：预算受限时约束落在哪一层？

- **先分清算力约束与显存约束，再谈选型**
- 两模型同基线架构，差异在注意力与 FFN
- 计算量随激活参数走，显存随参数量走
- 原文未给显存 / 吞吐 / 延迟，须待实测

02 / 08

Mistral 7B ： 滑窗注意力与 GQA 换长序列效率

- GQA ： 32 个查询头配 8 个 KV 头，降解码期内存
- SWA ： 每层最多回看 W=4096 个 token
- 32 层理论依赖跨度约 131K token
- 16K 序列下实测 2x 提速（对比 vanilla ）

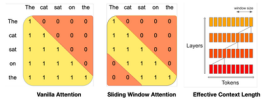


Figure 1: Sliding Window Attention. The number of operations in vanilla attention is quadratic in the sequence length, and the memory increases linearly with the number of tokens. At inference time, this incurs higher latency and smaller throughput due to reduced cache availability. To alleviate this issue, we use sliding window attention: each token can attend to at most W tokens from the previous layer (here, $W = 3$). Note that tokens outside the sliding window still influence next word prediction. At each attention layer, information can move forward by W tokens. Hence, after k attention layers, information can move forward by up to $k \times W$ tokens.

03 / 08

Mixtral ： 47B 总参数，每 token 只激活 13B

1	**路由打分**	每层每 token 对 8 个专家算门控 logits
2	**取 Top-2**	K=2 ，保留前两名专家做 softmax
3	**加权求和**	输出为两专家输出的加权和
4	**跳过其余**	门控为零的专家不参与计算

04 / 08

专家层结构： MoE 替换前馈块，每 token 选 2 个专家

- 门控网络从 8 个专家中选 2 个
- 输出为两专家输出的加权和



Figure 1: Mixture of Experts Layer. Each input vector is assigned to 2 of the 8 experts by a router. The layer's output is the weighted sum of the outputs of the two selected experts. In Mistral, an expert is a standard feedforward block as in a vanilla transformer architecture.

05 / 08

同源指标并置：各自完整评测口径与可比边界

- 两表同源指标定义相同，但对照组不同

口径项	Mistral 7B	Mixtral 8x7B
评测框架	自有 pipeline 重跑	自有 pipeline 重跑
MMLU(5-shot)	60.1%	70.6%
GSM8K(8-shot maj@8)	52.2%	74.4%
HumanEval(0-shot)	30.5%	40.2%
MBPP(3-shot)	47.5%	60.7%

06 / 08

同维度对照：参数口径、计算来源与序列机制

密集 Mistral 7B	稀疏 Mixtral 8x7B
总参数 = 激活参数 =7B	总参 47B ，每 token 激活 13B
计算与参数同增，无路由开销	服务显存随 47B 稀疏参数
长序列效率靠 SWA 与 GQA	路由与多专家带来额外开销
16K 序列报 2x 提速	小 batch 更快、大 batch 吞吐更高

07 / 08

结论与待实测清单

- **约束落在算力还是显存，决定选型，且二者需分别实测**
- 小 batch 算力受限：稀疏激活更少，但需实测路由开销
- 显存受限：按 47B 稀疏参数粗估上限，非按 13B
- 专家并行下负载不均可能削弱稀疏收益
- 本稿未验证：用户硬件显存 / 吞吐 / 延迟与公平复跑

08 / 08

8页；稿件SHA 16d377b0f22a04d42772a83fe6334454566b7d0caf13e3042c00e6c9be8d9c56；run eea7923b444f4d81af69d8124e83a987

Mistral 7B + Mixtral / B 普通组合脚本 / 跨重启修订稿 / 版本1

RESEARCH BRIEF

受限服务资源下：选密集 7B 还是稀疏 MoE

- 两篇原论文的机制、评测口径与决策边界
- 面向组会：算力预算固定时如何选型

01 / 08

决策问题：预算受限时约束落在哪一层？

- 先分清算力约束与显存约束，再谈选型
- 两模型同基线架构，差异在注意力与 FFN
- 计算量随激活参数走，显存随参数量走
- 原文未给显存 / 吞吐 / 延迟，须待实测

02 / 08

Mistral 7B ： 滑窗注意力与 GQA 换长序列效率

- GQA ： 32 个查询头配 8 个 KV 头，降解码期内存
- SWA ： 每层最多回看 W=4096 个 token
- 32 层理论依赖跨度约 131K token
- 16K 序列下实测 2x 提速（对比 vanilla ）

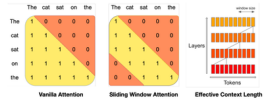


Figure 1: Sliding Window Attention. The number of operations in vanilla attention is quadratic in the sequence length, and the memory increases linearly with the number of tokens. At inference time, this incurs higher latency and smaller throughput due to reduced cache availability. To alleviate this issue, we use sliding window attention: each token can attend to at most W tokens from the previous layer (here, W = 3). Note that tokens outside the sliding window still influence next word prediction. At each attention layer, information can move forward by W tokens. Hence, after k attention layers, information can move forward by up to k × W tokens.

03 / 08

Mixtral ： 47B 总参数，每 token 只激活 13B

1	路由打分	每层每 token 对 8 个专家算门控 logits
2	取 Top-2	K=2 ，保留前两名专家做 softmax
3	加权求和	输出为两专家输出的加权和
4	跳过其余	门控为零的专家不参与计算

04 / 08

专家层结构： MoE 替换前馈块，每 token 选 2 个专家

- 门控网络从 8 个专家中选 2 个
- 输出为两专家输出的加权和



Figure 1: Mixture of Experts Layer. Each input vector is assigned to 2 of the 8 experts by a router. The layer's output is the weighted sum of the outputs of the two selected experts. In Mistral, an expert is a standard feedforward block as in a vanilla transformer architecture.

05 / 08

同源指标并置：各自完整评测口径与可比边界

- 两表同源指标定义相同，但对照组不同

口径项	Mistral 7B	Mixtral 8x7B
评测框架	自有 pipeline 重跑	自有 pipeline 重跑
MMLU(5-shot)	60.1%	70.6%
GSM8K(8-shot maj@8)	52.2%	74.4%
HumanEval(0-shot)	30.5%	40.2%
MBPP(3-shot)	47.5%	60.7%

06 / 08

同维度对照：参数口径、计算来源与序列机制

密集 Mistral 7B	稀疏 Mixtral 8x7B
总参数 = 激活参数 =7B	总参 47B ，每 token 激活 13B
计算与参数同增，无路由开销	服务显存随 47B 稀疏参数
长序列效率靠 SWA 与 GQA	路由与多专家带来额外开销
16K 序列报 2x 提速	小 batch 更快、大 batch 吞吐更高

07 / 08

选型建议：四类决策输入与待实测清单

- 论文事实定口径与质量，硬件结论仍是设计推论，须实测
- 总内存：按 47B 稀疏参数规划，不可按 13B 激活参数
- 服务负载：单条快、批量吞吐高，路由有额外开销
- 质量： Mixtral 在多类目超 Llama2-70B ，激活参数少 5 倍
- 待实测：用户硬件显存 / 吞吐 / 延迟与负载不均

08 / 08

8页；稿件SHA e5f248a399766575ca076619e4dca87cb98a49f28dacba5c7e8f13c56ce2aa35；run 9c849aaf61b049a5b885b3ce19259d32

Mistral 7B + Mixtral / A 普通 DSH / 初稿 / 版本1

RESEARCH BRIEF

受限服务资源下：密集模型还是稀疏 MoE

- Mistral 7B 与 Mixtral 8x7B 原论文方案讨论
- 面向：研究同学组会，8 页

01 / 08

决策问题：受限资源下先锁定可核算的约束

激活参数只对应算力，不等价于加载显存

- 服务资源可核算项：显存占用、推理算力、吞吐与延迟
- Mistral 7B：7B 参数密集，逐 token 全量使用
- Mixtral 8x7B：总参数 47B，每 token 激活 13B
- 现缺条件：显存 / 吞吐 / 延迟只写待实测

02 / 08

Mistral 7B：注意力与缓存如何压低推理开销

W=4096 时理论注意跨度约 131K tokens

- 原图 Figure 1：滑动窗口注意力，W=3
- 窗口固定使缓存有界，长序列开销受控

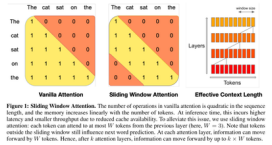


Figure 1: Sliding Window Attention. The number of operations in vanilla attention is quadratic in the sequence length, and the memory increases linearly with the number of tokens. At inference time, this incurs higher latency and smaller throughput due to reduced cache availability. To alleviate this issue, we use sliding window attention: each token can attend to at most W tokens from the previous layer (here, $W = 3$). Note that tokens outside the sliding window still influence next word prediction. At each attention layer, information can move forward by W tokens. Hence, after k attention layers, information can move forward by up to $k \times W$ tokens.

03 / 08

Mixtral：路由只激活 top-2 专家，算力与容量解耦

每 token 可见 47B 参数，推理仅用 13B 激活

- 原图 Figure 1：路由器从 8 个专家中选 2 个
- 输出为两个被选专家输出的加权和



Figure 1: Mixture of Experts Layer. Each input vector is assigned to 2 of the 8 experts by a router. The layer's output is the weighted sum of the outputs of the two selected experts. In Mistral, an expert is a standard feedforward block as in a vanilla transformer architecture.

04 / 08

Mixtral 如何路由与激活专家

1	**线性层打分**	对每个 token 计算专家 logits
2	**TopK 取前二**	写作 G(x):=Softmax(TopK(x · Wg))
3	**选 2 个专家**	每个专家是 SwiGLU 前馈块
4	**加权求和输出**	按门控权重相加被选专家输出

05 / 08

架构对照：同口径项与单篇专有项

项	Mistral 7B	Mixtral 8x7B
层数 / dim	32 / 4096	32 / 4096
头数 / kv 头	32 / 8	32 / 8
hidden / vocab	14336 / 32000	14336 / 32000
仅单篇给出	window 4096，ctx 8192	ctx 32768，专家 8 选 2
参数口径	7B 密集全量	47B 总 / 13B 激活

06 / 08

结果阅读：两篇论文各自的口径不可直接拼分

跨论文同分数不等于公平对比

- Mistral：HellaSwag 81.3%、MMLU 60.1%、GSM8K 52.2%
- Mixtral：MMLU 70.6%、HumanEval 40.2%、GSM8K 74.4%
- 两文协议差异：MBPP 用手工核验子集、TriviaQA 不给维基上下文
- 故只能各自与自身基线比，不跨论文排名

07 / 08

结论与待验证：决策所需证据清单

倾向 Mistral 7B 密集

- 参数口径单一，容量与算力一致
- SWA+GQA 明确降低推理开销
- 知识类基准压缩率更低（1.9x）
- 显存 / 吞吐 / 延迟：待实测

倾向 Mixtral 8x7B 稀疏

- 总 47B、激活 13B，算力与容量解耦
- 多语言与数学代码结果更强
- 内存按 47B 计，且有路由开销
- 显存 / 吞吐 / 延迟：待实测

08 / 08

8页；稿件SHA a446866e0fd8e6754d7de3558532419acf58ef5d56477446f97afc5526fb6e0b；run 6f4e1767b03748cdb31a4c6e8cdedd31

Mistral 7B + Mixtral / A 普通 DSH / 跨重启修订稿 / 版本1

RESEARCH BRIEF

受限服务资源下：密集模型还是稀疏 MoE

- Mistral 7B 与 Mixtral 8x7B 原论文方案讨论
- 面向：研究同学组会， 8 页

01 / 08

决策问题：受限资源下先锁定可核算的约束

激活参数只对应算力，不等价于加载显存

- 服务资源可核算项：显存占用、推理算力、吞吐与延迟
- Mistral 7B： 7B 参数密集，逐 token 全量使用
- Mixtral 8x7B： 总参数 47B，每 token 激活 13B
- 现缺条件：显存 / 吞吐 / 延迟只写待实测

02 / 08

Mistral 7B： 注意力与缓存如何压低推理开销

W=4096 时理论注意跨度约 131K tokens

- 原图 Figure 1： 滑动窗口注意力， W=3
- 窗口固定使缓存有界，长序列开销受控

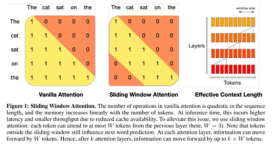


Figure 1: Sliding Window Attention. The number of operations in vanilla attention is quadratic in the sequence length, and the memory increases linearly with the number of tokens. At inference time, this incurs higher latency and smaller throughput due to reduced cache availability. To alleviate this issue, we use sliding window attention: each token can attend to at most W tokens from the previous layer (here, $W = 3$). Note that tokens outside the sliding window still influence next word prediction. At each attention layer, information can move forward by W tokens. Hence, after k attention layers, information can move forward by up to $k \times W$ tokens.

03 / 08

Mixtral： 路由只激活 top-2 专家，算力与容量解耦

每 token 可见 47B 参数，推理仅用 13B 激活

- 原图 Figure 1： 路由器从 8 个专家中选 2 个
- 输出为两个被选专家输出的加权和



Figure 1: Mixture of Experts Layer. Each input vector is assigned to 2 of the 8 experts by a router. The layer's output is the weighted sum of the outputs of the two selected experts. In Mixtral, an expert is a standard feedforward block as in a vanilla transformer architecture.

04 / 08

Mixtral 如何路由与激活专家

1	线性层打分	对每个 token 计算专家 logits
2	TopK 取前二	写作 G(x):=Softmax(TopK(x · Wg))
3	选 2 个专家	每个专家是 SwiGLU 前馈块
4	加权求和输出	按门控权重相加被选专家输出

05 / 08

架构对照：同口径项与单篇专有项

项	Mistral 7B	Mixtral 8x7B
层数 / dim	32 / 4096	32 / 4096
头数 / kv 头	32 / 8	32 / 8
hidden / vocab	14336 / 32000	14336 / 32000
仅单篇给出	window 4096， ctx 8192	ctx 32768，专家 8 选 2
参数口径	7B 密集全量	47B 总 / 13B 激活

06 / 08

结果阅读：两篇论文各自的口径不可直接拼分

跨论文同分数不等于公平对比

- Mistral： HellaSwag 81.3%、 MMLU 60.1%、 GSM8K 52.2%
- Mixtral： MMLU 70.6%、 HumanEval 40.2%、 GSM8K 74.4%
- 两文协议差异： MBPP 用手工核验子集、 TriviaQA 不给维基上下文
- 故只能各自与自身基线比，不跨论文排名

07 / 08

最终选择建议：四类证据与归属

总内存按 47B 与 7B 锁定，其余待实测

维度	Mistral 7B	Mixtral 8x7B	归属
总内存	按 7B 全量	按 47B 总量	原文 / 第 4 页
服务负载	算力即 7B	激活 13B，含路由开销	原文 / 第 1、 4 页
质量证据	自身 MMLU 60.1%	自身 MMLU 70.6%	原文 / 各自口径
待实测	显存 / 吞吐 / 延迟	显存 / 吞吐 / 延迟	待实测

08 / 08

8页；稿件SHA f0d176450c37368d845d9ca5c4fa1ae16e2898aac61a709477f2f56cacda3fdf；run 7c83889fe51d4c9693a715e3df15e304

8 / 学习成本、复现与适用范围

工具提案失败+正常轨迹训练+独立认证的已记录学习成本：请求 127、token 3,251,893、代理估费 $0.175220；工具失败不能从学习成本移除。没有合格任务净节省证据，不给出虚假的盈亏平衡或摊销收益。

有效配置：deepseek-flash，reasoning=off，压缩=False；每阶段预算$2.0、48步、8000输出，总防失控守卫$20.0。48步是限制而非目标请求数。只服务器运行，本轮无commit/push/PR。

复现入口：同目录driver_v8.py prepare/run与matrix_v8.py --stage train/certify/evaluate；使用新的私有运行目录，训练冻结后才能打开一次认证。API只从服务器私有配置取值，报告不会包含密钥。脚本文件与实际运行版本/来源/工具schema由摘要SHA绑定，原始日志另外下载。

适用范围：本场景批准的PDF/PPTX科研PPT生成与同job有限局部修订。本轮未证明通用PPT复杂编辑、完全自主新工具成功率、Windows真实场景、人工同质量降本或整套跨应用产品。Zotero/Obsidian/分析/Quarto等仓库新主线仍需各自真实任务证据。

下一步由独立人工逐页验事实、图意、可读性及任务完成，记录修订分钟；仅比较同门槛合格稿的实际成本并核账单。若简单组合脚本更好就采用它，按真实证据缩小RSI/Motif主张；本轮不覆盖V7负面结果。